



Universiteit Antwerpen
| Faculteit Wetenschappen

ELEMENTAIRE STATISTIEK

Prof. dr. Tim Verdonck

Voorwoord

Dit is de cursus voor het vak ELEMENTAIRE STATISTIEK (11001WETEST). Deze cursus en de bijhorende slides uit de hoorcolleges dienen gekend te zijn voor het examen. Het doel van deze cursus is om de studenten de basis bij te brengen van de statistiek.

Opmerkingen en suggesties voor verbeteringen zijn steeds welkom!

Tim Verdonck

Referenties

- A. Agresti en C. Franklin (2009). *Statistics: the Art and Science of Learning from Data*. Pearson, 2nd edition.
- J. Beirlant, G. Dierckx en M. Hubert (2005). *Statistiek en Wetenschap*. Acco Uitgeverij, Leuven.
- M.H. DeGroot and M.J. Schervish (2011). *Probability and Statistics*. Pearson.
- J. Rice (2006). *Mathematical Statistics and Data Analysis*. Cengage Learning.
- D. Wackerly, W. Mendenhall and R.L. Scheaffer (2014). *Mathematical statistics with applications*. Cengage Learning.

INHOUDSOPGAVE

1	Belangrijke verdelingen	1
1.1	Discrete univariate verdelingen	1
1.1.1	Discrete uniforme verdeling	1
1.1.2	Bernoulli verdeling	2
1.1.3	Binomiaalverdeling	3
1.1.4	Negatief binomiaalverdeling	5
1.1.5	Poissonverdeling	6
1.2	Continue univariate verdelingen	7
1.2.1	Continue uniforme verdeling	7
1.2.2	Univariate normale verdeling	8
1.2.3	χ_n^2 -verdeling	12
1.2.4	t_n verdeling	15
1.2.5	F -verdeling	16
2	Beschrijvende statistiek	19
2.1	Beschrijven van frequenties	19
2.1.1	Frequentietabellen en staafjesdiagram	20
2.1.2	Histogram	21
2.1.3	Empirische verdelingsfunctie en kwantielfunctie	25
2.2	Kenmerken voor locatie en schaal	27
2.2.1	Centrumkenmerken	27
2.2.1.1	Steekproefgemiddelde	27
2.2.1.2	Steekproefmediaan	28
2.2.1.3	Modus	28
2.2.2	Spreidingskenmerken	29
2.2.2.1	Empirische variantie en standaardafwijking	29
2.2.2.2	Empirisch interkwartielafstand	30
2.2.2.3	Median absolute deviation	31
2.3	Boxplot	31
2.4	Covariantie en correlatie	34
2.5	Kruistabel	36
2.6	QQ-plot	37
3	Het schatten van parameters	41
3.1	Voorbeeld: steekproefgemiddelde	41
3.1.1	Verdeling van het steekproefgemiddelde	42
3.1.2	Centrale limietstelling	44

4 Inhoudsopgave

3.2	Puntschatters	45
3.2.1	Schatter en schatting	45
3.2.2	Eigenschappen schatters	46
3.2.3	Schatten van de parameters van een normale populatie	48
3.2.4	Schatten van proporties of kansen	49
4	Betrouwbaarheidsintervallen of intervalschattingen	51
4.1	Gemiddelde van normale verdeling met bekende variantie	52
4.2	Variantie van normale verdeling	55
4.3	Gemiddelde van normale verdeling (onbekende variantie)	57
4.4	Proportie	60
5	Hypothesetesten	63
5.1	Gemiddelde van een normale verdeling met bekende variantie	65
5.1.1	Tweezijdige z -test (“two-sided one-sample z -test”)	66
5.1.2	Eenzijdige z -test (“one-sided one-sample z -test”)	67
5.1.3	De p -waarde (“ p -value”)	68
5.2	Gemiddelde van een normale verdeling met onbekende variantie	70
5.2.1	Tweezijdige t -test (“two-sided one-sample t -test”)	70
5.2.2	Eenzijdige t -test (“one-sided one-sample t -test”)	73
5.2.3	Meer over type-I en type-II fout	75
5.3	Normaliteitsassumptie	78
5.4	Variantie van een normale verdeling	79
5.5	Proportie	82
5.5.1	Benaderende test als steekproef voldoende groot is	82
5.5.2	Exacte test als de steekproef klein is	82
6	Vergelijkingstesten	85
6.1	Vergelijken van varianties	85
6.2	Vergelijken van gemiddelden	88
6.2.1	Bij ongepaarde waarnemingen	89
6.2.2	Bij gepaarde waarnemingen	93
6.3	Vergelijken van twee proporties	95
7	Verdelingstoetsen	97
7.1	Testen van een discrete verdeling	97
7.2	Testen van een continue verdeling	101
7.2.1	χ^2 -test	101
7.2.2	Kolmogorov-Smirnov test	103
8	Toetsen van onafhankelijkheid	105
8.1	Onafhankelijkheid van discrete veranderlijken	105
8.2	Onafhankelijkheid van continue variabelen	108

9	Enkelvoudige lineaire regressie	113
9.1	Lineaire model	113
9.2	Schatten van parameters	114
9.3	Betrouwbaarheidsintervallen en hypothesetesten	118
9.4	Voorbeeld	120

BELANGRIJKE VERDELINGEN

1.1 Discrete univariate verdelingen

1.1.1 Discrete uniforme verdeling


Stel X het aantal ogen gegooid met een (eerlijke) dobbelsteen, dan is elke uitkomst in $\Omega = \{1, \dots, 6\}$ even waarschijnlijk. We zeggen dan dat X uniform verdeeld is op Ω . De uniforme verdeling beschrijft dus de eigenschap dat elke uitkomst “even waarschijnlijk” is.

Definitie. De **discrete uniforme verdeling** is steeds gedefinieerd op een eindig universum $\Omega = \{1, \dots, n\}$. Dan is

$$\begin{cases} x_j = j \\ p_j = P(\{x_j\}) = \frac{1}{n} \end{cases} \quad j = 1, \dots, n.$$

We zien dat dit inderdaad een discrete verdeling definieert, want $p_j \geq 0$ en $\sum_j p_j = 1$.

Grafische voorstelling:



De kentallen van deze verdeling zijn:

$$\bullet \quad E[X] = \sum_{j=1}^n x_j p_j = \frac{n+1}{2} \quad (= \text{centrum van symmetrie})$$

$$\text{gebruikmakend van } \sum_{j=1}^n j = \frac{n(n+1)}{2} \quad (\text{bewijs per inductie})$$

$$\bullet \quad \text{Var}[X] = E[X^2] - E[X]^2 = \sum_{j=1}^n x_j^2 p_j - E[X]^2 = \frac{(n+1)(n-1)}{12}$$

$$\text{gebruikmakend van } \sum_{j=1}^n j^2 = \frac{n(n+1)(2n+1)}{6} \quad (\text{bewijs per inductie})$$

1.1.2 Bernoulli verdeling

Indien een bepaald experiment slechts 2 mogelijke uitkomsten kan hebben, dan noemen we dit een Bernoulli experiment. Denk hiervoor aan binaire kenmerken zoals “man/vrouw” of “roker/niet-roker”. Ook het opwerpen van een muntstuk (kop/munt) is een voorbeeld van een Bernoulli experiment. Deze uitkomsten worden meestal gezien als “succes” of “geen succes” en worden bijgevolg gecodeerd als 1 en 0.


Definitie. Voor X een **Bernoulli verdeelde** s.v. is $\Omega = \{0, 1\}$ en zijn de kansen gedefinieerd als

$$\begin{cases} P(X = 1) = p & \text{kans op succes} \\ P(X = 0) = q = 1 - p & \text{kans op mislukking} \end{cases}$$

met $0 < p < 1$. We noteren dit als

$$X \sim \mathcal{B}(1, p).$$

Grafische voorstelling:



De kentallen zijn:

- $E[X] = \sum_j x_j p_j = 0q + 1p = p$
- $\text{Var}[X] = E[X^2] - E[X]^2 = \sum_j x_j^2 p_j - p^2$
 $= 0^2 q + 1^2 p - p^2 = p(1 - p)$

$$\begin{aligned} \text{OF } \text{Var}[X] &= \sum_j (x_j - p)^2 p_j = (0 - p)^2 q + (1 - p)^2 p \\ &= p^2(1 - p) + (1 - p)^2 p = p(1 - p)(p + 1 - p) = pq \end{aligned}$$

1.1.3 Binomiaalverdeling

Wanneer eenzelfde Bernoulli experiment n keer na elkaar herhaald wordt op een manier dat de uitkomsten onafhankelijk van elkaar zijn, dan bekomen we een geordend n -tal van successen en mislukkingen. Als we Y het aantal successen in ons experiment noemen, dan is Y binomiaal verdeeld.

Definitie. Voor onderling onafhankelijke s.v. $X_i \sim \mathcal{B}(1, p)$, $i = 1, \dots, n$ is de s.v. $Y = X_1 + \dots + X_n$ **binomiaal verdeeld** met parameters n en p . We noteren dan

$$Y \sim \mathcal{B}(n, p).$$

Bijgevolg is $\Omega = \{0, 1, \dots, n\}$ en

$$P(Y = k) = \binom{n}{k} p^k q^{n-k} = \frac{n!}{k!(n-k)!} p^k q^{n-k}.$$

Opmerking. Indien de s.v. X_i , $i = 1, \dots, n$ onderling onafhankelijk en gelijk verdeeld zijn, noemt men deze **i.i.d.** (*independent and identically distributed*).


In bovenstaande formule voor de kans is $\binom{n}{k}$ het aantal deelverzamelingen van k elementen uit een verzameling van n elementen. Het geeft dus het aantal mogelijkheden om precies k elementen uit n te kiezen. De binomiale verdeling

werd ingevoerd door James Bernoulli (1713). Bovendien is ze ook echt wel een verdeling, want we zien dat alle $p_j = P(Y = j) > 0$ en dat

$$\sum_{j=0}^n p_j = \sum_{j=0}^n \binom{n}{j} p^j q^{n-j} = (p + q)^n = 1^n = 1$$

gebruikmakend van het binomium van Newton, waaraan de verdeling haar naam ontleent.

Grafische voorstelling:




De modus/modi vinden we aan de hand van het staafjesdiagram, de andere kentallen volgen direct uit $Y = X_1 + \dots + X_n$:

- $E[Y] = E[X_1] + \dots + E[X_n] = np$
- $\text{Var}[Y] = \text{Var}[X_1] + \dots + \text{Var}[X_n] = npq$

Merk op dat voor $p \approx 0$, $\text{Mod}(Y) = 0$, en voor $p \approx 1$ is $\text{Mod}(Y) = n$.

Grafische voorstelling:



Eigenschap. Als $Y_1 \sim \mathcal{B}(n_1, p)$ en $Y_2 \sim \mathcal{B}(n_2, p)$ onafhankelijk zijn, dan

$$Y_1 + Y_2 \sim \mathcal{B}(n_1 + n_2, p).$$

Interpretatie : $n_1 + n_2$ (i.i.d.) experimenten na elkaar uitvoeren.

1.1.4 Negatief binomiaalverdeling

Neem opnieuw een rij i.i.d. Bernoulli variabelen $X_1, X_2, \dots$ met dezelfde $0 < p < 1$ en kies een natuurlijk getal $r \geq 1$. Stel dan X het aantal mislukkingen vooraleer het r -de succes optreedt. Dan vinden we voor elke $j \in \{0, 1, 2, \dots\}$ dat:

$$\begin{aligned} P(X = j) &= P(X_{j+r} = 1) \cdot P(\text{juist } r - 1 \text{ successen in de} \\ &\quad \text{eerste } j + r - 1 \text{ experimenten}) \\ &= p \binom{j+r-1}{r-1} p^{r-1} q^j = \binom{j+r-1}{j} p^r q^j. \end{aligned}$$

Gewoonlijk wordt ook hier de notatie $\theta = 1 - p$ gehanteerd, dus

Definitie. De **negatief binomiaalverdeling** met parameters $r \geq 1$ en $0 < \theta < 1$ heeft als universum $\Omega = \{0, 1, 2, \dots\}$ en wordt gekarakteriseerd door de kansen:

$$P(X = j) = \binom{j+r-1}{j} (1-\theta)^r \theta^j.$$

We noteren deze verdeling als

$$X \sim \text{NB}(r, \theta).$$

Pas op, soms wordt ook $X \sim \text{NB}(r, p)$ geschreven, ga dus steeds goed na welke van de twee notaties er gebruikt wordt.

De naam van de verdeling komt van het feit dat

$$P(X = j) = \binom{-r}{j} p^r (-q)^j$$

want

$$\begin{aligned} (-1)^j \binom{-r}{j} &= (-1)^j \frac{\overbrace{(-r)(-r-1)\dots(-r-j+1)}^{j \text{ negatieve factoren}}}{j!} \\ &\stackrel{!}{=} \binom{j+r-1}{j}. \end{aligned}$$

1.1.5 Poissonverdeling

De Poissonverdeling (1837) wordt, onder bepaalde voorwaarden, gebruikt om de kans te bepalen dat een bepaald aantal gebeurtenissen zich voordoet in een vast interval (tijd of ruimte). M.a.w. de s.v. X telt dus het aantal gebeurtenissen in dat interval. Voorbeelden hiervan kunnen zijn:

- Het aantal dodelijke ongevallen in Vlaanderen in een weekend.
- Het aantal ontvangen oproepen per uur in een telefooncentrale.
- Het aantal uitgestraalde radioactieve deeltjes per minuut.

Bijkomende voorwaarden voor de Poissonverdeling zijn dat de gebeurtenissen zich moeten voordoen met een gekende gemiddelde snelheid α (**risicoparameter** of **rate** genoemd) en dat ze onafhankelijk zijn van wanneer de laatste gebeurtenis heeft plaatsgevonden (dus het aantal gebeurtenissen dat optreedt in disjuncte intervallen is onafhankelijk van elkaar).



Definitie. De **Poissonverdeling** $\mathcal{P}(\alpha)$ met parameter $0 < \alpha < \infty$ is gedefinieerd op $\Omega = \{0, 1, 2, \dots\}$ door

$$p_j = P(X = j) = \frac{\alpha^j}{j!} e^{-\alpha}.$$

Dit bepaalt wel degelijk een kansmaat, want alle $p_j > 0$ en

$$\sum_{j=0}^{\infty} p_j = e^{-\alpha} \sum_{j=0}^{\infty} \frac{\alpha^j}{j!} = e^{-\alpha} e^{\alpha} = 1.$$

Grafische voorstelling:



Voor een stochastiek $X \sim \mathcal{P}(\alpha)$ vinden we:

- $E[X] = \sum_{j=0}^{\infty} j \frac{\alpha^j}{j!} e^{-\alpha} = \sum_{j=1}^{\infty} j \frac{\alpha^j}{j!} e^{-\alpha} = \alpha \sum_{j=1}^{\infty} \frac{\alpha^{j-1}}{(j-1)!} e^{-\alpha} = \alpha$
- $\text{Var}[X] = \alpha$ (analoog maar langer)

Eigenschap. Als $X_1 \sim \mathcal{P}(\alpha_1)$ en $X_2 \sim \mathcal{P}(\alpha_2)$ onafhankelijk zijn, dan

$$X_1 + X_2 \sim \mathcal{P}(\alpha_1 + \alpha_2)$$

Interpretatie: als X_1 het aantal branden per dag in Antwerpen telt en X_2 het aantal branden per dag in Brussel, dan zal $X_1 + X_2$ het aantal branden in Antwerpen en Brussel samentellen, en dus is dit opnieuw Poisson verdeeld.

1.2 Continue univariate verdelingen

1.2.1 Continue uniforme verdeling


Deze verdeling is de continue versie van de discrete uniforme verdeling en beschrijft het willekeurig kiezen uit een interval $[a, b]$. Het is dus een kansmaat P op $\mathbb{R}$ waarbij de kansmassa evenredig verdeeld is over $[a, b]$.

Definitie. De s.v. X volgt een continue uniforme verdeling op $[a, b]$ met $-\infty < a < b < +\infty$, genoteerd als $X \sim \mathcal{U}[a, b]$, als X de volgende dichtheid heeft:

$$f_{a,b}(x) = \frac{1}{b-a} \mathbb{1}_{[a,b]}(x).$$

Inderdaad geldt dat voor alle x $f_{a,b}(x) \geq 0$ en $\int_{-\infty}^{\infty} f_{a,b}(x)dx = 1$.
Wegens de vorm van $f_{a,b}$ noemt men deze ook wel *rechthoeksverdeling*.

Grafische voorstelling:



De verdelingsfunctie is

$$\begin{aligned} F_{a,b}(x) &= P([-\infty, x]) = \int_{-\infty}^x f_{a,b}(t)dt \\ &= \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & a \leq x \leq b \\ 1 & x > b \end{cases} \end{aligned}$$

en de kentallen zijn

$$\begin{aligned} \bullet \quad E[X] &= \int_{-\infty}^{\infty} x f_{a,b}(x)dx = \int_a^b x f_{a,b}(x)dx \\ &= \frac{1}{b-a} \left[\frac{x^2}{2} \right]_a^b = \frac{b^2 - a^2}{2(b-a)} = \frac{a+b}{2} \\ \bullet \quad E[X^2] &= \frac{1}{b-a} \int_{-\infty}^{\infty} x^2(x)dx = \frac{1}{b-a} \left[\frac{x^3}{3} \right]_a^b = \frac{1}{b-a} \frac{b^3 - a^3}{3} = \frac{a^2 + ab + b^2}{3} \\ \text{Var}[X] &= \frac{a^2 + ab + b^2}{3} - \frac{a^2 + 2ab + b^2}{4} = \frac{a^2 + b^2 - 2ab}{12} = \frac{(b-a)^2}{12} \end{aligned}$$

1.2.2 Univariate normale verdeling

De meest gekende verdeling is zonder twijfel de normale verdeling met haar typische klokvormige dichtheidsfunctie. Ze wordt ook wel verdeling van Gauss

(1809) of Gaussiaanse verdeling genoemd. Nochtans werd deze verdeling eerder gecreëerd door De Moivre (1733) met de bedoeling problemen die verband houden met kansspelen op te lossen. Nadien werd ze ook al beschouwd door Laplace (1774). De verdeling werd vooral bekend toen de Belgische wiskundige Quetelet rond 1870 het idee had om de normale dichtheid als een “ideaal” histogram te beschouwen.


Standaard normale verdeling $\mathcal{N}(0, 1)$

Definitie. De **standaard normale verdeling** $\mathcal{N}(0, 1)$ is gedefinieerd door de dichtheidsfunctie

$$\phi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2} \quad \forall x \in \mathbb{R}.$$

Een s.v. die standaard normaalverdeeld is, wordt genoteerd met de letter Z .

Grafische voorstelling:




Het is duidelijk dat $\phi(x) \geq 0$ voor alle $x \in \mathbb{R}$. Er bestaat echter geen expliciete stamfunctie van $\phi(x)$. Vermits $\phi(-x) = \phi(x)$ is ϕ *even* (= symmetrisch rond y -as).

De *verdelingsfunctie* van $\mathcal{N}(0, 1)$ wordt genoteerd als

$$\Phi(x) = \int_{-\infty}^x \phi(t) dt.$$

Grafische voorstelling:



Voor de standaard normale verdeling geldt dat:


- $E[Z] = \alpha_1 = 0$
- $\text{Var}[Z] = E[(Z - 0)^2] = \alpha_2 = 1$

Verder bemerken we dat:

- $\Phi(-x) = 1 - \Phi(x)$ want $\mathcal{N}(0, 1)$ is symmetrisch rond 0 .
- Er bestaat geen expliciete formule voor Φ , waarden worden bepaald a.h.v. tabellen.
- Voor een $Z \sim \mathcal{N}(0, 1)$ geldt (tabel):

$$\begin{cases} P(|Z| \leq 1) & \approx 0.6827 \\ P(|Z| \leq 2) & \approx 0.9545 \\ P(|Z| \leq 3) & \approx 0.9973 \end{cases}$$

Grafische voorstelling:



- Via de tabel worden ook de de *kwantielen* $\Phi^{-1}(p)$ voor $p = 0.75, 0.90, 0.95, \dots$ gevonden. Te kennen zijn:

$$\star \Phi^{-1}(0.95) = 1.645$$

$$\star \Phi^{-1}(0.975) = 1.96$$

Algemene normale verdeling $\mathcal{N}(\mu, \sigma^2)$

Definitie. De **algemene normale verdeling**^a met $\mu \in \mathbb{R}$ en $\sigma > 0$ is de verdeling van $X = \sigma Z + \mu$ waarbij $Z \sim \mathcal{N}(0, 1)$. We noteren dit als

$$X \sim \mathcal{N}(\mu, \sigma^2).$$


De dichtheidsfunctie is dan:

$$f_{\mu, \sigma}(x) = \frac{1}{|\sigma|} f_Z\left(\frac{x - \mu}{\sigma}\right) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

^aWe beschouwen hier lineaire transformatie van een standaardnormale verdeling. Transformaties worden in meer detail bestudeerd in het volgende hoofdstuk.

De dichtheid is symmetrisch rond μ , en σ geeft de spreiding van de verdeling weer. Voor $\sigma \downarrow 0$ vinden we een piek (=puntmassa) δ_μ .

Grafische voorstelling:



De verdelingsfunctie van $X \sim \mathcal{N}(\mu, \sigma^2)$ is

$$F_X(x) = F_Z\left(\frac{x - \mu}{\sigma}\right) = \Phi\left(\frac{x - \mu}{\sigma}\right)$$

en dus zien we dat we enkel de tabel van Φ nodig hebben.

Voor een algemene normale verdeling zijn de kentallen:

- $E[X] = E[\sigma Z + \mu] = \mu$ (= symmetriecentrum)
- $\text{Var}[X] = \text{Var}[\sigma Z + \mu] = \sigma^2 \Rightarrow \sigma$ is standaardafwijking

Eigenschap. Als $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$ en $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$ onafhankelijk, dan

$$X_1 + X_2 \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2).$$

Opmerking. Voor het opzoeken in tabellen gebruiken we dat


$$\frac{X - E[X]}{\sqrt{\text{Var}[X]}} = \frac{X - \mu}{\sigma} = Z \sim \mathcal{N}(0, 1)$$

Voorbeeld. Voor een $X \sim \mathcal{N}(5, 4)$ bereken de kans

$$\begin{aligned} P(1 \leq X \leq 7) &= P\left(-2 \leq \frac{X - 5}{2} \leq 1\right) \\ &= P(-2 \leq Z \leq 1) \\ &= P(Z \leq 1) - P(Z < -2) \\ &= \Phi(1) - \Phi(-2) \\ &= \Phi(1) - (1 - \Phi(2)) \\ &= 0.8413 - (1 - 0.9772) \\ &= 0.8185 \end{aligned}$$

1.2.3 χ_n^2 -verdeling

Een boogschutter mikt op het centrum van een roos, en noem dit doelwit $(0,0)$, maar treft (Z_1, Z_2) in de plaats. Stel Z_1 de horizontale afwijking en Z_2 de verticale afwijking. Als Z_1 en Z_2 onafhankelijk zijn en beide een $\mathcal{N}(0, 1)$ -verdeling volgen, dan zal voor de afstand d tussen het doelwit en de pijl gelden dat $d^2 \sim \chi_2^2$.



Definitie. Laat $Z_1, Z_2, \dots, Z_n$ ($n \geq 1$) i.i.d. $\mathcal{N}(0, 1)$ -verdeeld zijn, dan noemt men de verdeling van

$$X = Z_1^2 + \dots + Z_n^2$$

een **chi-kwadraat verdeling met n vrijheidsgraden** en schrijft men

$$X \sim \chi_n^2.$$

De dichtheidsfunctie is gegeven door

$$f_{\chi_n^2}(x) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma\left(\frac{n}{2}\right)} e^{-\frac{x}{2}} x^{\frac{n}{2}-1} & x > 0 \\ 0 & x \leq 0. \end{cases}$$

De χ^2 -verdeling werd verkregen door Bienaymé in 1852.

Opmerking. In deze uitdrukking gebruiken we de **gammafunctie**

$$\Gamma(t) := \int_0^\infty x^{t-1} e^{-x} dx \quad (t > 0)$$


die de volgende eigenschappen heeft :

- $\forall t > 0 : \Gamma(t+1) = t\Gamma(t)$
- $\forall n \in \mathbb{N} : \Gamma(n+1) = n! \quad (\text{en } \Gamma(1) = 0! = 1)$
- $\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$

- **Formule van Stirling:** $\Gamma(t) \sim \left(\frac{t-1}{e}\right)^{t-1} \sqrt{2\pi(t-1)}$

in de zin dat $\lim_{t \rightarrow \infty} \frac{\Gamma(t)}{\left(\frac{t-1}{e}\right)^{t-1} \sqrt{2\pi(t-1)}} = 1$

- Voor $t = n+1$ geeft dit $n! \sim \left(\frac{n}{e}\right)^n \sqrt{2\pi n}$



We zien uit de grafiek dat voor de dichtheidsfuncties voor $n = 1$ en $n = 2$ geldt:

- $f_{\chi_1^2}$ strikt dalend ($f' < 0$), $\lim_{x \downarrow 0} f_{\chi_1^2}(x) = \infty$
- $f_{\chi_2^2}$ strikt dalend ($f' < 0$), $\lim_{x \downarrow 0} f_{\chi_2^2}(x) = \frac{1}{2\Gamma(1)} = \frac{1}{2}$


Verder hebben we:

- $E[X] = E[Z_1^2 + \dots + Z_n^2] = nE[Z_1^2] = n$
- $\text{Var}[X] = n\text{Var}[Z_1^2] = n(E[Z_1^4] - E[Z_1^2]^2)$
 $= n(\alpha_4(Z_1) - \alpha_2^2(Z_1)) = n(3 - 1^2) = 2n$

Eigenschap. Als $X_1 \sim \chi_{n_1}^2$ en $X_2 \sim \chi_{n_2}^2$ onafhankelijk zijn, dan

$$X_1 + X_2 \sim \chi_{n_1+n_2}^2.$$

De χ^2 tabel geeft de **kwantielen** $\chi_{n,p}^2 = F_{\chi_n^2}^{-1}(p)$ weer.



Opmerking. Voor $n \geq 30$ geldt *benaderend*

$$\sqrt{2X} \approx \mathcal{N}(\sqrt{2n-1}, 1)$$

(zonder bewijs). Hiermee kunnen de overige kwantielen benaderd worden.

1.2.4 t_n verdeling

Definitie. Laat $Z \sim \mathcal{N}(0, 1)$ en $X \sim \chi_n^2$ onafhankelijk zijn ($n \geq 1$), dan heet de verdeling van

$$T = \frac{Z}{\sqrt{X/n}}$$

een **Student verdeling met n vrijheidsgraden**, genoteerd als


$$T \sim t_n.$$

De verdeling werd in 1908 gedefinieerd door Student, een pseudoniem voor W. Gosset. De reden dat er voor X/n gekozen werd, is omdat in dat geval $E[X/n] = E[X]/n = n/n = 1$.

De Student verdeling is symmetrisch, met dichtheid

$$f_{t_n}(t) = \frac{K_n}{\left(1 + \frac{t^2}{n}\right)^{\frac{n+1}{2}}} \quad -\infty < t < \infty, n = 1, 2, \dots$$


waarbij $K_n = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)}$ (zonder bewijs).



We hebben als kentallen:

- $E[T] = 0$ ($n > 1$) (f_{t_n} symmetrisch rond 0)
- $\text{Var}[T] = \frac{n}{n-2}$ ($n > 2$) (zonder bewijs)

Men kan ook aantonen dat hoe meer vrijheidsgraden er beschouwd worden, hoe beter de normale verdeling benaderd wordt door de Student verdeling. Ook voor de t_n verdeling bestaan er tabellen met de kwantielen $t_{n,p} = F_{t_n}^{-1}(p)$ in voor verschillende waarden van n .



1.2.5 F -verdeling

In 1924 definieerde Fisher de volgende verdeling.

Definitie. Als $W \sim \chi_m^2$ en $V \sim \chi_n^2$ onafhankelijk zijn, dan noemt men de verdeling van

$$X = \frac{W/m}{V/n}$$


de **F -verdeling** met m vrijheidsgraden in de teller en n vrijheidsgraden in de noemer. Notatie:

$$X \sim F_{m,n}.$$

De dichtheidsfunctie is (zonder bewijs):

$$f_{m,n}(x) = \begin{cases} K_{m,n} \frac{x^{\frac{m}{2}-1}}{(n+mx)^{\frac{n+m}{2}}} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

waarbij $K_{m,n} = \frac{m^{\frac{m}{2}} n^{\frac{n}{2}} \Gamma(\frac{m+n}{2})}{\Gamma(\frac{m}{2}) \Gamma(\frac{n}{2})}$.



Verder geldt er:

- $E[X] = \frac{n}{n-2} \quad (n > 2)$
- $\text{Var}[X] = \frac{2n^2(m+n-2)}{m(n-4)(n-2)^2} \quad (n > 4)$

Eigenschap. Voor elke $x > 0$ geldt

$$F_{m,n}(x) = 1 - F_{n,m}\left(\frac{1}{x}\right).$$

Bewijs.

$$\begin{aligned} F_{m,n}(x) &= P\left(\frac{W/m}{V/n} \leq x\right) = P\left(\frac{1}{x} \leq \frac{V/n}{W/m}\right) \\ &= 1 - P\left(\frac{V/n}{W/m} < \frac{1}{x}\right) = 1 - P\left(\frac{V/n}{W/m} \leq \frac{1}{x}\right) = 1 - F_{n,m}\left(\frac{1}{x}\right) \end{aligned}$$

□

Deze eigenschap helpt de afmetingen van de tabellen te reduceren, want voor de kwantielen ($F_{m,n,\alpha} = F_{F_{m,n}}^{-1}(\alpha)$) volgt hieruit dat

$$F_{m,n,\alpha} = \frac{1}{F_{n,m,1-\alpha}}.$$

Speciaal geval: voor $m = n$ en $\alpha = \frac{1}{2}$ vinden we dan

$$F_{m,m,\frac{1}{2}} = \frac{1}{F_{m,m,\frac{1}{2}}}$$

BESCHRIJVENDE STATISTIEK

Beschrijvende statistiek dateert van vóór het computertijdperk en houdt zich bezig met het samenvatten (aan de hand van kentallen) en grafisch voorstellen van gegevens, meestal door hen in klassen in te delen.

De exploratieve data analyse (EDA) is een recentere aanpak (sinds 1970) die tracht patronen en structuren in de dataset te vinden. Dit gebeurt vaak aan de hand van nieuwe computer-gegenereerde grafische voorstellingen zoals de QQ-plot en de boxplot.

Soms werken we met deterministische gegevens die een (kleine) populatie volledig omvatten, zoals alle atomen in de tabel van Mendeljev of alle staten die door de VN erkend worden, maar in de meeste studies worden de variabelen niet gemeten voor de hele populatie (omwille van tijd, geld, complexiteit, ... of omdat het niet realistisch en zelfs vaak onmogelijk is - denk maar aan destructieve onderzoeken). Daarom selecteert men vaak slechts een deel van de populatie om op te meten of te ondervragen. Deze selectie van n observaties wordt een **steekproef** (met steekproefgrootte of omvang n) genoemd en dient uiteraard representatief te zijn voor de gehele populatie, zodat we op basis van de steekproef toch algemene uitspraken kunnen doen. Uiteraard kan men stellen dat naarmate men meer informatie verkrijgt (n groter) men duidelijkere besluiten zal kunnen trekken. Anderzijds brengt het onderzoeken van bijkomende observaties vaak een belangrijke meerkost met zich mee (geld, tijd, ...). Beschrijvende statistiek en EDA worden dus meestal toegepast op gegevens die een *steekproef* vormen uit een grotere populatie.

2.1 Beschrijven van frequenties

We willen nagaan hoe de uitkomsten van een stochastische veranderlijke in een steekproef verdeeld zijn. We vertrekken van steekproefmetingen $x_1, \dots, x_n$ voor die bepaalde variabele en we willen antwoorden zoeken op vragen zoals:

- Zijn er grote verschillen tussen de gegevens, of lopen ze redelijk gelijk?
- Hoe verschillen ze?
- Zijn er trends in de data terug te vinden?
- Zijn er bepaalde getallen die veel van de rest van de data verschillen?

We bespreken eerst de verschillende mogelijkheden voor een variabele:

- **Kwalitatieve** variabelen zijn variabelen die aangeven tot welke categorie een observatie behoort. Zij kunnen onderverdeeld worden in nominale en ordinale variabelen.
 - **Nominale** variabelen worden gebruikt om dingen te klasseren of te identificeren, maar deze klassen zijn niet onderling te vergelijken (er is dus geen rangorde). Ze kunnen wel gebruikt worden om te bepalen of de elementen al dan niet gelijk zijn. Voorbeelden hiervan zijn geslacht, windrichting, nationaliteit, diersoorten,
 - **Ordinale** variabelen kunnen wel geordend worden volgens een bepaald criterium (bijvoorbeeld veel – weinig, klein – groot, ...), maar bewerkingen met de meetwaarden zijn niet echt zinvol en/of slechts zeer beperkt mogelijk. Voorbeelden hiervan zijn de onderverdeling tussen opleidingsniveau, rangen in het leger, kwaliteitsbeoordeling van een product,
- **Kwantitatieve** variabelen zijn variabelen die numerieke waarden aannemen zodat rekenkundige bewerkingen zin hebben. Zij hebben een metrisch meetniveau en kunnen continu of discreet (met eindige of oneindige uitkomstenverzameling) zijn. Doordat er een vaste (interpreteerbare) meeteenheid is, kunnen verschillen tussen zulke variabelen uitgedrukt worden in die eenheid. Het is hier dus niet alleen mogelijk om een verschil te detecteren, je kan het ook effectief kwantificeren. Voorbeelden zijn lengte, leeftijd,

2.1.1 Frequentietabellen en staafjesdiagram

Veronderstel dat we werken met een kwalitatieve variabele en beschikken over een steekproef $(x_1, \dots, x_n)$. De uitkomstenverzameling is dan een eindige verzameling $\Omega = \{m_1, \dots, m_k\}$. Tellen we voor elke mogelijke uitkomst $m_j \in \Omega$ hoe vaak deze uitkomst voorkomt in de steekproef, dan bekommen we de **absolute frequentie** n_j van de uitkomst m_j . Om zulke frequentiegegevens op eenzelfde schaal te zetten, delen we door het totaal aantal observaties n , wat ons de **relatieve frequenties** $h_j = n_j/n$ oplevert. Uiteraard geldt



$$\sum_{j=1}^k n_j = n \quad \sum_{j=1}^k h_j = 1.$$

We kunnen deze frequenties weergeven in een **frequentietabel** of grafisch voorstellen aan de hand van een (relatief) **staafjesdiagram**. Hierbij worden horizontaal de mogelijke uitkomsten gezet en op de verticale as wordt een staaf getekend met als hoogte de (relatieve) frequentie. De hoogte geeft dus aan hoe vaak, en dus hoe *waarschijnlijk*, een bepaalde uitkomst is binnen onze genomen steekproef. Soms worden ook balken getekend in de plaats van staafjes. Een andere grafische voorstelling is het **taartdiagram** waarbij de relatieve frequenties gebruikt worden om te tonen hoe de taart verdeeld wordt.

Voorbeeld. Stel dat een land opgedeeld is in 5 regio's: Centrum, Noord, Noord-Oost, Zuid-Oost en West. Er zijn $n = 60$ steden in dit land en we tellen hoeveel steden elke regio bevat. Dit resulteert in volgende frequentietabel:

Uitkomst	n_j	h_j
C	10	$10/60=16.7\%$
N	15	$15/60=25.0\%$
NO	24	$24/60=40.0\%$
ZO	5	$5/60=8.3\%$
W	6	$6/60=10.0\%$

We zien dat er bijvoorbeeld 15 steden in de regio 'Noord' liggen, wat goed is voor 25% van het totale aantal. Grafisch voorgesteld geeft deze tabel:



2.1.2 Histogram

Voor kwantitatieve gegevens kan het universum eindig of oneindig zijn. Voor een eindige uitkomstenverzameling kunnen we hetzelfde doen als bij de kwalitatieve data, maar voor een oneindige uitkomstenverzameling is dit niet meer mogelijk. Er zijn dan immers te veel mogelijke uitkomsten en een groot deel daarvan zal nooit bekomen worden in de steekproef (o.a. omdat we maar met een beperkte nauwkeurigheid kunnen meten, dus bijvoorbeeld het getal π zullen we nooit tegenkomen). Daarom gaan we de gegevens *discretiseren* of *groeperen* in **klassen**.

We zullen de verschillende termen invoeren aan de hand van een voorbeeld.

Voorbeeld. Van 300 voorbijrijdende auto's heeft men de snelheid gemeten:

$$(x_1, \dots, x_i, \dots, x_n) \quad \text{ruwe gegevens.}$$

We werken dus met een steekproef met steekproefgrootte $n = 300$. Om deze massa van gegevens samen te vatten kan men ze indelen in klassen (meestal tussen 5 en 20 klassen, bij voorkeur met een constante breedte). Klassen zijn aangrenzende deelintervallen van Ω die elkaar niet overlappen. Indien de klassen van gelijke breedte zijn, noemt men deze breedte de **klassenbreedte** en noteert men deze met Δ .

De gemeten snelheden (in km/u) zijn getallen tussen 44.5 en 94.5, dus men kan bijvoorbeeld volgende 10 klassen beschouwen:

$$[44.5, 49.5], [49.5, 54.5], \dots, [89.5, 94.5]$$

De klassenbreedte Δ is in dit geval 5 en het aantal klassen k is 10. Elke klasse heeft een **centrum** of **klassenmidden** c_i . Men beschouwt dus eigenlijk een nieuwe discrete uitkomstenverzameling $\Omega = \{c_1, \dots, c_k\}$. In dit voorbeeld zijn $c_1 = 47, \dots, c_{10} = 92$. Het aantal waarnemingen in de klasse j noemt men de **absolute frequentie** n_j en indien we deze delen door het aantal waarnemingen n bekomen we de **relatieve frequentie** h_j . Ook hier geldt

$$\sum_{j=1}^k n_j = n \quad \sum_{j=1}^k h_j = 1 = 100\%.$$

Stel dat de frequenties in het voorbeeld als volgt zijn:


$$\begin{array}{cccccc} n_1 = 8 & n_2 = 6 & n_3 = 29 & n_4 = 63 & n_5 = 60 \\ n_6 = 74 & n_7 = 29 & n_8 = 14 & n_9 = 15 & n_{10} = 2 \end{array}$$

We organiseren deze informatie in een overzichtstabel en we plaatsen hierin ook al berekeningen die later nuttig zullen blijken:

Klasse	c_j	n_j	h_j	$n_j c_j$	$n_j (c_j - \bar{x})^2$
[44.5, 49.5]	47	8	2.67%	367	3602.3
[49.5, 54.5]	52	6	2.00%	312	1578.5
[54.5, 59.5]	57	29	9.67%	1653	3650.8
[59.5, 64.5]	62	63	21.00%	3906	2437.4
[64.5, 69.5]	67	60	20.00%	4020	89.3
[69.5, 74.5]	72	74	24.67%	5328	1057.3
[74.5, 79.5]	77	29	9.67%	2233	2235.6
[79.5, 84.5]	82	14	4.67%	1148	2658.4
[84.5, 89.5]	87	15	5.00%	1305	5290.3
[89.5, 94.5]	92	2	0.67%	184	1131.0
Totaal		300	100%	20465	23730.9


De traditie van de overzichtstabel is ontstaan voor de opkomst van computers, als een manier om de gegevens en de berekeningen op een plaats te concentreren. Op deze manier hoefde men geen getallen over te schrijven (hetgeen fouten kan veroorzaken) en kon de juistheid van de berekeningen gemakkelijk nagegaan worden.

Om de frequenties (zowel de absolute als de relatieve) grafisch voor te stellen construeert men een **histogram**:




Het histogram is de continue tegenhanger van het staafjesdiagram. Bij elke klasse wordt een balk getekend met als basis de breedte van de klasse. De frequenties zijn evenredig met de **oppervlakte** van de balken. Indien we gelijke klassenbreedtes beschouwen, dan is de hoogte van de balk exact de (relatieve) frequentie en spreken we van het **klassiek histogram**. Bij het vastleggen van de klassenbreedte, het centrum en het aantal klassen moet men een compromis zoeken tussen te veel (erg gepiekt histogram) en te weinig (erg vlak histogram) klassen. Hiervoor bestaan geen vaste regels. De vorm van het histogram hangt vaak erg af van de keuze van de klassenindeling.

Soms wil men klassen gebruiken die niet even breed zijn (men noteert dan Δ_j voor de j -de klassenbreedte). Dit zal vooral het geval zijn wanneer bepaalde delen van Ω niet erg dicht bezet zijn, en men de gegevens daar wil groeperen om niet te veel pieken in het histogram te bekomen. Het nemen van de som van de (relatieve) frequenties van de deelklassen nemen, zal ons echter een vertekend beeld geven. Kijk bijvoorbeeld naar volgend histogram (in relatieve frequenties):




De laatste klassen geven niet veel extra informatie en willen we dus samen beschouwen. Tellen we gewoon alles op, dan bekommen we:



We zien dus dat er in de laatste klasse een overschatting ontstaat: we verwachten een veel lagere balk omdat de breedte groter geworden is. Hieruit blijkt dat de oppervlakte van een balk van belang is om een consistent beeld te bekomen en dus moeten we de balken zo construeren dat de oppervlakte (en dus niet de hoogte) evenredig is met de frequentie. Daarom zal bij het **dichtheidshistogram** het histogram verticaal herschalen door de hoogte van de balk gelijk te nemen aan de relatieve frequentie van de klasse *gedeeld door de overeenkomstige klassenbreedte*:

$$\text{hoogte} = \frac{h_j}{\Delta_j}.$$

Dit geeft dan volgende figuur



Het dichtheidshistogram gebruikt de oppervlakte (en niet de hoogte) van de balkjes om aan te geven hoe vaak een bepaalde uitkomst voorkomt in de steekproef. De totale oppervlakte van het dichtheidshistogram is dus

$$\text{totale oppervlakte} = \sum_{j=1}^k \Delta_j \frac{h_j}{\Delta_j} = 1.$$


We kunnen (de bovenrand van) het histogram dus beschouwen als een ruwe benadering van (de dichtheidsfunctie van) de verdeling van de populatie waaruit de waarnemingen voortkomen.

2.1.3 Empirische verdelingsfunctie en kwantielfunctie

Voor een willekeurige steekproef (dataset) kan men ook de bijbehorende **empirische verdelingsfunctie** tekenen, gedefinieerd door

$$\hat{F}_n(x) = \frac{\#\{x_i \leq x\}}{n}.$$

Dit is altijd een trapfunctie die stijgt van 0 tot 1.



Het gebeurt echter vaak dat men *enkel* over gegroepeerde gegevens beschikt¹. Dan kan men toch nog de **cumulatieve frequenties** berekenen voor alle klas-

¹Een veel voorkomende reden hiervoor is confidentialiteit. Indien het Nationale Instituut voor de Statistiek (NIS) de ruwe gegevens zou vrijgeven van alle burgers in een steekproef of volkstelling, zelfs zonder de naam van het individu, dan zou men toch sommige personen kunnen herkennen door de combinatie van regio, geslacht, leeftijd, aantal kinderen, inkomen, ... wat niet toegelaten is door de wet op de bescherming van de priv  sfeer. Een bedrijf doet hetzelfde om niet te veel informatie bekend te maken aan concurrerende bedrijven. Denk ook aan gegevens uit een ziekenhuis of de ziekteverzekering, waarbij de diagnoses van individuele pati  nten beroepsgeheim zijn.


sengrenzen met de n_j en h_j :

k	snelheid $\leq$ grens	aantal	%
0	≤ 44.5	0	0.00%
1	≤ 49.5	8	2.67%
2	≤ 54.5	14	4.67%
3	≤ 59.5	43	14.33%
4	≤ 64.5	106	35.33%
5	≤ 69.5	166	55.33%
6	≤ 74.5	240	80.00%
7	≤ 79.5	269	89.67%
8	≤ 84.5	283	94.33%
9	≤ 89.5	298	99.33%
10	≤ 94.5	300	100.00%

$$\text{Absolute cumulatieve frequentie} = \sum_{j=1}^k n_j$$

$$\text{Relatieve cumulatieve frequentie} = \sum_{j=1}^k h_j$$

Grafisch worden deze cumulatieve frequenties voorgesteld in een **relatieve cumulatieve frequentiehoek**:



Merk op dat deze figuur de onbekende verdelingsfunctie benadert.

De empirische verdelingsfunctie geeft dus voor elk reëel getal een percentage p , maar we kunnen ons ook de omgekeerde vraag stellen: gegeven $0 < p \leq 1$, welk

getal situeert zich dan op die positie in de steekproef? We willen dus eigenlijk de inverse van $\hat{F}_n$ bepalen, namelijk de **empirische kwantielfunctie** $\hat{Q}_n$. Omdat $\hat{F}_n$ een trapfunctie is, moeten we nauwkeurig definiëren hoe we deze inverse bepalen.

- Indien er geen enkele x is zodat $\hat{F}_n(x) = p$, dan nemen we de eerste x -waarde waarvoor $\hat{F}_n(x) > p$;
- Indien er een heel interval is waarop $\hat{F}_n(x) = p$, dan nemen we de kleinste waarde in dat interval.

We kunnen dus zeggen dat, voor $0 < p \leq 1$:

$$\hat{Q}_n(p) \text{ is de kleinste } x \text{ waarvoor } \hat{F}_n(x) \geq p.$$

Merk op dat deze x -waarde niet hoeft samen te vallen met een steekproefelement.

2.2 Kenmerken voor locatie en schaal

Vaak wil men een aantal karakteristieken van de gegevens numeriek uitdrukken, hiervoor gebruikt men zogenaamde ‘statistieken’.

2.2.1 Centrumkenmerken

Voor de **locatie** (*plaats, positie, ligging*) zijn er drie veelgebruikte centrumkentallen: het gemiddelde, de mediaan en de modus.

2.2.1.1 Steekproefgemiddelde

Voor een steekproef $(x_1, \dots, x_n)$ is het **steekproefgemiddelde**

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Indien men enkel beschikt over gegroepeerde gegevens dan benadert men dit als

$$\bar{x} = \frac{1}{n} \sum_{j=1}^k n_j c_j.$$

Dit zou exact zijn indien de waarnemingen in elke klasse zouden gelijk zijn aan het klassenmidden c_j .

Voorbeeld. In het voorbeeld van de snelheden wordt dit

$$\bar{x} = \frac{1}{300} 20465 \frac{\text{km}}{\text{u}} = 68.22 \frac{\text{km}}{\text{u}}$$

gebruikmakend van de $n_j c_j$ in de tabel.

2.2.1.2 Steekproefmediaan

Voor de volledige steekproef wordt de **steekproefmediaan** gedefinieerd als de middelste waarneming van een oneven aantal geordende observaties. Indien het aantal observaties even is, dan wordt het steekproefgemiddelde genomen van de twee middelste waarnemingen.

Wanneer men enkel gegroepeerde gegevens heeft, dan benadert men de steekproefmediaan $\text{med}(x)$ door het punt op de X -as zodat 50% van de oppervlakte van het histogram links ligt. In dit punt bereikt de frequentievelhoek ook 50%. Men kan de benaderende mediaan dus berekenen met de formule voor lineaire interpolatie:

$$\frac{y - y_0}{x - x_0} = \frac{y_1 - y_0}{x_1 - x_0}$$

waarbij (x_0, y_0) het beginpunt van het interval is, (x_1, y_1) het eindpunt en (x, y) het punt ertussen. In ons geval zal de onbekende y -waarde de mediaan zijn, en x zal gelijk aan 50% genomen moeten worden.

Voorbeeld. Voor het voorbeeld van de snelheden bekomen we dan

$$\begin{aligned} \text{med}(x) &= 64.5 + \left(\frac{50\% - 35.33\%}{55.33\% - 35.33\%} \right) (69.5 - 64.5) \\ &= 68.17 \frac{\text{km}}{\text{u}} \end{aligned}$$

Merk op dat, indien n oneven is, de steekproefmediaan ook gelijk is aan $\hat{Q}_n(1/2)$ bekomen via de empirische kwantiefunctie. Voor even n zal $\hat{Q}_n(1/2)$ een benadering van de mediaan geven.

Wanneer we werken met de geïnterpoleerde versie van de kwantiefunctie (dus gebaseerd op de relatieve cumulatieve frequentievelhoek), dan zal $\hat{Q}_n(1/2)$ altijd de mediaan opleveren.

Ten slotte merken we op dat de steekproefmediaan en het steekproefgemiddelde onberekenbaar zijn voor nominale variabelen. Voor ordinale variabelen kunnen we wel de mediaan bepalen.

2.2.1.3 Modus

Wanneer de waarnemingen in de volledige dataset (meestal) verschillende waarden aannemen heeft het weinig zin om over de **modus** (d.w.z. de meest voorkomende waarde) van de steekproef te spreken. Het is vaak wel zinvol om naar de gegroepeerde gegevens te kijken en de **modale klasse** te bepalen. Dit is de klasse met de grootste verhouding

$$\frac{\text{frequentie}}{\text{klassenbreedte}}$$

en is bijgevolg de klasse met de hoogste rechthoek in het histogram (zelfs indien de klassenbreedte niet constant is). In dat geval wordt de modus ook wel gedefinieerd als het midden van die klasse.

Voorbeeld. In het voorbeeld is de modale klasse $]69.5, 74.5]$.

De modale klasse hangt zeer sterk af van de klassenindeling, en is ook niet altijd eenduidig. Daarom wordt de modus minder vaak gebruikt dan het steekproefgemiddelde en de steekproefmediaan, die wel eenduidig zijn.

2.2.2 Spreidingskenmerken

Centrummaten alleen geven ons niet voldoende informatie over de verdeling van de steekproef. Daarom is het interessant om ook na te gaan hoe ver of hoe dichtbij de overige punten rond het locatiekenmerk gespreid liggen. Voor verschillende steekproeven kan bijvoorbeeld het gemiddelde gelijk zijn, terwijl de data totaal anders verspreid is.

Voor de **schaal** (*spreiding*) zullen we de empirische variantie, standaardafwijking, interkwartielafstand en median absolute deviation beschouwen.

2.2.2.1 Empirische variantie en standaardafwijking

Vertrekkende van een centrumkenmerk, ligt het voor de hand om de spreidingskenmerken te verkrijgen door de afstand tussen elke gemeten waarde x_i en het centrumkenmerk te beschouwen en die waardes dan uit te middelen over alle datapunten.

Zo is de **empirische variantie** van een steekproef $(x_1, \dots, x_n)$ gedefinieerd als

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Dit is duidelijk een maat voor de spreiding van de gegevens ten opzichte van het steekproefgemiddelde. De reden dat er voor een kwadraat gekozen wordt en niet voor bijvoorbeeld de absolute waarde, is dat een kwadraat enerzijds makkelijker rekt, en anderzijds zal op deze manier de variantie een aantal gewenste eigenschappen bezitten (zie hoofdstuk 3). Dit laatste is ook de reden voor de deling door $n-1$ en niet door n zoals men intuïtief zou verwachten. Kort gezegd delen we door $n-1$ omdat we in de formule van de variantie al gebruik maken van een andere schatter, namelijk het gemiddelde, waardoor we één vrijheidsgraad verliezen.

Voor discrete of gegroepeerde gegevens berekent men de variantie als

$$s^2 = \frac{1}{n-1} \sum_{i=1}^k n_i (c_i - \bar{x})^2$$

waarbij k het aantal klassen is, c_i de mogelijke uitkomsten (discrete geval) of de klassenmiddens (gegroepeerde geval) en n_i de bijhorende frequenties.

Voorbeeld. Voor de snelheden vinden we, gebruikmakend van de tabel:

$$s^2 = \frac{1}{299} 23730.9 = 79.36 \left(\frac{\text{km}}{\text{u}} \right)^2$$

Aangezien deze eenheden zinloos zijn, zal men de vierkantswortel nemen en bekomt men zo de **empirische standaardafwijking**:

$$s = \sqrt{s^2}.$$

Voorbeeld. Voor de snelheden vinden we dan:

$$s = 8.91 \frac{\text{km}}{\text{u}}.$$

De standaardafwijking heeft opnieuw de eenheden van de oorspronkelijke waarnemingen x_i en geeft een indicatie van hoe “breed” het histogram is.

De standaardafwijking kan gebruikt worden om aan te geven hoe verschillend een waarneming is ten opzichte van het centrum (in dit geval het steekproefgemiddelde). Het meest centrale deel van het histogram wordt dan typisch beschreven als

$$[\bar{x} - s, \bar{x} + s],$$

dus alle observaties die hoogstens één standaarddeviatie van het gemiddelde verwijderd liggen.

Voor data die *normaal verdeeld* zijn geldt dat ongeveer twee derde van de gegevens binnen dit interval liggen. Bovendien zal voor normaalverdeelde data ongeveer 95% van de waarnemingen op maximaal twee standaarddeviaties van het steekproefgemiddelde liggen.

2.2.2.2 Empirisch interkwartielafstand

Men kan de schaal ook schatten met de **empirische interkwartielsafstand** (IQR_n). De IQR_n geeft de breedte weer van het interval dat rond de mediaan ligt en ongeveer de helft van de observaties bevat. Hiertoe berekenen we het eerste en derde kwartiel van de gegevens, en nemen het verschil tussen beide:

$$\text{IQR}_n = \hat{Q}_n(3/4) - \hat{Q}_n(1/4).$$

In het geval van gegroepeerde gegevens bekomt men de gewenste kwartielen $\hat{Q}_n(\frac{1}{4})$ en $\hat{Q}_n(\frac{3}{4})$ door lineaire interpolatie, zoals bij de benadering van de steekproefmediaan $\hat{F}_n^{-1}(\frac{1}{2})$ hierboven.

2.2.2.3 Median absolute deviation

Een andere maat voor spreiding is de **median absolute deviation** gedefinieerd door:

$$\text{mad}(x) = \text{med}(|x - \text{med}(x)|).$$

Men berekent hier dus eerst de afstand van de waarnemingen tot de steekproefmediaan $\text{med}(x)$, en beschouwt vervolgens de mediaan van deze afstanden $|x_1 - \text{med}(x)|, \dots, |x_n - \text{med}(x)|$. Voor symmetrische verdelingen geldt dat $\text{IQR}_n \approx 2\text{mad}(x)$.

2.3 Boxplot

Het is interessant zijn om zoveel mogelijk informatie over de verdeling van de steekproef in een enkele oogopslag te verkrijgen. Grafisch zal men dit doen aan de hand van de **boxplot** (J. Tukey, 1977), dewelke in eenzelfde schema de mediaan ($\hat{Q}_n(1/2)$), het eerste en het derde kwartiel ($\hat{Q}_n(1/4)$ en $\hat{Q}_n(3/4)$), de IQR_n en de kleinste en de grootste waarde van de data weergeeft. Soms wordt hierbij ook nog het steekproefgemiddelde $\bar{x}$ toegevoegd.

Beschouw een dataset $(x_1, \dots, x_n)$. Deze wordt eerst geordend tot een nieuwe dataset $(x_{1:n}, \dots, x_{n:n})$, waarna als volgt de boxplot wordt opgesteld:

- zet een streepje bij de steekproefmediaan $\text{med}(x) = \hat{Q}_n(1/2)$;
- teken een **doos** (“box”) gaande van $\hat{Q}_n(1/4)$ tot $\hat{Q}_n(3/4)$, de lengte van deze doos is dus precies de IQR_n en bevat precies de helft van de gegevens;
- soms wordt in deze doos nog het steekproefgemiddelde $\bar{x}$ aangeduid door middel van een symbool;
- teken de **uitschieters**. Dit zijn de waarnemingen die afwijken van de reguliere datapunten, gedefinieerd als die punten die dus buiten

$$\left[\hat{Q}_n(1/4) - \frac{3}{2}\text{IQR}_n, \hat{Q}_n(3/4) + \frac{3}{2}\text{IQR}_n \right]$$

liggen;

- identificeer de extreme uitschieters, dit zijn de waarnemingen buiten

$$\left[\hat{Q}_n(1/4) - 3\text{IQR}_n, \hat{Q}_n(3/4) + 3\text{IQR}_n \right].$$

Deze worden soms met een apart symbool aangeduid;

- teken ten slotte de **whiskers** (“*snorharen*”) die gaan vanaf de doos tot de verste niet-uitschieters.


Voorbeeld. Gegeven de bevolking (in 10000) van 15 steden (USA, 1960):

1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
63	68	70	74	74	75	76	88	94	94	167	200	248	355	778

Voor deze dataset is:

- $\text{med}(x) = \hat{Q}_n(1/2) = x_{8:15} = 88$
- $\hat{Q}_n(1/4) = x_{4:15} = 74$
- $\hat{Q}_n(3/4) = x_{12:15} = 200$
- $\text{IQR}_n = 126$
- $\left[\hat{Q}_n(1/4) - \frac{3}{2}\text{IQR}_n, \hat{Q}_n(3/4) + \frac{3}{2}\text{IQR}_n \right] = [74 - 189, 200 + 189] = [-115, 389]$
en dus de enige uitschieter is $x_{15:15} = 778$ (New York)


De bijbehorende boxplot ziet er dus als volgt uit:



De boxplot geeft ons een idee over de verdeling van de gegevens:

- de **positie** van de steekproef: via de mediaan en eventueel het gemiddelde
- de **spreiding**: de lengte van de box is gelijk aan IQR_n
- de **scheefheid**:
 - de plaats van $\hat{Q}_n(1/2)$ tussen $\hat{Q}_n(1/4)$ en $\hat{Q}_n(3/4)$ geeft aan of de verdeling symmetrisch is of niet. Voor een symmetrische verdeling zal de mediaan in het midden van de doos liggen, bij rechtsscheve verdelingen vanonder/links in de doos en bij linksscheve verdelingen vanboven/rechts in de doos (afhankelijk of ze verticaal of horizontaal getekend is)
 - de relatieve lengte van de whiskers zal ook een aanduiding zijn voor scheefheid. Als het bovenste/rechtse *whisker* (snorhaar) langer (resp. korter) is dan het linkse, is dit een indicatie dat de verdeling rechts-scheef (resp. linksscheef) is.
- de **zwaarte van de staarten**: veel uitschieters wijst op een verdeling met zware staarten.


Boxplots zijn ook zeer nuttig om **verschillen tussen datasets** aan te tonen. Veronderstel dat we datasets hebben waaruit we volgende boxplots bekomen:



We zien dat de datasets vermoedelijk uit een scheve verdeling komen met staart (uitschieters) langs rechts en dus waarschijnlijk niet normaal verdeeld zullen zijn. Maar misschien zijn de x_i (per land) ongeveer lognormaal verdeeld. Om dit na te gaan kunnen, en dus om aan de scheefheid te verhelpen, kunnen we eens proberen om een logaritmische transformatie van de gegevens van elk land uit te voeren:

$$y_i := \ln(x_i) \Rightarrow y_{i:n} = \ln(x_{i:n})$$

Dit geeft dan de volgende boxplots:




We zien dat deze getransformeerde datasets minder scheef lijken en minder uitschieters aanduiden. Het is dus goed mogelijk dat de gegevens in deze datasets bij benadering lognormaal verdeeld zijn.

2.4 Covariantie en correlatie

Ook voor een steekproef kunnen we nagaan of er een lineair verband bestaat tussen twee (metrische) variabelen X en Y . Dit kan enerzijds op een grafische

manier, via een scatterplot, en anderzijds door het berekenen van de covariantie en de correlatiecoëfficiënt.

Laat ons starten met de grafische voorstelling. Twee metrische variabelen kunnen tegen elkaar uitgezet worden in een **scatterplot** of *puntenwolk* om na te gaan of er al dan niet een verband bestaat tussen de twee. Voor elke observatie plaatsen we dan de meting van de ene variabele op de horizontale as en de meting voor de andere variabele op de verticale as. Op die manier krijgt men bijvoorbeeld



In de linkse figuur staan de originele data tegenover elkaar getekend. We zien dat er een punt is dat afwijkt van de andere punten, namelijk ‘New Orleans’. Dit punt noemen we een **uitschieter**. Verder merken we dat als de waarde op de X -as stijgt, ook de waarde op de Y -as in het algemeen stijgt. Bijgevolg vermoeden we dat er een *positief verband* bestaat tussen beide variabelen. We zien ook dat het verband niet lineair is, maar eerder logaritmisch. We kunnen dit nagaan door op de horizontale as het logaritme van die waarnemingen te zetten in plaats van de waarnemingen zelf (rechtse figuur). Deze tekening toont wel een lineair patroon, maar het is niet exact lineair. Bij elke x -waarde kan y nog verschillende waarden aannemen, er is dus nog variabiliteit in deze puntenwolk. Een scatterplot laat ons toe om na te gaan of de variabelen al dan niet *positief* of *negatief gecorreleerd* zijn. Ook krijgen we op deze manier vaak een indicatie van de aard van dit verband, bijvoorbeeld lineair, kwadratisch of logaritmisch. Daarnaast geeft de scatterplot ook een idee van de sterkte van het verband; hierbij geldt dat hoe dichter de puntenwolk is, hoe zwakker de associatie tussen beide variabelen. Sterke associatie wil zeggen dat kennis van een van de variabelen toelaat om de andere variabele relatief nauwkeurig te bepalen, bij zwakke associatie zal de waarde van de ene variabele echter weinig vertellen over de waarde van de tweede variabele.

Naast de grafische voorstelling, kunnen we ook gebruik maken van de empirische versies van de covariantie en de correlatie om het bestaan van een lineair verband tussen X en Y na te gaan. De **steekproefcovariantie** is gedefinieerd als

$$\text{cov}(x, y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

Bovendien geldt ook hier dat

$$\text{cov}(x, x) = s_x^2 \quad (\text{steekproefvariantie van } x).$$

Omdat de covariantie sterk afhankelijk is van de gebruikte meeteenheid, is het dus moeilijk om over een sterke of zwakke associatie te oordelen. Daarom wordt de steekproefcovariantie herschaald door te delen door de standaarddeviaties. Op die manier bekomen we een beter interpreteerbare grootte, de (Pearson) **correlatiecoëfficiënt**:

$$r = r_{xy} = \text{corr}(x, y) = \frac{\text{cov}(x, y)}{s_x s_y}$$

als $s_x > 0$ en $s_y > 0$. Door de definities van de steekproefcovariantie en de empirische standaarddeviatie te gebruiken, kunnen we de correlatie herschrijven als

$$\begin{aligned} r &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \\ &= \frac{1}{n-1} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right) \left(\frac{y_i - \bar{y}}{s_y} \right). \end{aligned}$$

Men kan aantonen dat $-1 \leq r \leq 1$. Als de puntenwolk smaller wordt, zal de correlatiecoëfficiënt naar -1 of 1 gaan, afhankelijk van het feit of het een dalende of stijgende rechte betreft. Indien er geen associatie is tussen X en Y zal $r \approx 0$ zijn. Merk op dat bij een verband tussen X en Y niet noodzakelijk geldt dat $r \neq 0$, er immers is gewoon geen *lineair* verband (maar een kwadratisch verband is bijvoorbeeld wel mogelijk). Het is daarom aangeraden om eerst de scatterplot te tekenen en als die een indicatie geeft over het bestaan van een lineair verband, dit verband te meten aan de hand van r .

2.5 Kruistabel

Om het verband tussen twee *kwalitatieve* variabelen weer te geven, kan een **kruistabel** opgesteld worden. Om deze tabel te maken, wordt er geteld hoe vaak elke combinatie van twee variabelen in de steekproef voorkomt. Daarnaast worden ook de rij- en kolomsommen toegevoegd.

Stel dat we in een steekproef onderzoek hebben gedaan naar het gemiddeld inkomen (ingedeeld in 4 klassen) in een bepaalde stad en de regio waar deze stad ligt en dat we de volgende kruistabel bekomen:

	1	2	3	4	Totaal
C	2	3	4	1	10
N	5	8	2	0	15
NO	6	13	4	1	24
W	0	2	2	2	6
ZO	3	2	0	0	5
Totaal	16	28	12	4	60

We zien bijvoorbeeld dat er van de 60 steden zes zijn met een inkomstenniveau ‘1’ die in regio ‘NO’ liggen. In totaal liggen er 10 steden in regio ‘C’ en 28 steden hebben een gemiddeld inkomen in klasse ‘2’.

Er zijn echter heel wat nullen in deze tabel, en ook de overige waarden zijn redelijk klein, wat een goede statistische analyse bemoeilijkt. Daarom zullen we de regio’s gaan herdefiniëren; ‘C’ en ‘W’ zullen we groeperen tot ‘West’ en de overige drie nemen we samen als ‘Oost’. Dit levert dan volgende kruistabel

	1	2	3	4	Totaal
Oost	14	23	6	1	44
West	2	5	6	3	16
Totaal	16	28	12	4	60

We vragen ons af of de variabelen ‘Regio’ en ‘Inkomen’ onafhankelijk zijn, dus of het inkomen niet afhangt van de regio waarin de stad ligt. Hiervoor berekenen we de verwachte waarden die we zouden bekomen als de variabelen onafhankelijk zouden zijn. We zien dat $44/60 = 73.3\%$ van de steden in het oosten ligt en $16/60 = 26.7\%$ van de steden in het westen. Daarnaast hebben 28 steden een inkomen in categorie ‘2’. Indien de variabelen onafhankelijk zouden zijn, dan mogen we verwachten dat van deze 28 steden er 73.3% in het oosten liggen en 26.7% in het westen. Bijgevolg is de *verwachte waarde* voor de combinatie ‘Oost’ en ‘2’ gelijk aan 20.53, die voor ‘West’ en ‘2’ is 7.47. De verwachte waarde (indien variabelen onafhankelijk zouden zijn) wordt dus berekend als

$$\frac{\text{rijtotaal} \times \text{kolomtotaal}}{n}.$$

We berekenen alle verwachte waarden en bekomen

	1	2	3	4	Totaal
Oost	11.7	20.5	8.8	2.9	44
West	4.3	7.5	3.2	1.1	16
Totaal	16	28	12	4	60

Indien deze nieuwe kruistabel goed overeenkomt met de oude kruistabel, vermoeden we dat beide variabelen onafhankelijk zijn. Hier zien we echter duidelijke verschillen: in het oosten zijn de klassen 1 en 2 oververtegenwoordigd in de steekproef in vergelijking met de situatie waar er onafhankelijkheid wordt verondersteld en in het westen treedt het omgekeerde effect op. Bijgevolg vermoeden we dat regio en inkomen hier afhankelijk zijn. De uiteindelijke beslissing zal genomen worden aan de hand van een hypothesetest (zie hoofdstuk 5).

2.6 QQ-plot

Een **QQ-plot** (*Quantile-Quantile plot* of gewoon *kwantielplot*) wordt gebruikt om na te gaan of we kunnen veronderstellen dat onze data een bepaalde *continue* verdeling volgt. Meestal zal de kwantielplot gebruikt worden om normaliteit

van de gegevens na te gaan (normaal verdeelde data wordt vaak verondersteld), maar ze kan voor elke willekeurige verdeling opgesteld worden.

Deze plot zal, voor verschillende waarden van $0 \leq p \leq 1$, de empirische kwantielen $\hat{Q}_n(p)$ uitzetten tegenover de theoretische kwantielen $F^{-1}(p)$ van een bepaalde verdeling F (bijvoorbeeld $F = \mathcal{N}(0, 1)$). Indien de gegevens de veronderstelde verdeling zouden volgen, verwacht men dat de empirische en de theoretische kwantielen ongeveer overeenkomen, en dus dat de getekende punten ongeveer op een rechte lijn zouden liggen.

Voor welke p berekenen we dan de kwantielen? Wanneer we terugdenken aan de empirische kwantielfunctie, zien we dat

$$\hat{Q}_n(p) = x_{i:n} \text{ indien } p \in](i-1)/n, i/n]$$

waarbij $x_{i:n}$ of $x_{(i)}$ het i -de geordende getal voorstelt, dus: $x_{1:n} \leq x_{2:n} \leq \dots \leq x_{n:n}$. Het is dus logisch om ook bij het tekenen van de QQ-plot gebruik te maken van de waarden $p = 1/n, 2/n, \dots, (n-1)/n, 1$, wat leidt tot de grafiek met koppels


$$\left(F^{-1}\left(\frac{i}{n}\right), \hat{Q}_n\left(\frac{i}{n}\right) \right) = \left(F^{-1}\left(\frac{i}{n}\right), x_{i:n} \right) \quad i = 1, \dots, n.$$

Soms wordt er ook nog een continuïteitscorrectie uitgevoerd en plot men $(F^{-1}(\frac{i-0.5}{n}), x_{i:n})$ of $(F^{-1}(\frac{i}{n+1}), x_{i:n})$.


Men spreekt van een *normale QQ-plot* als er getest wordt ten opzichte van de normale verdeling. Als X normaal verdeeld is met parameters μ en σ^2 dan geldt

$$F^{-1}\left(\frac{i}{n}\right) = \mu + \sigma \Phi^{-1}\left(\frac{i}{n}\right).$$

In plaats van te kijken of $F^{-1}(\frac{i}{n})$ en $x_{i:n}$ op een rechte liggen kan men dus de n koppels $(\Phi^{-1}(\frac{i}{n}), x_{i:n})$ voor $i = 1, \dots, n$ bestuderen (en dus normaliteit testen ten opzichte van de standaard normale verdeling). Indien deze veronderstelling correct is, dan liggen de punten (ongeveer) op de eerste bissectrice, aangezien de theoretische en empirische kwantielen dan gelijk zijn. Bijgevolg kan men via de QQ-plot een idee krijgen over het gemiddelde en standaardafwijking:




Voorbeeld. In de volgende tekeningen zijn twee variabelen getekend ten opzichte van de standaard normale verdeling.




In de linkse figuur zien we dat de normale verdeling aannemelijk is, en dat de parameters $\mu = 74.6$ en $\sigma = 4.8$ zijn. De rechtse figuur toont dat voor deze variabele de veronderstelling van normaliteit niet geldig lijkt te zijn.

Soms kan men in een niet-lineaire (normale) QQ-plot een bepaalde functie herkennen. Dit laat ons toe om een transformatie van de data voor te stellen zodat de getransformeerde data wel (benaderend) normaal verdeeld zijn.



De gegevens in de linkerfiguur zijn waarschijnlijk niet normaal verdeeld, aangezien de QQ-plot geen rechte is. Wel kan men er een functioneel verband in herkennen: $\text{gegevens} = g(\text{normale kwantielen})$. Door de data dan te transformeren via g^{-1} (rechtse plot), krijgen we wel een rechte lijn in de kwantielplot. Om een idee te krijgen van deze g^{-1} dient men de normale kwantielen op de Y-as te tekenen en de geordende data op de X-as. De zo bekomen grafiek geeft dan de functie g^{-1} weer.

Voorbeeld. Hernemen we de rechterfiguur uit het vorige voorbeeld, maar draaien we de assen om, dan krijgen we de onderstaande linkse figuur.



De bekomen grafiek lijkt logaritmisch te zijn, dus nemen we het logaritme van de data en stellen dan met deze nieuwe gegevens nogmaals de normale kwantielplot op. De rechterfiguur toont ons dat de getransformeerde data wel (benaderend) normaal verdeeld zijn.

Analoog kan men ook een **PP-plot** (*Probability-Probability plot*) opstellen die de theoretische en de empirische kansen vergelijkt. De redenering (en besluiten) zijn dezelfde als bij de QQ-plot, maar er wordt op een andere schaal gewerkt.

Het opstellen van een QQ-plot of PP-plot zal normaal gezien steeds met een statistisch programma zoals R/RStudio² gebeuren. Er dient wel opgemerkt te worden dat zo'n plot slechts een indicatie geeft over de verdeling van de data, en dat deze veronderstelling achteraf nog door een formele statistische toets gecontroleerd dient te worden.

²R is een software programma om statistische berekeningen en grafieken te maken dat kan gedownload worden via volgende link: <http://cran.r-project.org>. RStudio is een populaire en handige interface voor R, zie <http://www.rstudio.com>.

HET SCHATTEN VAN PARAMETERS

3.1 Voorbeeld: steekproefgemiddelde

We hebben reeds gezien dat de meeste kansmodellen één of meerdere parameters bevatten: μ en σ^2 in het normale model, α in het Poisson model, p in het binomiale model, ... Vaak zijn deze parameters in de praktijk onbekend. Men wenst dan een benaderende waarde voor deze parameters te vinden aan de hand van een steekproef met concrete metingen. In dit hoofdstuk nemen we beslissingen voor een populatie op basis van een steekproef (hiervoor zullen we gebruik maken van de centrale limietstelling). Hoe zo een *schatting* bekomen wordt uit de steekproef en wat de betrouwbaarheid is van zo een schatting, zal ook in dit hoofdstuk worden behandeld. We bestuderen eerst het specifieke geval van het steekproefgemiddelde als schatter voor het populatiegemiddelde en daarna zullen we algemene definities invoeren.

Het is duidelijk dat het steekproefgemiddelde slechts een benadering is van het populatiegemiddelde $E[X]$ en dat het resultaat afhangt van de gekozen steekproef. Het is immers zeer onwaarschijnlijk dat je bij het beschouwen van een nieuwe steekproef opnieuw exact hetzelfde steekproefgemiddelde zou bekomen. Elke nieuwe steekproef zal dus een ander steekproefgemiddelde opleveren! Uiteraard willen we dan weten hoe goed een steekproefgemiddelde het populatiegemiddelde benadert. Het is dan belangrijk om de maximale afwijking die kan optreden tussen het steekproefgemiddelde en het echte populatiegemiddelde te bestuderen. Door verschillende steekproeven te observeren, kunnen we wel een idee krijgen hoeveel het steekproefgemiddelde en het populatiegemiddelde kunnen verschillen. Omdat het steekproefgemiddelde niet vast is, kunnen we het als een stochastische veranderlijke (s.v.) beschouwen die verschillende uitkomsten kan aannemen. Wanneer we het steekproefgemiddelde als s.v. beschouwen, noteren we het met een hoofdletter, terwijl we de geobserveerde waarde van het steekproefgemiddelde van een specifieke steekproef aanduiden met kleine letter. Dus we definiëren het steekproefgemiddelde $\bar{X}_n$ als

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

en het steekproefgemiddelde $\bar{x}_n$ als


$$\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$$

waarbij $X_1, \dots, X_n$ onafhankelijke s.v. zijn met eenzelfde verdeling. Een toeval-
lige steekproef $(x_1, \dots, x_n)$ wordt dan beschouwd als een realisatie van een rij
toevalsvariabelen $(X_1, \dots, X_n)$.

Voorbeeld. Beschouw bijvoorbeeld een s.v. $X \sim \mathcal{N}(10, 9)$. Hiervan kunnen
we op willekeurige en onafhankelijke wijze een steekproef met steekproefgrootte
 $n = 60$ trekken. Elk van die 60 observaties volgt dan de kansverdeling van de s.v.
 X , dus elke realisatie van X ligt bijvoorbeeld met 68% kans tussen 7 en 13. Dit
‘random genereren’ van steekproeven uit een specifieke verdeling kan eenvoudig
uitgevoerd worden in statistische software zoals R. Als we dan 50 steekproeven
uit deze verdeling genereren (telkens met steekproefgrootte $n = 60$), bekomen
we ook 50 steekproefgemiddeldes

$$\begin{array}{ll} (x_1^{(1)}, \dots, x_{60}^{(1)}) & \text{met steekproefgemiddelde } \bar{x}_n^{(1)} \\ \dots & \dots \\ (x_1^{(50)}, \dots, x_{60}^{(50)}) & \text{met steekproefgemiddelde } \bar{x}_n^{(50)} \end{array}$$

Voor elke gegenereerde steekproef, kunnen we een histogram opstellen (zie linkse
figuur hieronder voor de eerste gegenereerde steekproef - 60 observaties). We
kunnen echter ook een histogram construeren voor de steekproefgemiddeldes
(rechtse figuur hieronder - 50 gemiddeldes worden nu beschouwd als observa-
ties). Het rechtse histogram geeft een idee van de verdeling van de s.v. $\bar{X}_n$,
vermits de 50 steekproefgemiddeldes realisaties zijn van deze $\bar{X}_n$.



We merken op dat er verschillende uitkomsten voor $\bar{X}_n$ mogelijk zijn, maar dat
de meerderheid van de observaties tussen 9 en 11 lijkt te liggen. Het is dan ook
aannemelijk dat het populatiegemiddelde $\mu = E[X]$ zich ergens in die buurt
situeert. We merken uit de figuur ook op dat $\bar{X}_n$ normaal verdeeld lijkt te zijn
en dat de spreiding van $\bar{X}_n$ veel kleiner is dan die van X zelf.

3.1.1 Verdeling van het steekproefgemiddelde

Omdat we $\bar{X}_n$ als een s.v. beschouwen, kunnen we van $\bar{X}_n$ de verwachtings-
waarde en de variantie berekenen. Deze kenmerken zijn eenvoudig terug te vin-
den uit de verdeling van $(X_1, \dots, X_n)$ omdat het gemiddelde $\bar{X}_n$ te schrijven is

als een lineaire combinatie van de X_i , $i = 1, \dots, n$.

Aangezien de s.v. $X_1, \dots, X_n$ allemaal dezelfde verdeling hebben, geldt dat

$$\begin{aligned} E[\bar{X}_n] &= E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} E\left[\sum_{i=1}^n X_i\right] \\ &= \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n} n E[X_1] \end{aligned}$$

en dus

$$E[\bar{X}_n] = E[X_1].$$

Het gemiddelde concentreert zich dus rond dezelfde waarde als waarrond de componenten zich concentreren. Merk op dat hier niet verondersteld wordt dat de X_i onafhankelijk zijn.

Voor de variantie is die onafhankelijkheid wel nodig, want anders mogen we niet gebruiken dat $\text{Var}[X + Y] = \text{Var}[X] + \text{Var}[Y]$. Voor het steekproefgemiddelde geldt dan dat

$$\begin{aligned} \text{Var}[\bar{X}_n] &= \text{Var}\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n^2} \text{Var}\left[\sum_{i=1}^n X_i\right] \\ &= \frac{1}{n^2} \sum_{i=1}^n \text{Var}[X_i] = \frac{1}{n^2} n \text{Var}[X_1] \end{aligned}$$

en bijgevolg

$$\text{Var}[\bar{X}_n] = \frac{1}{n} \text{Var}[X_1].$$

De spreiding van de variantie van het steekproefgemiddelde is dus omgekeerd evenredig met de grootte n van de steekproef en recht evenredig met de variantie van de steekproefgegevens zelf. Hoe groter onze steekproef, hoe kleiner de variantie van het steekproefgemiddelde en hoe nauwkeuriger we hier iets over kunnen zeggen.

We hebben reeds gezien dat een lineaire combinatie van i.i.d. normaal verdeelde variabelen opnieuw normaal verdeeld is. Bijgevolg kunnen we voor een normaal-verdeelde populatie *exact* de verdeling van het steekproefgemiddelde bepalen:

$$X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2) \text{ i.i.d.} \Rightarrow \bar{X}_n \sim \mathcal{N}(\mu, \sigma^2/n).$$

Voor andere verdelingen bekommen we een *benadering* van de verdeling van $\bar{X}_n$ via de **centrale limietstelling**¹ (indien de steekproefgrootte n voldoende groot is), die we in volgende sectie kort herhalen.

¹Zie Discrete Wiskunde.

3.1.2 Centrale limietstelling

Stelling (Centrale Limiet Stelling). Zij $X_1, X_2, \dots$ een rij onafhankelijke toevalsveranderlijken met allen dezelfde verdeling (i.i.d.), waarvoor $E(X_i) = \mu$ en $\text{Var}(X_i) = \sigma^2 > 0$ en eindig, dan geldt:

$$\lim_{n \rightarrow \infty} P\left(\frac{\bar{X}_n - \mu}{\sigma} \leq z\right) = \Phi(z)$$

waarbij $\Phi(z)$ de verdelingsfunctie van de standaard normale verdeling is.

Dit noteren we ook als volgt

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{D} Z \quad \text{of} \quad \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{D} N(0, 1)$$

met $Z \sim N(0, 1)$ en waarbij de afkorting D staat voor convergentie in verdeling (*Distribution*).

Vaak is men in de praktijk immers meer geïnteresseerd in de volgende interpretatie van deze belangrijke stelling: indien n voldoende groot is, dan kan de verdeling van het gemiddelde van identiek verdeelde variabelen $X_1, X_2, \dots, X_n$ (elk met eindige verwachtingswaarde μ en variantie σ^2) benaderd worden door de normale verdeling, ongeacht welke verdeling de variabelen $X_1, X_2, \dots, X_n$ ook volgen (deze verdeling hoeft zelfs niet continu te zijn). Met andere woorden:

$$\bar{X}_n \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Dit drukt uit dat het gemiddelde van n i.i.d. uitkomsten bij benadering normaal verdeeld is rond de verwachtingswaarde μ (i.e., de limietwaarde volgens de wetten van de grote aantallen). De variantie neemt af naarmate het aantal uitkomsten n toeneemt, dus de precisie van de benadering $\bar{X}_n$ voor de parameter μ stijgt als n groter wordt.

Analoog geldt ook dat de verdeling van een som van identiek verdeelde variabelen $X_1, X_2, \dots, X_n$ (elk met eindige verwachtingswaarde μ en variantie σ^2) benaderd kan worden door de normale verdeling, ongeacht welke verdeling de variabelen $X_1, X_2, \dots, X_n$ ook volgen:

$$S_n = X_1 + X_2 + \dots + X_n \approx \mathcal{N}(n\mu, n\sigma^2)$$

Of, als we kijken naar de gestandaardiseerde som, krijgen we

$$\frac{S_n - n\mu}{\sqrt{n}\sigma} \approx \mathcal{N}(0, 1).$$

De centrale limietstelling is opmerkelijk, omdat de vorm van de oorspronkelijke verdeling willekeurig is. Onafhankelijk van de verdeling van de s.v.

$X_1, X_2, \dots, X_n$ (voor zover σ^2 bestaat), zal de verdeling van de som (voor n groot genoeg) steeds normaalverdeeld worden. Het is echter onmogelijk om uit te drukken hoe goed de benadering is voor een bepaalde waarde van n (of een bepaalde waarde voor n te geven die altijd voldoende groot is). Het is bijvoorbeeld zo dat indien de oorspronkelijke verdeling van de variabelen $X_1, X_2, \dots, X_n$ een scheve verdeling is, dat we dan minder snel de vorm van een normale verdeling zullen krijgen voor de verdeling van de som (en dus een grotere n nodig hebben).

3.2 Punt-schatters

Bij beschrijvende statistiek worden de uitslagen van een experiment waargenomen, maar is het onderliggende kansmodel geheel of gedeeltelijk onbekend en worden de waarnemingen gebruikt om dit model af te leiden. Gegeven is dus een steekproef van onafhankelijke en identiek verdeelde stochastische veranderlijken $X_1, \dots, X_n$ waarbij de verdeling van X_i afhangt van bepaalde parameter(s), zoals het gemiddelde μ of de proportie p . In het algemeen noteren we deze parameter met θ en de verdeling zelf noteren we met F_θ . Vaak zal men een idee hebben van de verdeling F_θ op basis van het experiment en wil men de bijbehorende parameter(s) θ bepalen. Men wenst deze dus te *schatten* op basis van de steekproef. Laat ons dan nu het begrip (punt)schatter definiëren en enkele eigenschappen bespreken.

3.2.1 Schatter en schatting

Om het populatiegemiddelde te benaderen hebben we in vorige sectie gebruik gemaakt van het steekproefgemiddelde. Dit steekproefgemiddelde is een functie van de steekproef en kunnen we beschouwen als een stochastische veranderlijke. In het algemeen spreken we over **statistieken**, gedefinieerd als volgt:

Definitie. Een **statistiek** T is een toevalsveranderlijke die enkel afhangt van de steekproef $(X_1, \dots, X_n)$ en niet van de onbekende parameter θ .

Net omdat T een toevalsveranderlijke is, kunnen we dus ook spreken over de verdeling van T en die gebruiken om meer informatie over de onbekende populatieparameter θ te bekomen.

Voorbeeld. Een reële statistiek is bijvoorbeeld

$$T(X_1, \dots, X_n) = (X_1^5 + \dots + X_n^5)/n^2$$

In een concreet experiment neemt T dus een getalwaarde aan.

Definitie. Een **schatter** van θ is een statistiek $T = T(X_1, \dots, X_n)$ die men gebruikt om de onbekende parameter θ te benaderen. Een **schatting** is de getalwaarde $T(x_1, \dots, x_n)$ van T in een concreet geval.

Voorbeeld. Veronderstel dat we van een s.v. X reeds weten dat die normaal verdeeld is, maar dat we de echte waarde van μ niet kennen. We weten reeds dat μ gelijk is aan de verwachtingswaarde (of het populatiegemiddelde) $E[X]$. Het steekproefgemiddelde $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ is een schatter van μ . Voor de concrete realisatie (170, 178, 185, 168, 182) krijgt men dan de schatting

$$\bar{x}_n = \frac{170 + 178 + 185 + 168 + 182}{5} = 176.6$$

Het is belangrijk om goed het onderscheid te maken tussen het steekproefgemiddelde $\bar{X}_n$ en het (populatie)gemiddelde van de verdeling $N(\mu, \sigma^2)$.

Een andere mogelijkheid zou zijn om de steekproefmediaan te nemen als schatting. De steekproefmediaan benadert voor grote steekproeven de populatiemediaan, en omdat de normale verdeling symmetrisch is, vallen gemiddelde en mediaan samen.

Er zijn dus vaak meerdere schatters mogelijk voor een bepaalde parameter, maar welke is dan de beste? Stel dat men uit ervaring weet dat het populatiegemiddelde gelijk is aan 45. Afhankelijk van de genomen steekproef zal, door het toeval dat verbonden is aan een stochastische veranderlijke, in het ene geval het steekproefgemiddelde en in het andere geval de steekproefmediaan dichter bij de werkelijke waarde 45 liggen. Wanneer we ons de vraag stellen welke schatting de beste benadering zal opleveren, willen we dit echter niet doen voor één bepaalde steekproef, maar zoeken we de schatting die globaal gezien, dus over alle steekproeven heen, het beste antwoord zal geven. Door zowel steekproefgemiddelde als mediaan als statistieken te beschouwen en deze als *schatters* van μ te bekijken, zullen we op deze vraag een antwoord kunnen formuleren.

3.2.2 Eigenschappen schatters

Aangezien een onbekende parameter θ op verschillende manieren geschat kan worden (denk maar aan steekproefgemiddelde en steekproefmediaan voor het populatiegemiddelde μ), hebben we (performantie)criteria nodig om die mogelijke schatters met elkaar te vergelijken. Men wil natuurlijk dat de schatter gemiddeld gezien de onbekende parameter θ oplevert. Anders gezegd, een goede schatter zal θ niet systematisch over- of onderschatten.

Definitie. Een schatter T van θ heet **zuiver** of **onvertekend** (*unbiased*)

$$\Leftrightarrow E[T] = \theta \quad (\forall \theta)$$

Men zegt ook dat de **bias** of vertekening van de schatter gelijk is aan 0:

$$b(T) = E(T) - \theta = 0$$

Voorbeeld. Indien $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, dan is

$$E[\bar{X}_n] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \mu.$$

Bijgevolg is $\bar{X}_n$ een zuivere schatter van μ .

Vermits de spreiding van een schatter een idee geeft over de nauwkeurigheid, is dit ook een belangrijke eigenschap en verkiezen we (zuivere) schatters met een zo klein mogelijke variantie.

Voorbeeld. Indien $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, dan is

$$\text{Var}[\bar{X}_n] = \frac{1}{n^2} \sum_{i=1}^n \text{Var}[X_i] = \frac{\sigma^2}{n}.$$

In het algemeen willen we de schatter vinden die θ zo dicht mogelijk benadert en hiervoor wordt vaak het gemiddelde verlies of de **mean squared error** beschouwd:

$$\boxed{\text{MSE}(T) = E[(T - \theta)^2]} \leq \infty$$

Hoe kleiner de MSE, hoe beter de nauwkeurigheid van T !

Voor een bepaalde parameter, kunnen we dus verschillende schatters definiëren en binnen deze verzameling van schatters voor die bepaalde parameter, gaan we dan op zoek naar de schatter met minimale MSE.

We hebben het volgende verband tussen bias, variantie en mean squared error.

Eigenschap. Voor iedere kwadratisch integreerbare schatter T geldt:

$$\text{MSE}(T) = (b(T))^2 + \text{Var}(T) \quad \forall \theta \in \Theta.$$

Voor een zuivere en kwadratisch integreerbare schatter geldt dus:

$$\text{MSE}(T) = \text{Var}[T] \quad (\forall \theta).$$

Naast de onvertekendheid van een schatter, willen we de variantie van de schatter zo klein mogelijk houden opdat de parameter θ zo nauwkeurig mogelijk geschat kan worden. Of met andere woorden, we zoeken de *onvertekende schatter met minimale MSE*.

Opmerking. Als T een zuivere schatter is van θ , dan volgt daaruit *niet* dat $g(T)$ een zuivere schatter is van $g(\theta)$.

3.2.3 Schatten van de parameters van een normale populatie

In dit deel gaan we op zoek naar schatters voor μ en σ^2 van een normale populatie en gaan we na of deze onvertekend zijn. Neem $(X_1, \dots, X_n)$ een steekproef uit een $\mathcal{N}(\mu, \sigma^2)$ -verdeelde populatie. Zoals we al gezien hebben, is het steekproefgemiddelde $\bar{X}_n$ een schatter voor μ . Ook de steekproefmediaan kan gebruikt worden om μ te schatten. Men verkiest echter toch om $\bar{X}_n$ te gebruiken om de volgende redenen:

- Het steekproefgemiddelde is onvertekend:

$$E[\bar{X}_n] = E[X_1] = \mu.$$

- Er geldt dat

$$\text{MSE}(\bar{X}_n) = \text{Var}[\bar{X}_n] = \frac{\sigma^2}{n}$$

omdat $\bar{X}_n$ onvertekend is. Men kan aantonen dat, onder de veronderstellingen van onafhankelijkheid en normaliteit, dit de **onvertekende schatter is met de kleinste variantie**.

We hadden we ook reeds de verdeling van $\bar{X}_n$ bepaald:

$$\bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Merk op dat $\bar{X}_n$ slechts optimaal is onder bepaalde voorwaarden; als er bijvoorbeeld uitschieters voorkomen in de data, dan zal de steekproefmediaan een beter resultaat geven.

Om de variantie σ^2 te schatten, beschikken we over de schatter

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$

De hoofdletter geeft aan dat we de steekproefvariantie hier als een s.v. beschouwen. Vermits $E[S^2] = \sigma^2$ (ga na), is S^2 een onvertekende schatter voor σ^2 . De noemer ' $n-1$ ' dient er dus voor om te zorgen dat de schatter S^2 onvertekend is indien we ons baseren op een steekproef $X_1, \dots, X_n$ bestaande uit onafhankelijke s.v. De achterliggende reden is dat we reeds 1 vrijheidsgraad verloren hebben bij het schatten van $\bar{X}_n$ voor μ . Indien μ exact gekend was, dan konden we de schatter

$$T = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$$

gebruiken. Deze schatter T is zuiver omdat

$$E[T] = \frac{1}{n} \sum_{i=1}^n E[(X_i - \mu)^2] = \sigma^2.$$

Meestal kunnen we dit echter niet zo doen, omdat we voor de bepaling van T enkel van de steekproef gebruik mogen maken en we dus μ niet kennen.

Onder de veronderstellingen van normaliteit en onafhankelijkheid is de steekproefverdeling van S^2 exact gekend:

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Dit volgt uit de stelling van Helmer (1876).

Stelling (Stelling van Helmer). Als $X_1, \dots, X_n$ i.i.d. $\sim \mathcal{N}(\mu, \sigma^2)$ met $n \geq 2$ dan geldt :

$$(1) \quad \bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

$$(2) \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

$$(3) \quad \bar{X} \text{ en } S^2 \text{ zijn onafhankelijk.}$$

Zonder bewijs.

Bovendien leert deze stelling ons dus ook dat $\bar{X}_n$ en S^2 onafhankelijk zijn.

3.2.4 Schatten van proporties of kansen

Veronderstel dat we een rij $X_1, \dots, X_n$ van onafhankelijke Bernoulli toevalsvariabelen hebben die een waarde 1 aannemen met kans p en een waarde 0 met kans $q = 1 - p$. In het geval van zo een steekproef van Bernoulli variabelen wordt $\bar{X}_n$ ook wel de **relatieve frequentie** van het aantal successen of de **proportie** successen genoemd. We noteren de proportie met $\hat{P}$ en deze is dus gelijk aan

$$\hat{P} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i,$$

waarbij de hoofdletter opnieuw aanduidt dat het om een s.v. gaat. Een kleine letter $\hat{p}$ zal dan staan voor de steekproefproportie horende bij een specifieke

steekproef. De parameter p uit de verdeling duidt de populatieproportie aan.

Het is eenvoudig na te gaan dat

$$\begin{aligned} \mathrm{E}[\hat{P}] &= p \\ \mathrm{Var}[\hat{P}] &= \frac{p(1-p)}{n} \end{aligned}$$

wat dus maakt dat $\hat{P}$ een onvertekende schatter voor p is. Uit de centrale limietstelling volgt bovendien dat, voor $n \rightarrow \infty$,

$$\mathrm{P} \left(\frac{\hat{P} - p}{\sqrt{\frac{p(1-p)}{n}}} \leq x \right) \rightarrow \Phi(x).$$

We zien dus dat de variantie omgekeerd evenredig is met de steekproefgrootte n . Dus hoe meer observaties we beschouwen, hoe nauwkeuriger we p kunnen schatten. Bijgevolg zal de steekproefproportie $\hat{p}$ zich stabiliseren rond de populatieproportie p voor stijgende waarden van n .

BETROUWBAARHEIDSINTERVALLEN INTERVALSCHATTINGEN

OF

Tot nu hebben we schatters voor een onbekende parameter θ beschouwd, die voor een specifieke steekproef een welbepaald getal (verschillend van steekproef tot steekproef) opleverden als schatting. Vandaar dat men deze schatters ook wel **puntschatters** noemt. We kunnen de schatting gebruiken als benadering voor θ , maar we moeten ons ook vraag stellen hoe goed deze schatting is. Daarom willen we een idee krijgen over de *fout* die we kunnen maken. Omdat de afwijking van de schatter ten opzichte van de parameter toevallig is, moeten we de verdeling van “*schatter* – θ ” beschouwen om een genuanceerde (kans)uitspraak te kunnen maken over deze fout. Hiervoor zullen we **betrouwbaarheidsintervallen** voor parameters definiëren.

Definitie. Het interval $[L(X_1, \dots, X_n), R(X_1, \dots, X_n)]$ is een $(1 - \alpha)$ **betrouwbaarheidsinterval (BI)** indien

$$P(\theta \in [L(X_1, \dots, X_n), R(X_1, \dots, X_n)]) = 1 - \alpha.$$

Het getal $1 - \alpha$ wordt het **betrouwbaarheidsniveau** (altijd tussen 0 en 1) genoemd (typische keuzes zijn bijvoorbeeld 0.9, 0.95 of 0.99). α noemen we het **significantieniveau**.

Merk op dat een betrouwbaarheidsinterval niet uniek bepaald is: er zijn immers 2 grenzen en slechts 1 voorwaarde. Meestal beperkt men zich echter tot **tweezijdige** of **eenzijdige** BI's.

Definitie. Een tweezijdig $(1 - \alpha)$ BI is een $(1 - \alpha)$ BI waarbij

$$P(\theta < L(X_1, \dots, X_n)) = P(\theta > R(X_1, \dots, X_n)) = \alpha/2.$$

Een linkseenzijdig $(1 - \alpha)$ BI is een $(1 - \alpha)$ BI van de vorm

$$[-\infty, R(X_1, \dots, X_n)].$$

Een rechtseenzijdig $(1 - \alpha)$ BI is een $(1 - \alpha)$ BI van de vorm

$$[L(X_1, \dots, X_n), \infty].$$

Een algemene strategie om een betrouwbaarheidsinterval te construeren is als volgt

- (1) Vind een goede schatter T voor θ .
- (2) Vind de verdeling van een functie van T en θ , waarbij die verdeling onafhankelijk is van θ : $h(T, \theta) \sim \dots$
- (3) Zoek de gepaste kwartielen van die verdeling, dwz. zoek a en b zodat

$$P(a \leq h(T, \theta) \leq b) = 1 - \alpha.$$

- (4) Zorg ervoor dat T enkel in het linker- en rechterlid van de ongelijkheid voorkomt en dat θ enkel in het middelste deel van de ongelijkheid voorkomt.

We zullen nu concreet betrouwbaarheidsintervallen opstellen en bestuderen voor enkele typische parameters.

4.1 Gemiddelde van normale verdeling met bekende variantie

We trekken een steekproef van omvang n uit een normale verdeling $\mathcal{N}(\mu, \sigma^2)$ waarbij σ bekend is, maar μ onbekend. We hebben dus n onafhankelijke stochastische veranderlijken $X_1, X_2, \dots, X_n$, die allemaal $\mathcal{N}(\mu, \sigma^2)$ verdeeld zijn. Het onderliggende statistisch model is bijgevolg $(\mathbb{R}^n, \mathcal{B}(\mathbb{R})^{\otimes n}, \{\mathcal{N}(\mu, \sigma^2)^{\otimes n}; \mu \in \mathbb{R}\})$. We hebben gezien dat het steekproefgemiddelde $\bar{X}_n$ een zuivere schatter is van μ in dit model, en dat

$$\bar{X}_n \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Hieruit volgt dat de verdeling van $\bar{X}_n$ symmetrisch is rond μ , en dat voor groter wordende steekproeven ($n \uparrow \infty$) $\bar{X}_n$ zich meer en meer concentreert: hoe meer waarnemingen hoe beter, want dan wordt de schatting nauwkeuriger!

Herinner dat we een s.v. met een hoofdletter (bijvoorbeeld X) opschrijven en dat we zijn getalwaarde in een concreet experiment met een kleine letter (bijvoorbeeld $x = 18.59$ kg) noteren. Een **schatter** zoals $\bar{X}_n$ is dus een functievoorschrift en $\bar{x}_n = 24.17$ km is een **schatting**.


We willen nu nagaan hoe nauwkeurig schattingen van μ op basis van $\bar{X}_n$ zijn. Beschouw daarvoor de gestandaardiseerde veranderlijke

$$Z := \frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$$

die overeenkomt met de gestandaardiseerde fout van $\bar{X}_n$ ten opzichte van μ . Merk op dat Z een functie is van $T = \bar{X}_n$ en $\theta = \mu$ en dat de verdeling¹ van $Z = h(T, \theta)$ niet afhangt van θ .

Aan de hand van de tabel van $\mathcal{N}(0, 1)$ vinden we

$$P(-1.96 \leq Z \leq 1.96) = 95\%.$$



$$\Rightarrow P(|Z| \leq 1.96) = 95\%$$

Bijgevolg:
$$\Rightarrow P\left(|\bar{X}_n - \mu| \leq 1.96 \frac{\sigma}{\sqrt{n}}\right) = 95\%$$

$$P\left(\bar{X}_n - 1.96 \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X}_n + 1.96 \frac{\sigma}{\sqrt{n}}\right) = 95\%.$$

We hebben dus een **betrouwbaarheidsinterval** (BI) gevonden voor μ (indien data normaal verdeeld en σ gekend is):

$$\left[\bar{x}_n - 1.96 \frac{\sigma}{\sqrt{n}}, \bar{x}_n + 1.96 \frac{\sigma}{\sqrt{n}}\right].$$

In een concrete situatie (we hebben een specifieke steekproef $(x_1, \dots, x_n)$) kan men dit BI werkelijk berekenen omdat het enkel afhangt van $\bar{x}$, n , en σ . Dit illustreren we in het volgende voorbeeld:

Voorbeeld. Men wil de hoogte van een berg schatten met behulp van een meetapparaat waarvan de standaarddeviatie op de metingen $\sigma = 2\text{m}$ bedraagt. Men voert 16 metingen uit, en vindt $\bar{x} = 3118.5\text{m}$. Indien we veronderstellen dat de data uit een normale verdeling komen, is het 95% BI gelijk aan

$$\left[3118.5\text{m} - 1.96 \frac{2\text{m}}{\sqrt{16}}, 3118.5\text{m} + 1.96 \frac{2\text{m}}{\sqrt{16}}\right] = [3117.52\text{m}, 3119.48\text{m}].$$

Het BI is symmetrisch rond de gegeven waarde $\bar{x}_n$, en daarom noteert men ook vaak


$$\left[\bar{x}_n \pm 1.96 \frac{\sigma}{\sqrt{n}}\right] = [3118.5\text{m} \pm 0.98\text{m}].$$

De juiste interpretatie van dit 95% betrouwbaarheidsinterval is zeer belangrijk. Hiervoor stellen we ons voor dat we het experiment een oneindig aantal keer herhalen (we beschikken dus over een oneindig aantal onafhankelijke steekproeven met dezelfde steekproefgrootte n uit dezelfde populatie). Elke steekproef zou dan een ander interval $[l^{(1)}, r^{(1)}], [l^{(2)}, r^{(2)}], \dots$ opleveren (het gevonden interval

¹Zo een verdeling moeten we vinden in stap 2 van de algemene strategie om BI op te stellen.

is immers afhankelijk van de steekproef). Als dit een 95% betrouwbaarheidsinterval is, dan zullen deze intervallen **in 95% van de gevallen** de werkelijke μ bevatten. In de praktijk beschikken we natuurlijk slechts over 1 van deze oneindige steekproeven en de waarde van μ ligt hetzij binnen, hetzij buiten het geschatte betrouwbaarheidsinterval. Men kan voor een specifieke steekproef dus niet stellen dat μ met 95% kans binnen het interval valt! Men zegt soms dat μ met 95% *betrouwbaarheid* binnen het interval valt.

Men kiest natuurlijk niet altijd een betrouwbaarheidsdrempel van 95%. Men kan eender welke andere oppervlakte $1 - \alpha$ kiezen (meestal kiest men significantieniveau $\alpha = 5\%$, $\alpha = 1\%$, of $\alpha = 0.1\%$):



Men noteert de totale oppervlakte links en rechts als α en noemt $1 - \alpha$ het **betrouwbaarheidsniveau** vermits

$$P\left(|Z| \leq \Phi^{-1}\left(1 - \frac{\alpha}{2}\right)\right) = 1 - \alpha$$

dus

$$P\left(\bar{X}_n - \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X}_n + \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha.$$

Bijgevolg moeten we het $(1 - \frac{\alpha}{2})$ -kwantiel bepalen. We noteren dit kwantiel met $z_{1-\alpha/2}$ ²! Bijgevolg geldt dat

$$P\left(-z_{1-\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{1-\alpha/2}\right) = 1 - \alpha$$

en dit leidt tot volgende definitie:

²Merk op dat in veel handboeken de notatie $z_{\alpha/2}$ wordt gebruikt ipv $z_{1-\alpha/2}$ en dit kan soms verwarrend zijn. De notatie die wij gebruiken is analoog aan de definitie van het (beneden)kwantiel, i.e. z_α zodat $P(Z \leq z_\alpha) = \alpha$ voor standaard normaal verdeelde s.v. Z

Het $(1 - \alpha)$ BI voor μ is

$$\left[\bar{x} - z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}} \right].$$

Merk op dat we in het BI gebruik maken van $\bar{x}$ en niet van $\bar{X}_n$ omdat het BI concreet berekend is voor de steekproef. Dit BI is duidelijk symmetrisch rond de berekende $\bar{x}$. Merk tevens op dat we voor het bepalen van het $(1 - \alpha)$ BI gebruik maken van het $z_{1-\alpha/2}$ of het $100 \left(1 - \frac{\alpha}{2}\right)$ %-kwantiel.

Voor grotere steekproeven ($n \uparrow$) wordt het BI *smaller* (want $\frac{1}{\sqrt{n}} \downarrow$) omdat de schatter $\bar{X}_n$ dan nauwkeuriger wordt. Omgekeerd, indien men een grotere betrouwbaarheid wenst (bijvoorbeeld 99% in plaats van 95%) dan wordt het BI *breder* (want uit $\alpha \downarrow$ volgt $z_{1-\alpha/2} \uparrow$).

Opmerking. In de meeste toepassingen is σ echter *niet* vooraf bekend. Hier komen we later op terug.

4.2 Variantie van normale verdeling

We beschouwen opnieuw onafhankelijke waarnemingen

$$X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2),$$

maar nu zijn zowel μ als σ onbekend. Het onderliggende statistisch model is nu

$$(\mathbb{R}^n, \mathcal{B}(\mathbb{R})^{\otimes n}, \{\mathcal{N}(\mu, \sigma^2)^{\otimes n}; \mu \in \mathbb{R}, \sigma \in]0, +\infty[\}) .$$

We willen $g(\sigma) = \sigma^2$ schatten en hiervoor hebben we enkel de steekproef $X_1, \dots, X_n$ ter beschikking.

We kunnen σ^2 schatten met de steekproefvariantie S^2 , gedefinieerd als

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2.$$


Deze is een zuivere schatter van σ^2 , d.w.z. $E[S^2] = \sigma^2$.

Voor de verdeling van S^2 weten we uit de stelling van Helmer dat:

Stelling. Als $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ onafhankelijk zijn, dan

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2.$$

Met behulp van deze stelling kunnen we een BI voor σ^2 construeren, met betrouwbaarheid $1 - \alpha$. Hiervoor gebruiken we de kwantielen $\chi_{n-1, \frac{\alpha}{2}}^2$ en $\chi_{n-1, 1-\frac{\alpha}{2}}^2$.



$$P \left(\chi_{n-1, \frac{\alpha}{2}}^2 \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{n-1, 1-\frac{\alpha}{2}}^2 \right) = 1 - \alpha.$$

In deze uitdrukking is σ^2 onbekend, terwijl $(n-1)S^2$ en de kwantielen berekend kunnen worden. We willen de ongelijkheden dus uitdrukken in functie van σ^2 :

$$\begin{aligned} \Rightarrow P \left(\frac{\chi_{n-1, \frac{\alpha}{2}}^2}{(n-1)S^2} \leq \frac{1}{\sigma^2} \leq \frac{\chi_{n-1, 1-\frac{\alpha}{2}}^2}{(n-1)S^2} \right) &= 1 - \alpha \\ \Rightarrow P \left(\frac{(n-1)S^2}{\chi_{n-1, \frac{\alpha}{2}}^2} \geq \sigma^2 \geq \frac{(n-1)S^2}{\chi_{n-1, 1-\frac{\alpha}{2}}^2} \right) &= 1 - \alpha \\ \Rightarrow P \left(\frac{(n-1)S^2}{\chi_{n-1, 1-\frac{\alpha}{2}}^2} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi_{n-1, \frac{\alpha}{2}}^2} \right) &= 1 - \alpha. \end{aligned}$$

Het betrouwbaarheidsinterval voor σ^2 met betrouwbaarheid $1 - \alpha$ is

$$\left[\frac{(n-1)s^2}{\chi_{n-1, 1-\frac{\alpha}{2}}^2}, \frac{(n-1)s^2}{\chi_{n-1, \frac{\alpha}{2}}^2} \right].$$

Merk op dat dit BI *niet* symmetrisch is rond s^2 ! Ook hier wordt opnieuw s^2 genoteerd in plaats van S^2 zodat interval concreet kan berekend worden (voor een specifieke steekproef).

Om een BI te verkrijgen voor de standaardafwijking σ in de plaats van de variantie σ^2 , nemen we gewoon de vierkantswortel

$$\Rightarrow P \left(\sqrt{\frac{(n-1)S^2}{\chi_{n-1, 1-\frac{\alpha}{2}}^2}} \leq \sigma \leq \sqrt{\frac{(n-1)S^2}{\chi_{n-1, \frac{\alpha}{2}}^2}} \right) = 1 - \alpha$$

dus het overeenkomstige BI wordt

$$\left[\sqrt{\frac{(n-1)s^2}{\chi_{n-1, 1-\frac{\alpha}{2}}^2}}, \sqrt{\frac{(n-1)s^2}{\chi_{n-1, \frac{\alpha}{2}}^2}} \right].$$

Voorbeeld. De steekproefvariantie van de lengte van 16 willekeurig gekozen soldaten van de lichte 1989 is 5.76cm^2 . Merk op dat de lengte van volwassen mannen (en vrouwen) van een bepaalde leeftijd bij benadering normaal verdeeld is. Men wil een 95% BI voor de standaardafwijking σ . We weten dan

$$n-1 = 15 \text{ vrijheidsgraden}, \quad \alpha = 5\%, \quad s^2 = 5.76\text{cm}^2$$

en uit de tabel halen we

$$\chi_{15, 0.025}^2 = 6.262, \quad \chi_{15, 0.975}^2 = 27.488$$

dus het BI wordt

$$\left[\sqrt{\frac{15 \times 5.76}{27.488} \text{ cm}^2}, \sqrt{\frac{15 \times 5.76}{6.262} \text{ cm}^2} \right] = [1.77\text{cm}, 3.72\text{cm}].$$

Voor een betrouwbaarheid van 99% heeft men $\alpha = 1\%$ en

$$\chi_{15, 0.005}^2 = 4.601 \quad \chi_{15, 0.995}^2 = 32.801$$

dus het BI in dit geval is

$$\left[\sqrt{\frac{15 \times 5.76}{32.801} \text{ cm}^2}, \sqrt{\frac{15 \times 5.76}{4.601} \text{ cm}^2} \right] = [1.62\text{cm}, 4.34\text{cm}].$$

We zien dus dat het 99% BI breder is dan het 95% BI (zoals we verwachten). Indien men een smaller 95% BI wil, dan moet men n vergroten, dus meer metingen uitvoeren (hetgeen meestal duur en/of tijdsintensief is).

4.3 Gemiddelde van normale verdeling (onbekende variantie)

We hebben opnieuw een steekproef

$$X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$$

en we willen een BI voor μ . Vermits σ in dit geval ook onbekend is (realistisch geval), kunnen we de eerder bekomen formule niet gebruiken. We moeten eerst σ^2 schatten met behulp van S^2 en daarna rekening houden met de verdeling van S^2 . We zijn dus geïnteresseerd in volgende gestandaardiseerde veranderlijke:

Stelling.

$$T = \frac{\bar{X}_n - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

De nieuwe statistiek is dus Student verdeeld met $n - 1$ vrijheidsgraden.

Bewijs. Combineer de s.v. Z en Y :

$$Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1) \quad \text{uit sectie 4.1}$$

$$Y = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2 \quad \text{uit sectie 4.2}$$

Uit de definitie van de Studentverdeling volgt dan dat


$$T := \frac{Z}{\sqrt{Y/(n-1)}} \sim t_{n-1}$$

met

$$T = \frac{\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}}{\sqrt{\frac{(n-1)S^2}{\sigma^2(n-1)}}} = \frac{\bar{X}_n - \mu}{S/\sqrt{n}}$$

Merk op dat deze uitdrukking de onbekende σ niet meer bevat! □

Beschouw de kwantielen $t_{n-1, 1-\frac{\alpha}{2}}$ en $t_{n-1, \frac{\alpha}{2}} = -t_{n-1, 1-\frac{\alpha}{2}}$ (wegens symmetrie van de t -verdeling):



Hieruit volgt dan dat

$$\begin{aligned} & \text{P} \left(\left| \frac{\bar{X}_n - \mu}{S/\sqrt{n}} \right| \leq t_{n-1, 1-\frac{\alpha}{2}} \right) = 1 - \alpha \\ \Rightarrow & \text{P} \left(|\bar{X}_n - \mu| \leq t_{n-1, 1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}} \right) = 1 - \alpha \\ \Rightarrow & \text{P} \left(\bar{X}_n - t_{n-1, 1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}} \leq \mu \leq \bar{X}_n + t_{n-1, 1-\frac{\alpha}{2}} \frac{S}{\sqrt{n}} \right) = 1 - \alpha. \end{aligned}$$

Het BI voor μ met betrouwbaarheid $1 - \alpha$ is

$$\left[\bar{x} - t_{n-1, 1-\frac{\alpha}{2}} \frac{s}{\sqrt{n}}, \bar{x} + t_{n-1, 1-\frac{\alpha}{2}} \frac{s}{\sqrt{n}} \right].$$

Dit is een **exact** resultaat, want er werd geen enkele benadering gebruikt in de berekening. Historisch gezien heeft William Gosset (onder het pseudoniem Student) juist voor deze reden (en hieraan verwante redenen) de t -verdeling ingevoerd.

Opmerking. Indien $n \rightarrow \infty$ dan $s \rightarrow \sigma$ en $t_{n-1, 1-\frac{\alpha}{2}} \rightarrow z_{1-\alpha/2}$, en in dat geval vinden we dus de formule uit sectie 4.1 terug.

Voorbeeld. Stel dat het gewicht van een gevuld paasei normaal verdeeld is. Men heeft de volgende 12 metingen van het gewicht van een gevuld paasei (in gram):

170	183	185	175	177	173
172	181	183	177	176	180

en men wil een 95% BI voor μ en voor σ opstellen.

$$\begin{aligned} \bar{x} &= \frac{2132}{12} = 177.66\text{g} \\ s^2 &= \frac{58.777 + \dots + 5.444}{11} = \frac{250.661}{11} = 22.787\text{g}^2 \\ \Rightarrow s &= 4.774\text{g} \end{aligned}$$

95% BI voor μ :

$$n - 1 = 11 \quad \alpha = 0.05 \quad t_{11, 0.975} = 2.201$$

$$\left[177.66 - 2.201 \frac{4.774}{\sqrt{12}}, 177.66 + 2.201 \frac{4.774}{\sqrt{12}} \right] = [174.6\text{g}, 180.7\text{g}]$$

95% BI voor σ :

$$\chi_{11, 0.025}^2 = 3.816 \quad \chi_{11, 0.975}^2 = 21.92$$

$$\left[\sqrt{\frac{11 \times 22.787}{21.92}}, \sqrt{\frac{11 \times 22.787}{3.816}} \right] = [3.38\text{g}, 8.09\text{g}]$$

Beide intervallen zijn tamelijk breed omdat n klein is!

4.4 Proportie

In een populatie beschouwt men een binair kenmerk, zoals man/vrouw, succes/faling, niet-roker/roker, Indien men een willekeurige persoon uit de populatie “trekt” heeft men dus volgende s.v.

$$X = \begin{cases} 1 & \text{met kans } p \text{ (“succes”)} \\ 0 & \text{met kans } q = 1 - p \text{ (“mislukking”)} \end{cases}$$

Het model voor 1 waarneming is bijgevolg $(\{0, 1\}, 2^{\{0,1\}}, \{\mathcal{B}(1, p); 0 < p < 1\})$. Men wil de parameter p (= het percentage “successen” in de hele populatie) schatten aan de hand van een steekproef

$$X_1, X_2, \dots, X_n$$

met het model $(\{0, 1\}^n, 2^{\{0,1\}^{\otimes n}}, \{\mathcal{B}(1, p)^{\otimes n}; 0 < p < 1\})$. Hiervoor gebruikt men dan het percentage successen in de steekproef of de steekproefproportie:

$$\hat{P} = \frac{\text{Aantal waargenomen successen}}{n} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}_n.$$

Deze statistiek is een zuivere schatter van p want

$$\mathbb{E}[\hat{P}] = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] = \frac{np}{n} = p.$$

Voor de verdeling weten we dat

$$n\hat{P} = \sum_{i=1}^n X_i \sim \mathcal{B}(n, p).$$

Veronderstel nu dat $n \geq 30$ en $np \geq 5$ en $nq \geq 5$, dan geldt

$$\begin{aligned} \mathcal{B}(n, p) &\approx \mathcal{N}(np, npq) \\ \Rightarrow n\hat{P} &\approx \mathcal{N}(np, npq) \\ \Rightarrow \hat{P} &\approx \mathcal{N}\left(p, \frac{pq}{n}\right) \end{aligned}$$

Omdat n groot is, mag men aannemen dat de onbekende standaardafwijking $\sqrt{\frac{p(1-p)}{n}}$ goed benaderd wordt door $\sqrt{\frac{\hat{P}(1-\hat{P})}{n}}$. Door standaardisatie vinden we

$$Z := \frac{\hat{P} - p}{\sqrt{\frac{\hat{P}(1-\hat{P})}{n}}} \approx \mathcal{N}(0, 1)$$

en dus

$$\begin{aligned}
 &\Rightarrow P(|Z| \leq z_{1-\alpha/2}) \approx 1 - \alpha \\
 &\Rightarrow P\left(|\hat{P} - p| \leq z_{1-\alpha/2} \sqrt{\frac{\hat{P}(1 - \hat{P})}{n}}\right) \approx 1 - \alpha \\
 &\Rightarrow P\left(\hat{P} - z_{1-\alpha/2} \sqrt{\frac{\hat{P}(1 - \hat{P})}{n}} \leq p \leq \hat{P} + z_{1-\alpha/2} \sqrt{\frac{\hat{P}(1 - \hat{P})}{n}}\right) \approx 1 - \alpha
 \end{aligned}$$

Het BI voor p met *benaderende* betrouwbaarheid $1 - \alpha$ is

$$\left[\hat{p} - z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}, \hat{p} + z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right].$$

Merk op dat *twee benaderingen* worden toegepast:

- benaderen van de exacte binomiaalverdeling door de normale verdeling
- vervanging van p door $\hat{P}$ in de standaardafwijking van de schatter.

Voor $n \uparrow$ wordt het interval smaller, en voor $\alpha \downarrow$ wordt het breder.

Voorbeeld. Enkele dagen vóór een verkiezing houdt men een enquête. Hiervoor beschouwt men een steekproef van 200 aselekt getrokken personen (en hoopt men dat de steekproef representatief is). In de steekproef waren 110 personen vóór kandidaat A.

Stel nu een 95% en een 99% BI op voor het globale percentage kiezers voor A.

$$\hat{p} = \frac{110}{200} = 55\% \quad \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} = \sqrt{\frac{(0.55)(0.45)}{200}} = 0.0352$$

$$\underline{\alpha = 5\%} \quad \text{betrouwbaarheid} = 95\% \quad z_{1-\alpha/2} = 1.96$$

$$\Rightarrow [0.55 - (1.96)(0.0352), 0.55 + (1.96)(0.0352)]$$

$$= [0.55 - 0.069, 0.55 + 0.069] = [48.1\%, 61.9\%]$$

$$\underline{\alpha = 1\%} \quad \text{betrouwbaarheid} = 99\% \quad z_{1-\alpha/2} = 2.576$$

$$\Rightarrow [0.55 - (2.576)(0.0352), 0.55 + (2.576)(0.0352)]$$

$$= [0.55 - 0.091, 0.55 + 0.091] = [45.9\%, 64.1\%]$$

Het is dus helemaal niet zeker dat A minstens 50% van de kiezers achter zich heeft. Merk ook op dat beide intervallen redelijk breed zijn.

Uit het voorgaande kunnen we dus concluderen dat men *grote steekproeven* nodig heeft om betrouwbare voorspellingen te kunnen doen. Helaas rapporteren media zelden de breedte van het BI, en zelfs niet altijd de steekproefgrootte n .

HYPOTHESETESTEN

In het vorige hoofdstuk hebben we gezien hoe we parameters van een kansverdeling kunnen schatten op basis van een steekproef en hoe we hun nauwkeurigheid kunnen aanduiden door middel van een betrouwbaarheidsinterval. Zowel binnen de wetenschap als in de industrie is de uiteindelijke probleemstelling vaak dat men dient te beslissen of een parameterwaarde al dan niet aan een bepaalde voorwaarde voldoet zoals bijvoorbeeld:

- Overschrijdt de CO_2 -uitstoot de Kyoto-norm?
- Gaat dit type batterij echt langer mee dan een ander merk?
- Is de standaarddeviatie van de diameter van een staaf dezelfde bij productiemethode 1 als bij productiemethode 2?
- Werkt een nieuw medicijn beter dan het traditionele product (en moet men hier dus in investeren)?

Indien we over een oneindig grote steekproef beschikken, kunnen we de parameter(s) exact schatten en vinden we onmiddellijk het antwoord op de vraag. Voor een eindige steekproef is dit echter niet evident: het is immers mogelijk dat de werkelijke onbekende waarde van de parameter voldoet maar dat de schatting niet voldoet omwille van een toevallige fout (afwijking) t.o.v. de exacte waarde. Een zekere uitspraak zullen we dus nooit kunnen doen. Het is immers mogelijk om met een eerlijke dobbelsteen 15 keer na elkaar 6 te gooien, maar op grond van de waarneming zullen we dan (meestal) besluiten dat deze bewering (de dobbelsteen is eerlijk) te onwaarschijnlijk is om waar te zijn.

De beweringen omtrent populaties die we willen nagaan, vatten we samen in zogenaamde hypothesen. De vraag wordt dan geformuleerd als een beslissingsprobleem, waarbij men dient te kiezen tussen twee hypothesen die elkaars tegengestelde zijn. Het nagaan van de geldigheid van de ene of de andere hypothese wordt het **testen van die hypothese** genoemd.

We bespreken eerst hoe het testen van hypothesen in het algemeen verloopt en daarna passen we deze algemene procedure toe in enkele typische situaties. We onderscheiden vier stappen:

- (1) Eerst worden de beweringen omtrent de populatieparameter samengevat in zogenaamde **hypothesen**. De vraag zelf wordt dus geformuleerd als een **beslissingsprobleem** waarbij men moet kiezen tussen twee hypothesen die elkaars tegengestelde zijn, namelijk de **nulhypothese** H_0 en de **alternatieve hypothese** H_1 (soms ook H_A genoteerd). Het nagaan

van de geldigheid van een hypothese wordt dan het **testen** van die hypothese genoemd. Hierbij zal men trachten de nulhypothese te verwerpen ten voordele van de alternatieve hypothese.

- (2) Definieer vervolgens een **teststatistiek** (of toetsingsgrootheid) T , dit is een s.v. die men op basis van de steekproef kan berekenen en waarvan men (bij benadering) de verdeling kent in de veronderstelling dat de nulhypothese waar is.
- (3) Daarna wordt het **beslissingscriterium** voor de toets gedefinieerd. Als de geobserveerde waarde van T ‘te extreem’ is ten opzichte van de verdeling onder H_0 zal men H_0 verwerpen ten voordele van de alternatieve hypothese. Hierbij zal men gebruik maken van een **significantieniveau** α (zoals bij betrouwbaarheidsintervallen) en H_0 verwerpen van zodra men onder H_0 minder dan $\alpha\%$ kans heeft op een uitkomst die minstens zo extreem (groot of klein) is als de geobserveerde T -waarde (dus de geobserveerde T -waarde zal dan niet in het *aanvaardingsgebied* liggen). Indien men de nulhypothese H_0 niet kan verwerpen, zegt men vaak dat *de nulhypothese H_0 aanvaard wordt*. Merk op dat dit *niet* betekent dat we hebben aangetoond dat de nulhypothese waar is! Een alternatieve en veel gebruikte methode om een beslissing te nemen is via de **p -waarde** van de test (hier komen we later op terug).
- (4) Merk op dat we twee mogelijke fouten kunnen maken:
 - De nulhypothese verwerpen terwijl de alternatieve hypothese fout is, heet een **type-I fout**.
 - De nulhypothese niet verwerpen terwijl de alternatieve hypothese waar is, heet een **type-II fout**.

		Populatie (werkelijkheid)	
		H_0 is waar	H_0 is fout
Steekproef (beslissing)	verwerp H_0	type-I fout kans α	OK kans $1 - \beta$
	verwerp H_0 niet	OK kans $1 - \alpha$	type-II fout kans β

Een goed opgezette studie moet uiteraard de kans op deze fouten beperken.

Bij een geldige hypothesetest met significantieniveau α wordt de kans op een type-I fout beperkt tot α . Men wil dus vooral vermijden dat H_0 onterecht verworpen wordt. Vandaar wordt H_0 ook wel eens de conservatieve hypothese genoemd: H_0 is de bewering die men standaard, zonder extra informatie, zou aannemen. H_1 is de hypothese die men enkel aanvaardt indien daar voldoende argumentatie voor is. De kans op een type-II fout wordt aangeduid met β en $1 - \beta$ wordt de **power** (of het onderscheidingsvermogen) van de test genoemd. Hoewel de power op zich geen rol speelt voor de geldigheid van een hypothesetest is een zo hoog mogelijke power natuurlijk wel gewenst. De *beste hypothesetest* is dan ook degene die binnen de klasse van geldige hypothesetesten met significantieniveau α voor een bepaald probleem de hoogste power heeft¹. We zullen deze begrippen nu verder uitwerken voor een aantal verschillende gevallen.

5.1 Gemiddelde van een normale verdeling met bekende variantie

Gegeven een steekproef

$$X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$$

waarbij μ onbekend is en σ bekend. Iemand beweert nu dat $\mu = \mu_0$ (deze μ_0 is een concreet getal, bijvoorbeeld 3.71kg). We moeten dan beslissen of we deze hypothese zullen verwerpen of niet, en kunnen enkel gebruik maken van de steekproef om de beslissing te nemen. We moeten hierbij, afhankelijk van de gebruikte alternatieve hypothese, een onderscheid maken tussen een **tweezijdige** en een **eenzijdige test**.

Merk op dat we niet zomaar mogen afgaan op het resultaat van de genomen steekproef om een beslissing te nemen. Stel dat we willen testen of $\mu = 1000$ en dat we hiervoor een steekproef hebben genomen die ons als resultaat $\bar{x} = 945$ geeft. Alhoewel deze waarde verschilt van 1000, kunnen we daarom nog niet besluiten dat μ ook effectief verschillend is van 1000. De gevonden waarde 945 is namelijk het resultaat van één willekeurige steekproef, en voor andere steekproeven zullen andere resultaten bekomen worden voor $\bar{X}$ (een tweede steekproef geeft misschien $\bar{x} = 1060$ als resultaat). Daarom zullen we gebruik moeten maken van de verdeling van $\bar{X}$ om een statistisch verantwoorde beslissing te nemen.

De keuze van de hypothesen in de test hangt af van verschillende factoren. De nulhypothese moet zodanig gekozen worden dat het gedrag van de toetsingsgrootheid te bepalen is in de veronderstelling dat H_0 waar is. De uitspraak die je wilt bewijzen wordt steeds in de alternatieve hypothese gezet. Het uitvoeren van een test bewijst immers nooit de nulhypothese (het niet kunnen verwerpen van de nulhypothese is een zwak besluit).

¹Hier wordt verder op ingegaan in Kansrekenen en Statistiek II

5.1.1 Tweezijdige z -test (“two-sided one-sample z -test”)

We spreken van een tweezijdige test, als de alternatieve hypothese langs beide kanten rond de nulhypothese verdeeld is, of anders gezegd, als

$$\begin{cases} H_0 : \mu = \mu_0 & (\text{nulhypothese}) \\ H_1 : \mu \neq \mu_0 & (\text{alternatieve hypothese}) \end{cases}$$

Dit is tweezijdig, want zowel $\mu > \mu_0$ als $\mu < \mu_0$ zijn voorzien in de alternatieve hypothese. De alternatieve hypothese spreekt zich dus niet uit over het al dan niet groter of kleiner zijn dan μ_0 , maar enkel over het verschillend zijn.

Indien H_0 werkelijk waar is, dan geldt

$$Z := \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1) \quad \underbrace{|H_0}_{\text{“onder de nulhypothese”}}$$

We noemen Z de **teststatistiek**. Onder de voorwaarde H_0 is het dus onwaarschijnlijk dat $|Z|$ zeer groot zou zijn, want dit zou betekenen dat $\bar{X}$ zeer sterk van μ_0 zou afwijken. Wanneer we, *na* het experiment, vaststellen dat de waargenomen waarde van $|Z|$ toch zeer groot is, dan geloven we niet dat H_0 juist is en zullen we dus de nulhypothese *verwerpen*. In het andere geval zeggen we dat we H_0 *niet verwerpen*.

Voor een vooraf gekozen niveau α geldt

$$P(-z_{1-\alpha/2} \leq Z \leq z_{1-\alpha/2}) = 1 - \alpha \quad |H_0.$$

Dit leidt tot de volgende **beslissingsregel**:

- als de waarde van Z in $[-z_{1-\alpha/2}, z_{1-\alpha/2}]$ ligt, dan kunnen we H_0 niet verwerpen H_0 op het niveau α (zwak besluit);
- indien de waarde van Z buiten dit interval ligt, verwerpen we H_0 op het niveau α (sterk besluit).

We noemen $[-z_{1-\alpha/2}, z_{1-\alpha/2}]$ het **aanvaardingsgebied**, en het complement ervan het **verwerpingsgebied** of de **kritieke zone**. De scheidingspunten tussen aanvaardings- en verwerpingsgebied zijn de **kritieke (kritische)** punten. De waarde α noemen we het **significantieniveau**. Wanneer H_0 verworpen wordt, zegt men dat het verschil tussen $\bar{X}$ en μ_0 **significant** (*beduidend, wezenlijk*) is en wanneer H_0 niet verworpen wordt zegt men dat het verschil tussen $\bar{X}$ en μ_0 **niet significant** is.

We zien dus dat we lang aan de nulhypothese blijven vasthouden en pas op H_1 overstappen wanneer we in de steekproef observaties tegenkomen die niet verwacht waren of die significant verschillend zijn van wat we verwachten onder H_0 . Om dit ‘significant verschillend’ op een eenduidige manier te definiëren kiezen we voor een maximaal toelaatbare kans α op een type-I fout, vandaar

ook de naam ‘significantieniveau’. Daardoor wordt de kans op observaties ‘die helemaal niet verwacht waren onder H_0 wanneer H_0 toch waar is’ beperkt tot α . Merk op dat het significantieniveau dus gedefinieerd wordt als de kans om een type-I fout te maken.

Opmerking. Een alternatieve en voor de hand liggende redenering om het beslissingsprobleem op te lossen bestaat erin om met behulp van de methodes van het vorige hoofdstuk een betrouwbaarheidsinterval op te stellen voor de onbekende parameter en dan na te gaan of de vooropgestelde waarde voor de parameter al dan niet in het betrouwbaarheidsinterval ligt. We hebben dan ook het volgende verband tussen **tweezijdige** testen en het BI:

$$\begin{array}{c} H_0 : \mu = \mu_0 \text{ wordt niet verworpen op het niveau } \alpha \\ \Updownarrow \\ \mu_0 \text{ behoort tot het BI voor } \mu \text{ met betrouwbaarheid } 1 - \alpha \end{array}$$

Dit is triviaal, want beide uitspraken zijn equivalent met

$$|\bar{X} - \mu_0| \leq z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}$$

omdat het BI altijd tweezijdig is! Hypothesetoetsen laten ons echter toe om het resultaat op een meer directe wijze af te leiden en laten ons bovendien ook toe om de kans te bepalen dat de test voldoet of faalt als de vooropgestelde parameterwaarde niet juist is maar overeenkomt met een alternatieve waarde².

5.1.2 Eenzijdige z -test (“one-sided one-sample z -test”)

In deze situatie is de alternatieve hypothese eenzijdig, dus:

$$\begin{cases} H_0 : \mu \leq \mu_0 & (\text{nulhypothese}) \\ H_1 : \mu > \mu_0 & (\text{alternatieve hypothese}) \end{cases} \quad \text{rechtseenzijdig}$$

of

$$\begin{cases} H_0 : \mu \geq \mu_0 & (\text{nulhypothese}) \\ H_1 : \mu < \mu_0 & (\text{alternatieve hypothese}) \end{cases} \quad \text{linkseenzijdig}$$

Men is dus niet geïnteresseerd in het feit of μ verschilt van een bepaalde waarde, maar wel of μ groter (resp. kleiner) is dan de waarde μ_0 .

Men gebruikt hiervoor dezelfde teststatistiek als bij de tweezijdige test, namelijk $Z \sim \mathcal{N}(0, 1)$, maar men interesseert zich nu alleen voor de mogelijkheid dat $\bar{X}$ veel groter (resp. kleiner) zou zijn dan μ_0 . In dat geval is Z een groot positief

²Op het examen zal de methodologie moeten gebruikt worden die gevraagd wordt. Verder in de cursus zullen we ook zien dat BI en hypothesetest voor een proportie niet exact overeenkomen.

(klein negatief) getal.

Als $\mu = \mu_0$ volgt hieruit dat

$$P(Z \leq z_{1-\alpha}) = 1 - \alpha \quad | H_0.$$

Dit betekent dat het voor een kleine waarde van α onwaarschijnlijk is, om onder H_0 , een steekproef te observeren met $z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$ groter dan $z_{1-\alpha}$. De beslissingsregel voor een rechtsezijdige test wordt bijgevolg

- als $Z \in] -\infty, z_{1-\alpha}] \Rightarrow H_0$ niet verwerpen,
- als $Z \in] z_{1-\alpha}, +\infty[\Rightarrow H_0$ verwerpen.

Voor een linksezijdige test bekomen we $[-z_{1-\alpha}, +\infty[$ als aanvaardingsgebied en $] -\infty, -z_{1-\alpha}]$ als verwerpingsgebied.

5.1.3 De p -waarde (“ p -value”)

Tot hiertoe hebben we steeds vooraf een significantieniveau vastgelegd wat leidde tot een bepaald aanvaardingsgebied om onze statistische beslissing op te baseren. Dit houdt echter in dat we voor verschillende significantieniveau's telkens opnieuw het aanvaardingsgebied moeten berekenen. Per berekening (voor bepaald significantieniveau α) kunnen we dan antwoorden op de vraag of “de nulhypothese verworpen wordt op significantieniveau α ”. Dit geeft ons reeds heel wat informatie, maar via de p -waarde kunnen we ook antwoorden op de vraag: is de nulhypothese nipt verworpen (dus lag de geobserveerde waarde dicht bij het kritieke punt) of zouden we ze ook verwerpen op een (veel) lager significantieniveau (de geobserveerde waarde ligt dan ver van het kritiek punt)? De p -waarde lost het toetsingsprobleem dus in één keer op voor alle significantieniveau's. Tegenwoordig wordt de p -waarde meer gebruikt dan het verwerpingsgebied, omdat ze enerzijds meer informatie geeft en anderzijds standaard gebruikt wordt als output in meeste statistische software programma's om hypothesetesten uit te voeren.

Laat ons eerst naar de *eenzijdige* test $H_0 : \mu \geq \mu_0$ versus $H_1 : \mu < \mu_0$ kijken. Om dit probleem op te lossen vraagt men zich dus af of de waarneming $z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$ voldoende waarschijnlijk is als H_0 waar is. De waarschijnlijkheid van z onder H_0 kunnen we uitdrukken via de kans

$$P(Z \leq z \mid \mu = \mu_0) = P\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \leq \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} \mid \mu = \mu_0\right)$$

die aanduidt hoever z in de (linker)staart van de verdeling onder de nulhypothese ligt. Deze kans noemen we de **p -waarde** en kunnen we berekenen omdat onder H_0 geldt dat $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$.

In de vorige sectie zagen we dat we H_0 verwerpen als $z < -z_{1-\alpha} = z_\alpha$. Het is eenvoudig na te gaan dat dit equivalent is met $p = P(Z \leq z) < \alpha$.

De **p -waarde** of **overschrijdingskans** is dus de kans, onder H_0 , dat de teststatistiek Z minstens zo extreem ligt in de richting van het alternatief als de waargenomen testwaarde z .

Hieruit volgt dus dat hoe kleiner de p -waarde is, hoe minder waarschijnlijk het is dat de nulhypothese waar is. Een p -waarde kleiner dan α zal dus aanleiding geven tot het verwerpen van H_0 op significantieniveau α .

De redenering voor de eenzijdige test $H_0 : \mu \leq \mu_0$ versus $H_1 : \mu > \mu_0$ verloopt analoog, hier zal $p = P(Z \geq z)$ zijn.

Bij de *tweezijdige* test $H_0 : \mu = \mu_0$ versus $H_1 : \mu \neq \mu_0$ observeren we dezelfde testwaarde $z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$. De p -waarde is dan de kans, onder de nulhypothese, dat we voor de teststatistiek $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ een waarde bekommen die even ver of nog verder van 0 ligt dan deze z . Voor z positief is deze kans dus gelijk aan

$$p = P(Z \geq z) + P(Z \leq -z) = 2P(Z \geq z).$$

We hebben reeds afgeleid dat we H_0 verwerpen als $z > z_{1-\alpha/2}$, wat overeenkomt met het verwerpen van H_0 als $P(Z \geq z) < \alpha/2$ of dus $p = 2P(Z \geq z) < \alpha$. Voor z negatief volgt een analoge redenering:

$$p = P(Z \geq -z) + P(Z \leq z) = 2P(Z \leq z).$$

Hier verwerpen we H_0 als $z < -z_{1-\alpha/2}$, dus als $P(Z \leq z) < \alpha/2$ of ook nog als $p = 2P(Z \leq z) < \alpha$.

We kunnen deze twee situaties nu combineren door de p -waarde te definiëren als $p = 2P(Z \geq |z|)$.

Samengevat geeft dit:

- Eenzijdig: $\begin{cases} \text{voor } H_1 : \mu > \mu_0 & \text{stel } p = P_{H_0}(Z \geq z) \\ \text{voor } H_1 : \mu < \mu_0 & \text{stel } p = P_{H_0}(Z \leq z) \end{cases}$
- Tweezijdig: $p = 2P_{H_0}(Z \geq |z|)$

De p -waarde is dus gedefinieerd als de kans, indien de nulhypothese H_0 waar is, dat de teststatistiek gelijk is aan de experimentele waarde of meer in de richting van H_1 ligt. We verwerpen H_0 indien de p -waarde kleiner is dan α en we kunnen H_0 niet verwerpen indien de p -waarde groter is dan α . Zowel voor eenzijdige als voor tweezijdige testen geldt dus dat

$$p < \alpha \Leftrightarrow \text{verwerp } H_0 \text{ op het niveau } \alpha$$

dus als $p < \alpha$ dan bevinden we ons eigenlijk in het verwerpingsgebied (horende bij significantieniveau α) en verwerpen we dus de nulhypothese.

Soms gebruikt men de volgende codering:

$$\begin{aligned} 0.05 < p \leq 1 &\Rightarrow \text{niet significant verschillend/groter/kleiner} \\ 0.01 < p \leq 0.05 &\Rightarrow + \\ 0.001 < p \leq 0.01 &\Rightarrow ++ \\ 0 \leq p \leq 0.001 &\Rightarrow +++ \end{aligned}$$

Opmerking. De p -waarde is duidelijk onafhankelijk van α en kan ook gezien worden als het kleinste niveau waarop H_0 wordt verworpen.

5.2 Gemiddelde van een normale verdeling met onbekende variantie

We hebben opnieuw een steekproef

$$X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$$

waarbij deze keer μ en σ beide onbekend zijn en we willen ook hier de hypothese testen of $\mu = \mu_0$. Ook hier maken we weer het onderscheid tussen een eenzijdige en een tweezijdige test.

5.2.1 Tweezijdige t -test (“two-sided one-sample t -test”)

In dit geval zijn de hypothesen

$$\begin{cases} H_0 : \mu = \mu_0 & \text{(nulhypothese)} \\ H_1 : \mu \neq \mu_0 & \text{(alternatieve hypothese)} \end{cases}$$

Onder de aanname van H_0 gebruiken we de volgende teststatistiek:

$$T := \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1} \quad | H_0$$


Bij significantieniveau α geldt dan

$$P(-t_{n-1, 1-\frac{\alpha}{2}} \leq T \leq t_{n-1, 1-\frac{\alpha}{2}}) = 1 - \alpha \quad | H_0$$

en we bekommen zo

- het aanvaardingsgebied $[-t_{n-1, 1-\frac{\alpha}{2}}, t_{n-1, 1-\frac{\alpha}{2}}]$ en
- het verwerpingsgebied $] -\infty, -t_{n-1, 1-\frac{\alpha}{2}}[\cup]t_{n-1, 1-\frac{\alpha}{2}}, \infty[$,

hetgeen grafisch voorgesteld is op de volgende figuur.



We hebben de beslissingsregel hier uitgedrukt in termen van de waarde van de teststatistiek T : we verwerpen H_0 immers niet als

$$-t_{n-1, 1-\frac{\alpha}{2}} \leq \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \leq t_{n-1, 1-\frac{\alpha}{2}}.$$

We kunnen dit ook herschrijven in functie van het steekproefgemiddelde $\bar{x}$. We zullen dan H_0 niet verwerpen als

$$\mu_0 - t_{n-1, 1-\frac{\alpha}{2}} \frac{s}{\sqrt{n}} \leq \bar{x} \leq \mu_0 + t_{n-1, 1-\frac{\alpha}{2}} \frac{s}{\sqrt{n}}$$


of

$$|\bar{x} - \mu_0| \leq t_{n-1, 1-\frac{\alpha}{2}} \frac{s}{\sqrt{n}}.$$

Hieruit volgt dat het al dan niet verwerpen van H_0 (ligt $\bar{x}$ dicht genoeg bij μ_0 ?) afhangt van het significantieniveau α , van de grootte van de steekproef n en van de nauwkeurigheid van de metingen, uitgedrukt via de steekproefstandaardafwijking s . Hoe groter α , hoe kleiner de bijhorende $t_{n-1, 1-\frac{\alpha}{2}}$ en hoe sneller we dus besluiten dat $\bar{x}$ te ver van μ_0 ligt (en we de nulhypothese dus verwerpen). Op dezelfde manier zal een kleinere s er ook voor zorgen dat het verschil tussen $\bar{x}$ en μ_0 sneller als ‘te groot’ beoordeeld wordt. Voor de steekproefgrootte n geldt het omgekeerde. Dit kan ertoe leiden dat het verschil tussen $\bar{x}$ en μ_0 als significant verklaard wordt voor een grote steekproef, terwijl voor een kleinere n hetzelfde verschil niet significant zal zijn.

Analoog aan de z -test hebben we als p -waarde

$$p = 2P_{H_0}(T \geq |t|).$$



Opmerking. Ook hier geldt het verband tussen de tweezijdige test en het BI, namelijk dat

$$\begin{array}{c}
 H_0 : \mu = \mu_0 \text{ wordt niet verworpen op het niveau } \alpha \\
 \Updownarrow \\
 \mu_0 \text{ behoort tot het BI voor } \mu \text{ met betrouwbaarheid } 1 - \alpha
 \end{array}$$

want beide uitspraken zijn nu equivalent met

$$|\bar{X} - \mu_0| \leq t_{n-1, 1-\frac{\alpha}{2}} \frac{S_n}{\sqrt{n}}.$$

Voorbeeld. Een machine maakt staalplaten die een gemiddelde dikte van 0.5mm zouden moeten hebben. Men wil testen of de machine goed afgesteld is, op basis van een steekproef van 10 metingen. Verdonderstel dat de diktes normaal verdeeld zijn. Wat is de conclusie indien $\bar{x} = 0.53\text{mm}$ en $s = 0.03\text{mm}$?

Dit is een *tweezijdige* probleemstelling, met

$$\begin{cases} H_0 : \mu = 0.5\text{mm} \\ H_1 : \mu \neq 0.5\text{mm} \end{cases}$$

De testwaarde is

$$t = \frac{\bar{x} - 0.5\text{mm}}{s/\sqrt{n}} = \frac{0.53\text{mm} - 0.50\text{mm}}{0.03\text{mm}/\sqrt{10}} = 3.162.$$

Merk op dat t geen eenheden heeft!

Voor $\alpha = 5\%$ $t_{9, 0.975} = 2.262$ ($n - 1 = 9$)

$\Rightarrow$ aanvaardingsgebied $= [-2.262, 2.262]$ bevat t niet

$\Rightarrow H_0$ verwerpen op niveau 5% $\Rightarrow$ machine nakijken!

Voor $\alpha = 1\%$ $t_{9,0.995} = 3.25$

$\Rightarrow$ aanvaardingsgebied $= [-3.25, 3.25]$ bevat t
 $\Rightarrow H_0$ niet verwerpen op niveau $1\% \Rightarrow$ machine niet nakijken

Het verschil tussen het waargenomen steekproefgemiddelde 0.53mm en de ideale waarde van 0.50mm is significant op het 5% niveau, maar niet op het 1% niveau. Via de p -waarde: $P_{H_0}(T \geq 3.162) = 0.00575$ (bekomen via statistische software) dus

$$p = 2P_{H_0}(T \geq 3.162) = 0.0115$$

dus we verwerpen H_0 op het 5% niveau, maar niet op het 1% niveau $\Rightarrow +$.

5.2.2 Eenzijdige t -test (“one-sided one-sample t -test”)

Hier test men weer


$$\begin{cases} H_0 : \mu \leq \mu_0 & (\text{nulhypothese}) \\ H_1 : \mu > \mu_0 & (\text{alternatieve hypothese}) \end{cases}$$

gebruik makende van dezelfde teststatistiek $T \sim t_{n-1}$. Net zoals bij de eenzijdige z -test interesseert men zich slechts voor de mogelijkheid dat $\bar{X}$ veel **groter** zou zijn dan μ_0 , dus dat T een groot positief getal is.

$$P(T \leq t_{n-1,1-\alpha}) = 1 - \alpha \quad | H_0$$

We bekommen dan:


- als $T \in]-\infty, t_{n-1,1-\alpha}] \Rightarrow H_0$ niet verwerpen
- als $T \in]t_{n-1,1-\alpha}, +\infty[\Rightarrow H_0$ verwerpen



Voor de omgekeerde situatie:


$$\begin{cases} H_0 : \mu \geq \mu_0 \\ H_1 : \mu < \mu_0 \end{cases}$$

neemt men het aanvaardingsgebied gelijk aan $[-t_{n-1,1-\alpha}, +\infty[$ en het verwerpingsgebied als $] -\infty, -t_{n-1,1-\alpha}[$.




Voor de p -waarden hebben we opnieuw

- Voor $H_1 : \mu > \mu_0$: stel $p = P_{H_0}(T \geq t)$



- Voor $H_1 : \mu < \mu_0$: stel $p = P_{H_0}(T \leq t)$



Voorbeeld. Een fabrikant beweert dat zijn touwen een breekpunt van 8000kg hebben. Testaankoop bepaalt het breekpunt van 6 touwen (kleine steekproef, want de touwen moeten stuk gemaakt worden) en vindt $\bar{x} = 7750\text{kg}$ met

$s = 145\text{kg}$. Is de bewering van de fabrikant houdbaar op het significantieniveau 5%, en op 1% (in de veronderstelling dat de breekpunten normaal verdeeld zijn)?

Dit is een *eenzijdige* probleemstelling, met

$$\begin{cases} H_0 : \mu \geq 8000\text{kg} \\ H_1 : \mu < 8000\text{kg} \end{cases} \quad (\text{want het kan geen kwaad als } \mu > 8000\text{kg})$$

De testwaarde is

$$t = \frac{\bar{x} - 8000\text{kg}}{s/\sqrt{6}} = \frac{-250\text{kg}\sqrt{6}}{145\text{kg}} = -4.223.$$

Voor $\alpha = 5\%$ $t_{5,0.95} = 2.015$ $(n - 1 = 5)$

$$\begin{aligned} \Rightarrow \text{aanvaardingsgebied} &= [-2.015, +\infty[\quad \text{bevat } t \text{ niet} \\ \Rightarrow H_0 &\text{ wordt verworpen op het } 5\% \text{ niveau} \end{aligned}$$

Voor $\alpha = 1\%$ $t_{5,0.99} = 3.3648$

$$\begin{aligned} \Rightarrow \text{aanvaardingsgebied} &= [-3.3648, +\infty[\quad \text{bevat } t \text{ niet} \\ \Rightarrow H_0 &\text{ wordt zelfs verworpen op het } 1\% \text{ niveau} \end{aligned}$$

Indien we de p -waarde gebruiken, bekomen we:

$$p = P_{H_0}(T \leq -4.223) = 0.0042,$$

dus significant op het 1% niveau (sterk verwerpen) $\Rightarrow ++$.

Conclusie: we geloven de fabrikant niet!

5.2.3 Meer over type-I en type-II fout

Het significantieniveau α is de kans dat H_0 verworpen wordt terwijl H_0 toch waar is, dus de type-I fout. Wanneer men echter α zeer klein kiest kan het gemakkelijk gebeuren dat men H_0 niet verworpt wanneer H_0 *niet* waar is, dus dan wordt β , de kans op een type-II fout, te groot. Een compromis is dus nodig, en bij conventie neemt men meestal $\alpha = 5\%$, $\alpha = 1\%$, of $\alpha = 0.1\%$. De grootte van β wordt voornamelijk bepaald door de steekproefgrootte n , het niveau α , de grootte van het werkelijke effect en de variantie (en wordt dus niet op voorhand vastgelegd). Door bijvoorbeeld een grotere steekproef te nemen, kan men streven naar een zo klein mogelijke waarde van β . De waarde $1 - \beta$, de power van de test, geeft de kans dat een werkelijk effect ook gedetecteerd wordt, dus hoe goed de test in staat is om een alternatief te ontdekken.

Op basis van de type-I en type-II fouten, merken we op dat er een asymmetrie in het gestelde testprobleem bestaat. De kans op een type-I fout kan immers


willekeurig klein gemaakt worden door α goed te kiezen, maar daardoor zal de kans op een type-II fout vergroten. Daarom zal men de nulhypothese en alternatieve hypothese zo vastleggen dat type-I fouten ‘belangrijker’ zijn dan type-II fouten. Type-I fouten worden namelijk niet zo vaak gemaakt. Dit is ook de reden waarom de te verwerpen stelling in de nulhypothese gezet wordt. In de realiteit wil men vaak een klassieke werkwijze vergelijken met een nieuwe methode. De klassieke werkwijze wordt dan onder H_0 gezet omdat men het ten onrechte verwerpen van deze klassieke assumptie als erger beschouwd dan het ten onrechte niet-verwerpen van de klassieke methode. De notatie H_0 en term nulhypothese komen ook hiervandaan, namelijk van de Engelstalige uitdrukking ‘null-change’, dus als we H_0 niet verwerpen is er geen verandering in de gebruikte werkwijze.

Bij de interpretatie van een “significant” effect moet men er altijd rekening mee houden dat significant niet synoniem is aan belangrijk! Immers wanneer n groot genoeg wordt genomen, kan de power heel groot worden en zal een effect dat in de praktijk te klein is om belang te hebben, toch gedetecteerd worden. Significant moet eerder geïnterpreteerd worden als niet afhankelijk van het toeval, het experiment is herhaalbaar.

We tonen aan dat de kans op een type-I fout effectief α is. We doen dit voor een tweezijdige t -test, maar de redenering voor een ander type test of voor een eenzijdige test verloopt analoog.

$$\begin{aligned} P(\text{type-I fout}) &= P(H_0 \text{ verwerpen} \mid H_0 \text{ is waar}) \\ &= P(T \in]-\infty, -t_{n-1, 1-\frac{\alpha}{2}}[\cup]t_{n-1, 1-\frac{\alpha}{2}}, \infty[\mid \mu = \mu_0) \\ &= P(T \in]-\infty, -t_{n-1, 1-\frac{\alpha}{2}}[\mid \mu = \mu_0) \\ &\quad + P(T \in]t_{n-1, 1-\frac{\alpha}{2}}, \infty[\mid \mu = \mu_0) \end{aligned}$$

Omdat $T \sim t_{n-1}$ als $\mu = \mu_0$, volgt hieruit onmiddellijk dat $P(\text{type-I fout}) = \alpha/2 + \alpha/2 = \alpha$.



De type-I fout is dus begrensd door het significantieniveau α . Door α vast te leggen *vooraleer* men de test uitvoert, bepalen we dus vooraf de maximale kans

die we toelaten voor een type-I fout. Deze α mag niet te groot zijn. Anderzijds mag α ook niet te klein gekozen worden omdat we dan bijna nooit de nulhypothese zouden verwerpen en dus de kans op een type-II fout te groot maken.

De kans op een type-II fout is

$$\beta = P(\text{type-II fout}) = P(H_0 \text{ niet verwerpen} \mid H_0 \text{ is niet waar}).$$

Deze β kunnen we, in tegenstelling tot α , niet zelf controleren, en kan dus ook voor bepaalde steekproeven vrij groot worden. Bovendien kunnen we β ook niet expliciet berekenen, omdat ‘ H_0 is niet waar’ ons geen informatie geeft over de werkelijke waarde van μ . Voor een specifiek alternatief, zoals $\mu = \mu_1$ (waarbij μ_1 een waarde is die voldoet aan H_1), kunnen we wel de type-II fout bepalen:


$$\begin{aligned} P(\text{type-II fout} \mid \mu = \mu_1) &= P(H_0 \text{ niet verwerpen} \mid \mu = \mu_1) \\ &= P\left(-t_{n-1, 1-\frac{\alpha}{2}} \leq \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \leq t_{n-1, 1-\frac{\alpha}{2}} \mid \mu = \mu_1\right) \end{aligned}$$

en omdat voor $\mu = \mu_1$ geldt dat $T := \frac{\bar{X} - \mu_1}{S/\sqrt{n}} \sim t_{n-1}$ is dit gelijk aan

$$\begin{aligned} &= P\left(-t_{n-1, 1-\frac{\alpha}{2}} - \frac{\mu_1 - \mu_0}{S/\sqrt{n}} \leq \frac{\bar{X} - \mu_1}{S/\sqrt{n}} \leq t_{n-1, 1-\frac{\alpha}{2}} - \frac{\mu_1 - \mu_0}{S/\sqrt{n}} \mid \mu = \mu_1\right) \\ &= P\left(-t_{n-1, 1-\frac{\alpha}{2}} - \frac{\mu_1 - \mu_0}{S/\sqrt{n}} \leq T \leq t_{n-1, 1-\frac{\alpha}{2}} - \frac{\mu_1 - \mu_0}{S/\sqrt{n}}\right). \end{aligned}$$

We zien dus dat de type-II fout onder andere afhangt van n , S en het verschil tussen μ_1 en μ_0 . Hoe groter n , hoe kleiner S en hoe groter $\mu_1 - \mu_0$, hoe kleiner de kans op een type-II fout. Grotere steekproeven helpen dus om zowel de type-I fout als de type-II fout te beperken.

Uit de laatste formule kunnen we opmerken dat het niet eenvoudig is om de kans op een type-II fout exact te bepalen omdat in de uitdrukking nog de s.v. S voorkomt. We kunnen wel een idee krijgen over de grootte van deze kans door S te vervangen door de steekproefstandaarddeviatie s . Grafisch kan de kans op een type-II fout dan als volgt worden voorgesteld:



De linkse dichtheidscurve toont de verdeling van $\bar{X}$ onder H_0 , waarbij σ^2 benaderd is door s^2 (vermits $\bar{X} \sim \mathcal{N}(\mu_0, \sigma^2) \approx \mathcal{N}(\mu_0, s^2)$). We hebben hier ook de kritieke waarden $\mu_0 \pm t_{n-1, 1-\frac{\alpha}{2}} \frac{s}{\sqrt{n}}$ (vergelijk met hoofdstuk 5.2.1, formulering in functie van $\bar{x}$) aangeduid. De rechtse dichtheidscurve is die voor H_1 waarbij $\bar{X} \sim \mathcal{N}(\mu_1, \sigma^2) \approx \mathcal{N}(\mu_1, s^2)$.

5.3 Normaliteitsassumptie

Voor de hiervoor besproken testen werd er bijna steeds aangenomen dat de data normaal verdeeld waren. De t -test is wel redelijk bestand tegen afwijkingen van deze assumptie van normaliteit, en voor grote steekproeven geldt vanwege de CLS een benaderende normaliteit, maar voor kleine steekproeven is het belangrijk om de normaliteitsveronderstelling te controleren.

We hebben reeds gezien dat een normale QQ-plot een visueel idee geeft over het al dan niet normaal verdeeld zijn van de data. Indien de geplotte punten geen rechtlijnig patroon volgen, mogen we geen normaliteit veronderstellen. Via het berekenen van de bijbehorende correlatiecoëfficiënt r_Q kunnen we deze visuele indruk in een getal samenvatten. Indien de correlatiecoëfficiënt ongeveer 1 is, zal er geen twijfel bestaan over normaliteit, aangezien dit wil zeggen dat de punten ongeveer op een rechte liggen. In de praktijk zal dit echter nooit het geval zijn wegens de invloed van het toeval bij een experiment. Op basis van de gegevens moeten we dus de test

$$\begin{cases} H_0 : \text{de gegevens zijn normaal verdeeld} \\ H_1 : \text{de gegevens zijn niet normaal verdeeld} \end{cases}$$

uitvoeren. Men zal de normaliteit verwerpen als de berekende r_Q ‘te ver onder’ 1 gelegen is om goed verklaard te worden door de nulhypothese van normaliteit. Onderstaande tabel toont de (beneden)kwantielen voor 1% en 5% (deze waarden worden slechts in respectievelijk 1% en 5% van de gevallen overschreden, indien men in gedachten het experiment herhaalt en de populatie inderdaad normaal verdeeld). Deze kritieke waarden zijn niet gegenereerd uit een theoretische verdeling, maar bekomen via een zeer uitgebreide simulatiestudie. Men zal H_0 verwerpen als de waargenomen r_Q lager is dan de kritieke waarde uit de tabel. De resultaten zijn gebaseerd op de Pearson correlatiecoëfficiënt en zijn dus gevoelig aan uitschieters. Het is daarom aangewezen om ook nog steeds een kwantielplot maken, omdat hieruit eventueel de mogelijke oorzaak van het verwerpen van normaliteit afgeleid kan worden. Een vergelijkbare test is de *Shapiro-Wilk test*. Deze wordt op analoge wijze bekomen, maar gebruikt een andere definitie van kwantielplot en correlatie. Het is deze laatste test die meestal standaard in statistische software is geprogrammeerd.

n	$\alpha = 0.01$	$\alpha = 0.05$
10	.880	.918
15	.911	.938
20	.929	.950
25	.941	.958
30	.949	.964
40	.960	.972
50	.966	.976
60	.971	.980
75	.976	.984
100	.981	.986
150	.987	.991
200	.990	.993

Wanneer een variabele niet normaal verdeeld blijkt te zijn, kan men na het raadplegen van de QQ-plot deze proberen te transformeren naar een normaal verdeelde variabele (zie bespreking bij QQ-plot). Het is trouwens aangeraden om de QQ-plot steeds te bekijken, ook indien de r_Q groter is dan de kritieke waarde uit de tabel omdat procedures voor het testen van normaliteit niet erg krachtig zijn. Het kan gebeuren dat men duidelijk afwijkende patronen merkt in de QQ-plot, terwijl de test normaliteit niet zal verwerpen.

Wanneer een variabele X niet normaal verdeeld is, maar zijn logaritme bijvoorbeeld wel, kan men de test

$$\begin{cases} H_0 : \mu_{\log(X)} = \log(\mu_0) \\ H_1 : \mu_{\log(X)} \neq \log(\mu_0) \end{cases}$$

uitvoeren. Merk op dat dit *niet* equivalent is met

$$\begin{cases} H_0 : \mu_X = \mu_0 \\ H_1 : \mu_X \neq \mu_0. \end{cases}$$

Als de bestudeerde s.v. niet normaal verdeeld is en men ze ook niet kan transformeren naar een normaal verdeelde variabele, kan men een niet-parametrische toets (bvb. Wilcoxon of Mann-Whitney test) uitvoeren.

5.4 Variantie van een normale verdeling

In dezelfde situatie als voorheen, namelijk

$$X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2) \quad \text{met } \mu \text{ en } \sigma \text{ onbekend}$$

wil men testen of $\sigma^2 = \sigma_0^2$.

Onder de nulhypothese $H_0 : \sigma^2 = \sigma_0^2$ geldt

$$X^2 := \frac{(n-1)S^2}{\sigma_0^2} \sim \chi_{n-1}^2 \quad | H_0$$

waarin we de teststatistiek als X^2 noteren en de waarde bekomen uit de metingen als χ^2 . Herinner dat de χ^2 -verdeling alleen positieve waarden kan aannemen en dat ze niet symmetrisch is.

Analoog aan de testen voor het gemiddelde bekomen we nu de volgende resultaten.

Tweezijdige χ^2 test:

$$\begin{cases} H_0 : \sigma^2 = \sigma_0^2 \\ H_1 : \sigma^2 \neq \sigma_0^2 \end{cases}$$

We verwerpen hier de nulhypothese H_0 niet als de waarde van de teststatistiek X^2 in het aanvaardingsgebied $[\chi_{n-1, \frac{\alpha}{2}}^2, \chi_{n-1, 1-\frac{\alpha}{2}}^2]$ ligt en verwerpen indien het niet tot dit interval behoort.

Of als we dit formuleren in functie van p -waarde, dan verwerpen we H_0 als $p < \alpha$ met

$$p = 2 \min\{P_{H_0}(X^2 \geq \chi^2), P_{H_0}(X^2 \leq \chi^2)\}.$$

Eenzijdige χ^2 test:

Voor de test

$$\begin{cases} H_0 : \sigma^2 \leq \sigma_0^2 \\ H_1 : \sigma^2 > \sigma_0^2 \end{cases}$$

is het aanvaardingsgebied $[0, \chi_{n-1, 1-\alpha}^2]$ en verwerpen we de nulhypothese als $\chi > \chi_{n-1, 1-\alpha}^2$. De overschrijdingskans wordt dan $p = P_{H_0}(X \geq \chi)$.

In het andere geval

$$\begin{cases} H_0 : \sigma^2 \geq \sigma_0^2 \\ H_1 : \sigma^2 < \sigma_0^2 \end{cases}$$

wordt het aanvaardingsgebied $[\chi_{n-1, \alpha}^2, +\infty[$ en verwerpen we H_0 indien $\chi < \chi_{n-1, \alpha}^2$. Hier is de overschrijdingskans $p = P_{H_0}(X \leq \chi)$.

Voorbeeld. De standaardafwijking van het gewicht van blikjes groenten van 500g van het merk Greentables is altijd 2.5g geweest, maar men vreest dat de variabiliteit groter kan geworden zijn omdat de machines verouderen. Een steekproef van 20 blikjes levert $s = 3.2g$ op. Is deze stijging significant op het 5% en het 1% niveau?

De probleemstelling is *eenzijdig*:

$$\begin{cases} H_0 : \sigma^2 \leq (2.5g)^2 \\ H_1 : \sigma^2 > (2.5g)^2 \end{cases}$$

De testwaarde is

$$\chi^2 = \frac{(n-1)s^2}{\sigma_0^2} = \frac{19(3.2g)^2}{(2.5g)^2} = 31.13$$

en heeft geen eenheden.

Voor $\alpha = 5\%$ $\chi_{n-1,1-\alpha}^2 = \chi_{19,0.95}^2 = 30.144$

$\Rightarrow$ aanvaardingsgebied = $[0, 30.144]$ bevat 31.13 niet
 $\Rightarrow H_0$ verwerpen

Voor $\alpha = 1\%$ $\chi_{n-1,1-\alpha}^2 = \chi_{19,0.99}^2 = 36.191$

$\Rightarrow$ aanvaardingsgebied = $[0, 36.191]$ bevat 31.13 wel
 $\Rightarrow H_0$ niet verwerpen

We kunnen dus besluiten dat de *stijging* van de variabiliteit significant is op het 5% niveau, maar niet op het 1% niveau.

Via de p -waarde krijgen we dezelfde oplossing:

$$p = P_{H_0}(X^2 \geq 31.13) = 0.0391$$

dus $0.01 < p \leq 0.05 \Rightarrow +$.

Indien men vraagt of de variabiliteit *veranderd* was (in plaats van “gestegen”), dan moeten we *tweezijdige* aanvaardingsgebieden gebruiken en krijgen we:

$$\alpha = 5\% : \quad [\chi_{19,0.025}^2, \chi_{19,0.975}^2] = [8.907, 32.852]$$

$$\alpha = 1\% : \quad [\chi_{19,0.005}^2, \chi_{19,0.995}^2] = [6.844, 38.582].$$

We zien dat in dit geval H_0 niet kunnen verwerpen, en dit zowel voor $\alpha = 5\%$ als voor $\alpha = 1\%$. De *verandering* is dus *niet* significant! Hier zien we duidelijk dat de probleemstelling een grote invloed kan hebben op het besluit.

Voor de tweezijdige vraagstelling geldt $P_{H_0}(X^2 \geq 31.13) \leq \frac{1}{2}$, dus is dit de kleinste van de twee kansen en (bekomen via statistische software)

$$p = 2P_{H_0}(X^2 \geq 31.13) = 0.0781$$

dus $p > 0.05 \Rightarrow$ niet significant.

Opmerking. Voor de *tweezijdige* test geldt opnieuw:

$$\begin{array}{c} H_0 : \sigma^2 = \sigma_0^2 \text{ wordt niet verworpen op het niveau } \alpha \\ \Downarrow \\ \sigma_0^2 \text{ behoort tot het BI voor } \sigma^2 \text{ met betrouwbaarheid } 1 - \alpha \end{array}$$

5.5 Proportie

Indien we testen omtrent een proportie willen uitvoeren, moeten we onderscheid maken tussen twee gevallen: als de steekproef voldoende groot is, mogen we een benaderende test uitvoeren; indien we echter over een kleine steekproef beschikken, dienen we een exacte test toe te passen.

5.5.1 Benaderende test als steekproef voldoende groot is

We weten dat we een proportie p schatten met $\hat{P} = \frac{1}{n} \sum_{i=1}^n X_i$ voor een steekproef $(X_1, \dots, X_n)$ met $X_i \sim \mathcal{B}(1, p)$ en i.i.d. Bovendien geldt indien $n \geq 30$, $np \geq 5$ en $n(1-p) \geq 5$ dat benaderend $\hat{P} \approx \mathcal{N}(p, \frac{p(1-p)}{n})$. We kunnen dan, net als bij het BI,

$$Z = \frac{\hat{P} - p}{\sqrt{\frac{p(1-p)}{n}}} \approx \mathcal{N}(0, 1)$$

als teststatistiek nemen. Aangezien deze grootheid normaal verdeeld is met gekende variantie, kunnen we hierop een z -test uitvoeren waarbij de hypothesen zijn:

$$\begin{cases} H_0 : p = p_0 \\ H_1 : p \neq p_0 \end{cases}$$

of een equivalente eenzijdige test. Omdat we testen ten opzichte van een gekende waarde p_0 zullen we de teststatistiek dus ook exact kunnen bepalen, in tegenstelling tot het betrouwbaarheidsinterval, waar we de p -termen in de standaardafwijking moesten benaderen met $\hat{P}$. Onder de nulhypothese is de teststatistiek dus

$$Z = \frac{\hat{P} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \approx \mathcal{N}(0, 1) \quad | H_0$$

met als aanvaardingsgebied $[-z_{1-\alpha/2}, z_{1-\alpha/2}]$ zoals bij de z -test. Ook de berekening van de p -waarde is analoog aan de z -test: $p = 2P_{H_0}(Z \geq |z|)$.

5.5.2 Exacte test als de steekproef klein is

Indien echter de steekproef niet groot genoeg is om de binomiaalverdeling te mogen benaderen door een normale verdeling, kunnen we een exacte test uitvoeren. Hiervoor gebruiken we de teststatistiek $n\hat{P}$ waarvan we weten dat die onder de nulhypothese $\mathcal{B}(n, p_0)$ verdeeld is. Dit exacte resultaat kan dan ook gebruikt worden om kritieke waarden te berekenen, een betrouwbaarheidsinterval te bepalen of de p -waarde uit te rekenen.

Voorbeeld. Stel dat men wil testen of 65% van de Vlamingen het eens is met een bepaald wetsvoorstel. Bij een steekproef van grootte 14 gingen er 7 personen akkoord. Bevestigt dit de veronderstelling dat 65% het eens is met het

wetsvoorstel (met $\alpha = 5\%$)? Bepaal de p -waarde.

Stel $X = 1$ als de persoon akkoord gaat en $X = 0$ anders en noem p de populatieproportie die het eens is met het wetsvoorstel. De hypothesen zijn dan

$$\begin{cases} H_0 : p = 0.65 \\ H_1 : p \neq 0.65. \end{cases}$$

Aangezien het hier om een kleine steekproef gaat, mag de normaalbenadering niet gebruikt worden. Onder de nulhypothese is $p = 0.65$ en $np = 9.1$ en geldt er dat $n\hat{P} = n\bar{X} \sim \mathcal{B}(14, 0.65)$. Er zijn 7 successen in de steekproef.

$$\begin{aligned} P(|n\hat{P} - 9.1| \geq |7 - 9.1|) &= P(n\hat{P} - 9.1 \geq 2.1 \text{ of } n\hat{P} - 9.1 \leq -2.1) \\ &= P(n\hat{P} \geq 11.2) + P(n\hat{P} \leq 7). \end{aligned}$$

Deze kansen zijn:

$$\begin{aligned} P(n\hat{P} \geq 11.2) &= P(n\hat{P} \geq 12) = P(Y \leq 2) = 0.0839 \\ P(n\hat{P} \leq 7) &= P(Y \geq 7) = 1 - P(Y \leq 6) = 0.1836 \end{aligned}$$

met $Y \sim \mathcal{B}(14, 0.65)$. Bijgevolg is de p -waarde gelijk aan $0.0839 + 0.1836 = 0.2675$ en mogen we H_0 dus niet verwerpen op significantieniveau 5%.

We bekijken nu een voorbeeld met meer gegevens en vergelijken het resultaat van de exacte en de benaderende test voor een proportie.

Voorbeeld. Stel dat men wil testen ($\alpha = 0.05$) of de kans op een bepaalde gebeurtenis groter is dan 0.5. De hypothesen zijn dan

$$\begin{cases} H_0 : p \leq 0.5 \\ H_1 : p > 0.5, \end{cases}$$

dus een eenzijdige test. We beschikken voor deze test over een steekproef van $n = 60$ observaties, waarvan er 50 effectief groter zijn dan 0.5. Bijgevolg is $\hat{p} = \frac{50}{60} = 0.833$.

Indien we de p -waarde *benaderend* bepalen (dus in de veronderstelling dat n voldoende groot is), dan vinden we dat bij benadering

$$\hat{P} \approx \mathcal{N}\left(0.5, \frac{0.5(1-0.5)}{60}\right) \quad |H_0$$

of

$$Z = \frac{\hat{P} - 0.5}{\sqrt{\frac{0.5(1-0.5)}{60}}} \approx \mathcal{N}(0, 1).$$

We zullen H_0 dus verwerpen indien $z = \frac{\hat{p} - 0.5}{\sqrt{\frac{0.5(1-0.5)}{60}}} = 5.16$ significant groter is dan 0. De kritieke waarde voor deze test is $\Phi^{-1}(1 - \alpha) = 1.64$, want onder

H_0 is $P_{H_0}(Z > 1.64) = 0.05$. In dit geval is $5.16 > 1.64$ en dus verwerpen we de nulhypothese op significantieniveau 5%. Hetzelfde besluiten we via de p -waarde, dewelke gedefinieerd is als de kans, onder H_0 , om een waarde voor de teststatistiek Z te bekomen die minstens zo groot is als de geobserveerde testwaarde $z = 5.16$. De p -waarde hier is dus

$$p = P_{H_0}(Z \geq 5.16) \approx 0.$$

p is dus kleiner dan α , en we verwerpen H_0 .

Passen we nu de exacte methode toe, dan is de p -waarde

$$\begin{aligned} p &= P_{H_0}\left(\hat{P} \geq \frac{50}{60}\right) = P\left(\hat{P} \geq \frac{50}{60} | p = 0.5\right) \\ &= P(60\hat{P} \geq 50 | p = 0.5) = P(Y \geq 50) \end{aligned}$$

met $Y \sim \mathcal{B}(60, 0.5)$. Deze kans is $8 \cdot 10^{-8} \approx 0$. Het besluit verandert dus niet indien we de p -waarde exact berekenen, we verwerpen H_0 nog steeds.

VERGELIJKINGSTESTEN

6.1 Vergelijken van varianties

Tot hiertoe hebben we steeds testen uitgevoerd op één parameter en die vergeleken met een vaste (veronderstelde) waarde. In de praktijk zullen er echter vaak twee groepen met elkaar vergeleken worden, en zullen we besluiten willen formuleren omtrent de verhouding van de populatieparameters van de beide groepen; zijn ze gelijk, of verschillend, of is er één significant groter dan de andere? Om uitspaken van deze aard te kunnen maken, worden opnieuw hypothesetesten gebruikt, maar de teststatistiek zal in deze gevallen gebaseerd zijn op een verschil (of verhouding zoals hier bij σ^2) van de puntschatters van beide groepen voor de desbetreffende populatieparameter.

Veronderstel dat we twee onafhankelijke steekproeven hebben

$$\begin{aligned} X_1, \dots, X_{n_1} &\sim \mathcal{N}(\mu_1, \sigma_1^2) && \mu_1 \text{ en } \sigma_1 \text{ onbekend} \\ Y_1, \dots, Y_{n_2} &\sim \mathcal{N}(\mu_2, \sigma_2^2) && \mu_2 \text{ en } \sigma_2 \text{ onbekend} \end{aligned}$$

die mogelijk een verschillende grootte hebben, het kan dus zijn dat $n_1 \neq n_2$. We willen dan testen of $\sigma_1 = \sigma_2$, zonder ons af te vragen of de parameters μ_1 en μ_2 gelijk zijn of niet. We zullen weer moeten beginnen met σ_1^2 en σ_2^2 te schatten via de steekproefvarianties

$$\begin{aligned} S_1^2 &= \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (X_i - \bar{X}_{n_1})^2 \\ S_2^2 &= \frac{1}{n_2 - 1} \sum_{j=1}^{n_2} (Y_j - \bar{Y}_{n_2})^2. \end{aligned}$$

Stelling. Er geldt dat $\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{n_1-1, n_2-1}$ (met σ_1 en σ_2 onbekend!)

Met dit resultaat kunnen we ook een betrouwbaarheidsinterval voor de verhouding van twee varianties σ_1^2 en σ_2^2 . Uit vorige stelling volgt immers

$$P\left(F_{n_1-1, n_2-1, \frac{\alpha}{2}} \leq \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \leq F_{n_1-1, n_2-1, 1-\frac{\alpha}{2}}\right) = 1 - \alpha$$

Herinner ook de eigenschap

$$F_{n,m,\alpha} = \frac{1}{F_{m,n,1-\alpha}}$$

die toeliet om de tabellen van de F -verdeling te reduceren. Bijgevolg bekomen we volgend betrouwbaarheidsinterval voor $\frac{\sigma_1^2}{\sigma_2^2}$

$$\left[\frac{S_1^2}{S_2^2} \frac{1}{F_{n_1-1, n_2-1, 1-\frac{\alpha}{2}}}, \frac{S_1^2}{S_2^2} F_{n_2-1, n_1-1, 1-\frac{\alpha}{2}} \right].$$

Onder de nulhypothese dat $\sigma_1 = \sigma_2$ geldt bijgevolg

$$F := \frac{S_1^2}{S_2^2} \sim F_{n_1-1, n_2-1} \quad | H_0$$

voor de teststatistiek F , zodat $P(F \leq F_{n_1-1, n_2-1, \alpha}) = \alpha$. Deze test is een van de redenen waarom Fisher de F -verdeling ingevoerd heeft.

Tweezijdige F -test

$$\begin{cases} H_0 : \sigma_1^2 = \sigma_2^2 \\ H_1 : \sigma_1^2 \neq \sigma_2^2 \end{cases}$$

of equivalent

$$\begin{cases} H_0 : \frac{\sigma_1^2}{\sigma_2^2} = 1 \\ H_1 : \frac{\sigma_1^2}{\sigma_2^2} \neq 1 \end{cases}$$

Bereken dan de f -waarde van de steekproef als $f = \frac{s_1^2}{s_2^2}$. We zullen dan de nulhypothese niet verwerpen op significantieniveau α als deze f -waarde in het aanvaardingsgebied $[F_{n_1-1, n_2-1, \frac{\alpha}{2}}, F_{n_1-1, n_2-1, 1-\frac{\alpha}{2}}]$ ligt en verwerpen als ze erbuiten ligt. De overschrijdingskans of p -waarde is in dit geval gegeven door

$$\begin{aligned} p &= 2 \min\{P_{H_0}(F \leq f), P_{H_0}(F \geq f)\} \\ &= 2 \min\{F_{n_1-1, n_2-1}(f), 1 - F_{n_1-1, n_2-1}(f)\} \end{aligned}$$

wat volgt uit

$$\begin{cases} \text{als } P_{H_0}(F \geq f) \leq \frac{1}{2} & \text{stel } p = 2P_{H_0}(F \geq f) \\ \text{als } P_{H_0}(F \leq f) \leq \frac{1}{2} & \text{stel } p = 2P_{H_0}(F \leq f). \end{cases}$$

Eenzijdige F -test

Voor dezelfde f -waarde kunnen we ook eenzijdige testen uitvoeren. Voor de rechtseenzijdige test

$$\begin{cases} H_0 : \sigma_1 \leq \sigma_2 \\ H_1 : \sigma_1 > \sigma_2 \end{cases}$$

bekomen we als aanvaardingsgebied $[0, F_{n_1-1, n_2-1, 1-\alpha}]$ en $p = P_{H_0}(F \geq f) = 1 - F_{n_1-1, n_2-1}(f)$ als p -waarde.

Voor de linkseenzijdige test

$$\begin{cases} H_0 : \sigma_1 \geq \sigma_2 \\ H_1 : \sigma_1 < \sigma_2 \end{cases}$$

is het aanvaardingsgebied $[F_{n_1-1, n_2-1, \alpha}, +\infty[$ en is de bijbehorende p -waarde $p = P_{H_0}(F \leq f) = F_{n_1-1, n_2-1}(f)$.

Opmerking. Uit de bovenstaande formules volgt dat je voor de tweezijdige test steeds twee F -waarden moet bepalen. Dit kan echter vermeden worden door X en Y zodanig te kiezen dat $\sigma_1^2 \geq \sigma_2^2$ zodat automatisch $f \geq 1$ is. Omdat de mediaan van de F -verdeling nooit erg ver van 1 ligt, zal de linkergrens van het aanvaardingsgebied kleiner zijn dan 1 en ligt f sowieso rechts van $F_{n_1-1, n_2-1, \frac{\alpha}{2}}$, zodat we enkel nog moeten nagaan of f kleiner is dan de rechtergrens. Dit komt eigenlijk overeen met het uitvoeren van een eenzijdige toets met alternatief $\sigma_1^2 > \sigma_2^2$ en met een *gehalveerd* significantieniveau. Voor de eenzijdige test kan je ook steeds X en Y zo kiezen dat de alternatieve hypothese $\sigma_1^2 > \sigma_2^2$ is.

Voorbeeld. Men wil testen of twee voltmeters dezelfde variabiliteit (=on nauwkeurigheid) hebben. Met elk van de toestellen wordt een bepaalde meting herhaaldelijk uitgevoerd. Men vindt $s_1 = 4\mu V$ ($n_1 = 16$) en $s_2 = 3\mu V$ ($n_2 = 21$). Voer de test uit met $\alpha = 5\%$.

De probleemstelling is tweezijdig, dus

$$\begin{cases} H_0 : \sigma_1 = \sigma_2 \\ H_1 : \sigma_1 \neq \sigma_2 \end{cases}$$

De teststatistiek is

$$f = \frac{s_1^2}{s_2^2} = \frac{(4\mu V)^2}{(3\mu V)^2} = 1.777 \quad (\text{geen eenheden})$$

en de kwantielen zijn

$$\begin{aligned} F_{15,20,0.975} &= 2.57 \\ F_{15,20,0.025} &= \frac{1}{F_{20,15,0.975}} = \frac{1}{2.76} = 0.362. \end{aligned}$$

De f -waarde van 1.777 ligt dus in het aanvaardingsgebied $[0.362, 2.57]$, wat betekent dat we H_0 niet mogen verwerpen op significantieniveau 5%. Het onderscheid tussen de variabiliteiten is bijgevolg niet significant.

Als we de berekening via de p -waarde doen, bekomen we

$$P_{H_0}(F \geq f) = 0.1142 \leq \frac{1}{2}$$

dewelke dus de kleinste van de twee kansen is en bijgevolg is

$$p = 2P_{H_0}(F \geq f) = 0.2284 > 0.05$$

en is het verschil in variabiliteit niet significant.

6.2 Vergelijken van gemiddelden

In het vorige deel hebben we de varianties vergeleken van twee onafhankelijke normaal verdeelde steekproeven. In dit deel zullen we testen bestuderen die toelaten om de gemiddelden van twee groepen waarnemingen met elkaar te vergelijken. Hierbij zullen we een onderscheid moeten maken tussen **gepaarde** en **ongepaarde** waarnemingen. Veronderstel dat we opnieuw beschikken over twee steekproeven:

$$X_1, \dots, X_{n_1} \sim \mathcal{N}(\mu_1, \sigma_1^2) \quad \mu_1 \text{ en } \sigma_1 \text{ onbekend}$$

$$Y_1, \dots, Y_{n_2} \sim \mathcal{N}(\mu_2, \sigma_2^2) \quad \mu_2 \text{ en } \sigma_2 \text{ onbekend}$$

Indien er geen enkel verband tussen beide steekproeven $X_1, \dots, X_{n_1}$ en $Y_1, \dots, Y_{n_2}$ bestaat (i.e. ze zijn onafhankelijk van elkaar), spreken we van **ongepaarde** data. Dit is bijvoorbeeld het geval wanneer men twee benzinemerken X en Y wil vergelijken door het verbruik te meten van

$$\begin{array}{ll} 10 \text{ auto's met benzine van merk } X & (n_1 = 10) \\ 12 \text{ auto's met benzine van merk } Y & (n_2 = 12). \end{array}$$

Hierbij zijn er 22 verschillende auto's, dus het verbruik X_2 is bijvoorbeeld totaal onafhankelijk van het verbruik Y_2 .

Deze onafhankelijkheid geldt echter niet altijd! Men noemt beide steekproeven **gepaard** indien er een relatie bestaat tussen elk element X_i van de eerste dataset met juist één element Y_i van de tweede dataset. Dit houdt dus in dat beide steekproeven van *eenzelfde grootte* moeten zijn, i.e. $n_1 = n_2$ ¹. Laat ons nu een experiment beschouwen met **gepaarde waarnemingen** (*matched pairs*). Men kan bijvoorbeeld het verbruik van 10 auto's meten, één keer met benzine van merk X en één keer met benzine van merk Y . Omdat de wagens in beide steekproeven identiek zijn, zijn de waarnemingen dus verbonden, voor elke wagen hebben we twee metingen, één voor merk X en één voor merk Y . Dan is

$$\begin{cases} X_1 & X_2 & \dots & X_{10} \\ Y_1 & Y_2 & \dots & Y_{10} \end{cases} \quad n_1 = n_2 = 10 = n.$$

¹Uiteraard is het best mogelijk dat bij ongepaarde data beide steekproeven ook even groot zijn (maar onafhankelijk zijn van elkaar).

In dit geval zijn X_2 en Y_2 duidelijk niet meer onafhankelijk, want wanneer de tweede auto erg zwaar is, of een slecht afgestelde motor heeft, dan zullen X_2 en Y_2 *allebei* tamelijk groot zijn. We kunnen dan het verbruik gaan vergelijken en bepalen welk merk benzine het beste is. Gepaarde of ongepaarde data vergt een andere aanpak en het is dus zeer belangrijk om dit onderscheid te maken op basis van het experiment.

Vooraleer een test uit te voeren op de data, is het ook steeds een goed idee om de boxplots van beide steekproeven naast elkaar uit te zetten (dus op dezelfde schaal) en zo een grafische vergelijking te maken. Hieruit kunnen soms al duidelijke verschillen naar boven komen. Zeker als de beide boxplots geen overlap hebben, kan men zo goed als zeker veronderstellen dat de gemiddelden van de beide steekproeven verschillend zullen zijn.

6.2.1 Bij ongepaarde waarnemingen

Om bij ongepaarde waarnemingen iets zinnigs te kunnen besluiten, veronderstelt men dat de twee steekproeven afkomstig zijn van normale verdelingen met *dezelfde* (onbekende) σ . Dit wil zeggen dat

$$\sigma_1 = \sigma_2 =: \sigma.$$

Het is zeer belangrijk om te testen of deze aanname klopt, vooraleer men een test voor het vergelijken van de gemiddelden opstelt. Men dient dus eerst een F -test te doen op de data en na te gaan dat effectief $\sigma_1 = \sigma_2$ geldt.

Indien dit zo is, herleiden de steekproeven zich tot

$$\begin{aligned} X_1, \dots, X_{n_1} &\sim \mathcal{N}(\mu_1, \sigma^2) \\ Y_1, \dots, Y_{n_2} &\sim \mathcal{N}(\mu_2, \sigma^2) \end{aligned} \quad \mu_1, \mu_2, \sigma \text{ onbekend}$$

We beschikken nu dus over $n_1 + n_2$ onafhankelijke en onder H_0 gelijk verdeelde stochastieken $X_1, \dots, X_{n_1}, Y_1, \dots, Y_{n_2}$.

Het doel is om na te gaan of $\mu_1 = \mu_2$.

Indien $\sigma = \sigma_1 = \sigma_2$ bekend is, geldt dat $\bar{X} - \bar{Y} \sim \mathcal{N}\left(\mu_1 - \mu_2, \frac{\sigma^2}{n_1} + \frac{\sigma^2}{n_2}\right)$ of ook dat

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim \mathcal{N}(0, 1).$$

In de praktijk zullen de varianties echter meestal niet bekend zijn en dus hebben we een schatting van σ^2 nodig. Het spreekt vanzelf dat we hiervoor *alle* data (dus beide steekproeven) zullen gebruiken. We schatten in dit geval σ^2 met behulp van de **gewogen** of **gepoolde** of **gemengde variantie**

$$\tilde{S}^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{(n_1 - 1) + (n_2 - 1)}$$

waarbij S_1^2 de steekproefvariantie is van $X_1, \dots, X_{n_1}$ en S_2^2 de steekproefvariantie van $Y_1, \dots, Y_{n_2}$. $\tilde{S}^2$ is dus een gewogen gemiddelde is van de steekproefvarianties S_1^2 en S_2^2 , waaruit eenvoudig volgt dat

$$\begin{aligned} E[\tilde{S}^2] &= E\left[\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{(n_1 - 1) + (n_2 - 1)}\right] \\ &= \sigma^2 \end{aligned}$$

en bijgevolg is $\tilde{S}^2$ een onvertekende schatter voor σ^2 .

Verder kunnen we aantonen dat

Stelling.

$$T := \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\tilde{S} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{(n_1-1)+(n_2-1)} = t_{n_1+n_2-2}.$$

Bewijs. Aangezien $\bar{X} \sim \mathcal{N}\left(\mu_1, \frac{\sigma^2}{n_1}\right)$ en $\bar{Y} \sim \mathcal{N}\left(\mu_2, \frac{\sigma^2}{n_2}\right)$ en beide steekproeven onafhankelijk zijn, volgt hieruit dat $\bar{X} - \bar{Y} \sim \mathcal{N}\left(\mu_1 - \mu_2, \frac{\sigma^2}{n_1} + \frac{\sigma^2}{n_2}\right)$, of na standaardisatie,

$$U := \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim \mathcal{N}(0, 1).$$

Daarnaast weten we dat $\frac{(n_1 - 1)S_1^2}{\sigma^2} \sim \chi_{n_1-1}^2$ en $\frac{(n_2 - 1)S_2^2}{\sigma^2} \sim \chi_{n_2-1}^2$, waaruit volgt dat

$$V := \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{\sigma^2} \sim \chi_{(n_1-1)+(n_2-1)}^2$$

omdat de steekproeven onafhankelijk zijn.

Uiteindelijk geldt dus

$$T \stackrel{!}{=} \frac{U}{\sqrt{\frac{V}{(n_1 - 1) + (n_2 - 1)}}} \sim t_{(n_1-1)+(n_2-1)}.$$

□

Uit het resultaat van vorige stelling volgt onmiddellijk dat

$$P\left(-t_{n_1+n_2-2, 1-\frac{\alpha}{2}} \leq \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\tilde{S} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \leq t_{n_1+n_2-2, 1-\frac{\alpha}{2}}\right) = 1 - \alpha.$$

Hiermee bekomen we volgend $100(1-\alpha)\%$ betrouwbaarheidsinterval voor $\mu_1 - \mu_2$ met onbekende $\sigma = \sigma_1 = \sigma_2$

$$\left[\bar{x} - \bar{y} \pm t_{n_1+n_2-2, 1-\frac{\alpha}{2}} \tilde{s} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right].$$

Uiteraard geldt onder de nulhypothese $H_0 : \mu_1 = \mu_2$ dat $\bar{X} - \bar{Y} \sim \mathcal{N}\left(0, \frac{\sigma^2}{n_1} + \frac{\sigma^2}{n_2}\right)$ of ook dat

$$\frac{\bar{X} - \bar{Y}}{\sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim \mathcal{N}(0, 1).$$

Voor onbekende $\sigma = \sigma_1 = \sigma_2$ geldt bijgevolg onder de nulhypothese $H_0 : \mu_1 = \mu_2$ dat

$$T := \frac{\bar{X} - \bar{Y}}{\tilde{S} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}.$$

Tweezijdige t -test (“two-sided two-sample t -test”)

$$\begin{cases} H_0 : \mu_1 = \mu_2 \\ H_1 : \mu_1 \neq \mu_2 \end{cases}$$

We verwerpen H_0 niet op het significantieniveau α indien de t -waarde in het aanvaardingsgebied

$$\left[-t_{n_1+n_2-2, 1-\frac{\alpha}{2}}, t_{n_1+n_2-2, 1-\frac{\alpha}{2}} \right]$$

ligt. De p -waarde wordt in dit geval gegeven door

$$p = 2P_{H_0}(T \geq |t|).$$

Eenzijdige t -test (“one-sided two-sample t -test”)

$$\begin{cases} H_0 : \mu_1 \leq \mu_2 \\ H_1 : \mu_1 > \mu_2 \end{cases}$$

In dit geval is het aanvaardingsgebied gelijk aan $]-\infty, t_{n_1+n_2-2, 1-\alpha}]$ en de overschrijdingskans is

$$p = P_{H_0}(T \geq t).$$

Voor de linkseenzijdige test

$$\begin{cases} H_0 : \mu_1 \geq \mu_2 \\ H_1 : \mu_1 < \mu_2 \end{cases}$$

wordt het aanvaardingsgebied $[-t_{(n_1-1)+(n_2-1), 1-\alpha}, +\infty[$ en de p -waarde

$$p = P_{H_0}(T \leq t).$$

Voorbeeld. Een boer wil testen of een bepaalde kunstmeststof een verbetering van de graanoogst geeft. Daarvoor kiest hij 15 stroken akker met dezelfde oppervlakte, waarvan er 8 worden behandeld met de meststof en de overige 7 niet (deze laatste vormen de **controlegroep**). De gemiddelde graanopbrengst op de behandelde akkers is 5.8 ton met een standaardafwijking van 0.36 ton. Voor de controlegroep is de gemiddelde opbrengst 4.9 ton met standaardafwijking 0.40 ton. Mag men besluiten dat de productie significant hoger is op de behandelde akkers ($\alpha = 1\%$)?

Dit is een *eenzijdige* probleemstelling:

$$\begin{cases} H_0 : \mu_1 \leq \mu_2 & (\text{het waargenomen verschil is enkel toevallig}) \\ H_1 : \mu_1 > \mu_2 & (\text{de kunstmeststof verhoogt de opbrengst}) \end{cases}$$

Ga (met een tweezijdige F -test) na dat $\sigma_1^2 = \sigma_2^2$ en we dus de hierboven beschreven t -test mogen uitvoeren.

De gemengde variantie wordt

$$\tilde{s}^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{(n_1 - 1) + (n_2 - 1)} = \frac{7(0.36)^2 + 6(0.40)^2}{7 + 6} = 0.1436 \text{ ton}^2$$

zodat $\tilde{s} = 0.379$ ton. Bijgevolg is

$$t = \frac{\bar{x} - \bar{y}}{\tilde{s}\sqrt{\frac{1}{8} + \frac{1}{7}}} = \frac{5.8 \text{ ton} - 4.9 \text{ ton}}{(0.379 \text{ ton})(0.5175)} = 4.59.$$

Het aanvaardingsgebied $]-\infty, t_{13,0.99}] =]-\infty, 2.6503]$ bevat t niet, dus besluiten we dat de gemiddelde verhoging significant is en de meststof gemiddeld gezien dus effectief werkt.

De oplossing via de p -waarde is

$$p = P_{H_0}(T \geq t) = P_{H_0}(T \geq 4.59) = 0.0003 \leq 0.001$$

en dus significant op het 0.1% niveau $\Rightarrow + + +$.

Opmerking. We hebben in deze paragraaf aangenomen dat $\sigma_1 = \sigma_2$. Indien beide niet gelijk zijn, heeft het uiteraard geen zin om ze door eenzelfde gemengde variantie te schatten. In het algemene geval

$$\begin{aligned} X_1, \dots, X_{n_1} &\sim \mathcal{N}(\mu_1, \sigma_1^2) \\ Y_1, \dots, Y_{n_2} &\sim \mathcal{N}(\mu_2, \sigma_2^2) \end{aligned} \quad \mu_1, \mu_2, \sigma_1, \sigma_2 \text{ onbekend}$$

bestaat er geen exacte test voor $\mu_1 \stackrel{?}{=} \mu_2$, maar zijn er wel benaderingen mogelijk. Wanneer n_1 en n_2 groot zijn, is het alsof σ_1^2 en σ_2^2 bekend zouden zijn omdat $s_1^2 \approx \sigma_1^2$ en $s_2^2 \approx \sigma_2^2$. Indien we aannemen dat σ_1^2 en σ_2^2 bekend zijn kunnen we als volgt tewerk gaan:

$$\bar{X} - \bar{Y} \sim \mathcal{N}\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right)$$

of onder de nulhypothese

$$Z := \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim \mathcal{N}(0, 1).$$

Als aanvaardingsgebied voor Z nemen we dan:

- Tweezijdig: $[-z_{1-\alpha/2}, z_{1-\alpha/2}]$
- Eenzijdig: $] -\infty, z_{1-\alpha}]$ of $[-z_{1-\alpha}, +\infty[$.

Voor kleinere steekproeven kan men aantonen dat, onder de nulhypothese,

$$T := \frac{\bar{X} - \bar{Y}}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \approx t_r \quad \text{met } r = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}$$

en hiermee verder werken (Behrens-Fisher probleem). Merk op dat r zelf een stochastische variabele is, maar in de praktijk benaderd wordt door de schatters S_1^2 en S_2^2 te vervangen door hun steekproefschattingen s_1^2 en s_2^2 (het resultaat is in het algemeen geen natuurlijk getal).

6.2.2 Bij gepaarde waarnemingen

Bij de voorgaande test worden twee steekproeven $X_1, \dots, X_{n_1}$ en $Y_1, \dots, Y_{n_2}$ die op geen enkele manier afhankelijk van elkaar zijn vergeleken (in het voorbeeld werden de 22 random gekozen auto's immers geheel willekeurig in twee groepen verdeeld). Soms heeft het zin om de data opzettelijk afhankelijk van elkaar te maken door waarnemingen te paren. Een reden hiervoor kan zijn dat er meer factoren zijn die mogelijk een invloed hebben op de uitkomst. Corrigeren voor het effect van deze factoren kan de onderzoeksresultaten betrouwbaarder maken. In het bovenstaande voorbeeld hebben merk en leeftijd van de auto mogelijk een invloed op het benzineverbruik. Om hier rekening mee te houden bij het vergelijken van de twee benzinemerken, wordt dezelfde auto gebruikt voor beide merken. Zoals reeds vermeld betekent dit dat er met elke X_i precies één Y_i overeenkomt, en dus i.h.b. is $n_1 = n_2$.

Andere voorbeelden van gepaarde waarnemingen zijn:

- vergelijken van metingen in linkeroor en rechteroor,
- eigenschappen vergelijken bij tweelingen bestaande uit een jongen en een meisje.

In het algemeen hebben we dus n koppels (X_i, Y_i) met $X_i \sim \mathcal{N}(\mu_1, \sigma_1^2)$ en $Y_i \sim \mathcal{N}(\mu_2, \sigma_2^2)$ en het doel is te testen of $H_0 : \mu_1 = \mu_2$.

Dit probleem kan herleid worden tot het geval van één steekproef door een nieuwe variabele in te voeren:

$$D_i := X_i - Y_i \quad i = 1, \dots, n.$$

Voor deze geldt $E[D_i] = \mu_1 - \mu_2 =: \mu$. Als D_i opnieuw normaal verdeeld is (dit is bijvoorbeeld, maar niet uitsluitend, het geval indien de (X_i, Y_i) bivariaat normaal verdeeld zijn) dan geldt

$$D_1, \dots, D_n \sim \mathcal{N}(\mu, \sigma^2)$$

met onbekende $\sigma^2 \neq \sigma_1^2 + \sigma_2^2$ en $\mu = \mu_1 - \mu_2$.

Het nieuwe testprobleem is

$$\begin{cases} H_0 : \mu = 0 \\ H_1 : \mu \neq 0 \end{cases}$$

of een eenzijdige variant hiervan. Bij eerdere parameter testen hebben we gezien dat

$$T = \frac{\bar{D} - 0}{S_D/\sqrt{n}} \sim t_{n-1} \quad |H_0$$

$$\text{met } \bar{D} = \frac{1}{n} \sum_{i=1}^n D_i \text{ en } S_D^2 = \frac{1}{n-1} \sum_{i=1}^n (D_i - \bar{D})^2.$$

Voorbeeld. Men wil testen of benzine Y beter is dan benzine X . De afgelegde afstanden (in km) met 8 liter benzine zijn

auto nr.	1	2	3	4	5	6	7	8	9	10
benzine X	99	110	105	101	90	92	104	100	101	98
benzine Y	95	110	111	110	91	99	106	100	104	102
D	4	0	-6	-9	-1	-7	-2	0	-3	-4

We vinden eenvoudig dat:

$$\begin{aligned} \bar{d} &= \frac{1}{10}(-28) = -2.8 \text{ km} \\ s_D^2 &= \frac{1}{9}(46.24 + \dots + 1.44) = 14.844 \text{ km}^2 \\ s_D &= 3.853 \text{ km} \\ t &= \frac{\bar{d}_{10}}{s_D/\sqrt{10}} = -2.298. \end{aligned}$$

Aangezien we willen testen of Y *beter* is dan X , is de probleemstelling eenzijdig:

$$\begin{cases} H_0 : \mu \geq 0 \\ H_1 : \mu < 0 \end{cases}$$

Het aanvaardingsgebied is $[-t_{9,1-\alpha}, +\infty[$. Kiezen we

- $\alpha = 5\%$, dan is het aanvaardingsgebied $[-1.833, +\infty[\Rightarrow$ significant,
- $\alpha = 1\%$, dan is het aanvaardingsgebied $[-2.821, +\infty[\Rightarrow$ niet significant.

We kunnen ook de p -waarde berekenen. Vermits $H_1 : \mu < 0$ wordt dit

$$p = P_{H_0}(T \leq -2.298) = 0.0236 \Rightarrow +$$

wat de conclusie hierboven bevestigt.

6.3 Vergelijken van twee proporties

Testproblemen omtrent verschillen van proporties kunnen eveneens als twee-steekproef-problemen beschouwd worden.

Indien men wil nagaan of de kansen op twee verschillende gebeurtenissen G_1 en G_2 al dan niet verschillend zijn, zal men trachten om $P(G_1) - P(G_2) := p_1 - p_2$ af te schatten met behulp van een verschil van relatieve frequenties $\hat{P}_1 - \hat{P}_2$. Hierbij is $\hat{P}_1$ de relatieve frequentie van het voorkomen van gebeurtenis G_1 in een rij van n_1 onafhankelijke Bernoulli experimenten en $\hat{P}_2$ de relatieve frequentie dat G_2 voorkomt in een rij van n_2 Bernoulli experimenten, waarbij beide experimenten *onafhankelijk van elkaar* uitgevoerd worden.

Men kan eenvoudig nagaan (wegens de onafhankelijkheid van de beide experimenten) dat

$$\begin{aligned} E[\hat{P}_1 - \hat{P}_2] &= p_1 - p_2 \\ \text{Var}[\hat{P}_1 - \hat{P}_2] &= \text{Var}[\hat{P}_1] + \text{Var}[\hat{P}_2] = \frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}. \end{aligned}$$

Als n_1 en n_2 groot genoeg zijn, vertelt de centrale limietstelling ons bovendien dat, bij benadering,

$$Z := \frac{(\hat{P}_1 - \hat{P}_2) - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}} \approx \mathcal{N}(0, 1).$$

De test die we dan uitvoeren is

$$\begin{cases} H_0 : p_1 = p_2 \\ H_1 : p_1 \neq p_2 \end{cases} \quad \text{of ook} \quad \begin{cases} H_0 : p_1 - p_2 = 0 \\ H_1 : p_1 - p_2 \neq 0 \end{cases}$$

(of een equivalente eenzijdige test). We kunnen dan een $1 - \alpha$ betrouwbaarheidsinterval opstellen voor $p_1 - p_2$:

$$\begin{aligned}
1 - \alpha &= P \left(-\Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \leq \frac{(\hat{P}_1 - \hat{P}_2) - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}} \leq \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \right) \\
&= P \left((\hat{P}_1 - \hat{P}_2) - \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}} \leq (p_1 - p_2) \right. \\
&\quad \left. \leq (\hat{P}_1 - \hat{P}_2) + \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}} \right).
\end{aligned}$$

Indien we nu p_1 vervangen door $\hat{p}_1$ en p_2 door $\hat{p}_2$, dan vinden we een betrouwbaarheidsinterval met *benaderend* betrouwbaarheidsniveau α :

$$\left[(\hat{p}_1 - \hat{p}_2) \pm \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}} \right].$$

Voor het aanvaardingsgebied redeneren we analoog. We weten dat het aanvaardingsgebied opgesteld wordt onder H_0 en dus dat $p_1 - p_2 = 0$ en verder zullen we ook hier voor de berekening van de testwaarde p_1 vervangen door $\hat{p}_1$ en p_2 door $\hat{p}_2$. Dit geeft dan als aanvaardingsgebied

$$\left[-\Phi^{-1}\left(1 - \frac{\alpha}{2}\right), \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \right]$$

voor de benaderende teststatistiek (onder H_0)

$$Z := \frac{(\hat{P}_1 - \hat{P}_2)}{\sqrt{\frac{\hat{P}_1(1-\hat{P}_1)}{n_1} + \frac{\hat{P}_2(1-\hat{P}_2)}{n_2}}} \approx \mathcal{N}(0, 1).$$

Verder kunnen we $H_0 : p_1 - p_2 = 0$ ook verwerpen ten voordele van $H_1 : p_1 - p_2 \neq 0$ indien

$$p = 2P_{H_0} \left(Z \geq \frac{|\hat{p}_1 - \hat{p}_2|}{\sqrt{\frac{\hat{p}_1(1-\hat{p}_1)}{n_1} + \frac{\hat{p}_2(1-\hat{p}_2)}{n_2}}} \right)$$

een waarde aanneemt die kleiner is dan het gekozen significantieniveau α .

Een andere versie van deze test gebruikt een gemengde proportie. Omdat er onder H_0 verondersteld wordt dat $p_1 = p_2$, zal men deze schatten door middel van

$$\hat{p}_0 := \frac{n_1 \hat{p}_1 + n_2 \hat{p}_2}{n_1 + n_2}.$$


De p -waarde wordt dan in dat geval

$$p = 2P_{H_0} \left(Z \geq \frac{|\hat{p}_1 - \hat{p}_2|}{\sqrt{\hat{p}_0(1-\hat{p}_0) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \right).$$

VERDELINGSTOETSEN

7.1 Testen van een discrete verdeling

Men wil testen of de waarnemingen X_i komen uit een gegeven discrete verdeling gedefinieerd op een verzameling met k waarden $\{z_1, \dots, z_k\}$ met theoretische kansen $\{p_1, \dots, p_k\}$.



De nulhypothese wordt

$$H_0 : X_1, \dots, X_n \sim \text{de theoretische discrete verdeling}$$

Na uitvoering van het experiment krijgen we n waarden uit $\{z_1, \dots, z_k\}$. We berekenen hierop de waargenomen (empirische) frequenties

$$N_1 = \text{aantal } X_i \text{ die gelijk zijn aan } z_1$$

$$N_2 = \text{aantal } X_i \text{ die gelijk zijn aan } z_2$$

$$\vdots$$

$$N_k = \text{aantal } X_i \text{ die gelijk zijn aan } z_k$$

waar $N_1 + N_2 + \dots + N_k = n$ de steekproefgrootte.

Als H_0 waar is, dan voldoet de frequentie N_1 aan

$$N_1 = \text{aantal successen uit } n \text{ onafhankelijke experimenten} \sim B(n, p_1)$$

De benadering van Poisson levert dan

$$N_1 \approx P(\lambda) \text{ met } \lambda = np_1$$

Veronderstellen we dat $\lambda = np_1$ groot is, dan kunnen we de ‘normale’ benadering doorvoeren.

$$\frac{N_1 - np_1}{\sqrt{np_1}} = \frac{N_1 - \lambda}{\sqrt{\lambda}} \approx N(0, 1)$$

Als we dit herhalen voor $j = 1, \dots, k$ dan kunnen we de som

$$\left(\frac{N_1 - np_1}{\sqrt{np_1}}\right)^2 + \left(\frac{N_2 - np_2}{\sqrt{np_2}}\right)^2 + \dots + \left(\frac{N_k - np_k}{\sqrt{np_k}}\right)^2$$

berekenen en deze is benaderend χ^2 verdeeld. Het aantal vrijheidsgraden is niet k maar $k - 1$ omdat er een relatie is tussen de N_i 's.

Bijvoorbeeld: N_k is volledig bepaald door de overige, want

$$N_k = n - N_1 - \dots - N_{k-1}.$$

Dus geldt er,

$$\sum_{j=1}^k \left(\frac{N_j - np_j}{\sqrt{np_j}}\right)^2 \approx \chi_{k-1}^2 \quad | H_0 \quad (\text{K.Pearson})$$


Men kan dit ook uitdrukken als volgt:

$$\sum \frac{(\text{waargenomen frequenties} - \text{theoretische frequenties})^2}{\text{theoretische frequenties}}$$

De teststatistiek is altijd positief en als ze nul is, wil dit zeggen dat

$$N_1 - np_1 = 0, \dots, N_k - np_k = 0 \quad (\text{ideaal geval})$$

Om H_0 te testen is dus het nodig om te kijken of de statistiek niet te groot is.



Het aanvaardingsgebied is dan $[0, \chi_{k-1;1-\alpha}^2]$.


Voorbeeld

Een bibliothecaris wil weten of het aantal geleende boeken op maandag, dinsdag, woensdag, donderdag, vrijdag en zaterdag een uniforme verdeling heeft. We testen deze hypothese ($\alpha = 5\%$, $\alpha = 1\%$) aan de hand van de gegevens:

dag	ma.	di.	woe.	do.	vrij.	zat.
aantal boeken	26	32	23	29	34	41

$$k = 6, n = n_1 + \dots + n_6 = 185$$

De theoretische verdeling: alle $p_j = \frac{1}{6}$



Alle theoretische frequenties zijn $np_j = \frac{185}{6} = 30.833$

De teststatistiek wordt

$$\begin{aligned}
 & \sum_{j=1}^6 \frac{(n_j - 30.833)^2}{30.833} \quad (\text{geen dimensies!}) \\
 &= \frac{1}{30.833} \{23.361 + 1.361 + 61.361 + 3.361 + 10.028 + 103.361\} \\
 &= \frac{202.833}{30.833} = 6.578
 \end{aligned}$$

Het aanvaardingsgebied wordt dan:

$$\begin{aligned}
 \alpha = 5\% \quad [0, \chi_{5,0.95}^2] &= [0, 11.070] \quad \text{bevat } 6.578 \\
 \alpha = 1\% \quad [0, \chi_{5,0.99}^2] &= [0, 15.086] \quad \text{bevat } 6.578
 \end{aligned}$$

In de twee gevallen wordt de H_0 hypothese aanvaard, dus de afwijking van de uniformiteit is niet significant.

Opmerkingen

- (1) Om de benadering door een χ^2 -verdeling te rechtvaardigen hebben we verondersteld dat de np_j groot genoeg waren. In de praktijk wil men dat de np_j (= de theoretische frequenties) groter of gelijk zijn aan 5. Als het mogelijk is, neemt men een grote n . Indien niet, dan verhoogt men de theoretische frequenties door de z_j te hergroeperen in klassen. In het bijzonder is het altijd nodig te hergroeperen in klassen als het aantal mogelijke waarden z_j oneindig is. Het aantal klassen wordt genoteerd met k en men gebruikt dezelfde formules als voordien.
- (2) Soms gebruikt men hetzelfde experiment eerst voor de schatting van v parameters van de theoretische verdeling. In dat geval wordt het aantal vrijheidsgraden met v verminderd en werken we dus met χ_{k-v-1}^2 .

Voorbeeld

Men wil de hypothese testen dat een steekproef $x_1, \dots, x_{80}$ getrokken is uit een Poisson verdeling ($\alpha = 5\%$ en $\alpha = 1\%$).


De geobserveerde waarden zijn

z_j	0	1	2	3	4	5	6	≥ 7
n_j	7	25	19	16	9	3	1	0

Als de steekproef werkelijk uit een Poissonverdeling komt, wat is dan de parameter λ ? Men kan λ eerst schatten met de zuivere (of onvertekende) schatter $\bar{X}_n$ ($E[\bar{X}_n] = \lambda$):

$$\begin{aligned}\bar{x}_{80} &= \frac{1}{80} \sum_{i=1}^{80} x_i = \frac{1}{80} \{7 \times 0 + 25 \times 1 + 19 \times 2 + 16 \times 3 + 9 \times 4 + 3 \times 5 + 1 \times 6\} \\ &= \frac{168}{80} = 2.1\end{aligned}$$

Door gebruik te maken van de kansmassafunctie van de Poissonverdeling met parameter 2.1, vindt men de waarden voor p_j :



Dit geeft ons de theoretische frequenties $= 80p_j$:

z_j	0	1	2	3	4	5	6	≥ 7
np_j	9.80	20.57	21.60	15.12	7.94	3.34	1.16	0.47

We beschouwen vijf klassen: $\{0\}, \{1\}, \{2\}, \{3\}, \{4, 5, 6, 7, \dots\}$

De teststatistiek wordt

$$\begin{aligned}& \sum_{j=1}^5 \frac{(\text{geobserveerde frequenties} - \text{theoretische frequenties})^2}{\text{theoretische frequenties}} \\ &= \frac{(7 - 9.80)^2}{9.80} + \frac{(25 - 20.57)^2}{20.57} + \frac{(19 - 21.60)^2}{21.60} + \frac{(16 - 15.12)^2}{15.12} + \frac{(13 - 12.91)^2}{12.91} \\ &= 0.80 + 0.95 + 0.31 + 0.05 + 0.0006 \approx 2.11\end{aligned}$$

We hebben één parameter geschat dus is het aantal vrijheidsgraden gelijk aan

$$k - 1 - 1 = 5 - 1 - 1 = 3.$$

Het aanvaardingsgebied:

$$\begin{aligned}\alpha = 5\% \quad [0, \chi_{3,0.95}^2] &= [0, 7.815] \quad \text{bevat 2.11} \\ \alpha = 1\% \quad [0, \chi_{3,0.99}^2] &= [0, 11.345] \quad \text{bevat 2.11}\end{aligned}$$

Dus de nulhypothese wordt aanvaard.

7.2 Testen van een continue verdeling

7.2.1 χ^2 -test

Om te testen of de waarnemingen komen uit een gegeven continue verdeling

$$H_0 : X_1, X_2, \dots, X_n \sim \text{continue verdeling}$$

gaat men opnieuw de verdeling opsplitsen in k klassen en men berekent de theoretische kansen p_j en de theoretische frequenties np_j zodat $np_j \geq 5$, $\forall j = 1, \dots, k$ (zoniet, combineer de klassen).

De waargenomen frequenties zijn

$$N_j = \text{aantal } X_i \text{ die behoren tot klasse } j.$$

En we krijgen opnieuw:

$$\sum_{j=1}^k \left(\frac{N_j - np_j}{\sqrt{np_j}} \right)^2 \approx \chi_{k-1}^2 \quad | H_0$$

Als we dezelfde gegevens gebruiken om v parameters te schatten, nemen we χ_{k-v-1}^2 .

Voorbeeld

Van 300 voorbijrijdende auto's heeft men de snelheid gemeten:

$$(x_1, \dots, x_i, \dots, x_{300})$$

We beschikken niet over de ruwe gegevens, enkel over de indeling van de snelheden in 10 klassen:

$$]44.5, 49.5],]49.5, 54.5], \dots,]89.5, 94.5]$$

Elke klasse heeft een **centrum** c_i (=klassemidden).

klasse	c_j	n_j
]44.5, 49.5]	47	8
]49.5, 54.5]	52	6
]54.5, 59.5]	57	29
]59.5, 64.5]	62	63
]64.5, 69.5]	67	60
]69.5, 74.5]	72	74
]74.5, 79.5]	77	29
]79.5, 84.5]	82	14
]84.5, 89.5]	87	15
]89.5, 94.5]	92	2
totaal		300

Men wil testen of de observaties uit een normale verdeling $N(\mu, \sigma^2)$ komen ($\alpha = 5\%$).

Men moet eerst de parameters μ en σ schatten. We gebruiken hiervoor de centra c_j en de geobserveerde frequenties n_j :

$$\begin{aligned}\bar{x}_n &= \frac{1}{n} \sum_{j=1}^k n_j c_j = \frac{1}{300} 20465 = 68.22 \\ s_n^2 &= \frac{1}{n-1} \sum_{j=1}^k n_j (c_j - \bar{x}_n)^2 = \frac{1}{299} 23730.9 = 79.36 \\ s_n &= \sqrt{s_n^2} = 8.91\end{aligned}$$

Voor de verdeling $N(68.22, 79.36)$ kan men de kansen per klasse berekenen, bijvoorbeeld

$$\begin{aligned}P[49.5, 54.5[&= P[49.5 \leq X \leq 54.5] \quad \text{met } X \sim N(68.22, 79.36) \\ &= P\left[\frac{49.5 - 68.22}{8.912} \leq Z \leq \frac{54.5 - 68.22}{8.912}\right] \quad \text{met } Z \sim N(0, 1) \\ &= P[-2.10 \leq Z \leq -1.54] \\ &= P[1.54 \leq Z \leq 2.10] \\ &= \Phi(2.10) - \Phi(1.54) = 0.982 - 0.938 = 0.044\end{aligned}$$

Dit levert de theoretische frequenties. Merk op dat we de laagste en de hoogste klasse uitbreiden tot $-\infty$ en $+\infty$ zodat de som van de theoretische kansen gelijk is aan 1. We moeten de laatste twee klassen combineren dus $k = 9$.

De teststatistiek wordt $\sum_{j=1}^9 \frac{(n_j - np_j)^2}{np_j} = 21.64$

We hebben μ en σ moeten schatten dus hebben we $\chi_{k-v-1}^2 = \chi_{9-2-1}^2 = \chi_6^2$. Het aanvaardingsgebied $= [0, \chi_{6,0.95}^2] = [0, 12.592]$ bevat 21.64 niet dus de nulhypothese wordt verworpen op het niveau $\alpha = 5\%$.

klasse	p_j	np_j	n_j	$\frac{(n_j - np_j)^2}{np_j}$
$]-\infty, 49.5]$	0.018	5.4	8	1.25
$]49.5, 54.5]$	0.044	13.2	6	3.93
$]54.5, 59.5]$	0.102	30.6	29	0.08
$]59.5, 64.5]$	0.173	51.9	63	2.37
$]64.5, 69.5]$	0.219	65.7	60	0.49
$]69.5, 74.5]$	0.202	60.6	74	2.96
$]74.5, 79.5]$	0.140	42.0	29	4.02
$]79.5, 84.5]$	0.068	20.4	14	2.01
$]84.5, 89.5]$	0.026	7.8	15	4.53
$]89.5, +\infty]$	0.008	2.4	2	
totaal	1.000	300	300	21.64

7.2.2 Kolmogorov-Smirnov test

We vertrekken van een steekproef $X_1, X_2, \dots, X_n$ uit een continue verdeling. We willen nagaan of deze steekproef afkomstig is uit een specifieke verdeling P .

De nulhypothese van deze test is dus:


$$H_0 : X_1, X_2, \dots, X_n \sim P$$

tegenover

$$H_1 : X_1, X_2, \dots, X_n \text{ komen niet uit de verdeling } P$$

De Kolmogorov-Smirnov test zal hiertoe de verdelingsfunctie F_P van P en de empirische verdelingsfunctie $\hat{F}_n$ van de steekproef met elkaar vergelijken, waarbij

$$\hat{F}_n(x) = \frac{1}{n} \#\{i; X_i \leq x\}.$$



De teststatistiek is gedefinieerd als het maximale verschil tussen beide verdelingsfuncties:

$$D = \sup_x |\hat{F}_n(x) - F_P(x)|.$$

Kritische waarden voor deze test zijn terug te vinden in tabellen.

Het voordeel van de Kolmogorov-Smirnov test is dat hij exact is, en dus, in tegenstelling tot de χ^2 -test, geen voorwaarden oplegt aan de grootte van de dataset.

TOETSEN VAN ONAFHANKELIJKHEID

8.1 Onafhankelijkheid van discrete veranderlijken

Men heeft een steekproef $\{(X_1, Y_1); (X_2, Y_2); \dots, (X_n, Y_n)\}$ waar X_i en Y_i verbonden zijn (of gekoppeld).

De variabelen zijn discreet en mogen zelfs binair of nominaal zijn. Bijvoorbeeld heeft men n personen waarvan men registreert:

Variabele X: man/vrouw

Variabele Y: kleur haar: blond/bruin/zwart

Het gaat erom te testen of

H_0 : de variabelen X en Y zijn onafhankelijk.

Noteren we dan het aantal waarden van X door r en het aantal waarden van Y door k (bv. $r = 2$ en $k = 3$).

We berekenen de waargenomen frequenties:

N_{lj} = aantal waarnemingen (X_i, Y_i) waarbij $X_i = l$ en $Y_i = j$

We doen dit voor alle $l = 1, \dots, r$ en $j = 1, \dots, k$. Dan construeren we een **contingentietabel of kruistabel** met r rijen en k kolommen:

		Y			
		1	2	3	
X	1	N_{11}	N_{12}	N_{13}	$N_{1.}$
	2	N_{21}	N_{22}	N_{23}	$N_{2.}$
		$N_{.1}$	$N_{.2}$	$N_{.3}$	n

De marginale frequenties zijn de sommen van de waargenomen frequenties

$$N_{l.} = N_{l1} + N_{l2} + N_{l3} := \text{aantal } \{i; X_i = l\}$$

$$N_{.j} = N_{1j} + N_{2j} := \text{aantal } \{i; Y_i = j\}$$

Nu kunnen we de marginale kansen schatten:

$$p_{l.} = P[X = l]$$

$$p_{.j} = P[Y = j]$$

door de onvertekende (zuivere) schatters:

$$\hat{p}_{l.} = \frac{\text{aantal } X_i = l}{n} = \frac{N_{l.}}{n}$$

$$\hat{p}_{.j} = \frac{\text{aantal } Y_i = j}{n} = \frac{N_{.j}}{n}$$

Onder de nulhypothese geldt dan:

$$p_{lj} = P[X = l, Y = j] = P[X = l]P[Y = j] = p_{l.}p_{.j}$$

en we kunnen de p_{lj} schatten door

$$\hat{p}_{lj} = \hat{p}_{l.}\hat{p}_{.j}$$

$\hat{p}_{11}$	$\hat{p}_{12}$	$\hat{p}_{13}$	$\hat{p}_{1.}$
$\hat{p}_{21}$	$\hat{p}_{22}$	$\hat{p}_{23}$	$\hat{p}_{2.}$
$\hat{p}_{.1}$	$\hat{p}_{.2}$	$\hat{p}_{.3}$	1

zodat we uiteindelijk de theoretische frequenties kunnen berekenen:

$$n\hat{p}_{lj} = n\hat{p}_{l.}\hat{p}_{.j} = n \frac{N_{l.}}{n} \frac{N_{.j}}{n} = \frac{N_{l.}N_{.j}}{n}$$

Dit geeft ons de theoretische contingentietabel

$\frac{N_{1.}N_{.1}}{n}$	$\frac{N_{1.}N_{.2}}{n}$	$\frac{N_{1.}N_{.3}}{n}$	$N_{1.}$
$\frac{N_{2.}N_{.1}}{n}$	$\frac{N_{2.}N_{.2}}{n}$	$\frac{N_{2.}N_{.3}}{n}$	$N_{2.}$
$N_{.1}$	$N_{.2}$	$N_{.3}$	n

met dezelfde marginalen als voordien.

De waargenomen frequenties hebben een binomiale verdeling:

$$N_{lj} \sim B(n, p_{lj}).$$

Die kunnen we benaderen door een Poisson verdeling met parameter $\lambda = np_{lj}$ en deze kan op zijn beurt benaderd worden door een normale verdeling als np_{lj} groot genoeg is. Volgens het theorema van Pearson geldt dan dat de statistiek:

$$\sum \frac{(\text{waargenomen frequenties} - \text{theoretische frequenties})^2}{\text{theoretische frequenties}}$$

onder de nulhypothese benaderend χ^2 verdeeld is. Het aantal gevallen in de tabel is gelijk aan rk en we hebben dus rk termen. De volgende parameters hebben we geschat:

$$p_{1.} \quad p_{2.} \quad \dots \quad p_{r-1.} \quad \text{en } p_{r.} = 1 - p_{1.} - p_{2.} - \dots - p_{r-1.}$$

$$p_{.1} \quad p_{.2} \quad \dots \quad p_{.k-1} \quad \text{en } p_{.k} = 1 - p_{.1} - p_{.2} - \dots - p_{.k-1}$$

dus het totaal aantal geschatte parameters is $v = (r-1) + (k-1)$ zodat het aantal vrijheidsgraden gelijk wordt aan $rk - (r-1) - (k-1) - 1 = rk - r - k + 1 = (r-1)(k-1)$.

We hebben dus

$$\sum_{l=1}^r \sum_{j=1}^k \frac{\left(N_{lj} - \frac{N_{l.}N_{.j}}{n}\right)^2}{\frac{N_{l.}N_{.j}}{n}} \approx \chi_{(r-1)(k-1)}^2 \quad |H_0$$

als alle theoretische frequenties $\frac{N_{l,j}}{n} \geq 5$.

Het aanvaardingsgebied is $[0, \chi^2_{(r-1)(k-1); 1-\alpha}]$.

Als er theoretische frequenties zijn kleiner dan 5; hergroepeer de waarden in klassen zodat er minder gevallen zijn (en minder vrijheidsgraden voor de test).

Voorbeeld Men heeft aan 870 eerstejaarsstudenten gevraagd of ze alcohol dronken (bier, wijn,...). Er waren drie mogelijkheden:

$$\begin{aligned} X_i &= 1 && \text{regelmatig} \\ &= 2 && \text{soms} \\ &= 3 && \text{nooit} \end{aligned}$$

Vervolgens onderzocht men hun examenresultaten:

$$\begin{aligned} Y_i &= 1 && \text{niet geslaagd} \\ &= 2 && \text{geslaagd} \end{aligned}$$

We testen de onafhankelijkheid tussen deze twee. De geobserveerde frequenties zijn:

		examen		
		niet geslaagd	geslaagd	
alcohol	regelmatig	70	35	105
	soms	331	377	708
	nooit	39	18	57
		440	430	870

De theoretische frequenties onder H_0 worden dan:

53.1	51.9	105
358.1	349.9	708
28.8	28.2	57
440	430	870

De teststatistiek wordt:

$$\begin{aligned} &\frac{(70 - 53.1)^2}{53.1} + \frac{(35 - 51.9)^2}{51.9} + \frac{(331 - 358.1)^2}{358.1} + \frac{(377 - 349.9)^2}{349.9} \\ &+ \frac{(39 - 28.8)^2}{28.8} + \frac{(18 - 28.2)^2}{28.2} = 22.33 \end{aligned}$$

Vrijheidsgraden: $(r-1)(k-1) = (3-1)(2-1) = 2$

Aanvaardingsgebieden:

$$\begin{aligned} \alpha = 5\% \quad [0, \chi^2_{2,0.95}] &= [0, 5.991] \\ \alpha = 1\% \quad [0, \chi^2_{2,0.99}] &= [0, 9.210] \end{aligned}$$

Dus de hypothese van onafhankelijkheid is verworpen, zelfs voor $\alpha = 1\%$.

(Merk op dat het slaagpercentage veel hoger is voor de studenten die af en toe drinken (53 %) dan voor de twee andere groepen (33 % en 32 %).)

Opmerkingen:

- (1) De methode van χ^2 is invariant in de zin dat men hetzelfde resultaat verkrijgt door X en Y te permuteren of ook als men de code verandert (bv. $Y_i = 1$ bij succes, $Y_i = 2$ bij mislukking).
- (2) Het aantal vrijheidsgraden kan eenvoudig gerechtvaardigd worden: als men een blok van $(r-1)(k-1)$ frequenties kent en de marginale frequenties dan kan men de resterende frequenties daaruit afleiden.
- (3) Als in een 2×2 tabel de onafhankelijkheid verworpen wordt, zijn er maar 2 mogelijke situaties:

$$\begin{aligned}
 N_{11} > \frac{N_{1.}N_{.1}}{n} &\Rightarrow N_{12} < \frac{N_{1.}N_{.2}}{n} \\
 &\text{en } N_{21} < \frac{N_{2.}N_{.1}}{n} \\
 &\Rightarrow N_{22} > \frac{N_{2.}N_{.2}}{n}
 \end{aligned}$$

In dat geval is er een “positieve” relatie tussen de twee variabelen gevonden.

Of,

$$\begin{aligned}
 N_{11} < \frac{N_{1.}N_{.1}}{n} &\Rightarrow N_{12} > \frac{N_{1.}N_{.2}}{n} \\
 &\text{en } N_{21} > \frac{N_{2.}N_{.1}}{n} \\
 &\Rightarrow N_{22} < \frac{N_{2.}N_{.2}}{n}
 \end{aligned}$$

Hier kunnen we spreken van een “negatieve” relatie.

- (4) Een $2 \times k$ tabel komt overeen met een test van 2 discrete verdelingen ($k = 2 \Rightarrow$ Bernoulli)
- (5) Men kan de contingentietabel ook gebruiken voor continue variabelen als men hergroepeert in klassen.
- (6) Men kan testen $H_0 : X, Y, Z$ onafhankelijk met behulp van een driedimensionale contingentietabel met rkh gevallen en $(r-1)(k-1)(h-1)$ vrijheidsgraden.

8.2 Onafhankelijkheid van continue variabelen

Het doel is om na te gaan of twee continue verbonden variabelen X en Y onafhankelijk zijn:

$$X : \Omega \rightarrow \mathbb{R} ; Y : \Omega \rightarrow \mathbb{R}$$

Men kan enkele karakteristieke schatten vertrekkende van de steekproef $\{(X_1, Y_1); \dots; (X_n, Y_n)\}$ gebruikmakend van onvertekende schatters:

karakteristiek	zuivere schatter
$E[X]$	$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$
$E[Y]$	$\bar{Y}_n = \frac{1}{n} \sum_{i=1}^n Y_i$
$\text{Var}[X] = E[(X - E[X])^2]$	$S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$
$\text{Var}[Y] = E[(Y - E[Y])^2]$	$S_Y^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y}_n)^2$
$\text{Cov}[X, Y] = E[(X - E[X])(Y - E[Y])]$	$S_{XY} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)(Y_i - \bar{Y}_n)$

De covariantie lijkt op de variantie, maar is gebaseerd op twee variabelen en kan ook negatief zijn. Het bewijs dat S_{XY} een zuivere schatter is, is analoog aan dat van S_X^2 . De variantie is een speciaal geval van de covariantie:

$$\begin{array}{l|l} \text{Cov}[X, X] = \text{Var}[X] & S_{XX} = S_X^2 \\ \text{Cov}[Y, Y] = \text{Var}[Y] & S_{YY} = S_Y^2 \end{array}$$

Enkele eigenschappen van de covariantie:

$$\begin{array}{l|l} \text{Cov}[X, Y] = \text{Cov}[Y, X] & S_{XY} = S_{YX} \\ \text{Cov}[aX + b, cY + d] = ac \text{Cov}[X, Y] & S_{aX+b, cY+d} = acS_{XY} \end{array}$$

De covariantie heeft als eenheden deze van X keer Y . Als men een lineaire transformatie $X \rightarrow aX$ of $X \rightarrow aX + b$ uitvoert dan worden de covarianties eveneens met a vermenigvuldigd. (Vb. Fahrenheit omzetten in Celsius).

Om te testen of X en Y onafhankelijk zijn verkiest men iets zonder eenheden en invariant voor transformaties.

Definitie. De correlatie van X en Y is

$$\text{Corr}[X, Y] = \frac{\text{Cov}[X, Y]}{\sqrt{\text{Var}[X]\text{Var}[Y]}}$$

De empirische correlatie tussen X en Y is dan

$$R = R_{XY} = \frac{S_{XY}}{\sqrt{S_X^2 S_Y^2}} = \frac{\sum_{i=1}^n (X_i - \bar{X}_n)(Y_i - \bar{Y}_n)}{\sqrt{\sum_{i=1}^n (X_i - \bar{X}_n)^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y}_n)^2}}$$

Andere namen zijn: Pearson correlatie, correlatiecoëfficiënt, lineaire correlatie, correlatie van Bravais-Pearson. Merk op dat R_{XY} een goede schatter is voor $\text{Corr}[X, Y]$ maar met een kleine vertekening ($E[R_{XY}] \neq \text{Corr}[X, Y]$).

De correlatie heeft geen eenheden en is invariant onder transformaties $X \rightarrow aX + b$. De correlatie is ligt altijd tussen -1 en 1.

Eigenschappen:

$$\begin{array}{l|l}
-1 \leq \text{Corr}[X, Y] \leq 1 & -1 \leq R_{XY} \leq 1 \\
\text{Corr}[X, X] = 1 & R_{XX} = 1 \\
\text{Corr}[X, Y] = \text{Corr}[Y, X] & R_{XY} = R_{YX} \\
\text{Corr}[aX + b, cY + d] = \text{Corr}[X, Y] \text{ met } a, c > 0 & R_{aX+b, cY+d} = R_{XY}
\end{array}$$

Stelling. Als X en Y onafhankelijk zijn dan is $\text{Corr}[X, Y] = 0$.

Bewijs. $\text{Corr}[X, Y] = \frac{\text{Cov}[X, Y]}{\sqrt{\text{Var}[X]\text{Var}[Y]}} = 0$

met $\text{Cov}[X, Y] = E[(X - E[X])(Y - E[Y])] = E[X - E[X]]E[Y - E[Y]]$
 $= (E[X] - E[X])(E[Y] - E[Y]) = 0$. □

Het omgekeerde is niet altijd waar!

Voorbeeld: als $X \sim N(0, 1)$ en $Y = X^2$ dan zijn X en Y afhankelijk en toch geldt er

$$\begin{aligned}
\text{Cov}[X, Y] &= E[(X - E[X])(Y - E[Y])] = E[X(X^2 - E[X^2])] \\
&= E[X(X^2 - 1)] = E[X^3 - X] = E[X^3] - E[X] = 0 - 0 = 0
\end{aligned}$$

In het geval van een lineaire relatie $Y = aX + b$ ($a \neq 0$) geldt:


$$\begin{aligned}
\text{Cov}[X, Y] &= \text{Cov}[X, aX + b] = a\text{Cov}[X, X] = a\text{Var}[X] \\
\text{Corr}[X, Y] &= \frac{a\text{Var}[X]}{\sqrt{\text{Var}[X]\text{Var}[X]a^2}} = \frac{a}{\sqrt{a^2}} = \begin{cases} +1 & \text{als } a > 0 \\ -1 & \text{als } a < 0 \end{cases}
\end{aligned}$$

Omwille van deze relatie noemt men dit ook de lineaire correlatie.

Als men observaties $(x_1, y_1), \dots, (x_n, y_n)$ heeft, kan men deze representeren als punten met 2 coördinaten. Bekijken we enkele steekproeven en hun correlatie.


$r_{xy} = 1.0$: de puntenwolk is gereduceerd tot een rechte, een perfect positieve relatie

$r_{xy} = -1.0$: een perfecte negatieve relatie




$r_{xy} \approx 0.5$: positieve relatie, een verhoogde waarde van X_i komt overeen met een verhoogde waarde van Y_i


$r_{xy} \approx -0.5$: negatieve relatie, met een verhoogde waarde van X_i komt een verlaagde waarde van Y_i overeen



$r_{xy} \approx 0.0^2$: geen relatie, met elke waarde van X_i komt een willekeurige waarde van Y_i overeen.



In het laatste geval geldt bovendien dat de vorm van de wolk sferisch of elipsoïdaal is als de variabelen X en Y onafhankelijk zijn en normaal verdeeld. Als X en Y uniform verdeeld zijn of X en Y zijn bimodaal dan krijgt men respectievelijk de volgende grafieken



Voor de onafhankelijkheidstest veronderstellen we dat

$$X_1, \dots, X_n \sim N(\mu_1, \sigma_1^2)$$

$$Y_1, \dots, Y_n \sim N(\mu_2, \sigma_2^2)$$

met μ_1, μ_2, σ_1 en σ_2 onbekend. De nulhypothese veronderstelt

$$H_0 : X \text{ en } Y \text{ zijn onafhankelijk.}$$

Stelling. $\frac{R_{XY}}{\sqrt{\frac{(1-R_{XY}^2)}{n-2}}} \sim t_{n-2} \quad H_0$
--

Tweezijdige test:

$$\begin{cases} H_0 : \text{onafhankelijkheid}(\text{Corr}[X, Y] = 0) \\ H_1 : \text{lineaire afhankelijkheid}(\text{Corr}[X, Y] \neq 0) \end{cases}$$

Aanvaardingsgebied : $[-t_{n-2, 1-\frac{\alpha}{2}}, t_{n-2, 1-\frac{\alpha}{2}}]$

Eenzijdige test:

$$\begin{cases} H_0 : \text{onafhankelijkheid} \\ H_1 : \text{Corr}[X, Y] > 0 \end{cases} \quad \text{Aanvaardingsgebied : }] - \infty, t_{n-2, 1-\alpha}]$$

$$\begin{cases} H_0 : \text{onafhankelijkheid} \\ H_1 : \text{Corr}[X, Y] < 0 \end{cases} \quad \text{Aanvaardingsgebied : } [-t_{n-2, 1-\alpha}, +\infty[$$

Voorbeeld:

Bestaat er een positieve lineaire relatie tussen de gewichtstoename van de moeder gedurende de zwangerschap en het gewicht van de pasgeborene ($\alpha = 5\%$)? Voor de steekproef $(x_1, y_1), \dots, (x_{30}, y_{30})$ heeft men $r_{xy} = 0.47$ berekend.

$$\frac{r_{xy}}{\sqrt{\frac{(1-r_{xy}^2)}{28}}} = 2.818$$


Eenzijdig $\Rightarrow] - \infty, t_{28, 0.95}] =] - \infty, 1.7011]$

Besluit: de positieve lineaire relatie is significant op het 5% niveau.

ENKELVOUDIGE LINEAIRE REGRESSIE

9.1 Lineaire model

Men heeft de gegevens $\{(x_1, y_1), \dots, (x_n, y_n)\}$. Deze kunnen gerepresenteerd worden in een scatterplot met rechthoekig coördinatenstelsel.



Afhankelijk van de oorsprong van de data hebben we twee mogelijkheden:

- 1) de (x_i, y_i) zijn realisaties van de gekoppelde variabelen X_i en Y_i .
- 2) de x_i zijn vaste waarden, experimenteel gekozen, en de y_i zijn realisaties van een variabele Y_i waarvan de verdeling afhangt van x_i .

We zullen de situatie onder 2) veronderstellen, maar de resultaten zijn ook geldig in het eerste geval. Met behulp van lineaire regressie onderzoeken we op welke manier de waarde van Y_i op een lineaire manier kan voorspeld worden op basis van de waarde x_i .

Het model van **enkelvoudige lineaire regressie** is gedefinieerd als

$$Y_i = \alpha + \beta x_i + \varepsilon_i \quad i = 1, \dots, n$$

voor een zekere $\alpha, \beta \in \mathbb{R}$. De fouten ε_i zijn onafhankelijk en $N(0, \sigma_\varepsilon^2)$ verdeeld.

Omdat de Y_i afhangen van de x_i zeggen we dat X de verklarende (of onafhankelijke) veranderlijke is en Y is de respons (of afhankelijke) veranderlijke.

De verticale fluctuaties $\varepsilon_i = Y_i - \alpha - \beta x_i$ (de fouten of errors) rond de regressierechte zijn dus normaal verdeeld met een constante variantie σ_ε^2 (i.e. homoscedasticiteit), waar men zich ook bevindt op de horizontale as. Het lineaire regressiemodel maakt geen veronderstelling over de x_i . Ze kunnen realisaties zijn van een toevalsvariabele X , of overeenkomen met vastgelegde waarden. Men veronderstelt wel dat de x_i -waarden zonder meetfout verkregen worden.

Verder is de verwachtingswaarde van s.v. Y_i voor een bepaalde x_i gelijk aan

$$E[Y_i|x_i] = E[\alpha + \beta x_i + \epsilon] = \alpha + \beta x_i$$

Hieruit volgt dat we de responswaarde voor een bepaalde x_i -waarde gemiddeld gezien met behulp van de (populatie)regressierechte $y = \alpha + \beta x$ kunnen bepalen. De variantie van s.v. Y_i voor een bepaalde x_i is gelijk aan

$$\text{Var}[Y_i|x_i] = \text{Var}[\alpha + \beta x_i + \epsilon] = \sigma_\varepsilon^2$$

De variabiliteit van Y_i voor een bepaalde waarde x_i wordt dus bepaald door de foutenvariantie σ_ε^2 . De variantie van de verdeling van de Y -waarden is dus dezelfde in elke x (opnieuw homoscedasticiteit). Merk op dat de Y_i ook onafhankelijk zijn van elkaar

Het model van enkelvoudige lineaire regressie wordt volledig bepaald door drie onbekende parameters:

- α = de constante (intercept) = snijpunt van de rechte met de y -as
- β = de richtingscoëfficiënt (slope)
- σ_ε = de standaardafwijking van de fouten ε_i

Het intercept α levert de gemiddelde waarde voor Y bij $x = 0$. Indien $x = 0$ is immers $E(Y|0) = E(\alpha + \epsilon) = \alpha$. De richtingscoëfficiënt geeft aan hoe de gemiddelde Y -waarde wijzigt indien x met één eenheid toeneemt. Vermits


$$\begin{aligned} E(Y|x) &= \alpha + \beta x \\ E(Y|x+1) &= \alpha + \beta(x+1) \end{aligned}$$

bekomen we dat $E(Y|x+1) - E(Y|x) = \beta$.

9.2 Schatten van parameters

Het schatten van de theoretische rechte komt overeen met het vinden van de schatters, $\hat{\alpha}$ en $\hat{\beta}$, voor de parameters α en β .

In eerste instantie zou men bijvoorbeeld een grafische methode kunnen gebruiken waarbij de rechte $y = a + bx$ op een subjectieve manier aan de data aangepast wordt. Deze methode is snel maar niet eenduidig.



Om na te gaan of een gegeven rechte $y = a + bx$ goed aangepast is aan de gegevens (de gegevens goed ‘fit’), bekijkt men de residuen:

$$\begin{aligned} e_i(a, b) &= y_i - \hat{y}_i \\ &= \text{geobserveerde waarde} - \text{geschatte waarde} \\ &= y_i - (a + bx_i) \end{aligned}$$

Een residu kan zowel negatief als positief zijn of zelfs nul. Men wil dat de residuen klein zijn en daarvoor bestaan verschillende maten, zoals

$$\begin{array}{ll} \sum_{i=1}^n |e_i(a, b)| & \text{Laplace, Edgeworth} \\ \sum_{i=1}^n e_i(a, b)^2 & \text{Gauss, Legendre} \\ \sum_{i=1}^n e_i(a, b)^4 & \end{array}$$

De meest gebruikte maat is de tweede. Men kan dus de schattingen $\hat{\alpha}$ en $\hat{\beta}$ definiëren door te eisen dat deze maat geminimaliseerd moet worden, dus

$$(\hat{\alpha}, \hat{\beta}) = \underset{a, b}{\operatorname{argmin}} \sum_{i=1}^n e_i(a, b)^2$$

Deze schatting van $\hat{\alpha}$ en $\hat{\beta}$ heet de **methode van de kleinste kwadraten**. Om de (convexe) functie

$$\sum_{i=1}^n (y_i - (a + bx_i))^2$$

te minimaliseren, moeten we de partiële afgeleiden berekenen en gelijkstellen aan nul. Dit geeft ons de normaalvergelijkingen van de kleinste kwadratenrechte.

$$\begin{cases} \frac{\partial}{\partial b} \sum_{i=1}^n [y_i - (a + bx_i)]^2 = 0 \\ \frac{\partial}{\partial a} \sum_{i=1}^n [y_i - (a + bx_i)]^2 = 0 \end{cases}$$

$$\begin{aligned}
& \begin{cases} \sum_{i=1}^n 2(y_i - (a + bx_i))(-x_i) = 0 \\ \sum_{i=1}^n 2(y_i - (a + bx_i))(-1) = 0 \end{cases} \\
& \begin{cases} \sum_{i=1}^n (-x_i y_i + ax_i + bx_i^2) = 0 \\ \sum_{i=1}^n (-y_i + a + bx_i) = 0 \end{cases} \\
& \begin{cases} \sum_{i=1}^n x_i y_i = a \sum_{i=1}^n x_i + b \sum_{i=1}^n x_i^2 \\ \sum_{i=1}^n y_i = na + b \sum_{i=1}^n x_i \end{cases}
\end{aligned} \tag{9.1}$$

Uit de tweede vergelijking volgt dus dat

$$a = \frac{1}{n} \left(\sum_{i=1}^n y_i \right) - \frac{1}{n} \left(\sum_{i=1}^n x_i \right) b$$

En dus geeft de eerste vergelijking

$$b \sum_{i=1}^n x_i^2 + \frac{1}{n} \sum_{i=1}^n y_i \sum_{i=1}^n x_i - \frac{b}{n} \left(\sum_{i=1}^n x_i \right)^2 = \sum_{i=1}^n x_i y_i$$

Waaruit

$$b = \frac{\sum_{i=1}^n x_i y_i - \frac{1}{n} (\sum_{i=1}^n y_i) (\sum_{i=1}^n x_i)}{\sum_{i=1}^n x_i^2 - \frac{1}{n} (\sum_{i=1}^n x_i)^2}$$

Dit geeft

$$\begin{aligned}
\hat{\beta} &= \frac{\sum_{i=1}^n (x_i - \bar{x}_n)(y_i - \bar{y}_n)}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} \\
\hat{\alpha} &= \bar{y}_n - \hat{\beta} \bar{x}_n
\end{aligned}$$

Opmerkingen:

- (1) Uit (9.1) volgt dat $\sum_{i=1}^n e_i(\hat{\alpha}, \hat{\beta}) = 0$.
- (2) Uit de formule voor $\hat{\alpha}$ haalt men dat de rechte van de kleinste kwadraten door het punt $(\bar{x}_n, \bar{y}_n)$ gaat; dit noemt men het zwaartepunt van de wolk.
- (3) We kunnen $\hat{\beta}$ ook schrijven als

$$\hat{\beta} = \frac{s_{XY}}{s_X^2}$$

waar s_{XY} de empirische covariantie is en s_X^2 de empirische variantie.

Nadat $\hat{\alpha}$ en $\hat{\beta}$ berekend zijn, kunnen we σ_ε schatten mbv de verkregen residuen $e_i := e_i(\hat{\alpha}, \hat{\beta})$:

Stelling. $s_\varepsilon^2 = \frac{\sum_{i=1}^n e_i^2}{n-2}$ is een zuivere schatter voor σ_ε^2 .


De noemer is het aantal waarnemingen (n) min het aantal geschatte parameters (2, namelijk $\hat{\alpha}$ en $\hat{\beta}$).

Voorbeeld:

De verliezen van een bedrijf gedurende de eerste vijf maanden van het jaar zijn:

maand = x	1	2	3	4	5
verlies = y	11	6	4	0	-1

We passen een regressie toe om het verlies in de zesde maand te voorspellen. We beginnen altijd met het maken van een scatterplot om na te gaan of de relatie tussen y_i en x_i werkelijk lineair is.



	x_i	y_i	$(x_i - \bar{x}_n)^2$	$(y_i - \bar{y}_n)^2$	$(x_i - \bar{x}_n)(y_i - \bar{y}_n)$	$\hat{y}_i$	r_i	r_i^2
1	1	11	4	49	-14	10	1	1
2	2	6	1	4	-2	7	-1	1
3	3	4	0	0	0	4	0	0
4	4	0	1	16	-4	1	-1	1
5	5	-1	4	25	-10	-2	2	1
$\sum_{i=1}^n$	15	20	10	94	-30			4

De regressiecoëfficiënten zijn hier gelijk aan:

$$\begin{aligned}\hat{\beta} &= \frac{-30}{10} = -3 \\ \hat{\alpha} &= 4 - (-3)3 = 13\end{aligned}$$

Tekenen we de rechte $y = -3x + 13$ in de scatterplot, dan zien we dat deze door het punt $(\bar{x}_n, \bar{y}_n) = (3, 4)$ gaat.

De geschatte waarden voor de responsvariabele zijn $\hat{y}_i = -3x_i + 13$. Hieruit kunnen we de residuen $r_i = y_i - \hat{y}_i$ berekenen (deze zijn ook af te lezen van de tekening).

Schatten we vervolgens de spreiding van de fouten : $s_\varepsilon^2 = \frac{4}{3}$.

De voorspelling voor $x = 6$ wordt dan: $\hat{y} = (-3)6 + 13 = -5$. We moeten echter voorzichtig zijn bij de interpretatie van deze voorspelling, vermits de verklarende variabele buiten het gebied van de x_i valt, en we dus aan extrapolatie doen. De lineaire relatie is immers enkel gebaseerd op het domein $[1, 5]$ van de verklarende variabele, daarbuiten kan een andere relatie gelden.

9.3 Betrouwbaarheidsintervallen en hypothesetesten

Stelling. Als σ_ε de werkelijke spreiding is van de fouten, dan geldt:

$$\frac{(n-2)s_\varepsilon^2}{\sigma_\varepsilon^2} \sim \chi_{n-2}^2$$

Men kan dit resultaat gebruiken om een betrouwbaarheidsinterval op te stellen:

$$\begin{aligned} \mathrm{P} \left[\chi_{n-2, \frac{\alpha}{2}}^2 \leq \frac{(n-2)s_\varepsilon^2}{\sigma_\varepsilon^2} \leq \chi_{n-2, 1-\frac{\alpha}{2}}^2 \right] &= 1 - \alpha \\ \mathrm{P} \left[\frac{(n-2)s_\varepsilon^2}{\chi_{n-2, 1-\frac{\alpha}{2}}^2} \leq \sigma_\varepsilon^2 \leq \frac{(n-2)s_\varepsilon^2}{\chi_{n-2, \frac{\alpha}{2}}^2} \right] &= 1 - \alpha \end{aligned}$$

Dus,

$$\left[\frac{(n-2)s_\varepsilon^2}{\chi_{n-2, 1-\frac{\alpha}{2}}^2}, \frac{(n-2)s_\varepsilon^2}{\chi_{n-2, \frac{\alpha}{2}}^2} \right]$$

is een betrouwbaarheidsinterval voor σ_ε^2 met significantieniveau $1 - \alpha$.

Opmerking: zoals altijd is het aantal vrijheidsgraden het aantal observaties min het aantal parameters! Voor één enkele steekproef $\{x_1, \dots, x_n\}$ was dit gelijk aan $n - 1$ omdat we μ moesten schatten, hier schatten we β en α .

Men kan ook testen uitvoeren op σ_ε met behulp van deze stelling. Om te testen of $\sigma_\varepsilon^2 = \sigma_0^2$ moeten we de statistiek

$$\frac{(n-2)s_\varepsilon^2}{\sigma_0^2}$$

berekenen.

Tweezijdige test:

$$\begin{cases} H_0 : \sigma_\varepsilon^2 = \sigma_0^2 \\ H_1 : \sigma_\varepsilon^2 \neq \sigma_0^2 \end{cases} \quad \text{Aanvaardingsgebied: } [\chi_{n-2, \frac{\alpha}{2}}^2; \chi_{n-2, 1-\frac{\alpha}{2}}^2]$$

Eenzijdige test:

$$\begin{cases} H_0 : \sigma_\varepsilon^2 = \sigma_0^2 \\ H_1 : \sigma_\varepsilon^2 > \sigma_0^2 \end{cases} \quad \text{Aanvaardingsgebied: } [0; \chi_{n-2, 1-\alpha}^2]$$

$$\begin{cases} H_0 : \sigma_\varepsilon^2 = \sigma_0^2 \\ H_1 : \sigma_\varepsilon^2 < \sigma_0^2 \end{cases} \quad \text{Aanvaardingsgebied: } [\chi_{n-2, \alpha}^2; \infty[$$

Stelling. Als α en β de werkelijke parameters zijn dan geldt:

$$\frac{(\hat{\beta} - \beta) \sqrt{\sum_{i=1}^n (x_i - \bar{x}_n)^2}}{s_\varepsilon} \sim t_{n-2}$$

$$\frac{(\hat{\alpha} - \alpha) \sqrt{\sum_{i=1}^n (x_i - \bar{x}_n)^2}}{s_\varepsilon \sqrt{\bar{x}_n^2 + \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2}} \sim t_{n-2}$$

Deze stelling geeft opnieuw aanleiding tot betrouwbaarheidsintervallen en testen voor α en β .

Bijvoorbeeld: we willen weten of de richtingscoëfficiënt van de regressierechte significant is.

$$\begin{cases} H_0 : \beta = 0 \\ H_1 : \beta \neq 0 \end{cases}$$

Dus we berekenen de teststatistiek

$$t = \frac{\hat{\beta}}{s_\varepsilon} \sqrt{\sum_{i=1}^n (x_i - \bar{x}_n)^2}$$

en we kijken of deze in het tweezijdige aanvaardingsgebied $[-t_{n-2, 1-\frac{\alpha}{2}}; t_{n-2, 1-\frac{\alpha}{2}}]$ ligt. Op analoge manier testen we of $\alpha = 0$.

Voorbeeld:

In ons voorbeeld is het BTI (met 95% betrouwbaarheid) voor de onbekende variantie σ_ε^2 gelijk aan

$$\left[\frac{(n-2)s_\varepsilon^2}{\chi_{n-2, 1-\frac{\alpha}{2}}^2}, \frac{(n-2)s_\varepsilon^2}{\chi_{n-2, \frac{\alpha}{2}}^2} \right] = \left[\frac{3\frac{4}{3}}{\chi_{3, 0.975}^2}, \frac{3\frac{4}{3}}{\chi_{3, 0.025}^2} \right] = \left[\frac{4}{9.348}, \frac{4}{0.216} \right] = [0.428, 18.52]$$

wat heel groot is (n is klein).

Om te testen of de helling nul is ($H_0 : \beta = 0$) berekent men:

$$t = \frac{\hat{\beta} \sqrt{\sum_{i=1}^n (x_i - \bar{x}_n)^2}}{s_\varepsilon} = \frac{(-3)\sqrt{10}}{\sqrt{\frac{4}{3}}} = \frac{-3\sqrt{30}}{2} = -8.22$$

Het aanvaardingsgebied ($\alpha = 5\%$) $[-t_{3,0.975}, t_{3,0.975}] = [-3.18, 3.18]$ bevat $t = -8.22$ niet, dus is de helling significant op het 5% niveau.

Om te testen of de constante nul is ($H_0 : \alpha = 0$):

$$t = \frac{\hat{\alpha} \sqrt{\sum_{i=1}^n (x_i - \bar{x}_n)^2}}{s_\varepsilon \sqrt{\bar{x}_n^2 + \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2}} = \frac{13\sqrt{10}}{\sqrt{\frac{4}{3}}\sqrt{9+2}} = \frac{13\sqrt{30}}{2\sqrt{11}} = 10.73$$

wat ook niet behoort tot $[-3.18, 3.18]$. De constante is eveneens significant.

De correlatie tussen X en Y is

$$r_{XY} = \frac{-30}{\sqrt{10}\sqrt{94}} = -\sqrt{\frac{900}{940}} = -\sqrt{\frac{45}{47}} = -0.98$$

Om te testen of de correlatie significant is moet men de volgende waarde berekenen:

$$t = \frac{r_{XY}}{\sqrt{\frac{(1-r_{XY}^2)}{n-2}}} = \frac{-\sqrt{\frac{45}{47}}}{\sqrt{\frac{(1-\frac{45}{47})}{3}}} = -\sqrt{\frac{45.3}{2}} = \frac{-3\sqrt{30}}{2}$$

wat overeenkomt met de test voor de helling (en het aanvaardingsgebied is ook hetzelfde). De testen zijn equivalent.

9.4 Voorbeeld

De jaarlijkse belasting (in \$) voor 107 huizen in Albuquerque (USA) wordt vergeleken met de verkoopwaarde van de huizen (in 100\$). R geeft volgende output voor de regressie met 'tax' als responsvariabele en 'price' als verklarende variabele:

```
Call: lm(formula = pricetax$tax ~ pricetax$price)
```

```
Residuals:
```

```
    Min       1Q   Median       3Q      Max
-417.3 -74.28   1.12  72.48  463.6
```

```
Coefficients:
```

```
Value Std. Error t value Pr(>|t|)
```

```

(Intercept) 36.3444 43.2374      0.8406  0.4025
pricetax$price 0.7028  0.0378     18.5805  0.0000


```

Residual standard error: 149.5 on 105 degrees of freedom


Multiple R-Squared: 0.7668


F-statistic: 345.2 on 1 and 105 degrees of freedom, the p-value is 0

Merk op dat de helling van de rechte significant verschilt van 0, maar de intercept niet, we hebben hier dus te maken met een regressie door de oorsprong. Grafisch ziet de uitgevoerde regressie er als volgt uit:



De regressielijn lijkt aangetrokken te worden door enkele dure huizen, die onderbelast worden en dus de helling van de regressielijn verkleinen.





Uit de plot van de residuen ten opzichte van de geschatte waarde voor de responsvariabele blijkt dat de spreiding van de residuen toeneemt naarmate de geschatte waarde groter wordt. De veronderstelling dat alle errortermen ε_i een gelijke spreiding hebben is dus niet voldaan. Dit noemt men **heteroscedasticiteit**. Uit de QQ-plot van de residuen blijkt tevens dat ook de veronderstelling dat de residuen normaal verdeeld zijn, niet voldaan is.

Omwille van bovenstaande redenen is het misschien aangewezen om de data te transformeren en de regressie opnieuw uit te voeren. Een logaritmische transformatie geeft

```
Call: lm(formula = log(pricetax$tax) ~ log(pricetax$price))
```

Residuals:

Min	1Q	Median	3Q	Max
-0.7312	-0.08682	0.01957	0.1241	0.3553


Coefficients:

	Value	Std. Error	t value	Pr(> t)
(Intercept)	-0.6504	0.4190	-1.5521	0.1236
log(pricetax\$price)	1.0470	0.0604	17.3319	0.0000

Residual standard error: 0.1972 on 105 degrees of freedom

Multiple R-Squared: 0.741

F-statistic: 300.4 on 1 and 105 degrees of freedom, the p-value is 0



De spreiding van de residuen is overal even breed, enkel drie van de goedkopere huizen springen eruit met een kleine $\log(\text{tax})$ in vergelijking met de andere huizen. Bovendien blijft een zekere afwijking van de normaliteit van de residuen bestaan.

