
Computeroefenzitting 1

Inleiding tot Statistiek en Data analyse in R

Bachelor in de Informatica: **Elementaire statistiek**

1. Laad de dataset *resultaten.txt* in.
 - (a) Zet de score uit de *bachelor* uit als functie van de score in het *middelbaar* (maak een plot).
 - (b) Bereken de mediaan en het gemiddelde van de variabele *lengte* opgedeeld voor jongens en meisjes. Maak ook een boxplot voor beide.
 - (c) Wanneer je kijkt naar alle lengtes wat zijn dan de spreidingskenmerken, geef de variantie, de range en de IQR.
2. Bereken het volgende in R:
 - (a) $P(X < 8)$ als $X \sim \mathcal{N}(5, 4)$
 - (b) $f_X(2.1)$ als $X \sim \mathcal{N}(5, 4)$
 - (c) $P(X < 3.5)$ als $X \sim t_6$
 - (d) $P(X > 1)$ als $X \sim \chi_3^2$
 - (e) $P(X = 20)$ als $X \sim \mathcal{B}(30, 0.7)$
Extra: Bereken dit zonder het commando `pbinom` of `dbinom` te gebruiken.
 - (f) Het 91ste kwantiel van de standaard normale verdeling
 - (g) Het 25ste percentiel van t_{67}
 - (h) Genereer een steekproef van grootte 83 uit een F-verdeling $F_{27,15}$.
 - (i) Genereer een steekproef van grootte 50 uit de standaard normale verdeling. Bereken voor deze steekproef het gemiddelde, de mediaan en de variantie.
3. De tijd die nodig is om een toelatingsexamen voor een bepaalde cursus te beëindigen, is normaal verdeeld met een gemiddelde van 110 minuten en een standaardafwijking van 20 minuten.
 - (a) Welke proportie van studenten heeft in 2 uur het examen beëindigd?
 - (b) Hoelang moet het examen dan duren opdat 90% van de studenten het examen beëindigd heeft?
4. Veronderstel dat de pH van bodemstalen uit een bepaalde geografische streek normaal verdeeld is met gemiddelde 6 pH en standaardafwijking 0.1 pH. Stel dat de pH van een willekeurig geselecteerde bodem staal uit die streek bepaald is.
 - (a) Wat is dan de kans dat de resulterende pH-waarde tussen 5.90 pH en 6.15 pH ligt?
 - (b) Wat is dan de kans dat de resulterende pH-waarde groter is dan 6.10 pH?
 - (c) Wat is dan de kans dat de resulterende pH-waarde ten hoogste 5.95 pH is?
 - (d) Welke waarde zal overtroffen worden door slechts 5% van alle mogelijke pH-waarden?

5. (*Oefening 3 uit oefenzitting 2*) Men wenst het poreusheidspercentage te onderzoeken van een bepaald soort zandsteen. Daarom meet men dat percentage op 10 willekeurig gekozen monsters. De resultaten zijn

13, 17, 15, 23, 27, 29, 18, 27, 20, 24.

Wanneer we veronderstellen dat het poreusheidspercentage van een willekeurig gekozen monster $N(\mu, \sigma^2)$ verdeeld is, bepaal dan een 95% betrouwbaarheidsinterval voor μ .

6. Laad opnieuw de dataset *resultaten.txt* in.
- (a) Denk je dat de lengtes van mannen en vrouwen samen uit een normale verdeling komen? Maak een normale QQ-plot om je vermoeden te ondersteunen.
 - (b) Beantwoord dezelfde vraag voor de lengtes van de mannen en de vrouwen apart.
 - (c) Gebruik de Shapiro-Wilk test voor normaliteit en controleer of dat je antwoorden bij de vorige deelvragen kloppen. (Gebruik in *R* het commando: `shapiro.test`)
7. Denk je dat de gegevens van de variabele *data1*, *data2* en *data3* in respectievelijk datasets *statdata1.csv*, *statdata2.csv* en *statdata3.csv* uit een normale verdeling komen? Zo neen, kan je een transformatie vinden zodat de getransformeerde gegevens wel uit een normale verdeling zouden kunnen komen?

Extra Oefeningen:

8. Teken op een grafiek de dichtheidsfuncties van de exponentiële verdelingen met λ gelijk aan 1, 2, 5 en 10 op eenzelfde figuur. Gebruik verschillende kleuren en stijlen voor de verschillende functies. Maak ook een legende en geef de assen een naam.
9. Construeer $m = 100$ betrouwbaarheidsintervallen van 95% voor μ op basis van steekproeven van grootte $n = 100$ uit de standaard normale verdeling. Hoeveel van deze intervallen verwacht je dat de werkelijke waarde van μ bevatten? Hoeveel van deze intervallen bevatten de waarde van μ daadwerkelijk? Wat verandert er wanneer je m of n vergroot? (Gebruik een `for`-loop in *R*)