
Computeroefenzitting 2

Hypothesetesten in R

Bachelor in de Informatica: **Elementaire statistiek**

1. Op het weerbericht beweert men dat de gemiddelde junitemperatuur op het middaguur in Vlaams-Brabant 20°C bedraagt. Jij trekt die stelling in twijfel en denkt dat de gemiddelde junitemperatuur verschilt van 20°C . Je verzamelt daarom junitemperaturen op het middaguur op 30 verschillende locaties in Vlaams-Brabant (*datajuni.xls*) en onderzoekt of deze bewering klopt op significantieniveau $\alpha = 0.05$. We overlopen nog eens de verschillende stappen die je volgt bij een hypothesetest. (Gebruik de package `readxl` om de dataset in te laden.)
 - (a) Wat is de nulhypothese en de alternatieve hypothese?
 - (b) Welke veronderstellingen maak je? Zijn deze voldaan?
 - (c) Welke teststatistiek gebruik je? Wat is de verdeling van de teststatistiek onder H_0 ?
 - (d) Wat is je testwaarde en het aanvaardingsgebied?
 - (e) Wat is de bijbehorende p -waarde? (Je kan het commando `t.test` gebruiken in *R*, maar dit hoeft niet.)
 - (f) Maak een grafiek waarop je de testwaarde, de p -waarde en het aanvaardingsgebied aanduidt.
 - (g) Formuleer een besluit voor de test.
2. Laad de dataset *CO.csv* in. Toon aan dat de variabele `EMISSIE` niet normaal verdeeld is, maar dat normaliteit van de variabele `LOG(EMISSIE)` niet verworpen kan worden. Test de volgende hypothese: $H_0 : \mu_{\text{LOG(EMISSIE)}} = 1$ versus $H_1 : \mu_{\text{LOG(EMISSIE)}} \neq 1$.
3. Voor de dataset *evenwicht.xls* werden negen oudere en acht jonge mensen gevraagd deel te nemen aan een evenwichtsexperiment. Elke persoon stond op een platform en moest na het horen van een zeker geluid dat op een willekeurig moment te horen was, zo snel mogelijk op een knop drukken die ze in hun hand vast hielden. De variabelen zijn de volgende:

$$\text{leeftijd} = \begin{cases} 1 & \text{als de persoon een oudere persoon is,} \\ 2 & \text{als de persoon jong is.} \end{cases}$$

De tweede variabele is `ZWAAI`, nl. het logaritme van de grootte van de zwaai in millimeters die de persoon naar voren en achteren maakt bij het drukken op de knop. Test of de leeftijd invloed heeft op de gemiddelde logaritmische zwaai van een persoon.

4. Open de dataset *cholesterol.txt* in *RStudio*. In een Amerikaans medisch centrum werd het cholesterolgehalte in het bloed van hartaanval patiënten bestudeerd. Het cholesterolgehalte van 28 hartaanval patiënten werd eerst na 2 dagen gemeten (`CHOLEST2`) en vervolgens nog eens na 4 dagen (`CHOLEST4`). Ga na of het gemiddelde cholesterolgehalte in het bloed 2 dagen na een hartaanval significant hoger is dan het cholesterolgehalte in het bloed 4 dagen na een hartaanval.
5. In locatie A worden zeer veel slangen van soort S gevonden. Inspectie van 167 volwassen mannelijke slangen brengt aan het licht dat 35 onder hen een lichtgekleurde band in de nek

hebben. In een tweede locatie, B, op respectabele afstand van A, vindt men dit fenomeen bij 6 van de 27 gevonden mannetjesslangen terug. Is er een significant verschil tussen beide locaties wat betreft de frequentie van de banden?

Extra Oefeningen:

6. Beschouw een populatie van 30 personen. Men stelt $X = 1$ voor een roker en $X = 0$ voor een niet-roker. Men neemt waar

1, 0, 0, 0, 1, 1, 0, 0, 0, 1, 1, 0, 0, 0, 1, 1, 0, 0, 0, 1, 1, 0, 0, 0, 1, 1, 0, 0, 0, 1

Toets of er een betekenisvolle voorkeur is voor roken.

7. (*Oefening 2 uit oefenzitting 4*) De afdeling kwaliteitscontrole van een bedrijf wil aanpassingen doorvoeren aan de drukmachine voor compact-discs indien er op de dagproductie van 500 discs significant meer dan 3% defecten zijn.
- (a) De dagproductie van vandaag bevatte 17 defecten. Zal de afdeling in dit geval aanpassingen maken aan de machine? Bereken zowel het aanvaardingsgebied als de p -waarde van deze test en gebruik als significantieniveau 5%.
 - (b) De dagproductie van vandaag bevatte 25 defecten. Zal de afdeling in dit geval aanpassingen maken aan de machine? Bereken opnieuw zowel het aanvaardingsgebied als de p -waarde.
8. De dataset *rivieren.xls* bevat de lengte van 38 rivieren in Nieuw-Zeeland. De variabele LENGTE drukt de lengte uit in kilometer. De tweede variabele ZEE heeft waarde 1 als de rivier naar de Stille Zuidzee stroomt en waarde 2 als de rivier naar de Tasmaanse Zee stroomt. Ga na of een rivier die naar de Stille Zuidzee stroomt gemiddeld langer is dan een rivier die naar de Tasmaanse Zee stroomt.