
Computeroefenzitting 3

Onafhankelijkheid en Regressie in R

Bachelor in de Informatica: **Elementaire statistiek**

1. Ga na aan de hand van de volgende tabel of er een verband bestaat tussen de kleur van de ogen en de haarkleur van kinderen.

Extra: Doe dit zonder het commando `chisq.test` te gebruiken.

		haarkleur				
		blond	rood	bruin	donkerbruin	zwart
Kleur ogen	blauw	326	38	241	110	3
	lichtbruin	688	116	584	188	4
	bruin	343	84	909	412	26
	donkerbruin	98	48	403	681	85

Je kan deze tabel onmiddellijk creëren met het volgende commando in *RStudio*:

```
haarogen <- rbind(c(326,38,241,110,3),c(688,116,584,188,4),  
  c(343,84,909,412,26),c(98,48,403,681,85))
```

2. Laad de dataset *roken.xlsx* in. De dataset bevat informatie over het aantal rokers en de mortaliteit voor een aantal beroepsgroepen en bevat 3 variabelen: OCCUPATIONAL_GROUP, ROKERS en MORTALITEIT. Deze oefening onderzoekt het verband tussen variabelen ROKERS en MORTALITEIT.
 - (a) Maak een plot van de variabelen. Zoek de observatie die duidelijk afwijkt van de andere observaties (de uitschieter of outlier). Ga verder met de data zonder deze uitschieter.
 - (b) Ga na dat de variabelen ROKERS en MORTALITEIT normaal verdeeld zijn. Denk je dat bivariate normaliteit van ROKERS en MORTALITEIT een plausibele veronderstelling is?
 - (c) Bereken de Pearson correlatiecoëfficiënt en test of deze verschilt van 0. (Je kan het commando `cor.test` gebruiken in *R*.) Kan je nu besluiten dat de variabelen ROKERS en MORTALITEIT afhankelijk zijn van elkaar?
 - (d) Kan een lineair model de variabele MORTALITEIT goed voorspellen op basis van de variabele ROKERS? Geef het geschatte model en beoordeel of het zinvol is. Welke veronderstellingen maak je en zijn deze voldaan?
 - (e) Visualiseer het geschatte model samen met de data in een grafiek.
3. Laad de dataset *Advertising.csv*. Deze vertegenwoordigen de verkoop (in duizenden) van een product, gegeven de advertentiebudgetten (in duizend dollar) voor tv, radio en krant. De responsvariabele is SALES, terwijl de verklarende variabelen TV, RADIO en NEWSPAPER zijn. Doe een regressie analyse op deze dataset en formuleer een zo volledig mogelijk besluit.

4. Een student economie bestudeert voor zijn thesis het verband tussen de verkoop van een product (Y , in miljoen euro) in 50 gebieden en de grootte van de bevolking in het gebied waar het product wordt verspreid (X , in miljoen personen). Hij doet een regressie-analyse op de gegevens en verkrijgt de volgende R-uitvoer:

```
> resultaat <- lm(y~x)
> summary(resultaat)

Call:
lm(formula = y ~ x)

Residuals:
    Min       1Q   Median       3Q      Max
-0.48902 -0.19488 -0.04301  0.20660  0.68918

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.92493    0.07726  37.858 < 2e-16 ***
x            0.38531    0.14622    (a)      (b)
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2714 on 48 degrees of freedom
Multiple R-squared:  0.1264,    Adjusted R-squared:  0.1082
```

- (a) Wat zijn de waarden voor (a) en (b)?
 (b) Geef de vergelijking van de regressierechte en een schatting voor de spreiding van de foutentermen.
 (c) Maak een schets waarop je de testwaarde en de p -waarde aanduidt voor de hypothesetest die hoort bij de hypothese

$$H_0 : \beta = 0 \quad \text{versus} \quad H_1 : \beta \neq 0.$$

- (d) Geef in woorden weer wat de betekenis is van deze p -waarde.
 (e) Geef een schatting voor de verkoop van het product in een gebied met 10 miljoen personen.
 (f) Hoe veranderen de schattingen voor de slope, het intercept en de spreiding van de foutentermen indien X uitgedrukt wordt in 10 miljoen personen?
 (g) Hoe veranderen de schattingen voor de slope, het intercept en de spreiding van de foutentermen indien Y uitgedrukt wordt in 10 miljoen euro?

Extra Oefeningen:

5. Voor de jaarlijkse sportdag kunnen de leerlingen kiezen uit 3 sporten: atletiek, paardrijden of ijsschaatsen. De sportleerkrachten zijn benieuwd of er een verband is tussen de gekozen sport en het geslacht (jongen of meisje) van de leerling. De geobserveerde contingentietabel is:

	atletiek	paardrijden	schaatsen
jongen	34	33	7
meisje	22	22	4

6. Bekijk de dataset *vis.csv*. Deze bevat 2 variabelen, namelijk PRIJS70 en PRIJS80. Onderzoek of er een lineair verband is tussen de prijzen, en formuleer een zo volledig mogelijk besluit. Ga ook de nodige veronderstellingen na.
7. De groei van jonge kinderen is bijna lineair. Hier zijn de gegevens van Sarah:

leeftijd (in maanden)	36	48	51	54	57	60
lengte (in cm)	86	90	91	93	94	95

- (a) Zet deze gegevens uit op een grafiek (scatterplot).
- (b) Bereken de correlatiecoëfficiënt tussen de lengte en de leeftijd van Sarah.
- (c) Is er een significant verband tussen haar lengte en de leeftijd?