

Lineaire regressie

Met behulp van lineaire regressie onderzoeken op welke manier de waarde van variabele Y op een **lineaire manier** voorspeld kan worden op basis van de waarde van variabele X (of omgekeerd).

- Y = responsvariabele of afhankelijke variabele
- X = verklarende variabele of onafhankelijke variabele

Lineaire regressie

- ① Hoe ziet dit verband er uit? Welk statistisch model kunnen we gebruiken?
 - Ideaal geval: $y_i = \alpha + \beta x_i$, maar realiteit is meestal anders
 - In hoeverre wijkt de realiteit af van het ideale geval?
- ② Onder welke voorwaarden is het lineaire model een goed model? Hoe kunnen we deze voorwaarden nagaan?
- ③ Hoe goed (betrouwbaar) zijn deze schattingen? Welke afwijkingen kunnen we verwachten t.o.v. de voorspelde waarden?

Het enkelvoudige lineaire regressiemodel


Het verband tussen twee kwantitatieve variabelen X en Y wordt in het enkelvoudige lineaire regressie als volgt gemodelleerd:

Het enkelvoudige lineaire regressiemodel

$$Y_i = \alpha + \beta x_i + \varepsilon_i \quad \text{voor alle } i = 1, 2, \dots, n$$

voor een zekere $\alpha, \beta \in \mathbb{R}$.

De fouten ε_i zijn onafhankelijk en $\sim \mathcal{N}(0, \sigma_\varepsilon^2)$



Het enkelvoudige lineaire regressiemodel

Enkele opmerkingen:

- $E(Y_i | x_i) = E(\alpha + \beta x_i + \varepsilon_i) = \alpha + \beta x_i + E(\varepsilon_i) = \alpha + \beta x_i$

Met andere woorden: de modelformulering drukt uit dat we de responswaarde voor een bepaalde x_i -waarde **gemiddeld gezien** met behulp van de (populatie)regressierechte $y = \alpha + \beta x$ kunnen bepalen.

- Het intercept α levert de gemiddelde waarde voor Y bij $x = 0$.
- De richtingscoëfficiënt β geeft aan hoe de gemiddelde Y -waarde wijzigt indien x met 1 eenheid toeneemt.
- $\text{Var}(Y_i) = \text{Var}(\varepsilon_i) = \sigma_\varepsilon^2$ voor alle $i = 1, \dots, n$.
 $\Rightarrow$ homoscedasticiteit
- Omdat Y_i afhangen van de x_i , noemen we Y de respons en X de verklarende veranderlijke.
- Model van enkelvoudige lineaire regressie bevat 3 onbekende parameters α , β en σ_ε^2 .


Kleinste kwadratenmethode

Hoe de vergelijking van de rechte $y = \alpha + \beta x$ bepalen?

We zoeken schattingen $\hat{\alpha}$ en $\hat{\beta}$ voor α en β

- Definieer het residu $e_i(a, b)$ als de verticale afwijking van het punt (x_i, y_i) ten opzichte van de rechte met vergelijking $y = a + bx$

$$e_i(a, b) = y_i - (a + bx_i)$$



Kleinste kwadratenmethode


Hoe de vergelijking van de rechte $y = \alpha + \beta x$ bepalen?

We zoeken schattingen $\hat{\alpha}$ en $\hat{\beta}$ voor α en β

- Definieer het residu $e_i(a, b)$ als de verticale afwijking van het punt (x_i, y_i) ten opzichte van de rechte met vergelijking $y = a + bx$
- Zoek $\hat{\alpha}$ en $\hat{\beta}$ waarvoor de som van de gekwadrateerde residu's

$$\sum_{i=1}^n e_i^2(a, b) = \sum_{i=1}^n (y_i - (a + bx_i))^2$$

minimaal is



Kleinste kwadratenmethode

Hoe de vergelijking van de rechte $y = \alpha + \beta x$ bepalen?

We zoeken schattingen $\hat{\alpha}$ en $\hat{\beta}$ voor α en β

- Definieer het residu $e_i(a, b)$ als de verticale afwijking van het punt (x_i, y_i) ten opzichte van de rechte met vergelijking $y = a + bx$
- Zoek $\hat{\alpha}$ en $\hat{\beta}$ waarvoor de som van de gekwadrateerde residu's

$$\sum_{i=1}^n e_i^2(a, b) = \sum_{i=1}^n (y_i - (a + bx_i))^2$$

minimaal is

- Schattingen voor α en β worden gegeven door

$$\hat{\beta} = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = r \frac{s_y}{s_x}$$

$$\hat{\alpha} = \bar{y} - \hat{\beta} \bar{x}$$

Bewijs (kleinste kwadraten schattingen) I

Men kan aldus de schattingen $\hat{\beta}$ en $\hat{\alpha}$ definiëren door te eisen dat deze maat geminimaliseerd moet worden, dus

$$(\hat{\alpha}, \hat{\beta}) = \operatorname{argmin}_{a, b} \sum_{i=1}^n e_i^2(a, b)$$

Deze schatting van a en b heet de methode van de kleinste kwadraten. Om de (convexe) functie

$$\sum_{i=1}^n (y_i - (a + bx_i))^2$$

te minimaliseren, moeten we de partiële afgeleiden berekenen en gelijkstellen aan nul. Dit geeft ons de normaalvergelijkingen van de kleinste kwadratenrechte.

$$\begin{cases} \frac{\partial}{\partial b} \sum_{i=1}^n [y_i - (a + bx_i)]^2 = 0 \\ \frac{\partial}{\partial a} \sum_{i=1}^n [y_i - (a + bx_i)]^2 = 0 \end{cases}$$

Bewijs (kleinste kwadraten schattingen) II

$$\begin{cases} \sum_{i=1}^n 2(y_i - (a + bx_i))(-x_i) = 0 \\ \sum_{i=1}^n 2(y_i - (a + bx_i))(-1) = 0 \end{cases}$$

$$\begin{cases} \sum_{i=1}^n (-x_i y_i + ax_i + bx_i^2) = 0 \\ \sum_{i=1}^n (-y_i + a + bx_i) = 0 \end{cases} \quad (1)$$

$$\begin{cases} \sum_{i=1}^n x_i y_i = a \sum_{i=1}^n x_i + b \sum_{i=1}^n x_i^2 \\ \sum_{i=1}^n y_i = na + b \sum_{i=1}^n x_i \end{cases}$$

Uit de tweede vergelijking volgt dus dat

$$a = \frac{1}{n} \left(\sum_{i=1}^n y_i \right) - \frac{1}{n} \left(\sum_{i=1}^n x_i \right) b$$

En dus geeft de eerste vergelijking

$$\sum_{i=1}^n x_i y_i = \frac{1}{n} \sum_{i=1}^n y_i \sum_{i=1}^n x_i - \frac{b}{n} \left(\sum_{i=1}^n x_i \right)^2 + b \sum_{i=1}^n x_i^2$$

Bewijs (kleinste kwadraten schattingen) III

Waaruit

$$b = \frac{\sum_{i=1}^n x_i y_i - \frac{1}{n} (\sum_{i=1}^n y_i) (\sum_{i=1}^n x_i)}{\sum_{i=1}^n x_i^2 - \frac{1}{n} (\sum_{i=1}^n x_i)^2}$$

Dit geeft

$$\begin{aligned}\hat{\beta} &= \frac{\sum_{i=1}^n (x_i - \bar{x}_n)(y_i - \bar{y}_n)}{\sum_{i=1}^n (x_i - \bar{x}_n)^2} \\ \hat{\alpha} &= \bar{y}_n - \hat{\beta} \bar{x}_n\end{aligned}$$


We kunnen $\hat{\beta}$ ook schrijven als

$$\hat{\beta} = \frac{s_{XY}}{s_X^2}$$

waar s_{XY} de empirische covariantie is en s_X^2 de empirische variantie.

Kleinste kwadratenmethode

Voorbeeld: we onderzoeken of we de waarde van 'Mortaliteit' op een lineaire manier kunnen **voorspellen** op basis van de waarde van 'log(SO₂Pot)'



$$\text{'Mortaliteit'} = 863.39 + 22.77 \text{'log(SO}_2\text{Pot)'}$$

$$y = \hat{\alpha} + \hat{\beta} x$$

Kleinste kwadratenmethode

De geschatte kleinste-kwadratenrechte is dus van de vorm $y = \hat{\alpha} + \hat{\beta}x$

- Voor elke observatie levert dit de *geschatte waarde* $\hat{y}_i = \hat{\alpha} + \hat{\beta}x_i$
- De residu's voor deze geschatte rechte zijn gegeven door

$$e_i = e_i(\hat{\alpha}, \hat{\beta}) = y_i - \hat{y}_i = y_i - (\hat{\alpha} + \hat{\beta}x_i)$$

- Er geldt altijd dat $\sum_{i=1}^n e_i = 0$
- Het punt $(\bar{x}, \bar{y})$ ligt op deze rechte
- Als $r = r(x, y) = 0$, wordt een horizontale rechte geschat ($\hat{\beta} = 0$ en $\hat{\alpha} = \bar{y}$)
 ⇒ als er geen lineair verband is tussen X en Y , is $\bar{y}$ de beste voorspelling voor $Y|x_i$, ongeacht de waarde van x_i

Schatting voor σ_ε^2

Uit de modelveronderstelling $E(\varepsilon_i) = 0$, volgt dat

$$\sigma_\varepsilon^2 = \text{Var}(\varepsilon_i) = E(\varepsilon_i^2),$$

de gemiddelde kwadratische grootte van de fouten.

Het ligt dus voor de hand σ_ε^2 te schatten door een gemiddelde van de kwadraten van de geobserveerde residu's e_i :

$$s_\varepsilon^2 = \hat{\sigma}_\varepsilon^2 = \frac{1}{n-2} \sum_{i=1}^n e_i^2(\hat{\alpha}, \hat{\beta}) = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$


- noemer $n - 2$ (eerder dan n) resulteert in een zuivere of overtekende schatter voor σ^2 . Deze noemer is gelijk aan het aantal waarnemingen min het aantal geschatte parameters (α en β).

Voorbeeld I

De verliezen van een bedrijf gedurende de eerste vijf maanden van het jaar zijn:

maand = x	1	2	3	4	5
verlies = y	11	6	4	0	-1

We passen een regressie toe om het verlies in de zesde maand te voorspellen. We beginnen altijd met het maken van een scatterplot om na te gaan of de relatie tussen y_i en x_i werkelijk lineair is.



Voorbeeld II

	x_i	y_i	$(x_i - \bar{x}_n)^2$	$(y_i - \bar{y}_n)^2$	$(x_i - \bar{x}_n)(y_i - \bar{y}_n)$	$\hat{y}_i$	e_i	e_i^2
1	1	11	4	49	-14	10	1	1
2	2	6	1	4	-2	7	-1	1
3	3	4	0	0	0	4	0	0
4	4	0	1	16	-4	1	-1	1
5	5	-1	4	25	-10	-2	1	1
$\sum_{i=1}^n$	15	20	10	94	-30			4

De regressiecoëfficiënten zijn hier gelijk aan:

$$\begin{aligned}\hat{\beta} &= \frac{-30}{10} = -3 \\ \hat{\alpha} &= 4 - (-3)3 = 13\end{aligned}$$

Tekenen we de rechte $y = -3x + 13$ in de scatterplot, dan zien we dat deze door het punt $(\bar{x}_n, \bar{y}_n) = (3, 4)$ gaat.

Voorbeeld III

- De geschatte waarden voor de responsvariabele zijn $\hat{y}_i = -3x_i + 13$.
- Hieruit kunnen we de residuen $e_i = y_i - \hat{y}_i$ berekenen (deze zijn ook af te lezen van de tekening).
- Schatten we vervolgens de spreiding van de fouten : $\hat{\sigma}^2 = \frac{4}{3}$.
- De voorspelling voor $x = 6$ wordt dan: $\hat{y} = (-3)6 + 13 = -5$.
- We moeten echter voorzichtig zijn bij de interpretatie van deze voorspelling, vermits de verklarende variabele buiten het gebied van de x_i valt, en we dus aan extrapolatie doen.
- De lineaire relatie is immers enkel gebaseerd op het domein $[1, 5]$ van de verklarende variabele, daarbuiten kan een andere relatie gelden.

Betrouwbaarheidsintervallen en hypothesetesten I

Stelling

Als σ_ϵ de werkelijke spreiding is van de storingsterm, dan geldt

$$\frac{(n-2)s_\epsilon^2}{\sigma_\epsilon^2} \sim \chi_{n-2}^2$$

Men kan dit resultaat gebruiken om een betrouwbaarheidsinterval op te stellen:

$$\begin{aligned} P \left[\chi_{n-2, \frac{\alpha}{2}}^2 \leq \frac{(n-2)s_\epsilon^2}{\sigma_\epsilon^2} \leq \chi_{n-2, 1-\frac{\alpha}{2}}^2 \right] &= 1 - \alpha \\ P \left[\frac{(n-2)s_\epsilon^2}{\chi_{n-2, 1-\frac{\alpha}{2}}^2} \leq \sigma_\epsilon^2 \leq \frac{(n-2)s_\epsilon^2}{\chi_{n-2, \frac{\alpha}{2}}^2} \right] &= 1 - \alpha \end{aligned}$$

Dus,

$$\left[\frac{(n-2)s_\epsilon^2}{\chi_{n-2, 1-\frac{\alpha}{2}}^2}, \frac{(n-2)s_\epsilon^2}{\chi_{n-2, \frac{\alpha}{2}}^2} \right]$$

is betrouwbaarheidsinterval voor σ^2 met significantieniveau α .

Betrouwbaarheidsintervallen en hypothesetesten II

Om te testen of $\sigma_\epsilon^2 = \sigma_0^2$ moeten we volgende statistiek berekenen:

$$\frac{(n-2)s_\epsilon^2}{\sigma_0^2}$$

Tweezijdige test:

$$\begin{cases} H_0 : \sigma_\epsilon^2 = \sigma_0^2 \\ H_1 : \sigma^2 \neq \sigma_0^2 \end{cases}$$

Aanvaardingsgebied: $[\chi_{n-2, \frac{\alpha}{2}}^2; \chi_{n-2, 1-\frac{\alpha}{2}}^2]$

Eenzijdige test:

$$\begin{cases} H_0 : \sigma^2 = \sigma_0^2 \\ H_1 : \sigma^2 > \sigma_0^2 \end{cases}$$

Aanvaardingsgebied: $[0; \chi_{n-2, 1-\alpha}^2]$

$$\begin{cases} H_0 : \sigma^2 = \sigma_0^2 \\ H_1 : \sigma^2 < \sigma_0^2 \end{cases}$$

Aanvaardingsgebied: $[\chi_{n-2, \alpha}^2; \infty[$

Betrouwbaarheidsintervallen en hypothesetesten III

Stelling

Als α en β de werkelijke parameters zijn dan geldt

$$\frac{(\hat{\beta} - \beta) \sqrt{\sum_{i=1}^n (x_i - \bar{x}_n)^2}}{s_\epsilon} \sim t_{n-2}$$

$$\frac{(\hat{\alpha} - \alpha) \sqrt{\sum_{i=1}^n (x_i - \bar{x}_n)^2}}{s_\epsilon \sqrt{\bar{x}_n^2 + \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2}} \sim t_{n-2}$$

Deze stelling geeft opnieuw aanleiding tot betrouwbaarheidsintervallen en testen voor α en β .

Betrouwbaarheidsintervallen en hypothesetesten IV

Bijvoorbeeld: we willen weten of de richtingscoëfficiënt van de regressierechte significant is.

$$\begin{cases} H_0 : \beta = 0 \\ H_1 : \beta \neq 0 \end{cases}$$

Dus we berekenen de teststatistiek

$$t = \frac{\hat{\beta}}{s_\epsilon} \sqrt{\sum_{i=1}^n (x_i - \bar{x}_n)^2}$$

en kijken of deze in tweezijdige aanvaardingsgebied $[-t_{n-2, 1-\frac{\alpha}{2}}; t_{n-2, 1-\frac{\alpha}{2}}]$ ligt. Op analoge manier testen we via $\alpha = 0$ of de rechte door de oorsprong gaat.

Voorbeeld I

In ons voorbeeld is het BTI (met 95% betrouwbaarheid) voor de onbekende variantie σ^2 gelijk aan

$$\left[\frac{(n-2)s_{\epsilon}^2}{\chi_{n-2, 1-\frac{\alpha}{2}}^2}, \frac{(n-2)s_{\epsilon}^2}{\chi_{n-2, \frac{\alpha}{2}}^2} \right] = \left[\frac{3\frac{4}{3}}{\chi_{3, 0.975}^2}, \frac{3\frac{4}{3}}{\chi_{3, 0.025}^2} \right] = \left[\frac{4}{9.348}, \frac{4}{0.216} \right] = [0.428, 18.52]$$

wat heel groot is (n is zeer klein).

Om te testen of de richtingscoëfficiënt nul is ($H_0 : \beta = 0$) berekent men:

$$t = \frac{\hat{\beta} \sqrt{\sum_{i=1}^n (x_i - \bar{x}_n)^2}}{s_{\epsilon}} = \frac{(-3)\sqrt{10}}{\sqrt{\frac{4}{3}}} = \frac{-3\sqrt{30}}{2} = -8.22$$

Het aanvaardingsgebied ($\alpha = 5\%$) $[-t_{3, 0.975}, t_{3, 0.975}] = [-3.18, 3.18]$ bevat $t = -8.22$ niet, dus is de helling significant op het 5% niveau.

Voorbeeld II

Om te testen of de intercept nul is ($H_0 : \alpha = 0$):

$$t = \frac{\hat{\alpha} \sqrt{\sum_{i=1}^n (x_i - \bar{x}_n)^2}}{s_\epsilon \sqrt{\bar{x}_n^2 + \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2}} = \frac{13\sqrt{10}}{\sqrt{\frac{4}{3}}\sqrt{9+2}} = \frac{13\sqrt{30}}{2\sqrt{11}} = 10.73$$

wat ook niet behoort tot $[-3.18, 3.18]$. De intercept is dus eveneens significant.

Voorbeeld III

De correlatie tussen X en Y is

$$r_{XY} = \frac{-30}{\sqrt{10}\sqrt{94}} = -\sqrt{\frac{900}{940}} = -\sqrt{\frac{45}{47}} = -0.98$$

Om te testen of de correlatie significant is moet men de volgende waarde berekenen:

$$t = \frac{r_{XY}}{\sqrt{\frac{(1-r_{XY}^2)}{n-2}}} = \frac{-\sqrt{\frac{45}{47}}}{\sqrt{\frac{(1-\frac{45}{47})}{3}}} = -\sqrt{\frac{45.3}{2}} = \frac{-3\sqrt{30}}{2}$$

wat overeenkomt met de test voor de helling (en het aanvaardingsgebied is ook hetzelfde). De testen zijn equivalent.

Illustratie I

De jaarlijkse belasting (in \$) voor 107 huizen in Albuquerque (USA) wordt vergeleken met de verkoopwaarde van de huizen (in 100\$). R geeft volgende output voor de regressie met 'tax' als responsvariabele en 'price' als verklarende variabele:

```
Call: lm(formula = pricetax$tax ~ pricetax$price)
```

```
Residuals:
```

```
Min      1Q  Median      3Q      Max
-417.3 -74.28   1.12  72.48  463.6
```

```
Coefficients:
```

```
Value Std. Error t value Pr(>|t|)
```

```
(Intercept) 36.3444 43.2374    0.8406  0.4025
```

```
pricetax$price 0.7028  0.0378   18.5805  0.0000
```


```
Residual standard error: 149.5 on 105 degrees of freedom
```

```
Multiple R-Squared: 0.7668
```

```
F-statistic: 345.2 on 1 and 105 degrees of freedom, the p-value is 0
```


Illustratie II


Merk op dat de helling van de rechte significant verschilt van 0, maar de intercept niet, we hebben hier dus te maken met een regressie door de oorsprong. Grafisch ziet de uitgevoerde regressie er als volgt uit:



De regressielijn lijkt aangetrokken te worden door enkele dure huizen, die onderbelast worden en dus de helling van de regressielijn verkleinen.


Illustratie III

Uit de plot van de residuen ten opzichte van de geschatte waarde voor de responsvariabele blijkt dat de spreiding van de residuen toeneemt naarmate de geschatte waarde groter wordt. De veronderstelling dat alle errortermen een gelijke spreiding hebben is dus niet voldaan. Dit noemt men **heteroscedasticiteit**.



Illustratie IV

Uit de QQ-plot van de residuen blijkt tevens dat ook de veronderstelling dat de residuen normaal verdeeld zijn, niet voldaan is.



Illustratie V

Omwille van bovenstaande redenen is het misschien aangewezen om de data te transformeren en de regressie opnieuw uit te voeren. Een logaritmische transformatie geeft

```
Call: lm(formula = log(pricetax$tax) ~ log(pricetax$price))
```

Residuals:

Min	1Q	Median	3Q	Max
-0.7312	-0.08682	0.01957	0.1241	0.3553

Coefficients:


Value	Std. Error	t value	Pr(> t)
(Intercept)	-0.6504	0.4190	-1.5521 0.1236
log(pricetax\$price)	1.0470	0.0604	17.3319 0.0000

Residual standard error: 0.1972 on 105 degrees of freedom


Multiple R-Squared: 0.741

F-statistic: 300.4 on 1 and 105 degrees of freedom, the p-value is 0

Illustratie VI




Illustratie VII



De spreiding van de residuen is overal even breed, enkel drie van de goedkopere huizen springen eruit met een kleine $\log(\text{tax})$ in vergelijking met de andere huizen.

Illustratie VIII



Bovendien blijft een zekere afwijking van de normaliteit van de residuen bestaan.