

Doel van statistiek

- 1 Verzamelen en samenvatten van gegevens (**beschrijvende statistiek**).
Het is meestal onmogelijk of onpraktisch om de hele **populatie** waar te nemen $\Rightarrow$ we maken beslissingen uitgaande van de **steekproef**.

Uiteraard moet steekproef **representatief** zijn. Wij werken met steekproef die **zuiver toevallig** of **lukraak** is:

- elke observatie wordt onder identieke omstandigheden uitgevoerd;
- elke observatie in de steekproef mag als onafhankelijk beschouwd worden van de andere observaties in de steekproef.

- 2 Op basis van een steekproef (en met behulp van kansrekenen) conclusies trekken omtrent de populatie (**verklarende statistiek**).

Voorbeeld: A/B-test in een webapp

- **Context:** je wil weten of een nieuwe signup-pagina (B) beter converteert dan de huidige (A).
- **Populatie:** alle bezoekers van de site (bv. deze maand).
- **Steekproef:** bezoekers die tijdens het experiment langskomen en lukraak worden toegewezen:
 - groep A: ziet oude versie
 - groep B: ziet nieuwe versie
- We definiëren per bezoeker een variabele


$$X_i = \begin{cases} 1 & \text{als bezoeker } i \text{ converteert (signup)} \\ 0 & \text{anders} \end{cases}$$

Dan is X_i een **Bernoulli**-variabele met parameter p (de conversiekans). De steekproefproportie $\hat{p} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ is een **schatter** voor p .


- **Vraag:** is het verschil $\hat{p}_B - \hat{p}_A$ echt, of kan dit door toeval komen?
- **Statistiek:** onzekerheid kwantificeren en beslissen.

Verklarende statistiek

Idealiter



In realiteit hebben we echter vaak een beperkte (tot zeer beperkte) steekproefomvang en is er twijfel omtrent de vorm van de kansverdeling, bvb



Verklarende statistiek

We willen een uitspraak doen over een kenmerk (variabele) van een populatie.

We beschikken over een steekproef uit deze populatie.

We modelleren het kenmerk a.d.h.v. de verdeling van dat kenmerk.

- Welke verdeling is geschikt?
 - Misschien $\mathcal{N}(\mu, \sigma^2)$? Wat is dan een geschikte keuze voor μ en voor σ^2 ?
 - Misschien $\mathcal{B}(n, p)$? Wat is dan een geschikte keuze voor p ?
- Welke waarden bepalen we voor de parameters van de verdeling?
 $\Rightarrow$ Welke **schattingen** voor μ, σ^2, p ?
(Deze onbekende parameters worden in het algemeen θ genoemd.)

Verklarende statistiek

Een steekproef uit een populatie (met populatie s.v. X) kan beschouwd worden als een rij stochastische variabelen

$$X_1, X_2, \dots, X_n$$

waarbij

- $X_1, X_2, \dots, X_n$ dezelfde verdeling hebben
- $X_1, X_2, \dots, X_n$ onafhankelijk zijn

(resultaat van een trekking hangt niet af van de andere trekkingen).

De variabelen X_i zijn **onderling onafhankelijk en identiek verdeeld (o.o.i.v)**
In het Engels: **independent and identically distributed (i.i.d.)**.

We noemen $(x_1, \dots, x_n)$ een **realisatie** van $(X_1, X_2, \dots, X_n)$

(Elke x_i is een realisatie van een toevalsvariabele X_i .)

Statistieken

Met behulp van s.v. $X_1, \dots, X_n$, die steekproef vormen uit X , definieert men nieuwe s.v. (**statistieken** genoemd) die functies zijn van $X_1, \dots, X_n$.

Definitie

Een **statistiek** T is een stochastiek die enkel afhangt van de steekproef $X_1, \dots, X_n$ en niet van de onbekende θ :

$$T = T(X_1, \dots, X_n)$$

Enkele voorbeelden

- het steekproefgemiddelde $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
- de steekproefvariantie $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$
- $T(X_1, \dots, X_n) = |X_1| + \dots + |X_n|$
- $T(X_1, \dots, X_n) = [(X_1)^5 + \dots + (X_n)^5]/n^2$

In een concreet experiment neemt T dus een getalwaarde aan.

Definitie

Een **schatter** van θ is een statistiek T die men gebruikt om de onbekende parameter θ te benaderen. Een **schatting** is de getalwaarde van T in een concreet geval.

Een **schatter** is dus een formule, maar 179cm is bvb een **schatting**.

Voorbeeld


Het steekproefgemiddelde $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ is een schatter van μ . Voor de concrete realisatie (1.1, 2.0, 3.4, 2.9, 0.6) krijgt men de schatting

$$\bar{x}_5 = \frac{1.1 + 2.0 + 3.4 + 2.9 + 0.6}{5} = 2.0.$$

Men moet goed het onderscheid maken tussen het steekproefgemiddelde $\bar{X}_n$ en het (populatie)gemiddelde μ van de verdeling $N(\mu, \sigma^2)$.

Steekproefgemiddelde als toevalsvariabele

- De geobserveerde steekproef is **maar één** mogelijke uitkomst.
- Met dezelfde steekproefgrootte n hadden we (in principe) **oneindig veel** andere steekproeven kunnen trekken.
- Elke steekproef geeft een ander steekproefgemiddelde $\bar{X}$.
- Daarom beschouwen we $\bar{X}$ als een **stochastische variabele** met een eigen verdeling.
- Alles vertrekt vanuit een **verondersteld model** voor X (de populatieverdeling).




Steekproefgemiddelde als toevalsvariabele

Elke steekproef van grootte n uit eenzelfde populatie levert een ander steekproefgemiddelde!


We beschouwen **steekproefgemiddelde als een s.v. !**

Stel: $X_i \sim \mathcal{N}(10, 9)$ voor $i = 1, \dots, 60$


$(x_1^{(1)}, x_2^{(1)}, \dots, x_{60}^{(1)})$ $(x_1^{(2)}, x_2^{(2)}, \dots, x_{60}^{(2)})$... $(x_1^{(50)}, x_2^{(50)}, \dots, x_{60}^{(50)})$



$$\bar{x}^{(1)} = 9.31$$



$$\bar{x}^{(2)} = 10.6$$



$$\dots \quad \bar{x}^{(50)} = 9.84$$

Steekproefgemiddelde als toevalsvariabele

Deze steekproefgemiddeldes $\bar{x}^{(1)}, \bar{x}^{(2)}, \bar{x}^{(3)}, \dots, \bar{x}^{(50)}$ zijn realisaties van

$$\bar{X} = \frac{1}{n}(X_1 + \dots + X_n)$$

waarbij X_i 's i.i.d.

We noemen $\bar{X}$ een **schatter** (puntschatter), en $\bar{x}$ een **schatting**

- Wat proberen we eigenlijk te schatten met $\bar{X}$?
- Hoe nauwkeurig/betrouwbaar is deze schatting?



⇒ Wat is de verdeling van $\bar{X}$?

Steekproefgemiddelde als toevalsvariabele

Stel: $X_i \sim \mathcal{N}(10, 9)$ voor $i = 1, \dots, 60$

Beschouw 50 realisaties van $\bar{X}$: $\bar{x}^{(1)}, \bar{x}^{(2)}, \dots, \bar{x}^{(50)}$

Resulterende histogram:



Verdeling van het steekproefgemiddelde

Er geldt steeds (indien $X_1, \dots, X_n$ i.i.d., cfr. Kansrekenen I)

- $E[\bar{X}] = E[X_1]$
- $\text{Var}[\bar{X}] = \frac{1}{n} \text{Var}[X_1]$

Bovendien geldt:


$$X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2) \text{ en onafhankelijk} \Rightarrow \bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

We besluiten dat $\bar{X}$ een schatter is voor $E[X_1]$.


- Indien X_i normaal verdeeld is, is $\bar{X}$ een schatter voor μ .
- Voor andere verdelingen: gebruik CLS voor benaderende verdeling van $\bar{X}$

Verdeling van het steekproefgemiddelde

$$X_i \sim \mathcal{N}(10, 9):$$



$$\mathcal{N}(10, 9/60)$$



normale kwantielplot

Centrale Limietstelling (CLS) I

De centrale limietstelling (CLS)

Zij $X_1, X_2, \dots$ een rij onafhankelijke stochastische veranderlijken met allen dezelfde verdeling (i.i.d.), waarvoor $E(X_i) = \mu$ en $\text{Var}(X_i) = \sigma^2 > 0$ en eindig, dan geldt:

$$\forall x \in \mathbb{R} : \quad \lim_{n \rightarrow \infty} P \left(\frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \leq x \right) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{1}{2}u^2} du.$$

Of kortweg

$$P_{\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}} \xrightarrow{n \rightarrow \infty} \mathcal{N}(0, 1) \quad \text{of} \quad P_{\bar{X}_n} \xrightarrow{n \rightarrow \infty} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

Uit welke verdeling men de waarnemingen ook trekt (voorzover σ^2 bestaat), de verdeling van het gemiddelde van een groot aantal waarnemingen zal steeds normaal worden.

Centrale limietstelling

De centrale limietstelling wordt vaak losweg genoteerd als:

Praktisch nut CLS

Als (X_n) i.i.d. zijn met eindige variantie (en n is **voldoende groot**), dan

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

met $\mu = E[X_1]$ en $\sigma^2 = \text{Var}[X_1]$.

- Gemiddelde van n i.i.d. uitkomsten is bij benadering normaal verdeeld rond zijn limietwaarde (i.e. verwachtingswaarde μ).
- Variantie neemt af naarmate n stijgt, dus precisie van benadering $\bar{X}_n$ voor parameter μ stijgt als n groter wordt.

Centrale limietstelling

We kunnen de CLS ook herschrijven voor een som i.p.v. een gemiddelde (X_i i.i.d.):

$$S_n = n\bar{X} = X_1 + \dots + X_n \implies E[S_n] = n\mu; \quad \text{Var}[S_n] = n\sigma^2$$

Centrale Limietstelling (CLS) - Lindeberg 1922 - Lévy 1925

Stel $X_1, \dots, X_n, \dots$ zijn onafhankelijk en hebben dezelfde verdeling, met $m = E[X_1]$ en $\sigma^2 = \text{Var}[X_1] < \infty$.

Beschouw de gestandaardiseerde som

$$U_n = \frac{(X_1 + \dots + X_n) - E[X_1 + \dots + X_n]}{\sqrt{\text{Var}[X_1 + \dots + X_n]}} = \frac{S_n - E[S_n]}{\sqrt{\text{Var}[S_n]}}$$

Dan geldt

$$P_{U_n} \xrightarrow{n \rightarrow \infty} \mathcal{N}(0, 1) \quad \text{of} \quad P_{S_n} \xrightarrow{n \rightarrow \infty} \mathcal{N}(n\mu, n\sigma^2)$$

Centrale limietstelling

Er geldt dus dat voor $n \rightarrow \infty$

$$P \left[\left(\frac{S_n - n\mu}{\sqrt{n}\sigma} \right) \leq x \right] \rightarrow \Phi(x)$$

voor alle $x \in \mathbb{R}$ waarbij Φ de standaardnormale verdelingsfunctie voorstelt.

In de praktijk gebruiken we CLS opnieuw vooral in deze vorm:

Praktisch nut CLS

Als (X_n) i.i.d. zijn met eindige variantie (en n is **voldoende groot**), dan

$$S_n = \sum_{i=1}^n X_i \approx \mathcal{N}(n\mu, n\sigma^2)$$

met $\mu = E[X_1]$ en $\sigma^2 = \text{Var}[X_1]$.

Centrale limietstelling: opmerkingen

Deze stelling laat toe benaderend volgende kansen $P(\bar{X} \in A)$ en $P(S_n \in A)$ te berekenen. Normale benadering is geldig onder heel algemene voorwaarden!

- De verdeling van X_i hoeft niet continu te zijn!
- De verdeling van X_i hoeft niet symmetrisch te zijn! Maar hoe schever de verdeling van X_i , hoe groter n moet zijn om een nauwkeurige benadering te hebben.
- Vele kenmerken kunnen geïnterpreteerd worden als de som van een groot aantal kenmerken (bv lengte). De centrale limietstelling verklaart waarom de normale verdeling hiervoor een geschikte verdeling is.
- Er bestaan heel wat veralgemeningen van de centrale limietstelling, bijvoorbeeld wanneer de X_i niet onafhankelijk zijn.

Onmogelijk om uit te drukken hoe goed de benadering is voor een bepaalde (eindige) waarde van n ! De stelling geeft geen informatie over de kwaliteit voor een vast gekozen n (hangt sterk af van de ongekennde verdeling).

Zuivere schatters

Definitie

Een schatter van θ heet **zuiver** (“unbiased”, “onvertekend”) als zijn verwachtingswaarde gelijk is aan de parameter θ , dwz.

$$E[T] = \theta$$

voorbeeld

Indien $X_1, \dots, X_n$ i.i.d. met verwachtingswaarde $E[X_1] = \mu$ en variantie $\text{Var}[X_1] = \sigma^2$, dan is

$$E[\bar{X}_n] = E\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \frac{1}{n} \sum_{i=1}^n \mu = \mu$$

dus is $\bar{X}_n$ een zuivere schatter van μ .

We willen ook de spreiding van $\bar{X}_n$ kennen:

$$\text{Var}[\bar{X}_n] = \text{Var}\left[\frac{1}{n} \sum_{i=1}^n X_i\right] = \frac{1}{n^2} \sum_{i=1}^n \text{Var}[X_i] = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{\sigma^2}{n}$$

hetgeen een idee geeft over de nauwkeurigheid van de schatter.

Variantie en MSE

- We willen ook dat (zuivere) schatters een zo klein mogelijke spreiding hebben.
⇒ Klein mogelijke variantie
- Indien $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, dan is

$$\text{Var}[\bar{X}_n] = \frac{1}{n^2} \sum_{i=1}^n \text{Var}[X_i] = \frac{\sigma^2}{n}.$$

- In het algemeen willen we de schatter vinden die θ zo dicht mogelijk benadert en hiervoor wordt vaak het gemiddelde verlies of de **mean squared error** beschouwd:

$$\text{MSE}(T) = \text{E}[(T - \theta)^2] \leq \infty$$

Hoe kleiner de MSE, hoe beter de nauwkeurigheid van T !

We hebben het volgende verband tussen bias, variantie en mean squared error.

Definitie

Voor iedere kwadratisch integreerbare schatter T geldt:

$$\text{MSE}(T) = (b(T))^2 + \text{Var}(T) \quad \forall \theta \in \Theta.$$

Puntschatters voor spreidingskenmerken

Herinner

- Centrummaat alleen verschaft vaak te weinig informatie.
- Kenmerken die weergeven hoe ver/dicht punten rond centrummaat verspreid liggen:

Steekproefvariantie

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

OF

(Steekproef)standaardafwijking of (steekproef)standaarddeviatie

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

Puntschatters voor spreidingskenmerken

Kwadrateren ipv absolute waarde

- Kwadrateren is eenvoudiger te manipuleren mathematische bewerking dan absolute waarde.
- Variantie bezit bijzondere eigenschappen wanneer data normaalverdeeld.

Delen door $n - 1$ ipv door n

- Stel $n = 1$ (steekproefelement = steekproefgemiddelde)
 - Indien $\frac{1}{n}$: spreiding 0 $\rightarrow$ geen toeval meer (determinisme).
 - Indien $\frac{1}{n-1}$: spreiding onbepaald ($\frac{0}{0}$)
- Intuïtief argument: we hebben reeds 1 van de n vrijheidsgraden gebruikt bij de berekening van $\bar{X}$ in de formule van de standaardafwijking.

Puntschatters voor variantie van een normaal verdeelde populatie

We beschouwen steekproefvariantie als kansvariabele en noteren

$$\hat{\sigma}^2 = S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Stelling

Zij $X_1, \dots, X_n$ toevallige steekproef uit $\mathcal{N}(\mu, \sigma^2)$ verdeelde populatie, dan geldt

$$E[S^2] = \sigma^2$$

Bewijs I

$$\begin{aligned}E[S^2] &= E\left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right] \\&= \frac{1}{n-1} E\left[\sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2)\right] \\&= \frac{1}{n-1} E\left[\sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2\right] \\&= \frac{1}{n-1} E\left[\sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2\right] \\&= \frac{1}{n-1} \left(\sum_{i=1}^n E[X_i^2] - nE[\bar{X}^2]\right) \\&= \frac{n}{n-1} (E[X_1^2] - E[\bar{X}^2])\end{aligned}$$

Bewijs II

Vermits

- $\sigma^2 = \text{Var}(X_1) = E[X_1^2] - \mu^2$
 $\Rightarrow E[X_1^2] = \sigma^2 + \mu^2$
- $\text{Var}[\bar{X}] = \frac{\sigma^2}{n}$ en $E[\bar{X}] = \mu$
 $\Rightarrow E[\bar{X}^2] = \frac{\sigma^2}{n} + \mu^2$

geldt

$$\begin{aligned} E[S^2] &= \frac{n}{n-1} \left(E[X_1^2] - E[\bar{X}^2] \right) \\ &= \frac{n}{n-1} \left(\sigma^2 + \mu^2 - \left(\frac{\sigma^2}{n} + \mu^2 \right) \right) \\ &= \sigma^2 \end{aligned}$$

Puntschatters voor variantie van een normaal verdeelde populatie

Voor $S_*^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ geldt:

- $E[S_*^2] = E\left[\frac{n-1}{n} S^2\right] = \frac{n-1}{n} \sigma^2$

dus S_*^2 is **geen** zuivere schatter voor σ^2 !

- Is S een zuivere schatter voor σ ?

Kansverdeling van S^2

De afleiding van de verdeling van S^2 steunt op volgende stelling

Stelling van Helmert (1876)

Als $X_1, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$ onafhankelijk met $n \geq 2$ dan geldt

① $\bar{X} \sim \mathcal{N}(\mu, \frac{\sigma^2}{n})$

② $\bar{X}$ en S^2 zijn onafhankelijk

③ $\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$

Zonder bewijs


χ^2 -verdeling

Definitie

Laat $Z_1, \dots, Z_n \sim \mathcal{N}(0, 1)$ en onafhankelijk, dan heet de verdeling van $X = Z_1^2 + \dots + Z_n^2$ een χ_n^2 -verdeling


- De dichtheidsfunctie van χ_n^2 is $f_{\chi_n^2}(x) = \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} e^{-\frac{x}{2}} x^{\frac{n}{2}-1}$ voor $x > 0$
- We gebruiken gammafunctie $\Gamma(t) = \int_0^\infty x^{t-1} e^{-x} dx$ voor $t > 0$ met eigenschappen
 - $\Gamma(t+1) = t\Gamma(t)$ voor $t > 0$
 - $\Gamma(n+1) = n!$ voor elk positief geheel getal n
- $\mu_X = E[X] = n$
- $\sigma_X^2 = \text{Var}[X] = 2n$
- Enkel positieve waarden
- Rechtsscheef

χ^2 -verdeling met m vrijheidsgraden



Kansverdeling van S^2

- 1 Genereer 10000 reeksen van 10 getallen uit $\mathcal{N}(\mu = 5, \sigma^2 = 4)$
- 2 Bereken voor elke reeks de steekproefvariantie S^2
- 3 Vermenigvuldig telkens met $n - 1 = 9$ en deel door $\sigma^2 = 4$
- 4 Bekijk bijbehorend histogram



Puntschatter voor proportie (of kans) p

$$X_i \sim \mathcal{B}(1, p), i = 1, \dots, n$$

Relatieve frequentie of **proportie** successen in de steekproef:

$$\hat{P} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

- $E[\hat{P}] = p \quad \Rightarrow$ onvertekend
- $\text{Var}[\hat{P}] = \frac{p(1-p)}{n}$
- $\frac{\hat{P} - p}{\sqrt{\frac{p(1-p)}{n}}} \stackrel{CLS}{\approx} \mathcal{N}(0, 1)$ indien n voldoende groot

Puntschatter voor proportie (of kans) p

Variantie omgekeerd evenredig met de steekproefgrootte n

Dus hoe meer observaties, hoe nauwkeuriger p geschat kan worden

↪ steekproefproportie $\hat{p}$ zal zich stabiliseren rond populatieproportie p voor stijgende waarden van n

