

Onafhankelijkheidstest tussen twee discrete veranderlijken

Steekproef $\{(X_1, Y_1); \dots; (X_n, Y_n)\}$ waar discrete X_i en Y_i verbonden zijn.

Bvb.: Variabele X: roker/geen roker en Variabele Y: kleur haar:

blond/bruin/zwart

H_0 : de variabelen X en Y zijn onafhankelijk.

- We berekenen de waargenomen frequenties:

N_{lj} = aantal waarnemingen (X_i, Y_i) waarbij $X_i = l$ en $Y_i = j$

- We doen dit voor alle $l = 1, \dots, r$ en $j = 1, \dots, k$.
- We construeren **contingentietabel** met r rijen en k kolommen:

		Y			
		1	2	3	
X	1	N_{11}	N_{12}	N_{13}	$N_{1.}$
	2	N_{21}	N_{22}	N_{23}	$N_{2.}$
		$N_{.1}$	$N_{.2}$	$N_{.3}$	n

Onafhankelijkheidstest tussen twee discrete veranderlijken

De marginale frequenties zijn de sommen van de waargenomen frequenties

$$N_{l.} = N_{l1} + N_{l2} + N_{l3} := \text{aantal } \{i; X_i = l\}$$

$$N_{.j} = N_{1j} + N_{2j} := \text{aantal } \{i; Y_i = j\}$$

Nu kunnen we de marginale kansen schatten:

$$p_{l.} = P[X = l]$$

$$p_{.j} = P[Y = j]$$

door de onvertekende (zuivere) schatters:

$$\hat{p}_{l.} = \frac{\text{aantal } X_i = l}{n} = \frac{N_{l.}}{n}$$

$$\hat{p}_{.j} = \frac{\text{aantal } Y_i = j}{n} = \frac{N_{.j}}{n}$$

Onder H_0 geldt dan:

$$p_{lj} = P[X = l, Y = j] = P[X = l]P[Y = j] = p_{l.}p_{.j}$$

Onafhankelijkheidstest tussen twee discrete veranderlijken

We kunnen de p_{lj} schatten door $\hat{p}_{lj} = \hat{p}_{l.}\hat{p}_{.j}$

$\hat{p}_{11}$	$\hat{p}_{12}$	$\hat{p}_{13}$	$\hat{p}_{1.}$
$\hat{p}_{21}$	$\hat{p}_{22}$	$\hat{p}_{23}$	$\hat{p}_{2.}$
$\hat{p}_{.1}$	$\hat{p}_{.2}$	$\hat{p}_{.3}$	1

zodat we uiteindelijk de theoretische frequenties kunnen berekenen:

$$n\hat{p}_{lj} = n\hat{p}_{l.}\hat{p}_{.j} = n \frac{N_{l.}}{n} \frac{N_{.j}}{n} = \frac{N_{l.}N_{.j}}{n}.$$

Dit geeft ons de theoretische contingentietabel

$\frac{N_{1.}N_{.1}}{n}$	$\frac{N_{1.}N_{.2}}{n}$	$\frac{N_{1.}N_{.3}}{n}$	$N_{1.}$
$\frac{N_{2.}N_{.1}}{n}$	$\frac{N_{2.}N_{.2}}{n}$	$\frac{N_{2.}N_{.3}}{n}$	$N_{2.}$
$N_{.1}$	$N_{.2}$	$N_{.3}$	n

met dezelfde marginales als voordien.

Onafhankelijkheidstest tussen twee discrete veranderlijken

De waargenomen frequenties hebben een binomiale verdeling:

$$N_{ij} \sim B(n, p_{ij}).$$

- Benaderen door een Poisson verdeling met parameter $\lambda = np_{ij}$
- Deze daarna benaderen door normale verdeling als np_{ij} groot genoeg is.

Volgens theorema van Pearson geldt dan dat de statistiek:

$$\sum \frac{(\text{waargenomen frequenties} - \text{theoretische frequenties})^2}{\text{theoretische frequenties}}$$

onder H_0 benaderend χ^2 verdeeld is.

Onafhankelijkheidstest tussen twee discrete veranderlijken

Aantal gevallen in de tabel is gelijk aan rk en we hebben dus rk termen.
De volgende parameters hebben we geschat:

$$\begin{array}{ccccccc} p_{1.} & p_{2.} & \dots & p_{r-1.} & \text{en } p_{r.} = 1 - p_{1.} - p_{2.} - \dots - p_{r-1.} \\ p_{.1} & p_{.2} & \dots & p_{.k-1} & \text{en } p_{.k} = 1 - p_{.1} - p_{.2} - \dots - p_{.k-1} \end{array}$$

$\Rightarrow$ totaal aantal geschatte parameters is $v = (r - 1) + (k - 1)$

$\Rightarrow$ aantal vrijheidsgraden is

$$rk - (r - 1) - (k - 1) - 1 = rk - r - k + 1 = (r - 1)(k - 1).$$

We hebben dus

$$\sum_{l=1}^r \sum_{j=1}^k \frac{\left(N_{lj} - \frac{N_{l.} N_{.j}}{n} \right)^2}{\frac{N_{l.} N_{.j}}{n}} \approx \chi_{(r-1)(k-1)}^2 \quad | H_0$$

als alle theoretische frequenties $\frac{N_{l.} N_{.j}}{n} \geq 5$.

Het aanvaardingsgebied is $[0, \chi_{(r-1)(k-1); 1-\alpha}^2]$.

Onafhankelijkheidstest tussen twee discrete veranderlijken

Voorbeeld Men heeft aan 870 eerstejaarsstudenten gevraagd of ze alcohol dronken (bier, wijn,...). Er waren drie mogelijkheden:

$$\begin{aligned}X_i &= 1 && \text{regelmatig} \\ &= 2 && \text{soms} \\ &= 3 && \text{nooit}\end{aligned}$$

Vervolgens onderzocht men hun examenresultaten:

$$\begin{aligned}Y_i &= 1 && \text{niet geslaagd} \\ &= 2 && \text{geslaagd}\end{aligned}$$

We testen de onafhankelijkheid tussen deze twee.

Onafhankelijkheidstest tussen twee discrete veranderlijken

De geobserveerde frequenties zijn:

		examen		
		niet geslaagd	geslaagd	
alcohol	regelmatig	70	35	105
	soms	331	377	708
	nooit	39	18	57
		440	430	870

Onafhankelijkheidstest tussen twee discrete veranderlijken

De theoretische frequenties onder H_0 worden dan:

53.1	51.9	105
358.1	349.9	708
28.8	28.2	57
440	430	870

De teststatistiek wordt:

$$\frac{(70 - 53.1)^2}{53.1} + \frac{(35 - 51.9)^2}{51.9} + \frac{(331 - 358.1)^2}{358.1} + \frac{(377 - 349.9)^2}{349.9} + \frac{(39 - 28.8)^2}{28.8} + \frac{(18 - 28.2)^2}{28.2} = 22.33$$

Vrijheidsgraden: $(r - 1)(k - 1) = (3 - 1)(2 - 1) = 2$

Aanvaardingsgebieden:

$$\alpha = 5\% \quad [0, \chi^2_{2,0.95}] = [0, 5.991]$$

$$\alpha = 1\% \quad [0, \chi^2_{2,0.99}] = [0, 9.210]$$

Dus de hypothese van onafhankelijkheid is verworpen, zelfs voor $\alpha = 1\%$.

(Merk op dat het slaagpercentage veel hoger is voor de studenten die af en toe drinken (53 %) dan voor de twee andere groepen (33 % en 32 %).)

Onafhankelijkheidstest tussen 2 discrete veranderlijken I

Opmerkingen:

- ① De methode van χ^2 is invariant in de zin dat men hetzelfde resultaat verkrijgt door X en Y te permuteren of ook als men de code verandert (bv. $Y_i = 1$ bij succes, $Y_i = 2$ bij mislukking).
- ② Het aantal vrijheidsgraden kan eenvoudig gerechtvaardigd worden: als men een blok van $(r - 1)(k - 1)$ frequenties kent en de marginale frequenties dan kan men de resterende frequenties daaruit afleiden.
- ③ Als in een 2×2 tabel de onafhankelijkheid verworpen wordt, zijn er maar 2 mogelijke situaties:

$$\begin{aligned}
 N_{11} &> \frac{N_{1.} N_{.1}}{n} &\Rightarrow & N_{12} < \frac{N_{1.} N_{.2}}{n} \\
 &&\text{en} & N_{21} < \frac{N_{2.} N_{.1}}{n} \\
 &&&\Rightarrow & N_{22} > \frac{N_{2.} N_{.2}}{n}
 \end{aligned}$$

In dat geval is er een “positieve” relatie tussen de twee variabelen gevonden.

Onafhankelijkheidstest tussen 2 discrete veranderlijken II

Of,

$$\begin{aligned}
 N_{11} < \frac{N_{1.} N_{.1}}{n} &\Rightarrow N_{12} > \frac{N_{1.} N_{.2}}{n} \\
 \text{en } N_{21} &> \frac{N_{2.} N_{.1}}{n} \\
 &\Rightarrow N_{22} < \frac{N_{2.} N_{.2}}{n}
 \end{aligned}$$

Hier kunnen we spreken van een “negatieve” relatie.

- 4 Een $2 \times k$ tabel komt overeen met een test van 2 discrete verdelingen ($k = 2 \Rightarrow$ Bernoulli)
- 5 Men kan de contingentietabel ook gebruiken voor continue variabelen als men hergroepeert in klassen.
- 6 Men kan testen $H_0 : X, Y, Z$ onafhankelijk met behulp van een driedimensionale contingentietabel met rkh gevallen en $(r-1)(k-1)(h-1)$ vrijheidsgraden.

Onafhankelijkheid van continue variabelen

Onafhankelijk testen van twee continue verbonden variabelen X en Y :

$$X : \Omega \rightarrow \mathbb{R} ; Y : \Omega \rightarrow \mathbb{R}$$

karakteristiek	zuivere schatter
$E[X]$	$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$
$E[Y]$	$\bar{Y}_n = \frac{1}{n} \sum_{i=1}^n Y_i$
$\text{Var}[X] = E[(X - E[X])^2]$	$S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$
$\text{Var}[Y] = E[(Y - E[Y])^2]$	$S_Y^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y}_n)^2$
$\text{Cov}[X, Y] = E[(X - E[X])(Y - E[Y])]$	$S_{XY} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)(Y_i - \bar{Y}_n)$

Bewijs dat S_{XY} zuivere schatter is, is analoog aan dat van S_X^2 . Variantie is speciaal geval van covariantie:

$$\text{Cov}[X, X] = \text{Var}[X]$$

$$\text{Cov}[Y, Y] = \text{Var}[Y]$$

$$S_{XX} = S_X^2$$

$$S_{YY} = S_Y^2$$

Onafhankelijkheid van continue variabelen

Enkele eigenschappen van de covariantie:

$$\text{Cov}[X, Y] = \text{Cov}[Y, X]$$

$$S_{XY} = S_{YX}$$

$$\text{Cov}[aX + b, cY + d] = ac \text{Cov}[X, Y]$$

$$S_{aX+b, cY+d} = acS_{XY}$$

Covariantie heeft als eenheden deze van X keer Y .

Om te testen of X en Y onafhankelijk zijn verkiest men iets zonder eenheden en invariant voor transformaties.

Definitie

De correlatie van X en Y is

$$\text{Corr}[X, Y] = \frac{\text{Cov}[X, Y]}{\sqrt{\text{Var}[X]\text{Var}[Y]}}$$

De empirische correlatie tussen X en Y is dan

$$R = R_{XY} = \frac{S_{XY}}{\sqrt{S_X^2 S_Y^2}} = \frac{\sum_{i=1}^n (X_i - \bar{X}_n)(Y_i - \bar{Y}_n)}{\sqrt{\sum_{i=1}^n (X_i - \bar{X}_n)^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y}_n)^2}}$$

Onafhankelijkheid van continue variabelen

Merk op dat R_{XY} een goede schatter is voor $\text{Corr}[X, Y]$ maar met een kleine vertekening ($E[R_{XY}] \neq \text{Corr}[X, Y]$).

De correlatie heeft geen eenheden en is invariant onder transformaties $X \rightarrow aX + b$. De correlatie is ligt altijd tussen -1 en 1.

Eigenschappen:

$$-1 \leq \text{Corr}[X, Y] \leq 1$$

$$\text{Corr}[X, X] = 1$$

$$\text{Corr}[X, Y] = \text{Corr}[Y, X]$$

$$\text{Corr}[aX + b, cY + d] = \text{Corr}[X, Y] \text{ met } a, c > 0$$

$$-1 \leq R_{XY} \leq 1$$

$$R_{XX} = 1$$

$$R_{XY} = R_{YX}$$

$$R_{aX+b, cY+d} = R_{XY}$$

Onafhankelijkheid van continue variabelen

Stelling

Als X en Y onafhankelijk zijn dan is $\text{Corr}[X, Y] = 0$.

Bewijs:

$$\text{Corr}[X, Y] = \frac{\text{Cov}[X, Y]}{\sqrt{\text{Var}[X]\text{Var}[Y]}} = 0$$

$$\begin{aligned} \text{met } \text{Cov}[X, Y] &= E[(X-E[X])(Y-E[Y])] = E[X-E[X]]E[Y-E[Y]] \\ &= (E[X]-E[X])(E[Y]-E[Y]) = 0. \end{aligned}$$

Opmerking: Het omgekeerde is niet altijd waar!

Voorbeeld: als $X \sim N(0, 1)$ en $Y = X^2$ dan zijn X en Y afhankelijk en toch geldt:

$$\begin{aligned} \text{Cov}[X, Y] &= E[(X-E[X])(Y-E[Y])] = E[X(X^2 - E[X^2])] \\ &= E[X(X^2 - 1)] = E[X^3 - X] = E[X^3] - E[X] = 0 - 0 = 0 \end{aligned}$$

Onafhankelijkheid van continue variabelen

In het geval van een lineaire relatie $Y = aX + b$ ($a \neq 0$) geldt:

$$\text{Cov}[X, Y] = \text{Cov}[X, aX + b] = a\text{Cov}[X, X] = a\text{Var}[X]$$

$$\text{Corr}[X, Y] = \frac{a\text{Var}[X]}{\sqrt{\text{Var}[X]\text{Var}[X]a^2}} = \frac{a}{\sqrt{a^2}} = \begin{cases} +1 & \text{als } a > 0 \\ -1 & \text{als } a < 0 \end{cases}$$



Omwillen van deze relatie noemt men dit ook de lineaire correlatie. Andere namen zijn correlatiecoëfficiënt of correlatie van (Bravais-)Pearson.

Als men observaties $(x_1, y_1), \dots, (x_n, y_n)$ heeft, kan men deze representeren als punten met 2 coördinaten. Bekijken we enkele steekproeven en hun correlatie.

Onafhankelijkheid van continue variabelen



$r_{xy} = 1.0$: puntenwolk gereduceerd tot rechte, perfect positieve relatie

$r_{xy} = -1.0$: perfecte negatieve relatie



$r_{xy} \approx 0.5$: positieve relatie, verhoogde waarde van X_i komt overeen met verhoogde waarde van Y_i

$r_{xy} \approx -0.5$: negatieve relatie, met verhoogde waarde van X_i komt verlaagde waarde van Y_i overeen



Onafhankelijkheid van continue variabelen

Voor de onafhankelijkheidstest veronderstellen we dat

$$X_1, \dots, X_n \sim N(\mu_1, \sigma_1^2)$$

$$Y_1, \dots, Y_n \sim N(\mu_2, \sigma_2^2)$$

met μ_1, μ_2, σ_1 en σ_2 onbekend. De nulhypothese veronderstelt

$H_0 : X$ en Y zijn onafhankelijk.

Stelling

$$\frac{R_{XY}}{\sqrt{\frac{(1-R_{XY}^2)}{n-2}}} \sim t_{n-2} \quad | H_0$$

Onafhankelijkheid van continue variabelen

Tweezijdige test:

$$\begin{cases} H_0 : \text{onafhankelijkheid}(\text{Corr}[X, Y] = 0) \\ H_1 : \text{lineaire afhankelijkheid}(\text{Corr}[X, Y] \neq 0) \end{cases}$$

$$\text{Aanvaardingsgebied} : [-t_{n-2, 1-\frac{\alpha}{2}}, t_{n-2, 1-\frac{\alpha}{2}}]$$

Eenzijdige test:

$$\begin{cases} H_0 : \text{onafhankelijkheid} \\ H_1 : \text{Corr}[X, Y] > 0 \end{cases}$$

$$\text{Aanvaardingsgebied} :] -\infty, t_{n-2, 1-\alpha}]$$

$$\begin{cases} H_0 : \text{onafhankelijkheid} \\ H_1 : \text{Corr}[X, Y] < 0 \end{cases}$$

$$\text{Aanvaardingsgebied} : [-t_{n-2, 1-\alpha}, +\infty[$$

Onafhankelijkheid van continue variabelen

Voorbeeld:

Bestaat er een positieve lineaire relatie tussen de gewichtstoename van de moeder gedurende de zwangerschap en het gewicht van de pasgeborene ($\alpha = 5\%$)? Voor de steekproef $(x_1, y_1), \dots, (x_{30}, y_{30})$ heeft men $r_{xy} = 0.47$ berekend.

$$\frac{r_{xy}}{\sqrt{\frac{(1-r_{xy}^2)}{28}}} = 2.818$$

Eenzijdig $\Rightarrow] - \infty, t_{28,0.95}] =] - \infty, 1.7011]$


Besluit: de positieve lineaire relatie is significant op het 5% niveau.

Onafhankelijkheid bij continue veranderlijken

Merk op: een noodzakelijke voorwaarde voor bivariate normaliteit is de normaliteit van X en Y . De normaliteit van de marginale verdelingen kunnen we nagaan (QQ-plot).


- Omdat we bivariate normaliteit (nog) niet kunnen testen, is het steeds aangewezen een scatterplot van de gegevens te maken. Herinner dat voor bivariaat normaal verdeeld, de scatterplot van X ten opzichte van Y een elliptische puntenwolk zou moeten vormen.
(Ook mogelijke uitschieters kunnen hierop trouwens gedetecteerd worden.)
- Het is immers mogelijk dat X en Y afzonderlijk normaal verdeeld zijn en ongecorreleerd (zodat de hypothesetest H_0 niet zou verwerpen), maar dat o.w.v. het niet bivariaat normaal verdeeld zijn van (X, Y) de test niet geldig is en er in feite wel een afhankelijkheid tussen X en Y bestaat.

Onafhankelijkheid bij continue veranderlijken



elliptische puntenwolken

Onafhankelijkheid bij continue veranderlijken



geen elliptische puntenwolken