


# Testen van een discrete verdeling

Testen of  $X_i$  uit gegeven discrete verdeling gedefinieerd op verzameling met  $k$  waarden  $\{z_1, \dots, z_k\}$  met theoretische kansen  $\{p_1, \dots, p_k\}$  komen.



$H_0 : X_1, \dots, X_n \sim \text{de theoretische discrete verdeling}$

# Testen van een discrete verdeling

- Na experiment krijgen we  $n$  waarden uit  $\{z_1, \dots, z_k\}$ .
- Bereken hierop waargenomen (empirische) frequenties

$N_1 = \text{aantal } X_i \text{ die gelijk zijn aan } z_1$

$N_2 = \text{aantal } X_i \text{ die gelijk zijn aan } z_2$

$\vdots$

$N_k = \text{aantal } X_i \text{ die gelijk zijn aan } z_k$

waar  $N_1 + N_2 + \dots + N_k = n$  de steekproefgrootte.

- Als  $H_0$  waar is, dan voldoet de frequentie  $N_1$  aan  
 $N_1 = \text{aantal successen uit } n \text{ onafhankelijke experimenten} \sim B(n, p_1)$
- De benadering van Poisson levert dan  
 $N_1 \approx P(\lambda)$  met  $\lambda = np_1$
- Indien  $\lambda = np_1$  groot, dan kunnen we de 'normale' benadering doorvoeren.

$$\frac{N_1 - np_1}{\sqrt{np_1}} = \frac{N_1 - \lambda}{\sqrt{\lambda}} \approx N(0, 1)$$

# Testen van een discrete verdeling

- Als we dit herhalen voor  $j = 1, \dots, k$  dan kunnen we de som

$$\left( \frac{N_1 - np_1}{\sqrt{np_1}} \right)^2 + \left( \frac{N_2 - np_2}{\sqrt{np_2}} \right)^2 + \dots + \left( \frac{N_k - np_k}{\sqrt{np_k}} \right)^2$$

berekenen en deze is benaderend  $\chi^2$  verdeeld.

- Aantal vrijheidsgraden is niet  $k$  maar  $k - 1$  omdat er relatie is tussen  $N_i$ 's. Bijvoorbeeld:  $N_k$  is volledig bepaald door de overige, want

$$N_k = n - N_1 - \dots - N_{k-1}.$$

Dus geldt er,

$$\sum_{j=1}^k \left( \frac{N_j - np_j}{\sqrt{np_j}} \right)^2 \approx \chi_{k-1}^2 \quad | H_0 \quad (\text{K.Pearson})$$

Men kan dit ook uitdrukken als volgt:


$$\sum \frac{(\text{waargenomen frequenties} - \text{theoretische frequenties})^2}{\text{theoretische frequenties}}$$

# Testen van een discrete verdeling

De teststatistiek is altijd positief en als ze nul is, wil dit zeggen dat

$$N_1 - np_1 = 0, \dots, N_k - np_k = 0 \quad (\text{ideaal geval})$$

Om  $H_0$  te testen is dus het nodig om te kijken of de statistiek niet te groot is.



Het aanvaardingsgebied is dan  $[0, \chi^2_{k-1;1-\alpha}]$ .


# Testen van een discrete verdeling

Een bibliothecaris wil weten of het aantal geleende boeken op maandag, dinsdag, woensdag, donderdag, vrijdag en zaterdag een uniforme verdeling heeft. We testen deze hypothese ( $\alpha = 5\%$ ,  $\alpha = 1\%$ ) aan de hand van de gegevens:

| dag           | ma. | di. | woe. | do. | vrij. | zat. |
|---------------|-----|-----|------|-----|-------|------|
| aantal boeken | 26  | 32  | 23   | 29  | 34    | 41   |

$$k = 6, n = n_1 + \dots + n_6 = 185$$

De theoretische verdeling: alle  $p_j = \frac{1}{6}$



# Testen van een discrete verdeling

Alle theoretische frequenties zijn  $np_j = \frac{185}{6} = 30.833$

De teststatistiek wordt

$$\begin{aligned} & \sum_{j=1}^6 \frac{(n_j - 30.833)^2}{30.833} \quad (\text{geen dimensies!}) \\ &= \frac{1}{30.833} \{23.361 + 1.361 + 61.361 + 3.361 + 10.028 + 103.361\} \\ &= \frac{202.833}{30.833} = 6.578 \end{aligned}$$

Het aanvaardingsgebied wordt dan:

$$\alpha = 5\% \quad [0, \chi_{5,0.95}^2] = [0, 11.070] \quad \text{bevat } 6.578$$

$$\alpha = 1\% \quad [0, \chi_{5,0.99}^2] = [0, 15.086] \quad \text{bevat } 6.578$$

In de twee gevallen wordt de  $H_0$  hypothese aanvaard, dus de afwijking van de uniformiteit is niet significant.

# Testen van een discrete verdeling

## Opmerkingen

- 1 Om de benadering door een  $\chi^2$ -verdeling te rechtvaardigen hebben we verondersteld dat de  $np_j$  groot genoeg waren. In de praktijk wil men dat de  $np_j$  (= de theoretische frequenties) groter of gelijk zijn aan 5. Als het mogelijk is, neemt men een grote  $n$ . Indien niet, dan verhoogt men de theoretische frequenties door de  $z_j$  te hergroeperen in klassen. In het bijzonder is het altijd nodig te hergroeperen in klassen als het aantal mogelijke waarden  $z_j$  oneindig is. Het aantal klassen wordt genoteerd met  $k$  en men gebruikt dezelfde formules als voordien.
- 2 Soms gebruikt men hetzelfde experiment eerst voor de schatting van  $v$  parameters van de theoretische verdeling. In dat geval wordt het aantal vrijheidsgraden met  $v$  verminderd en werken we dus met  $\chi^2_{k-v-1}$ .

# Testen van een discrete verdeling

Men wil de hypothese testen dat een steekproef  $x_1, \dots, x_{80}$  getrokken is uit een Poisson verdeling ( $\alpha = 5\%$  en  $\alpha = 1\%$ ).

De geobserveerde waarden zijn

|       |   |    |    |    |   |   |   |          |
|-------|---|----|----|----|---|---|---|----------|
| $z_j$ | 0 | 1  | 2  | 3  | 4 | 5 | 6 | $\geq 7$ |
| $n_j$ | 7 | 25 | 19 | 16 | 9 | 3 | 1 | 0        |


Als de steekproef werkelijk uit een Poissonverdeling komt, wat is dan de parameter  $\lambda$ ? Men kan  $\lambda$  eerst schatten met de zuivere (of onvertekende) schatter  $\bar{X}_n$  ( $E[\bar{X}_n] = \lambda$ ):

$$\begin{aligned}\bar{x}_{80} &= \frac{1}{80} \sum_{i=1}^{80} x_i = \frac{1}{80} \{7 \times 0 + 25 \times 1 + 19 \times 2 + 16 \times 3 + 9 \times 4 + 3 \times 5 + 1 \times 6\} \\ &= \frac{168}{80} = 2.1\end{aligned}$$



# Testen van een discrete verdeling

Door gebruik te maken van de tabel voor de Poissonverdeling met parameter 2.1, vindt men de waarden voor  $p_j$ :



Dit geeft ons de theoretische frequenties  $= 80p_j$ :

| $z_j$  | 0    | 1     | 2     | 3     | 4    | 5    | 6    | $\geq 7$ |
|--------|------|-------|-------|-------|------|------|------|----------|
| $np_j$ | 9.80 | 20.57 | 21.60 | 15.12 | 7.94 | 3.34 | 1.16 | 0.47     |

## Testen van een discrete verdeling

We beschouwen vijf klassen:  $\{0\}, \{1\}, \{2\}, \{3\}, \{4, 5, 6, 7, \dots\}$

De teststatistiek wordt

$$\begin{aligned} & \sum_{j=1}^5 \frac{(\text{geobserveerde frequenties} - \text{theoretische frequenties})^2}{\text{theoretische frequenties}} \\ &= \frac{(7 - 9.80)^2}{9.80} + \frac{(25 - 20.57)^2}{20.57} + \frac{(19 - 21.60)^2}{21.60} + \frac{(16 - 15.12)^2}{15.12} + \frac{(13 - 12.91)^2}{12.91} \\ &= 0.80 + 0.95 + 0.31 + 0.05 + 0.0006 \approx 2.11 \end{aligned}$$

We hebben één parameter geschat dus is het aantal vrijheidsgraden gelijk aan

$$k - 1 - 1 = 5 - 1 - 1 = 3.$$

Het aanvaardingsgebied:

$$\alpha = 5\% \quad [0, \chi_{3,0.95}^2] = [0, 7.815] \quad \text{bevat } 2.11$$

$$\alpha = 1\% \quad [0, \chi_{3,0.99}^2] = [0, 11.345] \quad \text{bevat } 2.11$$

Dus de nulhypothese wordt aanvaard.

# Goodness of fit $\chi^2$ -test voor continue verdelingen I

- Steekproefmodel:  $(\mathbb{R}^n, \mathcal{R}^n, \{P^{\otimes n} : P \in \mathcal{P}\})$  waar  $\mathcal{P} = \{\text{continue verdelingen}\}$
- Nulhypothese:  $H_0 : X_1, \dots, X_n \sim P^*$
- Alternatieve hypothese:  $H_1 : X_1, \dots, X_n \approx P^*$
- **Procedure:** drager van  $P^*$  opsplitsen in  $k$  klassen zodat verwachte frequenties  $np_j \geq 5$ ,  $\forall j = 1, \dots, k$
- Teststatistiek:

$$T := \sum_{j=1}^k \left( \frac{N_j - np_j}{\sqrt{np_j}} \right)^2 \approx \chi_{k-1}^2 \text{ onder } H_0$$

waar  $N_j = \#\{X_i \in \text{klasse } j, i = 1, \dots, n\}$ .

- Nadeel: indeling in klassen is willekeurig en andere klasse-indelingen kunnen eindresultaat beïnvloeden.

# Voorbeeld I

Men wil graag testen of de verwerkingstijd exponentieel verdeeld is. De geobserveerde verwerkingstijden in een bank zijn

---

|                                 |        |        |        |        |        |         |
|---------------------------------|--------|--------|--------|--------|--------|---------|
| verwerkingstijd interval (min.) | [0, 1) | [1, 2) | [2, 3) | [3, 4) | [4, 5) | [5, 10) |
| aantal klanten ( $n_j$ )        | 14     | 28     | 32     | 22     | 12     | 20      |

---

- $\bar{x}_n = \frac{1}{n} \sum_{j=1}^6 c_j n_j = 3.2031$  waar  $c_j \equiv$  centrum van klasse  $j \Rightarrow \hat{\lambda} = \frac{1}{\bar{x}_n} = 0.3122$

## Voorbeeld II

- Verwachte frequenties ( $X \sim \text{Exp}(0.3122)$ )

| verwerkingstijd (min.) | theoretische kans                   | $np_j$             |
|------------------------|-------------------------------------|--------------------|
| [0, 1)                 | $P_{H_0}(X \leq 1) = 0.2682$        | 34.3246            |
| [1, 2)                 | $P_{H_0}(1 \leq X \leq 2) = 0.1963$ | 25.1201            |
| [2, 3)                 | $P_{H_0}(2 \leq X \leq 3) = 0.1436$ | 18.3839            |
| [3, 4)                 | $P_{H_0}(3 \leq X \leq 4) = 0.1051$ | 13.4540            |
| [4, 5)                 | $P_{H_0}(4 \leq X \leq 5) = 0.0769$ | 9.8462             |
| [5, $\infty$ )         | $P_{H_0}(X \geq 5) = 0.2099$        | 26.8712            |
| $\Sigma = 1$           |                                     | $\Sigma = n = 128$ |

- $t = \sum_{j=1}^6 \frac{(n_j - np_j)^2}{np_j} = 30.1064$
- één parameter geschat  $\Rightarrow$  aantal vrijheidsgraden  $= k - 1 - 1 = 4$
- $\chi_{4,0.95}^2 = 9.4877 \Rightarrow t \notin [0, \chi_{4,0.95}^2] = [0, 9.4877] \Rightarrow$  verwerp  $H_0$  op  $\alpha = 5\%$

# Kolmogorov-Smirnov test I

**Doel:** bepalen of een steekproef uit een specifieke continue verdeling komt

- Steekproefmodel:  $(\mathbb{R}^n, \mathcal{R}^n, \{P^{\otimes n} : P \in \mathcal{P}\})$  waar  $\mathcal{P} = \{\text{continue verdelingen}\}$
- $H_0 : X_1, \dots, X_n \sim P^*$  versus  $H_1 : X_1, \dots, X_n \not\sim P^*$
- **Procedure:** vergelijk  $\hat{F}_n$  met  $F^*$
- Teststatistiek:

$$D_n = \sup_x |\hat{F}_n(x) - F^*(x)|.$$

- **Kolmogorov-Smirnov (1930)** geeft verdeling van  $D_n$  onder  $H_0$

$$\lim_{n \rightarrow \infty} P(\sqrt{n}D_n \leq d) = 1 - 2 \sum_{k=1}^{\infty} (-1)^{k-1} \exp(-2k^2 d^2) := H(d), \quad \forall d > 0.$$

- Voor  $n \gg$ : verwerp  $H_0$  als  $\sqrt{n}D_n \geq H^{-1}(1 - \alpha)$

# Kolmogorov-Smirnov test II

Tabel: Verdelingsfunctie  $H$ .

| $d$  | $H(d)$ | $d$  | $H(d)$ | $d$  | $H(d)$ | $d$  | $H(d)$ |
|------|--------|------|--------|------|--------|------|--------|
| 0.30 | 0.0000 | 0.75 | 0.3728 | 1.20 | 0.8878 | 1.80 | 0.9969 |
| 0.35 | 0.0003 | 0.80 | 0.4559 | 1.25 | 0.9121 | 1.90 | 0.9985 |
| 0.40 | 0.0028 | 0.85 | 0.5347 | 1.30 | 0.9319 | 2.00 | 0.9993 |
| 0.45 | 0.0126 | 0.90 | 0.6073 | 1.35 | 0.9478 | 2.10 | 0.9997 |
| 0.50 | 0.0361 | 0.95 | 0.6725 | 1.40 | 0.9603 | 2.20 | 0.9999 |
| 0.55 | 0.0772 | 1.00 | 0.7300 | 1.45 | 0.9702 | 2.30 | 0.9999 |
| 0.60 | 0.1357 | 1.05 | 0.7798 | 1.50 | 0.9778 | 2.40 | 1.0000 |
| 0.65 | 0.2080 | 1.10 | 0.8223 | 1.60 | 0.9880 | 2.50 | 1.0000 |
| 0.70 | 0.2888 | 1.15 | 0.8580 | 1.70 | 0.9938 |      |        |