
Project 2026

Deadline: 31 Mei 2026

Bachelor in de Informatica: **Elementaire statistiek**

Instructies

Dit project draait om het gebruik van *R* om data te analyseren en statistische methoden toe te passen. Het project telt mee voor vier van de twintig punten en moet individueel worden gemaakt en ingediend. **De deadline is 31 Mei 2026 om 23:59.**

Los de onderstaande opgaven op met *R* en verwerk de antwoorden in een overzichtelijk en verzorgd verslag. Er is geen strikte paginalimiet, maar probeer niet veel meer dan vijf pagina's te gebruiken. Onderbouw je tekst met visuele of kwantitatieve resultaten uit *R*. Herhaal de opgave niet, begin direct met het antwoord. Gebruik of verwijst naar relevante theorie of formules uit de cursus, maar kopieer of herhaal niets letterlijk. Je hoeft geen methodes of technieken te gebruiken die niet in de lessen of oefenzittingen gezien zijn.

Het doel van dit project is om aan te tonen dat je met *R* kunt werken en in staat bent om de juiste statistische beslissingen te nemen. Zorg ervoor dat je verslag dit duidelijk laat zien. Beschrijf je denkproces en leg uit hoe je tot bepaalde inzichten of keuzes bent gekomen. Enkel het juiste of beste resultaat tonen zonder uitleg heeft weinig waarde.

De indiening via Blackboard bestaat uit een pdf met het verslag en de gebruikte *R* code. Geef de bestanden de naam *voornaam_achternaam.pdf* en *voornaam_achternaam.R*, zodat ze eenvoudig verwerkt kunnen worden. De *R* code wordt alleen bekeken bij onduidelijkheden in het verslag, de beoordeling gebeurt op basis van de pdf die op zichzelf te begrijpen moet zijn.

Bij vragen of problemen kan je contact opnemen met Flor via flor.debois@uantwerpen.be.

Persoonlijke data

Om ervoor te zorgen dat niet iedereen dezelfde data heeft, gebruik je de volgende *R* code om de drie datasets in te laden.

```
sneeuw = read.csv("Sneeuw.csv", row.names=1)
set.seed(0123456789); my_sneeuw_index = sample(1:5000, 500)
my_sneeuw = sneeuw[my_sneeuw_index,]

temp = read.csv("Temperatuur.csv", row.names=1)
set.seed(0123456789); my_temp_index = sample(1:4500, 250)
my_temp = temp[my_temp_index,]

wind = read.csv('Wind.csv', row.names=1)
set.seed(0123456789); my_wind_index = sample(1:605, 600)
my_wind = wind[my_wind_index,]
```

In de tweede lijn van elk blok code verander je telkens het nummer 0123456789 naar jouw studentnummer. Vertrek in de opgaven van de datasets *my_sneeuw*, *my_temp* en *my_wind*.

Opgaven

Een kennis van jou werkt samen met een kleine berggemeente die zich bezighoudt met het monitoren van lokale weersomstandigheden en hun impact op activiteiten in de regio. Ze hebben de afgelopen jaren verschillende datasets verzameld, maar hebben niet de expertise om deze te analyseren. Daarom vragen ze jouw hulp bij enkele concrete vragen. De drie vragen die ze jou stellen zijn de volgende:

Gebruik voor alle opgaven een significantieniveau van 1%.

1 - Sneeuwcondities

De organisatie heeft een dataset samengesteld waarin drie discrete variabelen werden bijgehouden:

- Temperatuurklasse (laag, gemiddeld, hoog)
- Sneeuwtype (droog, nat)
- Lawine alarm (licht, sterk)

Test of deze drie variabelen onderling afhankelijk zijn. Leg je methode uit en formuleer een besluit. *Gebruik één globale test en onderzoek niet afzonderlijk de afhankelijkheid voor elk paar variabelen.*

2 - Temperatuur

Daarnaast werd op verschillende locaties de temperatuur gemeten. Voor elke meting zijn de hoogte (in meter), de afstand tot de vallei (in km) en de gemeten temperatuur (in °C) beschikbaar. Is het mogelijk om de temperatuur te voorspellen aan de hand van de hoogte en de afstand tot de vallei. Kan je een model maken dat goede voorspellingen maakt?

3 - Wind

Tot slot werd er op een interessante locatie de windsnelheid (km/h) gemeten. Is de gemiddelde windsnelheid groter is dan 11.7 km/h? Kan je dit formeel testen?