

Numerieke Lineaire Algebra Matrix Normen

Gebaseerd op cursusnotities van Benny VH

Definitie: Een afbeelding $\| \cdot \|$ van $\mathbb{C}^m$ naar $\mathbb{R}$ is een vectornorm indien:

- 1 $\forall x \in \mathbb{C}^m : \|x\| \geq 0$ en $\|x\| = 0$ *asa* $x = 0$
- 2 $\|zx\| = |z|\|x\|$ voor $x \in \mathbb{C}^m$ en $z \in \mathbb{C}$
- 3 $\|x + y\| \leq \|x\| + \|y\|$ voor $x, y \in \mathbb{C}^m$

Enkele belangrijke vectornormen: Voor $x \in \mathbb{C}^m$:

- $\|x\|_1 = \sum_{i=1}^m |x_i|$
- $\|x\|_2 = \sqrt{\sum_{i=1}^m |x_i|^2} = \sqrt{x^* x}$
- $\|x\|_\infty = \max_i |x_i|$

Voorbeeld 1:

Laat $x^T = (1, -2, 3) \in \mathbb{R}^3$, dan

$$\|x\|_1 = |1| + |-2| + |3| = 1 + 2 + 3 = 6,$$

$$\|x\|_2 = \sqrt{1^2 + (-2)^2 + 3^2} = \sqrt{1 + 4 + 9} = \sqrt{14},$$

$$\|x\|_\infty = \max\{|1|, |-2|, |3|\} = \max\{1, 2, 3\} = 3.$$

Voorbeeld 2:

Laat $x^T = (1, -2, 3)$, $y^T = (2, 1, -1)$ en $z = -3$.

$$\|zx\|_1 = |-3| + |6| + |-9| = 18 = 3 \cdot 6 = |z|\|x\|_1.$$

en

$$x^T + y^T = (3, -1, 2), \quad \|x + y\|_1 = |3| + |-1| + |2| = 6,$$

$$\|y\|_1 = |2| + |1| + |-1| = 4.$$

Dus

$$\|x + y\|_1 = 6 \leq 6 + 4 = \|x\|_1 + \|y\|_1.$$

Alle vectornormen zijn equivalent: Gegeven twee vectornormen $\| \cdot \|_\alpha$ en $\| \cdot \|_\beta$, dan bestaat er een k en K zodat $k\|x\|_\alpha \leq \|x\|_\beta \leq K\|x\|_\alpha$ voor alle x

Definitie: Voor een vectornorm $\|\cdot\|_\alpha$ en matrix $A \in \mathbb{C}^{m \times n}$:

$$\|A\|_\alpha = \sup_{x \neq 0} \frac{\|Ax\|_\alpha}{\|x\|_\alpha} = \sup_{\|x\|_\alpha=1} \|Ax\|_\alpha$$

Interpretatie: maximale uitrekking van vector x door A .

Voorbeeld:

Laat $x^T = (0, 1)$ zodat $\|x\|_1 = 1$ en

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 2 \end{bmatrix},$$

dan $\|Ax\|_1 = |2| + |2| = 4$. Bijgevolg $\|A\|_1 \geq 4$.

Stelling: De 1-norm van een matrix A is de grootste kolomsom.

$$\|A\|_1 = \max_j \sum_i |a_{ij}|$$

Bewijs:

- Neem $x \in \mathbb{C}^n$ met $\|x\|_1 = 1$, dan

$$\|Ax\|_1 = \left\| \sum_j x_j a_j \right\|_1 \leq \sum_j \|x_j a_j\|_1 \leq \sum_j |x_j| \|a_j\|_1 \leq \max_j \|a_j\|_1$$

- Kies $x = e_j$ waar j die kolom met maximale som, dan $Ax = a_j$ en $\|Ax\|_1 = \max_j \|a_j\|_1$

Stelling: De ∞ -norm van A is de grootste rijsum:

$$\|A\|_\infty = \max_i \sum_j |a_{ij}|$$

Bewijs: Analoge redenering als bij de 1-norm, maar werk met rijvectoren in plaats van kolomvectoren (zie oefeningen).

Stelling: De 2-norm van een $m \times n$ matrix A is gelijk aan

$$\|A\|_2 = \sqrt{\max_{i=1}^n \lambda_i(A^*A)},$$

waarbij $\lambda_i(A^*A)$ de i -de eigenwaarde van de matrix A^*A weergeeft.

Later in de cursus zien we dat de 2-norm van de matrix A eveneens gelijk is aan de grootste singuliere waarde van A .

Voorbeeld: $\|A\|_2$ via eigenwaarden van A^*A :

$$A = \begin{pmatrix} 1 & 2 \\ 0 & 2 \end{pmatrix}, \quad A^*A = \begin{pmatrix} 1 & 2 \\ 2 & 8 \end{pmatrix}.$$

$$\det(A^*A - \lambda I) = \det \begin{pmatrix} 1-\lambda & 2 \\ 2 & 8-\lambda \end{pmatrix} = (1-\lambda)(8-\lambda) - 4 = \lambda^2 - 9\lambda + 4.$$

$$\Rightarrow \lambda_{1,2} = \frac{9 \pm \sqrt{65}}{2}.$$

Dus

$$\|A\|_2 = \sqrt{\frac{9 + \sqrt{65}}{2}} \approx 2.921.$$

Stelling: Voor een vector geïnduceerde matrixnorm $\|\cdot\|_\alpha$ met $x \in \mathbb{C}^n$, $A \in \mathbb{C}^{m,n}$ en $B \in \mathbb{C}^{n,p}$:

- $\|Ax\|_\alpha \leq \|A\|_\alpha \|x\|_\alpha$
- $\|AB\|_\alpha \leq \|A\|_\alpha \|B\|_\alpha$

Bewijs:

- De eerste uitspraak volgt uit de definitie
- De tweede uitspraak volgt door twee keer de eerste eigenschap toe te passen:

$$\|(AB)x\|_\alpha = \|A(Bx)\|_\alpha \leq \|A\|_\alpha \|Bx\|_\alpha \leq \|A\|_\alpha \|B\|_\alpha \|x\|_\alpha$$

Definitie: Een afbeelding $\|\cdot\|$ van $\mathbb{C}^{m,n}$ naar $\mathbb{R}$ is een **matrixnorm** indien volgende drie eigenschappen gelden, waarbij A en B $m \times n$ matrices zijn en $z \in \mathbb{C}$:

- 1 $\|A\| \geq 0$ and $\|A\| = 0$ indien $A = 0$,
- 2 $\|zA\| = |z| \|A\|$,
- 3 $\|A + B\| \leq \|A\| + \|B\|$.

Alle vektorgeïnduceerde matrixnormen voldoen aan deze drie eigenschappen.

Definitie: De Frobeniusnorm wordt gedefinieerd als

$$\|A\|_F = \sqrt{\sum_{i,j} |a_{ij}|^2} = \sqrt{\sum_i \|a_i^*\|_2^2} = \sqrt{\sum_j \|a_j\|_2^2}$$

Later in de cursus zien we dat $\|A\|_F$ ook gelijk is aan de vierkantswortel van de som van de kwadraten van de singuliere waarden van A .

Voorbeeld: $\|A\|_F = \sqrt{1^2 + 2^2 + 0^2 + 2^2} = 3$ voor de matrix

$$A = \begin{pmatrix} 1 & 2 \\ 0 & 2 \end{pmatrix},$$

Stelling: De Frobenius norm kan uitgedrukt worden als

$$\|A\|_F = \sqrt{\text{tr}(A^*A)},$$

waarbij $\text{tr}(\cdot)$ staat voor de *trace* of som van de diagonaal elementen.

Bewijs: Dit volgt meteen uit:

$$\begin{aligned} \|A\|_F^2 &= \sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2 = \sum_{i=1}^m \sum_{j=1}^n a_{ij}^* a_{ij} = \sum_{i=1}^m \sum_{j=1}^n (A^*)_{ji} a_{ij} \\ &= \sum_{j=1}^n \sum_{i=1}^m (A^*)_{ji} a_{ij} = \sum_{j=1}^n (A^*A)_{jj} = \text{tr}(A^*A), \end{aligned}$$

aangezien $|z|^2 = z^*z$ voor $z \in \mathbb{C}$.

Stelling: Laat A een $m \times n$ en B een $n \times p$ matrix zijn dan geldt

$$\|AB\|_F \leq \|A\|_F \|B\|_F,$$

Bewijs: Zij $C = AB$, dan $c_{jj} = a_i^* b_j$, bijgevolg

$$\|C\|_F^2 = \sum_{i,j} |a_i^* b_j|^2 \leq \sum_{i,j} \|a_i^*\|_2^2 \|b_j\|_2^2 = \|A\|_F^2 \|B\|_F^2,$$

aangezien $|x^*y| \leq \|x\|_2 \|y\|_2$ door de ongelijkheid van Cauchy-Schwarz

Andere voorbeelden van Frobeniusnormen zijn:

- $\|A\|_{F_1} = \sum_{i,j} |a_{ij}|$
- $\|A\|_{F_\infty} = \max_{i,j} |a_{ij}|$

Voorbeeld: $\|A\|_{F_1} = 1 + 2 + 0 + 2 = 5$ en $\|A\|_{F_\infty} = \max\{1, 2, 0, 2\} = 2$ voor de matrix

$$A = \begin{pmatrix} 1 & 2 \\ 0 & 2 \end{pmatrix}$$

Alle matrixnormen zijn equivalent: Gegeven twee matrixnormen $\|\cdot\|_\alpha$ en $\|\cdot\|_\beta$, dan bestaat er een k en K zodat $k\|A\|_\alpha \leq \|A\|_\beta \leq K\|A\|_\alpha$ voor alle $A \in \mathbb{C}^{m,n}$

Voorbeeld: Neem $\|\cdot\|_{F_1}$ en $\|\cdot\|_{F_\infty}$ voor matrices $A \in \mathbb{C}^{m,n}$, dan is

$$\|\cdot\|_{F_\infty} \leq \|\cdot\|_{F_1}$$

dus we kunnen $K = 1$ kiezen en

$$\|\cdot\|_{F_1} \leq mn \|\cdot\|_{F_\infty}$$

dus we kunnen $k = \frac{1}{mn}$ kiezen

Numerieke Lineaire Algebra QR Factorisaties

Gebaseerd op cursusnotities van Benny VH

Definitie: Voor $x, y \in \mathbb{C}^m$ heet x *orthogonaal* aan y indien $x^*y = 0$.

Een verzameling $S \subset \mathbb{C}^m$ heet *orthogonaal* indien alle vectoren paarsgewijs orthogonaal zijn.

Is bovendien $\|x\|_2 = 1$ voor alle $x \in S$, dan heet S *orthonormaal*.

Voorbeeld :

Laat $x^T = (1, 1)$ en $y^T = (1, -1)/\sqrt{2}$, dan is $x^*y = (1 - 1)/\sqrt{2} = 0$. De vectoren zijn dus orthogonaal. Tevens is y is orthonormaal, maar x niet.

Stelling: Een orthogonale set $S = \{v_1, \dots, v_m\}$ met $v_1, \dots, v_m \neq 0$ is lineair onafhankelijk.

Bewijs: Stel $v_k = \sum_{i \neq k} c_i v_i$. Vermenigvuldig links met v_k^* :

$$\|v_k\|_2^2 = \sum_{i \neq k} c_i v_k^* v_i = 0,$$

contradictie met $v_k \neq 0$.

Voorbeeld :

Laat $x^T = (1, -2, 3)$, $y^T = (2, 1, -1)$ en $z^T = (5, 0, 1)$. Deze set is niet orthogonaal, want $z^T = x^T + 2y^T$.

Definitie: $Q \in \mathbb{C}^{m,m}$ met kolommen $q_1, \dots, q_m$ is **unitair** indien $S = \{q_1, \dots, q_m\}$ een orthonormale set vormt. Indien Q reëel is, dan spreekt men eveneens van een orthogonale matrix.

Voorbeelden :

De matrices Z , H en R_θ zijn unitair met

$$Z = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}, \quad H = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad R_\theta = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

Stelling: Unitaire matrices zijn inverteerbaar en $Q^{-1} = Q^*$.

Bewijs: Indien q_j de j -de kolom van Q weergeeft, dan is q_i^* gelijk aan de i -de rij van Q^* . Indien we $C = Q^*Q$, dan zal $c_{ij} = q_i^*q_j$. Dit laatste is gelijk aan nul indien $i \neq j$ en $q_i^*q_i = \|q_i\|_2^2 = 1$, wat aantoont dat $C = I$.

Het omgekeerde is duidelijk ook waar is: indien $Q^* = Q^{-1}$, dan vormen de kolommen van Q een orthonormale set. Kortom, een matrix Q is unitair als $Q^* = Q^{-1}$.

Stelling: De matrix Q^* is unitair indien Q unitair is. Het product Q_1Q_2 van twee unitaire matrices Q_1 en Q_2 is eveneens unitair.

Bewijs: Indien Q unitair is, is $Q^*Q = I$, waardoor Q de inverse is van Q^* en $Q = (Q^*)^*$. Indien Q_1 en Q_2 unitair zijn, dan is $(Q_1Q_2)^*Q_1Q_2 = Q_2^*(Q_1^*Q_1)Q_2 = Q_2^*Q_2 = I$.

Voorbeeld :

Het product $R_{\theta_1}R_{\theta_2}$ is unitair en gelijk aan $R_{\theta_1+\theta_2}$. Verder is $R_\theta^* = R_{-\theta}$.

Stelling: Laat $Q \in \mathbb{C}^{m,m}$ unitair zijn en $x, y \in \mathbb{C}^m$, dan $(Qx)^*(Qy) = x^*y$, $\|Qx\|_2 = \|x\|_2$ en $\|Q\|_2 = 1$.

Bewijs: Daar $(Qx)^* = x^*Q^*$, zien we dat $(Qx)^*(Qy) = x^*(Q^*Q)y = x^*y$ en dat

$$\|Qx\|_2 = \sqrt{(Qx)^*(Qx)} = \sqrt{x^*(Q^*Q)x} = \sqrt{x^*x} = \|x\|_2.$$

Hieruit volgt onmiddellijk

$$\|Q\|_2 = \sup_{x \in \mathbb{C}^n, \|x\|_2=1} \|Qx\|_2 = \sup_{x \in \mathbb{C}^n, \|x\|_2=1} \|x\|_2 = 1.$$

Stelling: Laat $Q_1 \in \mathbb{C}^{m,m}$ en $Q_2 \in \mathbb{C}^{n,n}$ unitaire matrices zijn en $A \in \mathbb{C}^{m,n}$, dan is $\|Q_1A\|_2 = \|A\|_2$, $\|Q_1A\|_F = \|A\|_F$, $\|AQ_2\|_2 = \|A\|_2$ en $\|AQ_2\|_F = \|A\|_F$.

Bewijs: Uit de voorgaande eigenschap weten we dat $\|Q_1\|_2 = 1$. Bijgevolg is

$$\|Q_1A\|_2 \leq \|Q_1\|_2 \|A\|_2 = \|A\|_2.$$

Analoog

$$\|A\|_2 = \|Q_1^*Q_1A\|_2 \leq \|Q_1^*\|_2 \|Q_1A\|_2 = \|Q_1A\|_2.$$

Het bewijs voor de Frobenius norm gaat als volgt:

$$\|Q_1A\|_F^2 = \text{tr}((Q_1A)^*Q_1A) = \text{tr}(A^*Q_1^*Q_1A) = \text{tr}(A^*A) = \|A\|_F^2.$$

Stelling: Laat $Q \in \mathbb{C}^{m,m}$ unitair zijn, dan is $|\det Q| = 1$.

Bewijs: Aangezien $\det(AB) = \det(A)\det(B)$, weten we dat

$$1 = \det I = \det(Q^*Q) = \det(Q^*)\det(Q).$$

Verder geldt dat $\det(A^*) = \det(A)^*$ voor $A \in \mathbb{C}^{m,m}$ wat impliceert dat $1 = \det(Q)^*\det(Q) = |\det(Q)|^2$.

Laat $A \in \mathbb{C}^{m,n}$ met $m \geq n$ en beschouw de ruimtes

$$\langle a_1 \rangle \subseteq \langle a_1, a_2 \rangle \subseteq \langle a_1, a_2, a_3 \rangle \subseteq \dots \subseteq \langle a_1, \dots, a_n \rangle.$$

We zoeken orthonormale set $q_1, \dots, q_n \in \mathbb{C}^m$ zodat

$$a_1, \dots, a_j \in \langle q_1, \dots, q_j \rangle,$$

voor $j = 1, \dots, n$. We zoeken dus een set van vectoren $q_1, \dots, q_n$ en coëfficiënten r_{ij} , met $i \leq j$ zodat

$$\begin{aligned} a_1 &= r_{11}q_1 \\ a_2 &= r_{12}q_1 + r_{22}q_2 \\ a_3 &= r_{13}q_1 + r_{23}q_2 + r_{33}q_3 \\ &\vdots \\ a_n &= r_{1n}q_1 + r_{2n}q_2 + \dots + r_{nn}q_n \end{aligned} \tag{1}$$

We kunnen dit herschrijven in matrixvorm als

$$\begin{bmatrix} | & | & | & | \\ a_1 & a_2 & \dots & a_n \\ | & | & | & | \end{bmatrix} = \begin{bmatrix} | & | & | & | \\ q_1 & q_2 & \dots & q_n \\ | & | & | & | \end{bmatrix} \begin{bmatrix} r_{11} & r_{12} & \dots & r_{1n} \\ & r_{22} & & \vdots \\ & & \ddots & \\ & & & r_{nn} \end{bmatrix}.$$

of kortweg als

$$A = \hat{Q}\hat{R},$$

Dit is een gereduceerde QR factorisatie van A .

Set $\{q_1, \dots, q_n\}$ uitbreiden met $m - n$ orthonormale vectoren $\{q_{n+1}, \dots, q_m\}$ zodat $\{q_1, \dots, q_m\}$ een basis vormt voor $\mathbb{C}^m$.

Wanneer we de matrices Q en R dan definiëren als

$$Q = \left[\begin{array}{c|c|c|c} & & & \\ & \hat{Q} & & \\ \hline & q_{n+1} & \dots & q_m \end{array} \right] \quad \text{en} \quad R = \left[\begin{array}{cccc} r_{11} & r_{12} & \dots & r_{1n} \\ & r_{22} & & \vdots \\ & & \ddots & \\ & & & r_{nn} \end{array} \right],$$

dan is Q een unitaire $m \times m$ matrix is en R een $m \times n$ bovendriehoeksmatrix met

$$A = QR.$$

Dit is een volledige QR factorisatie van A .

Voorbeeld: Neem

$$A = \begin{bmatrix} 1 & 5 \\ 1 & -1 \end{bmatrix}$$

en


$$Q = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad R = \sqrt{2} \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix}.$$

dan is $A = QR$ een QR-factorisatie. Volgende matrices zijn eveneens een QR-factorisatie voor A

$$\tilde{Q} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}, \quad \tilde{R} = \sqrt{2} \begin{bmatrix} 1 & 2 \\ 0 & -3 \end{bmatrix}.$$

QR-factorisatie is wel uniek met enkel positieve reële diagonaalelementen

Idee:



Stel $q_1, \dots, q_j$ bepaald ($q_1 = a_1 / \|a_1\|_2$).

Laat $q_j = v_j / \|v_j\|_2$ met

$$v_j = a_j - (q_1^* a_j) q_1 - (q_2^* a_j) q_2 - \dots - (q_{j-1}^* a_j) q_{j-1}. \quad (2)$$

v_j is orthogonaal aan $q_1, \dots, q_{j-1}$: neem $1 \leq k < j$

$$q_k^* v_j = q_k^* a_j - (q_1^* a_j)(q_k^* q_1) - (q_2^* a_j)(q_k^* q_2) - \dots - (q_{j-1}^* a_j)(q_k^* q_{j-1}).$$

Aangezien $\{q_1, \dots, q_{j-1}\}$ een orthonormale set is, geeft dit aan dat

$$q_k^* v_j = q_k^* a_j - (q_k^* a_j) \|q_k\|_2^2 = 0,$$

wat de vereiste orthogonaliteit bewijst.

Verder behoort v_j tot $\langle a_1, \dots, a_j \rangle$, want het is een lineaire combinatie van $q_1, \dots, q_{j-1}, a_j$ en $q_k \in \langle a_1, \dots, a_k \rangle$ voor $k = 1, \dots, j-1$.

Vergelijking (2) kunnen we herschrijven als

$$v_j = a_j - r_{1j}q_1 - r_{2j}q_2 - \dots - r_{j-1,j}q_{j-1}$$

met $r_{ij} = q_i^* a_j$. Stel $r_{jj} = \|v_j\|_2$ dan

$$a_j = r_{jj}q_j + r_{1j}q_1 + r_{2j}q_2 + \dots + r_{j-1,j}q_{j-1}$$

Deze vergelijking voor $j = 1, \dots, n$ resulteren in $A = QR$ met Q unitair en R een bovendriehoeksmatrix.

We kunnen r_{jj} ook vervangen door zr_{jj} met $z \in \mathbb{C}$ en $|z| = 1$.

Voorbeeld: Laat

$$A = \begin{bmatrix} 1 & 5 \\ 1 & -1 \end{bmatrix},$$

Stap 1 (normaliseer a_1).

$$a_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad r_{11} = \|a_1\|_2 = \sqrt{2}, \quad q_1 = \frac{a_1}{r_{11}} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Stap 2 (orthogonaliseer a_2 t.o.v. q_1 en normaliseer).

$$a_2 = \begin{bmatrix} 5 \\ -1 \end{bmatrix}, \quad r_{12} = q_1^* a_2 = 2\sqrt{2}, \quad v_2 = a_2 - r_{12}q_1 = \begin{bmatrix} 3 \\ -3 \end{bmatrix},$$

$$r_{22} = \|v_2\|_2 = 3\sqrt{2}, \quad q_2 = \frac{v_2}{r_{22}} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Stap 3 (vorm Q en R).

$$Q = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad R = \begin{bmatrix} r_{11} & r_{12} \\ 0 & r_{22} \end{bmatrix} = \sqrt{2} \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix}, \quad A = QR.$$

Stelling: Elke matrix $A \in \mathbb{C}^{m,n}$ met $m \geq n$ heeft een volledige QR factorisatie en bijgevolg ook een gereduceerde.

Klassieke Gram-Schmidt Algoritme

```

for  $j = 1$  to  $n$ 
     $v_j = a_j$ 
    for  $i = 1$  to  $j - 1$ 
         $r_{ij} = q_i^* a_j$ 
         $v_j = v_j - r_{ij} q_i$ 
     $r_{jj} = \|v_j\|_2$ 
     $q_j = v_j / r_{jj}$ 

```

Dit algoritme is numeriek onstabiel. We kunnen het algoritme echter eenvoudig aanpassing om de stabiliteit te verbeteren.

Aangepaste Gram-Schmidt

$\sim n \cdot n/2 \cdot 4m = 2mn^2$ flops

```

for  $i = 1$  to  $n$ 
     $v_i = a_i$ 
    for  $i = 1$  to  $n$ 
         $r_{ii} = \|v_i\|_2$ 
         $q_i = v_i / r_{ii}$ 
        for  $j = i + 1$  to  $n$ 
             $r_{ij} = q_i^* v_j$ 
             $v_j = v_j - r_{ij} q_i$ 

```

Beide algoritmes zijn identiek in een exacte rekenomgeving. De numerieke afrondingen die optreden in een floating point omgeving zijn echter heel verschillend.

Laat $v \neq 0 \in \mathbb{C}^m$, definiëer de Householder reflectie matrix (of transformatie matrix) P als

$$P = I - \frac{2}{v^*v}vv^*.$$

De matrix P is Hermitisch (gebruik: $(v^*v)^* = v^*(v^*)^* = v^*v$):

$$P^* = I^* - \frac{2}{(v^*v)^*}(vv^*)^* = I - \frac{2}{v^*v}vv^* = P.$$

De matrix P is unitair:


$$P^*P = P^2 = I - 2\left(\frac{2}{v^*v}vv^*\right) + \frac{4}{(v^*v)^2}v(v^*v)v^* = I.$$

Stelling: Laat $P = I - \frac{2}{v^*v}vv^*$ en $x \in \mathbb{C}^m$, dan is

- 1 $v^*(Px) = -v^*x$,
- 2 $x - Px = \frac{2v^*x}{v^*v}v$,
- 3 $\|Px\|_2 = \|x\|_2$.

Bewijs:

- 1 $v^*(Px) = v^*(I - \frac{2}{v^*v}vv^*)x = v^*x - \frac{2}{v^*v}(v^*v)v^*x = v^*x - 2v^*x = -v^*x$
- 2 $x - Px = x - (x - \frac{2}{v^*v}vv^*x) = \frac{2v^*x}{v^*v}v$.
- 3 De matrix P is unitair en $\|Qx\|_2 = \|x\|_2$ voor alle Q unitair.



Laat $x, y \in \mathbb{C}^m$: bestaat er v zodat $Px = y$? In het bijzonder: wat als y veelvoud is van e_1 ?

Stelling: Laat $x \in \mathbb{R}^m$ en $P = I - \frac{2}{v^*v}vv^*$ met $v = x - \kappa \|x\|_2 e_1$, dan is $Px = \kappa \|x\|_2 e_1$ met $\kappa = \pm 1$.

Bewijs: We starten met v^*v te berekenen


$$\begin{aligned} v^*v &= (x - \kappa \|x\|_2 e_1)^*(x - \kappa \|x\|_2 e_1) \\ &= x^*x - x^*\kappa \|x\|_2 e_1 - \kappa^* \|x\|_2 e_1^*x + \underbrace{\kappa^*\kappa \|x\|_2^2 e_1^*e_1}_{x^*x} \\ &= 2(x^*x - \kappa \|x\|_2 x_1), \end{aligned}$$

daar $\kappa^*\kappa = 1$ en $e_1^*x = x_1 = x^*e_1$ want x is **reëel**. Aangezien

$$v^*x = x^*x - \kappa^* \|x\|_2 e_1^*x = x^*x - \kappa \|x\|_2 x_1,$$

volgt hieruit dat $v^*x = v^*v/2$. Bijgevolg

$$Px = x - \frac{2}{v^*v}v(v^*x) = x - v = \kappa \|x\|_2 e_1.$$



Indien $x \in \mathbb{C}^m$ kan men dit resultaat wel veralgemenen door

$$\kappa = \pm e^{i \arg x_1}$$

te nemen (met $\arg x_1 = \theta$ wanneer $x_1 = |x_1| e^{i\theta} = |x_1| (\cos(\theta) + i \sin(\theta))$). Het introduceren van de complexe factor $\pm e^{i\theta}$ zorgt ervoor dat $x_1^* \kappa = x_1 \kappa^* = |x_1|$ (daar $(e^{i\theta})^* = e^{-i\theta}$), waardoor het voorgaande bewijs ook opgaat in het complexe geval.

Bit-cancellation vermijden: zorgen dat x_1 en $-\kappa \|x\|_2 e_1$ hetzelfde teken hebben. Voor $x_1 \in \mathbb{R}$:

$$v = x + \text{sign}(x_1) \|x\|_2 e_1.$$

Voor $x_1 \in \mathbb{C}$:

$$v = x + e^{i \arg x_1} \|x\|_2 e_1.$$

Merk op:

- Als x_1 in eerste kwadrant: $\cos \theta, \sin \theta \geq 0$;
- Als x_1 in tweede kwadrant: $\cos \theta \leq 0, \sin \theta \geq 0$;
- Als x_1 in derde kwadrant: $\cos \theta, \sin \theta \leq 0$;
- Als x_1 in vierde kwadrant: $\cos \theta \geq 0, \sin \theta \leq 0$;

x_1 heeft zelfde teken als $e^{i \arg x_1}$ voor zowel reële als complexe deel

Stap 1: Stel $x = a_1$:

$$v_1 = a_1 + e^{i \arg a_{11}} \|a_1\|_2 e_1$$

en $P_1 = I - \frac{2}{v_1^* v_1} v_1 v_1^*$. Dit resulteert in

$$P_1 A = \begin{bmatrix} \times & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \end{bmatrix},$$

waarbij een $\times$ een willekeurig complex getal voorstelt.

Stap 2: Zoeken P_2 zodat

$$P_2 P_1 A = P_2 \begin{bmatrix} \times & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \end{bmatrix} = \begin{bmatrix} \times & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & 0 & \times & \times \\ 0 & 0 & \times & \times \\ 0 & 0 & \times & \times \end{bmatrix}.$$

Noteer tweede kolom van $P_1 A$ als $a_2^{(1)} = \begin{bmatrix} a_{12}^{(1)} \\ a_{\cdot 2}^{(1)} \end{bmatrix}$, met $a_{12}^{(1)} \in \mathbb{C}$, dan zien we dat

$\hat{P}_2 = I - \frac{2}{\hat{v}_2^* \hat{v}_2} \hat{v}_2 \hat{v}_2^*$ met $\hat{v}_2$ gelijk aan

$$\hat{v}_2 = a_{\cdot 2}^{(1)} + e^{i \arg a_{22}^{(1)}} \|a_{\cdot 2}^{(1)}\|_2 e_1,$$

ervoor zorgt dat $\hat{P}_2 a_{\cdot 2}^{(1)}$ een veelvoud is van $e_1 \in \mathbb{C}^{m-1}$.

Stel $P_2 = \begin{bmatrix} 1 & 0 \\ 0 & \hat{P}_2 \end{bmatrix}$ en P_2 is een Householder reflectie in $\mathbb{C}^m$ met $v_2 = \begin{bmatrix} 0 \\ \hat{v}_2 \end{bmatrix}$.

Vervolg: Wanneer we deze procedure n stappen uitvoeren, bekomen we $P_1, \dots, P_n$ zodat

$$P_n P_{n-1} \dots P_1 A = R$$

met R een bovendriehoeksmatrix, dus $A = QR$ met $Q = P_1 \dots P_n$.

Voorbeeld: Stel $A = \begin{bmatrix} 1 & 4 & 3 & 9 \\ 1 & -2 & 3 & -3 \\ 1 & 4 & 1 & -1 \\ 1 & -2 & 1 & 3 \end{bmatrix}$.

Step 1 (col 1):

$$x = a_1 = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}, \quad \|x\|_2 = 2, \quad v_1 = \begin{bmatrix} 3 \\ 1 \\ 1 \\ 1 \end{bmatrix}, \quad v_1^\top v_1 = 12$$

$$P_1 = I - \frac{2}{v_1^\top v_1} v_1 v_1^\top = I - \frac{1}{6} v_1 v_1^\top = \frac{1}{2} \begin{bmatrix} -1 & -1 & -1 & -1 \\ -1 & \frac{5}{3} & -\frac{1}{3} & -\frac{1}{3} \\ -1 & -\frac{1}{3} & \frac{5}{3} & -\frac{1}{3} \\ -1 & -\frac{1}{3} & -\frac{1}{3} & \frac{5}{3} \end{bmatrix}.$$

$$A^{(1)} = P_1 A = \begin{bmatrix} -2 & -2 & -4 & -4 \\ 0 & -4 & 2/3 & -22/3 \\ 0 & 2 & -4/3 & -16/3 \\ 0 & -4 & -4/3 & -4/3 \end{bmatrix}.$$

Step 2 (col 2, rows 2–4):

$$x = \begin{bmatrix} -4 \\ 2 \\ -4 \end{bmatrix}, \quad \|x\|_2 = 6, \quad v_2 = \begin{bmatrix} 0 \\ -10 \\ 2 \\ -4 \end{bmatrix}, \quad v_2^\top v_2 = 120,$$

$$P_2 = I - \frac{2}{v_2^\top v_2} v_2 v_2^\top = I - \frac{1}{60} v_2 v_2^\top = \frac{1}{3} \begin{bmatrix} 3 & 0 & 0 & 0 \\ 0 & -2 & 1 & -2 \\ 0 & 1 & \frac{14}{5} & \frac{2}{5} \\ 0 & -2 & \frac{2}{5} & \frac{11}{5} \end{bmatrix}.$$

$$A^{(2)} = P_2 A^{(1)} = \begin{bmatrix} -2 & -2 & -4 & -4 \\ 0 & 6 & 0 & 4 \\ 0 & 0 & -6/5 & -38/5 \\ 0 & 0 & -8/5 & 16/5 \end{bmatrix}.$$

Step 3 (col 3, rows 3–4):

$$x = \begin{bmatrix} -6/5 \\ -8/5 \end{bmatrix}, \quad \|x\| = 2, \quad v_3 = \begin{bmatrix} 0 \\ 0 \\ -16/5 \\ -8/5 \end{bmatrix},$$

$$P_3 = I - \frac{2}{v_3^\top v_3} v_3 v_3^\top = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & -\frac{3}{5} & -\frac{4}{5} \\ 0 & 0 & -\frac{4}{5} & \frac{3}{5} \end{bmatrix}.$$

$$A^{(3)} = P_3 A^{(2)} = \underbrace{\begin{bmatrix} -2 & -2 & -4 & -4 \\ 0 & 6 & 0 & 4 \\ 0 & 0 & 2 & 2 \\ 0 & 0 & 0 & 8 \end{bmatrix}}_{=:R}.$$

Matrix Q:

$$Q = P_1 P_2 P_3 = \frac{1}{2} \begin{bmatrix} -1 & 1 & 1 & 1 \\ -1 & -1 & 1 & -1 \\ -1 & 1 & -1 & -1 \\ -1 & -1 & -1 & 1 \end{bmatrix}$$

Householder QR factorisatie (impliciete Q) $\sim 2mn^2 - 2n^3/3$ flops**for** $k = 1$ **to** n

$$x = A_{k:m,k}$$

$$\hat{v}_k = x + e^{i \arg x_1} \|x\|_2 e_1$$

$$\hat{v}_k = \hat{v}_k / \|\hat{v}_k\|_2$$

$$A_{k:m,k:n} = A_{k:m,k:n} - 2\hat{v}_k(\hat{v}_k^* A_{k:m,k:n})$$

Impliciete berekening van Q^*b **for** $k = 1$ **to** n

$$b_{k:m} = b_{k:m} - 2\hat{v}_k(\hat{v}_k^* b_{k:m})$$

Impliciete berekening van Qx **for** $k = n$ **down to** 1

$$x_{k:m} = x_{k:m} - 2\hat{v}_k(\hat{v}_k^* x_{k:m})$$

Stelsel

$$Ax = b$$

met $A \in \mathbb{C}^{m,m}$ inverteerbaar. Stel

$$A = QR,$$

dan

$$Ax = b \Leftrightarrow Rx = Q^*b.$$

Dit stelsel oplossen in $O(m^2)$ tijd via achterwaartse substitutie

Lineaire stelsels via QR factorisatie

$\sim 4m^3/3$ flops (via Householder reflecties)

- 1 De QR factorisatie van A te berekenen.
- 2 De vector $y = Q^*b$ te bepalen.
- 3 Het stelsel $Rx = y$ op te lossen (via achterwaartse substitutie).

Stelsel

$$Ax = b$$

met $A \in \mathbb{C}^{m,n}$ met $m > n$. Zoeken x zodat

$$\|r\|_2 = \|Ax - b\|_2$$

minimaal is (deze Ax is projectie van b op $\langle a_1, \dots, a_n \rangle$).

Laat $A = QR$ dan

$$\|r\|_2 = \|Ax - b\|_2 = \|QRx - b\|_2 = \|Rx - Q^*b\|_2,$$

Gebruik verband volledige en gedeeltelijke QR factorisatie:

$$R = \begin{bmatrix} \hat{R} \\ 0 \end{bmatrix}, \quad Q = \begin{bmatrix} \hat{Q} & Q_2 \end{bmatrix}, \quad \text{en} \quad Q^*b = \begin{bmatrix} \hat{Q}^* \\ Q_2^* \end{bmatrix} b,$$

met $Q_2 \in \mathbb{C}^{m, m-n}$. Bijgevolg is

$$\|r\|_2^2 = \|Rx - Q^*b\|_2^2 = \left\| \begin{bmatrix} \hat{R}x \\ 0 \end{bmatrix} - \begin{bmatrix} \hat{Q}^*b \\ Q_2^*b \end{bmatrix} \right\|_2^2 = \left\| \hat{R}x - \hat{Q}^*b \right\|_2^2 + \|Q_2^*b\|_2^2.$$

Als $\text{rang}(A) = n$ dan $\hat{R}$ inverteerbaar, dus $x = \hat{R}^{-1}\hat{Q}^*b$ geeft minimale

$$\|r\|_2 = \|Q_2^*b\|_2.$$

Bepalen x door $\hat{R}x = \hat{Q}^*b$ op te lossen via achterwaartse substitutie.

Mogelijk snellere berekening voor minimale $\|r\|_2$:

$$\|r\|_2 = \|Ax - b\|_2 = \left\| \hat{Q}\hat{R}(\hat{R}^{-1}\hat{Q}^*b) - b \right\|_2 = \left\| \hat{Q}\hat{Q}^*b - b \right\|_2.$$

Let op:

$$\hat{Q}^*\hat{Q} = I, \quad \text{maar} \quad \hat{Q}\hat{Q}^* \neq I$$

Voorbeeld:

$$Q = I, \quad \hat{Q} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \text{dan} \quad \hat{Q}^*\hat{Q} = 1, \quad \text{en} \quad \hat{Q}\hat{Q}^* = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}.$$

Voorbeeld:

$$A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad b = \begin{bmatrix} 2 \\ 0 \\ 3 \\ 1 \end{bmatrix}.$$

Gereduceerde QR factorisatie (want a_1 en a_2 zijn al orthogonaal):

$$\hat{Q} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad \hat{R} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}, \quad A = \hat{Q}\hat{R}.$$

Oplossing x voldoet aan

$$\hat{R}x = \hat{Q}^\top b \implies x = \hat{R}^{-1}\hat{Q}^\top b.$$

Bereken

$$\hat{Q}^\top b = \frac{1}{2} \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & -1 & 1 & -1 \end{bmatrix} \begin{bmatrix} 2 \\ 0 \\ 3 \\ 1 \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 2 + 0 + 3 + 1 \\ 2 - 0 + 3 - 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 2 \end{bmatrix}.$$

Gezien $\hat{R} = \text{diag}(2, 2)$,

$$x = \begin{bmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{2} \end{bmatrix} \begin{bmatrix} 3 \\ 2 \end{bmatrix} = \boxed{\begin{bmatrix} 1.5 \\ 1 \end{bmatrix}}.$$

Minimale $\|r\|_2$:

$$Ax = \begin{bmatrix} 2.5 \\ 0.5 \\ 2.5 \\ 0.5 \end{bmatrix}, \quad r = Ax - b = \frac{1}{2} \begin{bmatrix} 1 \\ 1 \\ -1 \\ -1 \end{bmatrix}, \quad \|r\|_2 = \frac{1}{2}\sqrt{4} = 1.$$

Merk op, $r \perp \text{col}(A)$: $\hat{Q}^\top r = \mathbf{0}$.

Hessenberg decompositie 1

Laat $A \in \mathbb{C}^{m,m}$, zoeken een unitaire matrix Q zodat

$$A = QHQ^*,$$

met H een boven-Hessenberg matrix is:

$$H = \begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & 0 & \times & \times & \times \\ 0 & 0 & 0 & \times & \times \end{bmatrix}$$

Stap 1: Bepaal $\hat{P}_2 \in \mathbb{C}^{m-1,m-1}$ zodat (noteer $A_2 = A$)

$$P_2 A_2 = \begin{bmatrix} 1 & 0 \\ 0 & \hat{P}_2 \end{bmatrix} A_2 = \begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \end{bmatrix},$$

Bereken $A_3 \Rightarrow$ Nullen die P_2 heeft gecreëerd blijven behouden.

$$A_3 = (P_2 A_2) P_2^* = (P_2 A_2) P_2 = \begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \end{bmatrix},$$

Stap 2: Bepaal $\hat{P}_3 \in \mathbb{C}^{m-2,m-2}$ zodat

$$P_3 A_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & \hat{P}_3 \end{bmatrix} A_3 = \begin{bmatrix} \times & \times & \times & \times & \times \\ \times & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & 0 & \times & \times & \times \\ 0 & 0 & \times & \times & \times \end{bmatrix},$$

Laat $A_4 = P_3 A_3 P_3^* = P_3 A_3 P_3 \Rightarrow$ Nullen in eerste 2 kolommen blijven behouden

Herhaal $m - 2$ stappen: $H = (P_{m-1} P_{m-2} \dots P_2) A (P_2 P_3 \dots P_{m-1})$.

Voorbeeld: Laat $A = \begin{bmatrix} 4 & 1 & -2 & 2 \\ 1 & 2 & 0 & 1 \\ -2 & 0 & 3 & -2 \\ 2 & 1 & -2 & -1 \end{bmatrix}$.

Stap 1: $x = \begin{bmatrix} 1 \\ -2 \\ 2 \end{bmatrix}$, $\|x\|_2 = 3$, $v_1 = x + 3e_1 = \begin{bmatrix} 4 \\ -2 \\ 2 \end{bmatrix}$, $v_1^\top v_1 = 24$,

$$\hat{P}_1 = I - \frac{2v_1v_1^\top}{v_1^\top v_1} = I - \frac{1}{12} \begin{bmatrix} 16 & -8 & 8 \\ -8 & 4 & -4 \\ 8 & -4 & 4 \end{bmatrix}, \quad P_1 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & -\frac{1}{3} & \frac{2}{3} & -\frac{2}{3} \\ 0 & \frac{2}{3} & \frac{2}{3} & \frac{1}{3} \\ 0 & -\frac{2}{3} & \frac{1}{3} & \frac{2}{3} \end{bmatrix}$$

$$A_1 = P_1 A P_1 = \begin{bmatrix} 4 & -3 & 0 & 0 \\ -3 & \frac{10}{3} & 1 & \frac{4}{3} \\ 0 & 1 & \frac{5}{3} & -\frac{4}{3} \\ 0 & \frac{4}{3} & -\frac{4}{3} & -1 \end{bmatrix}.$$

Stap 2: $x = \begin{bmatrix} 1 \\ 4 \\ \frac{4}{3} \end{bmatrix}$, $\|x\|_2 = \frac{5}{3}$, $v_2 = x + \frac{5}{3}e_1 = \frac{1}{3} \begin{bmatrix} 8 \\ 4 \end{bmatrix}$, $v_2^\top v_2 = \frac{80}{9}$.

$$\hat{P}_2 = I - \frac{2v_2v_2^\top}{v_2^\top v_2} = I - \frac{1}{40} \begin{bmatrix} 64 & 32 \\ 32 & 16 \end{bmatrix}, \quad P_2 = I - \frac{2u_2u_2^\top}{u_2^\top u_2} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & -\frac{3}{5} & -\frac{4}{5} \\ 0 & 0 & -\frac{4}{5} & \frac{3}{5} \end{bmatrix}$$

$$H = P_2 A_1 P_2 = \begin{bmatrix} 4 & -3 & 0 & 0 \\ -3 & \frac{10}{3} & -\frac{5}{3} & 0 \\ 0 & -\frac{5}{3} & -\frac{33}{25} & \frac{68}{75} \\ 0 & 0 & \frac{68}{75} & \frac{149}{75} \end{bmatrix},$$

is boven-Hessenberg (toevallig ook tri-diagonaal omdat A symmetrisch is).

Matrix Q: $Q = P_1 P_2$ (orthogonaal) geeft $H = Q^\top A Q$ met

$$Q = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & -\frac{1}{3} & \frac{2}{15} & -\frac{14}{15} \\ 0 & \frac{2}{3} & -\frac{2}{3} & -\frac{1}{3} \\ 0 & -\frac{2}{3} & -\frac{11}{15} & \frac{2}{15} \end{bmatrix}.$$

Numerieke Lineaire Algebra Singuliere Waarden Ontbinding

Gebaseerd op cursusnotities van Benny VH

Singuliere waarden ontbinding 1

Gegeven $A \in \mathbb{C}^{m,n}$, met $m \geq n$. Zoeken U, Σ, V zodat


$$A = U\Sigma V^*,$$

met $U \in \mathbb{C}^{m,m}$ unitair en $V \in \mathbb{C}^{n,n}$ unitair, en $\Sigma \in \mathbb{R}^{m,n}$ diagonaalmatrix:

$$\Sigma = \left[\begin{array}{cccc} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \dots & 0 & \sigma_n \\ \hline 0 & \dots & 0 & \\ \vdots & \ddots & \vdots & \\ 0 & \dots & 0 & \end{array} \right], \quad \left. \begin{array}{c} \\ \\ \\ \\ \end{array} \right\} m - n \text{ rijen}$$

met $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$.

Geometrische interpretatie (reële geval):



$$\Rightarrow Av_i = (U\Sigma V^*)v_i = (U\Sigma)e_i = U(\sigma_i e_i) = \sigma_i u_i.$$

σ_i singuliere waarden, v_i rechts singuliere vectoren, u_i links singuliere vectoren

Voorbeeld:

$$U = \begin{bmatrix} \frac{\sqrt{3}}{2} & -\frac{1}{2} \\ \frac{1}{2} & \frac{\sqrt{3}}{2} \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 2 & 0 \\ 0 & \frac{3}{4} \end{bmatrix}, \quad V^* = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

$$\Sigma V^* = \frac{1}{\sqrt{2}} \begin{bmatrix} 2 & 2 \\ \frac{3}{4} & -\frac{3}{4} \end{bmatrix}.$$

$$A = U\Sigma V^* = \frac{1}{\sqrt{2}} \begin{bmatrix} \sqrt{3} - \frac{3}{8} & \sqrt{3} + \frac{3}{8} \\ 1 + \frac{3\sqrt{3}}{8} & 1 - \frac{3\sqrt{3}}{8} \end{bmatrix} = \frac{1}{8\sqrt{2}} \begin{bmatrix} 8\sqrt{3} - 3 & 8\sqrt{3} + 3 \\ 8 + 3\sqrt{3} & 8 - 3\sqrt{3} \end{bmatrix}.$$

Gereduceerde SVD: $\text{rang}(A)=n$

$$A \underbrace{\begin{bmatrix} | & & | \\ v_1 & \dots & v_n \\ | & & | \end{bmatrix}}_{V \text{ unitair}} = \underbrace{\begin{bmatrix} | & & | \\ u_1 & \dots & u_n \\ | & & | \end{bmatrix}}_{\hat{U}} \underbrace{\begin{bmatrix} | & & | \\ \sigma_1 & \dots & \sigma_n \\ | & & | \end{bmatrix}}_{\hat{\Sigma}} \Rightarrow A = \hat{U} \hat{\Sigma} V^*$$

Gereduceerde SVD: $\text{rang}(A)=r < n$, dan $\sigma_{r+1} = \dots = \sigma_n = 0$

$$A = \underbrace{\begin{bmatrix} | & & | \\ u_1 & \dots & u_r \\ | & & | \end{bmatrix}}_{\hat{U}_r} \underbrace{\begin{bmatrix} | & & | \\ \sigma_1 & \dots & \sigma_r \\ | & & | \end{bmatrix}}_{\hat{\Sigma}_r} \underbrace{\begin{bmatrix} | & & | \\ v_1 & \dots & v_r \\ | & & | \end{bmatrix}}_{\hat{V}_r^*}^* \Rightarrow A = \hat{U}_r \hat{\Sigma}_r \hat{V}_r^*$$

want $\hat{\Sigma}_r \hat{V}_r^*$ is gelijk aan eerste r rijen van $\hat{\Sigma} V^*$

Volledige SVD: $\text{rang}(A)=r \leq n$

- $\hat{U}$ aanvullen met $m - r$ kolommen zodat $U = [\hat{U} \ u_{r+1} \ \dots \ u_m]$ unitair is
- $\hat{V}$ aanvullen met $n - r$ kolommen zodat $V = [\hat{V} \ v_{r+1} \ \dots \ v_n]$ unitair is
- $\hat{\Sigma}$ aanvullen met $n - r$ kolommen gelijk aan nul en $m - r$ rijen gelijk aan nul

Voorbeeld: Stel

$$A = \begin{bmatrix} 0 & 3 \\ 0 & 0 \\ 0 & 4 \end{bmatrix}.$$

Volledige SVD:

$$A = \begin{bmatrix} 0 & 3 \\ 0 & 0 \\ 0 & 4 \end{bmatrix} = \underbrace{\begin{bmatrix} 3/5 & 0 & -4/5 \\ 0 & 1 & 0 \\ 4/5 & 0 & 3/5 \end{bmatrix}}_U \underbrace{\begin{bmatrix} 5 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}}_{\Sigma} \underbrace{\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}}_{V^*}.$$

Gereduceerde SVD:

$$A = \begin{bmatrix} 0 & 3 \\ 0 & 0 \\ 0 & 4 \end{bmatrix} = \underbrace{\begin{bmatrix} 3/5 & 0 \\ 0 & 1 \\ 4/5 & 0 \end{bmatrix}}_{\hat{U}} \underbrace{\begin{bmatrix} 5 & 0 \\ 0 & 0 \end{bmatrix}}_{\hat{\Sigma}} \underbrace{\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}}_{V^*}.$$

of nog

$$A = \begin{bmatrix} 0 & 3 \\ 0 & 0 \\ 0 & 4 \end{bmatrix} = \underbrace{\begin{bmatrix} 3/5 \\ 0 \\ 4/5 \end{bmatrix}}_{\hat{U}_r} \underbrace{\begin{bmatrix} 5 \end{bmatrix}}_{\hat{\Sigma}_r} \underbrace{\begin{bmatrix} 0 & 1 \end{bmatrix}}_{\hat{V}_r^*}.$$

Stelling: Elke matrix $A \in \mathbb{C}^{m,n}$ heeft een volledige singuliere waarden ontbinding $A = U\Sigma V$ (en een gereduceerde).

Bewijs: Laat $\sigma_1 = \|A\|_2 = \sup_{x \in \mathbb{C}^n, \|x\|_2=1} \|Ax\|_2 = \max_{x \in \mathbb{C}^n, \|x\|_2=1} \|Ax\|_2$.

- $\Rightarrow \exists v_1 \in \mathbb{C}^n$ met $\|v_1\|_2 = 1$, zodat $\|Av_1\|_2 = \sigma_1$.
- Laat $u_1 = (Av_1)/\sigma_1$, dan is $u_1 \in \mathbb{C}^m$, $\|u_1\|_2 = 1$ en $Av_1 = \sigma_1 u_1$.
- Vul v_1 aan met $\{v_2, \dots, v_n\} \in \mathbb{C}^n$ zodat $V_1 = [v_1 \dots v_n]$ unitair is
- Vul u_1 aan met $\{u_2, \dots, u_m\} \in \mathbb{C}^m$ zodat $U_1 = [u_1 \dots u_m]$ unitair is

Het product $U_1^* A V_1$ is dan gelijk aan

$$U_1^* A V_1 = \sigma_1 U_1^* u_1 = \sigma_1 e_1,$$

daar $u_j^* u_1 = 0$ voor $j > 1$ en $u_1^* u_1 = 1$. Bijgevolg is $S = U_1^* A V_1$ van de vorm

$$S = U_1^* A V_1 = \begin{bmatrix} \sigma_1 & w^* \\ 0 & B \end{bmatrix},$$

waarbij w^* een rijvector is van lengte $n-1$ en $B \in \mathbb{C}^{m-1, n-1}$. Nu

$$\left\| \begin{bmatrix} \sigma_1 & w^* \\ 0 & B \end{bmatrix} \begin{bmatrix} \sigma_1 \\ w \end{bmatrix} \right\|_2 = \left\| \begin{bmatrix} \sigma_1^2 + w^* w \\ B w \end{bmatrix} \right\|_2 \geq \sigma_1^2 + w^* w = (\sigma_1^2 + w^* w)^{1/2} \left\| \begin{bmatrix} \sigma_1 \\ w \end{bmatrix} \right\|_2.$$

Per definitie van de 2-norm: $\|S\|_2 \geq (\sigma_1^2 + w^* w)^{1/2}$. Echter, $S = U_1^* A V_1$, met U_1^* en V_1 unitair, wat aangeeft $\|S\|_2 = \|A\|_2 = \sigma_1$. Hieruit volgt dat $w = 0$.

Wanneer $n = 1$ dan SVD door $U = U_1$ en $V^* = V_1^*$. Anders per inductie: B heeft een volledige SVD heeft van de vorm $B = U_2 \Sigma_2 V_2^*$. Hierdoor kunnen we A schrijven als

$$A = U_1 S V_1^* = \underbrace{U_1 \begin{bmatrix} 1 & 0 \\ 0 & U_2 \end{bmatrix}}_U \underbrace{\begin{bmatrix} \sigma_1 & 0 \\ 0 & \Sigma_2 \end{bmatrix}}_\Sigma \underbrace{\begin{bmatrix} 1 & 0 \\ 0 & V_2 \end{bmatrix}^*}_{V^*} V_1^*,$$

Merk op:

$$\sigma_1 = \|A\|_2 = \|S\|_2 = \left\| \begin{bmatrix} 1 & 0 \\ 0 & U_2 \end{bmatrix} \Sigma \begin{bmatrix} 1 & 0 \\ 0 & V_2 \end{bmatrix}^* \right\|_2 = \|\Sigma\|_2$$

wat aangeeft dat $\sigma_1 \geq \dots \geq \sigma_n \geq 0$.

Stelling: De rang van een matrix $A \in \mathbb{C}^{m,n}$ is gelijk aan het aantal singuliere waarden dat verschilt van nul.

Bewijs:

- $\text{rang}(CB) = \text{rang}(B)$, $B \in \mathbb{C}^{m,n}$, $C \in \mathbb{C}^{m,m}$ inverteerbaar,
 - $\text{rang}(BD) = \text{rang}(B)$, $B \in \mathbb{C}^{m,n}$, $D \in \mathbb{C}^{n,n}$ inverteerbaar,
- $$\Rightarrow \text{rang}(A) = \text{rang}(U\Sigma V^*) = \text{rang}(\Sigma V^*) = \text{rang}(\Sigma).$$

Definitie: $\text{range}(A) = \text{Im}(A) = \{Ax \mid x \in \mathbb{C}^n\} \subseteq \mathbb{C}^m$ en
 $\text{null}(A) = \text{Ker}(A) = \{x \in \mathbb{C}^n \mid Ax = 0\}$

Stelling: Laat $A = U\Sigma V^*$ een rang r matrix zijn, dan is
 $\text{range}(A) = \langle u_1, \dots, u_r \rangle$ en $\text{null}(A) = \langle v_{r+1}, \dots, v_n \rangle$.

Bewijs:

- V^* is unitair: $\text{range}(V^*) = \mathbb{C}^n$
- $\text{range}(\Sigma) = \langle e_1, \dots, e_r \rangle$ (vorige eigenschap)
- U beeldt e_j af op u_j

Hieruit volgt dat $\text{range}(A) = \langle u_1, \dots, u_r \rangle$.

- U unitair: $\text{null}(A) = \text{null}(\Sigma V^*)$
- $\text{null}(\Sigma) = \langle e_{r+1}, \dots, e_n \rangle$
- V^* beeldt v_j af op e_j

Hieruit volgt dat $\text{null}(A) = \text{null}(\Sigma V^*) = \langle v_{r+1}, \dots, v_n \rangle$.

Stelling: $\|A\|_2 = \sigma_1$ en $\|A\|_F = \sqrt{\sigma_1^2 + \dots + \sigma_r^2}$

Bewijs: $\|A\|_2 = \sigma_1$ volgt uit het bewijs van existentie.

Voor Q_1, Q_2 unitair weten we dat $\|Q_1 A\|_F = \|A Q_2\|_F = \|A\|_F$, dus

$$\|A\|_F = \|U\Sigma V^*\|_F = \|\Sigma V^*\|_F = \|\Sigma\|_F = \sqrt{\sigma_1^2 + \dots + \sigma_r^2}.$$

Stelling: Laat $A \in \mathbb{C}^{m,n}$, dan is $\|A\|_* = \sum_{i=1}^n \sigma_i$ een matrixnorm. Deze norm wordt de nuclear of trace norm genoemd.

Bewijs:

- $\|A\|_* \geq 0$ en $\|A\|_* = 0$ als en slechts als $A = 0$.
- Eenvoudig om na te gaan dat $\|zA\|_* = |z| \|A\|_*$.
- Nog bewijzen dat $\|A + B\|_* \leq \|A\|_* + \|B\|_*$.

Bewijzen eerst dat

$$\|A\|_* = \sup_{Q: \|Q\|_2 \leq 1} \text{tr}(Q^* A),$$

met $Q \in \mathbb{C}^{m,n}$. Uit het feit dat

$$\text{tr}(CD) = \sum_i (CD)_{ii} = \sum_i \sum_j c_{ij} d_{ji} = \sum_j \sum_i d_{ji} c_{ij} = \sum_j (DC)_{jj} = \text{tr}(DC),$$

volgt dat

$$\text{tr}(Q^* A) = \text{tr}(Q^* U \Sigma V^*) = \text{tr}((V^* Q^* U) \Sigma) = \sum_{i=1}^n (V^* Q^* U)_{ii} \sigma_i,$$

gezien Σ een diagonaalmatrix is. Verder is $\|V^* Q^* U\|_2 = \|Q\|_2 \leq 1$, waardoor we weten dat $(V^* Q^* U)_{ii} \leq 1$. Kortom,

$$\sup_{Q: \|Q\|_2 \leq 1} \text{tr}(Q^* A) = \sup_{Q: \|Q\|_2 \leq 1} \sum_{i=1}^n (V^* Q^* U)_{ii} \sigma_i \leq \sup_{Q: \|Q\|_2 \leq 1} \sum_{i=1}^n \sigma_i = \|A\|_*.$$

Deze ongelijkheid is echter een gelijkheid indien we

$$Q = U \begin{bmatrix} I \\ 0 \end{bmatrix} V^*,$$

aangezien $(V^* Q^* U)_{ii}$ dan gelijk is aan 1. We besluiten bijgevolg dat

$$\begin{aligned} \|A + B\|_* &= \sup_{Q: \|Q\|_2 \leq 1} \text{tr}(Q^* (A + B)) = \sup_{Q: \|Q\|_2 \leq 1} (\text{tr}(Q^* A) + \text{tr}(Q^* B)) \\ &\leq \sup_{Q: \|Q\|_2 \leq 1} \text{tr}(Q^* A) + \sup_{Q: \|Q\|_2 \leq 1} \text{tr}(Q^* B) = \|A\|_* + \|B\|_*. \end{aligned}$$

Stelling: De singuliere waarden $\sigma_1 \geq \dots \geq \sigma_r$ zijn de vierkantswortels van de eigenwaarden van A^*A die verschillen van nul.

Bewijs:

$$A^*A = (U\Sigma V^*)^* U\Sigma V^* = V\Sigma U^* U\Sigma V^* = V\Sigma^2 V^*.$$

Nu

$$\begin{aligned}\det(V\Sigma^2 V^* - \lambda I) &= \det(V\Sigma^2 V^* - \lambda VV^*) = \det(V) \det(\Sigma^2 - \lambda I) \det(V^*) \\ &= \det(VV^*) \det(\Sigma^2 - \lambda I) = \det(\Sigma^2 - \lambda I),\end{aligned}$$

We besluiten:

$$\text{eig}(A^*A) = \text{eig}(V\Sigma^2 V^*) = \text{eig}(\Sigma^2) = \{\sigma_1^2, \dots, \sigma_r^2\}.$$

Stelling: Voor $A \in \mathbb{C}^{m,m}$ zien we dat $|\det(A)| = \prod_{j=1}^m \sigma_j$.

Bewijs: Aangezien $\det(AB) = \det(A) \det(B)$, geldt dat $\det(A) = \det(U) \det(\Sigma) \det(V^*)$, d.i.,

$$|\det(A)| = |\det(U)| \left(\prod_{j=1}^m \sigma_j \right) |\det(V^*)|.$$

Verder is $|\det(Q)| = 1$ met Q unitair.

Stelling: Laat A een rang r matrix zijn met SVD $A = U\Sigma V^*$, dan is

$$A = \sum_{j=1}^r \sigma_j u_j v_j^*,$$

waarbij σ_j de j -de singuliere waarde, u_j de j -de kolom van U en v_j^* de j -de rij van V^* voorstelt.

Bewijs: $\text{rang}(A) = r \Rightarrow \sigma_r > \sigma_{r+1} = \dots = \sigma_n = 0$. Laat

$$\Sigma = \Sigma_1 + \dots + \Sigma_r,$$

waarbij $\Sigma_j = \sigma_j e_j e_j^*$, dan is

$$A = \sum_{j=1}^r U \Sigma_j V^*.$$

$$\text{en } U \Sigma_j V^* = \sigma_j (U e_j) (e_j^* V^*) = \sigma_j u_j (V e_j)^* = \sigma_j u_j v_j^*$$

Stelling: Laat A een rang r matrix zijn met SVD $A = U\Sigma V^*$. Definieer A_k , voor $1 \leq k \leq r$ als

$$A_k = \sum_{j=1}^k \sigma_j u_j v_j^*,$$

waarbij σ_j de j -de singuliere waarde, u_j de j -de kolom van U en v_j^* de j -de rij van V^* voorstelt. Dan is

$$\|A - A_k\|_2 = \min_{B \in \mathbb{C}^{m,n}, \text{rang}(B) \leq k} \|A - B\|_2 = \sigma_{k+1},$$

met $\sigma_{r+1} = 0$ indien $r = n$.

Bewijs:

- $A - A_k$ singuliere waarden $\sigma_{k+1}, \dots, \sigma_r \Rightarrow \|A - A_k\|_2 = \sigma_{k+1}$.
- Stel $B \in \mathbb{C}^{m,n}$ met $\text{rang}(B) \leq k$ en $\|A - B\|_2 < \|A - A_k\|_2 = \sigma_{k+1}$.

Aangezien $\text{rang}(B) \leq k$, heeft $\text{null}(B)$ minstens dimensie $n - k$.

$\Rightarrow \exists (n - k)$ dimensionale deelruimte W van $\mathbb{C}^n$, zodat $Bw = 0$ voor $w \in W$.

Nu

$$\|Aw\|_2 = \|(A - B)w\|_2 \leq \|A - B\|_2 \|w\|_2 < \sigma_{k+1} \|w\|_2,$$

voor $w \in W$. Kortom, **er bestaat een $n - k$ dimensionale deelruimte W van $\mathbb{C}^n$ zodat $\|Aw\|_2 < \sigma_{k+1} \|w\|_2$.**

Anderzijds weten we dat $\langle v_1, \dots, v_{k+1} \rangle$ een $k + 1$ dimensionale deelruimte W' vormt van $\mathbb{C}^n$. Indien $w \in W'$, dan $w = Vx$ met $x \in \mathbb{C}^n$ en $x_{k+2} = \dots = x_n = 0$. Bijgevolg is $Aw = U\Sigma x \geq \sigma_{k+1} Ux$, zodat

$$\|Aw\|_2 \geq \sigma_{k+1} \|Ux\|_2 = \sigma_{k+1} \|x\|_2 = \sigma_{k+1} \|Vx\|_2 = \sigma_{k+1} \|w\|_2,$$

voor $w \in W'$, aangezien U en V unitaire matrices zijn. **Er bestaat een $k + 1$ dimensionale deelruimte W' van $\mathbb{C}^n$ zodat $\|Aw\|_2 \geq \sigma_{k+1} \|w\|_2$.**

De som van de dimensies van de twee deelruimtes W en W' kan echter niet groter zijn dan n , waardoor het gestelde (zijnde het bestaan van B) niet klopt.

Stelsel

$$Ax = b$$

met $A \in \mathbb{C}^{m,n}$ met $m > n$. Zoeken x zodat

$$\|r\|_2 = \|Ax - b\|_2$$

minimaal is (Ax is projectie van b op $\langle a_1, \dots, a_n \rangle$).

Laat $A = U\Sigma V^*$ dan

$$\|r\|_2 = \|Ax - b\|_2 = \|U\Sigma V^*x - b\|_2 = \|\Sigma V^*x - U^*b\|_2,$$

Gebruik verband volledige en gedeeltelijke SVD:

$$\Sigma = \begin{bmatrix} \Sigma_r & 0 \\ 0 & 0 \end{bmatrix}, \quad U = [U_r \quad U_2] \quad \text{en} \quad V = [V_r \quad V_2],$$

, dan

$$U^*b = \begin{bmatrix} U_r^*b \\ U_2^*b \end{bmatrix}, \quad V^*x = \begin{bmatrix} V_r^*x \\ V_2^*x \end{bmatrix}, \quad \text{en} \quad \Sigma V^*x = \begin{bmatrix} \Sigma_r V_r^*x \\ 0 \end{bmatrix}$$

Bijgevolg is

$$\|r\|_2^2 = \left\| \begin{bmatrix} \Sigma_r V_r^*x \\ 0 \end{bmatrix} - \begin{bmatrix} U_r^*b \\ U_2^*b \end{bmatrix} \right\|_2^2 = \|\Sigma_r V_r^*x - U_r^*b\|_2^2 + \|U_2^*b\|_2^2.$$

Σ_r inverteerbaar $\Rightarrow$ los $\Sigma_r y = U_r^*b$ op zodat

$$\|r\|_2 = \|U_2^*b\|_2$$

wanneer $x = V_r y = V_r \Sigma_r^{-1} U_r^* b$.

Mogelijk snellere berekening voor minimale $\|r\|_2$:


$$\|r\|_2 = \|Ax - b\|_2 = \|(U_r \Sigma_r V_r^*) V_r \Sigma_r^{-1} U_r^* b - b\|_2 = \|U_r U_r^* b - b\|_2.$$

Let op:

$$U_r^* U_r = I, \quad \text{maar} \quad U_r U_r^* \neq I$$

Toepassing 3: Handgeschreven cijfers herkennen

- Systeem *trainen* op basis van vele handgeschreven cijfers.
- Elk cijfer omzetten in 16x16 bitmap, elke pixel grijswaarde in $[0, 255]$



- Elk cijfer is vector in $\mathbb{R}^{256}$
- Alle cijfers gelijk aan i worden kolommen van matrix D_i voor $i = 0, \dots, 9$

Hoe onbekend cijfer d herkennen?

- Bepalen afstand ρ_i van ongekend cijfer d tot ruimte opgespannen door kolommen van D_i

$$\rho_i = \min_x \|D_i x - d\|_2$$

Dit zijn 10 kleinste kwadraten problemen

- $d = i$ indien ρ_i kleinste van de 10 ρ waardes is

Probleem:

Rang van matrices D_i loopt op als de trainingsset vergroot. In extremis tot dimensie 256 waardoor alle ρ waardes gelijk zijn aan nul. Voor hoge rang is ook de rektijd hoog.

Oplossing:

We benaderen de ruimte opgespannen door de kolommen van D_i door een ruimte met een vaste dimensie k (bv. $k = 10$). Deze k dimensionale ruimte wordt bepaald door de eerste k singuliere waarden van D_i , of nog, we gebruiken de best mogelijke rang k approximatie van D_i (voor elke i)






Werkt dit goed?

Test resultaten met $k = 10$:

Cijfer	Aantal	Juist	Fout	Succeskans
0	359	353	6	98.3287
1	264	261	3	98.8636
2	198	179	19	90.4040
3	166	146	20	87.9518
4	200	183	17	91.5000
5	160	139	21	86.8750
6	170	160	10	94.1176
7	147	138	9	93.8776
8	166	145	21	87.3494
9	177	166	11	93.7853

Wanneer gaat het systeem in de fout?

Deze zijn vaak ook vrij onduidelijk:



Het zou gaan om een 6, 2, 4, 6 en 3, terwijl het SVD algoritme deze catalogeerde als 0, 0, 7, 2 en 5.

Singuliere waarden van A zijn vierkantswortels van eigenwaardes van A^*A . Deze aanpak is echter niet altijd numeriek betrouwbaar. Beter via eigenwaardes van

$$H = \begin{bmatrix} 0 & A^* \\ A & 0 \end{bmatrix},$$

zie oefeningen.

In de praktijk SVD bepalen in 2 fases:

- 1 (Golub-Kahan bidiagonalisatie) zoek U_1 en V_1 unitair zodat

$$B = U_1^* A V_1 = \begin{bmatrix} \times & \times & 0 & 0 \\ 0 & \times & \times & 0 \\ 0 & 0 & \times & \times \\ 0 & 0 & 0 & \times \\ 0 & 0 & 0 & 0 \end{bmatrix}.$$

een boven-bidigonaalmatrix is

- 2 (iteratieve methode) zoek U_2 en V_2 unitair zodat

$$\Sigma = U_2^* B V_2 = \begin{bmatrix} \times & 0 & 0 & 0 \\ 0 & \times & 0 & 0 \\ 0 & 0 & \times & 0 \\ 0 & 0 & 0 & \times \\ 0 & 0 & 0 & 0 \end{bmatrix}.$$

een niet-negatieve diagonaalmatrix is

$\Rightarrow$ Als $U = U_1 U_2$ en $V = V_1 V_2$ dan

$$U^* A V = U_2^* \underbrace{U_1^* A V_1}_B V_2 = \Sigma,$$

zodat $A = U \Sigma V^*$

Golub-Kahan bidiagonalisatie

Stel $v_1 = a_1$, en laat P_1 de Householder reflectie matrix zijn met $v = v_1 + e^{i \arg (v_1)_1} \|v_1\|_2 e_1$, dan

$$A_1 = P_1 A = \begin{bmatrix} \times & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \end{bmatrix}.$$

Laat $w_1^* = (A_1)_{1,2:n}$ en definieer $\hat{Q}_1$ als de Householder reflectie matrix met $v = w_1 + e^{i \arg (w_1)_1} \|w_1\|_2 e_1$, dan is

$$C_1 = A_1 Q_1 = A_1 \begin{bmatrix} 1 & 0 \\ 0 & \hat{Q}_1 \end{bmatrix} = \begin{bmatrix} \times & \times & 0 & 0 \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & \times & \times & \times \end{bmatrix},$$

daar 1e kolom van $A_1 = 1$ e kolom van $A_1 Q_1$.

Stel $v_2 = (C_1)_{2:m,2}$ en $\hat{P}_2$ is de Householder reflectie matrix met $v = v_2 + e^{i \arg (v_2)_1} \|v_2\|_2 e_1$, dan

$$A_2 = P_2 C_1 = \begin{bmatrix} 1 & 0 \\ 0 & \hat{P}_2 \end{bmatrix} C_1 = \begin{bmatrix} \times & \times & 0 & 0 \\ 0 & \times & \times & \times \\ 0 & 0 & \times & \times \\ 0 & 0 & \times & \times \\ 0 & 0 & \times & \times \end{bmatrix},$$

daar 1e rij van $C_1 = 1$ e rij van $P_2 C_1$ en de nullen op de eerste kolom blijven.

Stel $w_2^* = (A_2)_{2,3:n}$ en $\hat{Q}_2$ is de Householder reflectie matrix met $v = w_2 + e^{i \arg (w_2)_1} \|w_2\|_2 e_1$, dan

$$C_2 = A_2 Q_2 = A_2 \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & \hat{Q}_2 \end{bmatrix} = \begin{bmatrix} \times & \times & 0 & 0 \\ 0 & \times & \times & 0 \\ 0 & 0 & \times & \times \\ 0 & 0 & \times & \times \\ 0 & 0 & \times & \times \end{bmatrix}.$$

Deze procedure herhalen resulteert in

$$A_{n-1} = P_{n-1} \dots P_2 P_1 A Q_1 Q_2 \dots Q_{n-2} = \begin{bmatrix} \times & \times & 0 & 0 \\ 0 & \times & \times & 0 \\ 0 & 0 & \times & \times \\ 0 & 0 & 0 & \times \\ 0 & 0 & 0 & \times \\ 0 & 0 & 0 & \times \\ 0 & 0 & 0 & \times \end{bmatrix}.$$

- Indien $m = n$ dan A_{n-1} een bidiagonaalmatrix
- Anders laatste $m - n$ elementen van de kolom n van A_{n-1} nul te maken via de Householder reflectie matrix $\hat{P}_n$ met $v = v_n + e^{j \arg(v_n)_1} \|v_n\|_2 e_1$ en $v_n = (A_{n-1})_{n:m,n}$

$\Rightarrow$ De gezochte unitaire matrices U_1^* en V_1 zijn bijgevolg gelijk aan:

$$U_1^* = P_n \dots P_1, \quad \text{en} \quad V_1 = Q_1 \dots Q_{n-2}.$$

Voorbeeld:

$$A = \begin{bmatrix} 2 & 1 & 1 \\ 2 & 1 & 1 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \in \mathbb{R}^{4 \times 3}.$$

Stap 1 (links):

$$P_1 = \begin{bmatrix} -\frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} & 0 & 0 \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} = I_4 - \frac{2v_1 v_1^\top}{v_1^\top v_1}, \quad v_1 = \begin{bmatrix} 2 + 2\sqrt{2} \\ 2 \\ 0 \\ 0 \end{bmatrix}.$$

dan

$$A_1 = P_1 A = \begin{bmatrix} -2\sqrt{2} & -\sqrt{2} & -\sqrt{2} \\ 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Stap 1 (rechts):

$$\hat{Q}_1 = \begin{bmatrix} -\frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix} = I_2 - \frac{2w_1 w_1^\top}{w_1^\top w_1}, \quad w_1 = \begin{bmatrix} -\sqrt{2} - 2 \\ -\sqrt{2} \end{bmatrix}$$

dan

$$C_1 = A_1 Q_1 = \begin{bmatrix} -2\sqrt{2} & 2 & 0 \\ 0 & 0 & 0 \\ 0 & -\frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ 0 & -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix}.$$

Stap 2 (links):

$$\hat{P}_2 = \begin{bmatrix} 0 & \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{1}{2} & -\frac{1}{2} \\ \frac{\sqrt{2}}{2} & -\frac{1}{2} & \frac{1}{2} \end{bmatrix} = I_3 - \frac{2v_2 v_2^\top}{v_2^\top v_2}, \quad v_2 = \begin{bmatrix} 1 \\ -\frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} \end{bmatrix},$$

dan

$$A_2 = P_2 C_1 = \begin{bmatrix} -2\sqrt{2} & 2 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & -\frac{\sqrt{2}}{2} \\ 0 & 0 & \frac{\sqrt{2}}{2} \end{bmatrix}.$$

Stap 3 (links):

$$\hat{P}_3 = \begin{bmatrix} -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix} = I_2 - \frac{2v_3 v_3^\top}{v_3^\top v_3}, \quad v_3 = \begin{bmatrix} -\frac{\sqrt{2}}{2} - 1 \\ \frac{\sqrt{2}}{2} \end{bmatrix},$$

dus

$$B = P_3 A_2 = \begin{bmatrix} -2\sqrt{2} & 2 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix}$$

$$V_1 = Q_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & -\frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ 0 & -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix} \quad \text{en} \quad U_1 = P_1 P_2 P_3 = \frac{\sqrt{2}}{2} \begin{bmatrix} -1 & 0 & 0 & -1 \\ -1 & 0 & 0 & 1 \\ 0 & 1 & -1 & 0 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

Numerieke Lineaire Algebra Conditionering en Stabiliteit

Gebaseerd op cursusnotities van Benny VH

Definitie: Wanneer f een probleem weergeeft (van $\mathbb{C}^n$ naar $\mathbb{C}^m$), dan is het **absolute conditiegetal** $\hat{\kappa}(x)$ in het punt $x \in \mathbb{C}^n$ gelijk aan

$$\hat{\kappa}(x) = \lim_{\delta \rightarrow 0} \sup_{\|\delta x\| \leq \delta} \frac{\|f(x + \delta x) - f(x)\|}{\|\delta x\|},$$

waarbij de norm in de teller (noemer) overeenstemt met de gekozen norm in $\mathbb{C}^m$ ($\mathbb{C}^n$).

Bijzondere gevallen:

- $f : \mathbb{R} \rightarrow \mathbb{R}$ en $f'(x)$ bestaat, dan

$$\hat{\kappa}(x) = |f'(x)|.$$

gezien $f'(x) = \lim_{\Delta \rightarrow 0} \frac{f(x+\Delta) - f(x)}{\Delta}$.

- $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ en differentieerbaar in x . Definieer de **Jacobiaan** $J(x)$ als $m \times n$ matrix

$$J(x) = \begin{bmatrix} \partial f_1(x)/\partial x_1 & \partial f_1(x)/\partial x_2 & \dots & \partial f_1(x)/\partial x_n \\ \partial f_2(x)/\partial x_1 & \partial f_2(x)/\partial x_2 & \dots & \partial f_2(x)/\partial x_n \\ \vdots & \vdots & \ddots & \vdots \\ \partial f_m(x)/\partial x_1 & \partial f_m(x)/\partial x_2 & \dots & \partial f_m(x)/\partial x_n \end{bmatrix}.$$

Eerste orde Taylor reeks expansie

$$f(x + \delta x) = f(x) + J(x)\delta x + o(\|\delta x\|),$$

waarbij $\lim_{\|\delta x\| \rightarrow 0} \frac{o(\|\delta x\|)}{\|\delta x\|} = 0$. Bijvoorbeeld als $f(x) = x^2$ dan

$$f(x + \delta x) = x^2 + 2x\delta x + (\delta x)^2 = f(x) + f'(x)\delta x + o(|\delta x|).$$

Bijgevolg

$$\hat{\kappa}(x) = \lim_{\delta \rightarrow 0} \sup_{\|\delta x\| \leq \delta} \frac{\|J(x)\delta x + o(\|\delta x\|)\|}{\|\delta x\|} = \sup_{\|\delta x\| \neq 0} \frac{\|J(x)\delta x\|}{\|\delta x\|} = \|J(x)\|.$$

matrixnorm is geïnduceerd door de vectornorm van $\mathbb{C}^n$ en $\mathbb{C}^m$.

- f een lineaire afbeelding: $f(x) = Ax$ met A een $m \times n$ matrix, dan

$$f_i(x_1, \dots, x_n) = a_{i1}x_1 + \dots + a_{in}x_n,$$

wat aangeeft dat $J(x) = A$.

Voorbeeld:

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}^3, \quad f(x_1, x_2) = \begin{bmatrix} x_1^2 - x_2^2 \\ 2x_1x_2 \\ x_1 + x_2 \end{bmatrix}.$$

Jacobiaan van f is

$$J_f(x_1, x_2) = \begin{bmatrix} 2x_1 & -2x_2 \\ 2x_2 & 2x_1 \\ 1 & 1 \end{bmatrix}.$$

Laat $r^2 = x_1^2 + x_2^2$. Noteer kolommen van J_f als

$$c_1 = \begin{bmatrix} 2x_1 \\ 2x_2 \\ 1 \end{bmatrix}, \quad c_2 = \begin{bmatrix} -2x_2 \\ 2x_1 \\ 1 \end{bmatrix}.$$

dan

$$\|c_1\|_2^2 = \|c_2\|_2^2 = 4r^2 + 1, \quad c_1^\top c_2 = 1,$$

zodat

$$J_f^\top(x_1, x_2) J_f(x_1, x_2) = \begin{bmatrix} 4r^2 + 1 & 1 \\ 1 & 4r^2 + 1 \end{bmatrix}.$$

De eigenwaarden van deze 2×2 matrix zijn

$$\lambda_{\pm} = (4r^2 + 1) \pm 1 = \{4r^2 + 2, 4r^2\},$$

zodat de singuliere waardes van J_f gelijk zijn aan

$$\sigma_1(J_f(x_1, x_2)) = \sqrt{4r^2 + 2}, \quad \sigma_2(J_f(x_1, x_2)) = \sqrt{4r^2}.$$

Het conditiegetal $\hat{\kappa}(x_1, x_2)$

$$\hat{\kappa}(x_1, x_2) = \|J_f(x_1, x_2)\|_2 = \sigma_1 = \sqrt{4(x_1^2 + x_2^2) + 2}.$$

Definitie: Wanneer f een probleem van $\mathbb{C}^n$ naar $\mathbb{C}^m$, dan het **relatieve conditiegetal** $\kappa(x)$ in het punt $x \in \mathbb{C}^n$ gelijk aan

$$\kappa(x) = \frac{\hat{\kappa}(x)}{\frac{\|f(x)\|}{\|x\|}} = \frac{\hat{\kappa}(x) \|x\|}{\|f(x)\|}.$$

Voorbeeld:

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}^3, \quad f(x_1, x_2) = \begin{bmatrix} x_1^2 - x_2^2 \\ 2x_1x_2 \\ x_1 + x_2 \end{bmatrix}.$$

dan

$$\|J_f(x_1, x_2)\|_2 = \sqrt{4r^2 + 2} \quad \text{en} \quad \|(x_1, x_2)\|_2 = \sqrt{x_1^2 + x_2^2} = r.$$

Mits wat rekenwerk zien we

$$\|f(x_1, x_2)\|_2^2 = (x_1^2 - x_2^2)^2 + (2x_1x_2)^2 + (x_1 + x_2)^2 = r^4 + (x_1 + x_2)^2.$$

Bijgevolg

$$\kappa(x_1, x_2) = \frac{r \sqrt{4r^2 + 2}}{\sqrt{r^4 + (x_1 + x_2)^2}}, \quad r^2 = x_1^2 + x_2^2.$$

Bijzondere gevallen.

- In het punt $(x_1, x_2) = (0, 0)$ is het conditiegetal niet gedefinieerd aangezien $f(0, 0) = 0$.
- Langs de lijn $x_2 = -x_1$ geldt $x_1 + x_2 = 0$, en dus

$$\kappa(x_1, -x_1) = \frac{\sqrt{4r^2 + 2}}{r}, \quad \text{met} \quad \kappa(x_1, -x_1) \approx \frac{\sqrt{2}}{r} \quad \text{voor } r \text{ klein}$$

wat divergeert als $r \rightarrow 0$: het probleem is dus slecht geconditioneerd in de buurt van deze lijn voor kleine r .

- Voor grote waarden van r geldt

$$\kappa(x_1, x_2) \approx 2,$$

zodat het probleem goed geconditioneerd wordt ver weg van de oorsprong.

Voorbeeld: Keuze van de norm maakt berekeningen vaak eenvoudiger

$$f(x_1, x_2) = \begin{bmatrix} x_1^2 - x_2^2 \\ 2x_1x_2 \\ x_1 + x_2 \end{bmatrix} \quad \text{en} \quad J_f(x_1, x_2) = \begin{bmatrix} 2x_1 & -2x_2 \\ 2x_2 & 2x_1 \\ 1 & 1 \end{bmatrix}.$$

dan

$$\|J(x)\|_1 = 2|x_1| + 2|x_2| + 1, \quad \|x\|_1 = |x_1| + |x_2|,$$

en

$$\|f(x)\|_1 = |x_1^2 - x_2^2| + 2|x_1x_2| + |x_1 + x_2|.$$

Indien nu $x_2 = -x_1$, dan $\|f(x)\| = 2x_1^2$, bijgevolg

$$\kappa(x_1, -x_1) = \frac{\|J(x)\|_1 \|x\|_1}{\|f(x)\|_1} = \frac{(4|x_1| + 1)2|x_1|}{2x_1^2} = 4 + \frac{1}{|x_1|}$$

dus slecht geconditioneerd in de buurt van de oorsprong. Voor grote $|x_1|$ nadert het conditiegetal de limietwaarde 4 en is het probleem goed geconditioneerd.

Ruw gesteld zullen we zien dat het aantal correcte digits dat we verliezen bij bepalen van $f(x)$ wordt gegeven door $\log_{10} \kappa(x)$

Voorbeelden:

- Stel $f(x) = x^{1/2}$ dan $\hat{\kappa}(x) = |J(x)| = |f'(x)| = |\frac{1}{2}x^{-1/2}|$. Dan

$$\kappa(x) = \frac{\hat{\kappa}(x)|x|}{|f(x)|} = \frac{|\frac{1}{2}x^{-\frac{1}{2}}||x|}{|x^{1/2}|} = \frac{1}{2}$$

Goed geconditioneerd.

- Stel lineaire afbeelding $f(x_1, x_2) = x_1 - x_2$, dan $A = J(x_1, x_2) = [1 \ -1]$ met $\|J(x_1, x_2)\|_\infty = 2$. Bijgevolg is

$$\kappa(x) = \frac{2 \max(|x_1|, |x_2|)}{|x_1 - x_2|}.$$

Wanneer $x_1 - x_2 \approx 0$, dan is het probleem slecht geconditioneerd.

- Bepaal twee oplossingen voor y van $y^2 - 2y + x = 0$ gegeven x , dan $f_1(x) = 1 - \sqrt{1-x}$ en $f_2(x) = 1 + \sqrt{1-x}$.

Dan

$$J(x) = \begin{bmatrix} \frac{1}{2\sqrt{1-x}} \\ -1 \\ \frac{-1}{2\sqrt{1-x}} \end{bmatrix}.$$

Voor $x \rightarrow 1$: $\|J(x)\|_1 = 1/\sqrt{1-x} \rightarrow \infty$, terwijl $\|f(x)\|_1 / \|x\|_1 \rightarrow 2$. Bijgevolg $\kappa(x) \rightarrow \infty$ als $x \rightarrow 1$. Bepalen van de twee wortels is slecht geconditioneerd voor x dicht bij 1.

- Eigenwaarden van een matrix A in functie van zijn elementen a_{ij} . Neem

$$A_1 = \begin{bmatrix} 1 & 10^3 \\ 0 & 1 \end{bmatrix}, \quad A_2 = \begin{bmatrix} 1 & 10^3 \\ 10^{-3} & 1 \end{bmatrix}.$$

Bepalen eigenwaarden is iha slecht geconditioneerd, want $\text{eig}(A_1) = \{1, 1\}$ en $\text{eig}(A_2) = \{0, 2\}$.

Het bepalen van de eigenwaarden van een symmetrische matrix is wel goed geconditioneerd. Men kan bewijzen dat indien A met eigenwaarde λ , vervangen wordt door $A + \delta A$, waarvan we de overeenkomstige eigenwaarde noteren als $\lambda + \delta\lambda$, dan zal $|\delta\lambda| \leq \|\delta A\|_2$.

Probleem 1: $Ax = b$ met x input en b output

Probleem 1: $f(x) = Ax$ met $A \in \mathbb{C}^{m,m}$ invertierbar.

Per definitie:

$$\kappa(x) = \frac{\hat{\kappa}(x) \|x\|}{\|f(x)\|} = \frac{\|A\| \|x\|}{\|Ax\|}.$$

Nu

$$\|x\| = \|A^{-1}(Ax)\| \leq \|A^{-1}\| \|Ax\|,$$

kortom

$$\kappa(x) \leq \frac{\|A\| \|A^{-1}\| \|Ax\|}{\|Ax\|} = \|A\| \|A^{-1}\|,$$

voor alle x .

Vraag: Bestaat er een x zodat $\kappa(x) = \|A^{-1}\| \|A\|$?

- $\|A\|_2 = \sigma_1$ en $\|A^{-1}\|_2 = 1/\sigma_m$, want stel $A = U\Sigma V^*$, dan

$$\|A^{-1}\|_2 = \|V\Sigma^{-1}U^*\|_2 = \|\Sigma^{-1}\|_2 = 1/\sigma_m.$$

- Neem $x = v_m$, dan $Ax = \sigma_m u_m$. Bijgevolg

$$\kappa(x) = \frac{\|A\|_2 \|x\|_2}{\|Ax\|_2} = \frac{\|A\|_2}{\sigma_m \|u_m\|_2} = \|A\|_2 \|A^{-1}\|_2.$$

Stelling: Laat $A \in \mathbb{C}^{m,m}$ een inverterbare matrix zijn en beschouw het stelsel $Ax = b$. Het probleem om b te bepalen in functie van x heeft als conditiegetal

$$\kappa(x) = \|A\| \|x\| / \|Ax\| \leq \|A\| \|A^{-1}\|.$$

Voor de 2-norm is $\kappa(\cdot) = \|A\| \|A^{-1}\| = \sigma_1/\sigma_m$ indien $x = v_m$ met $Av_m = \sigma_m u_m$.

Voorbeeld: Stel $A = U\Sigma V^*$ met

$$U = \begin{bmatrix} \frac{\sqrt{3}}{2} & -\frac{1}{2} \\ \frac{1}{2} & \frac{\sqrt{3}}{2} \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 2 & 0 \\ 0 & \frac{3}{4} \end{bmatrix}, \quad V^* = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

dan $\kappa(x) \leq \frac{\sigma_1}{\sigma_2} = \frac{8}{3}$ en $v_2 = \frac{1}{\sqrt{2}}(1, -1)^T$.

Probleem 2: $Ax = b$ met b input en x output

Probleem 2: Oplossen stelsel $Ax = b$, equivalent aan $f(b) = A^{-1}b$ met $A \in \mathbb{C}^{m,m}$ invertierbar. Hoe gevoelig is oplossing aan perturbaties in b ?

= Probleem 1 met rol van A en A^{-1} omgekeerd (daar $(A^{-1})^{-1} = A$) en rol van x en b omgekeerd.

Stelling: Laat $A \in \mathbb{C}^{m,m}$ een inverterbare matrix zijn en beschouw het stelsel $Ax = b$. Het probleem om x te bepalen in functie van b heeft als conditiegetal

$$\kappa(b) = \|A^{-1}\| \|b\| / \|A^{-1}b\| \leq \|A\| \|A^{-1}\|.$$

Voor de 2-norm is $\kappa(\cdot) = \|A^{-1}\| \|A\| = \sigma_1/\sigma_m$ indien $b = u_1$ met $Av_1 = \sigma_1 u_1$ voor het tweede.

Namelijk, gezien $Av_1 = \sigma_1 u_1$ hebben we

$$\kappa(u_1) = \frac{\|A^{-1}\|_2 \|u_1\|_2}{\|A^{-1}u_1\|_2} = \frac{\|A^{-1}\|_2}{\|v_1/\sigma_1\|_2} = \|A\|_2 \|A^{-1}\|_2$$

Definitie: Het **conditiegetal** $\kappa(A)$ van een inverterbare matrix $A \in \mathbb{C}^{m,m}$ wordt gegeven door $\|A\| \|A^{-1}\|$. Voor de 2-norm is $\kappa(A) = \sigma_1/\sigma_m$.

Indien we $\kappa(A) = \sigma_1/\sigma_m$ voor $A \in \mathbb{C}^{m,n}$ met $m > n$, dan zal het conditiegetal van probleem 1 begrensd blijven door $\kappa(A)$ (met gelijkheid in sommige gevallen).

Wanneer $A = Q$ unitair, dan $\|Q\|_2 = 1 = \|Q^{-1}\|_2$ waardoor $\kappa(A) = 1$.

Probleem 3: $Ax = b$ met A input en x output

Probleem 3: Oplossen stelsel $Ax = b$, equivalent aan $f(A) = A^{-1}b$ met $A \in \mathbb{C}^{m,m}$ inverteerbaar. Hoe gevoelig is oplossing aan perturbaties in A ?

Stel $(A + \delta A)(x + \delta x) = b$, dus $x + \delta x$ is oplossing van geperturbeerde stelsel, dan

$$A\delta x + \delta A(x + \delta x) = 0,$$

want $Ax = b$. Bijgevolg

$$\|\delta x\| = \|A^{-1} \delta A(x + \delta x)\| \leq \|A^{-1}\| \|\delta A\| \|x + \delta x\|.$$

Kortom

$$\frac{\|\delta x\| \|A\|}{\|\delta A\| \|x + \delta x\|} \leq \|A^{-1}\| \|A\|.$$

Merk nu op dat:

- $f(A) = x$ en $f(A + \delta A) = x + \delta x$
- $f(A + \delta A) - f(A) = \delta x$

We zien

$$\frac{\|f(A + \delta A) - f(A)\| \|A\|}{\|\delta A\| \|f(A + \delta A)\|} \leq \|A^{-1}\| \|A\|.$$

Hierdoor

$$\lim_{\delta \rightarrow 0} \sup_{\|\delta A\| \leq \delta} \frac{\|f(A + \delta A) - f(A)\|}{\|\delta A\| \|f(A + \delta A)\|} \|A\| \leq \|A^{-1}\| \|A\|.$$

of nog

$$\underbrace{\lim_{\delta \rightarrow 0} \sup_{\|\delta A\| \leq \delta} \frac{\|f(A + \delta A) - f(A)\|}{\|\delta A\|}}_{\text{absolute conditiegetal}} \frac{\|A\|}{\|f(A)\|} \leq \|A^{-1}\| \|A\|.$$

Besluit: relatieve conditiegetal κ van probleem 3 is begrensd door $\|A\| \|A^{-1}\|$. Deze bovengrens is afhankelijk van de input A .

Stelling: Laat $A \in \mathbb{C}^{m,m}$ een inverteerbare matrix zijn en beschouw het stelsel $Ax = b$. Het probleem om x te bepalen in functie van A (met b vast), heeft als conditiegetal

$$\kappa \leq \|A\| \|A^{-1}\|.$$

Het is ook mogelijk om te bewijzen dat er perturbaties δA bestaan zodat $\kappa = \|A\| \|A^{-1}\|$.

Definitie: De **machineprecisie** $\epsilon_{\text{machine}}$ is het kleinste reële getal waarvoor geldt dat voor elke $x \in \mathbb{R}$ er een ϵ bestaat met $|\epsilon| \leq \epsilon_{\text{machine}}$ zodat

$$\text{fl}(x) = x(1 + \epsilon) \quad (3)$$

en voor elke twee floating point getallen x, y , bestaat er eveneens een ϵ met $|\epsilon| \leq \epsilon_{\text{machine}}$ zodat

$$x \circledast y = (x * y)(1 + \epsilon), \quad (4)$$

waarbij $*$ = $+$, $-$, $\times$ of $\div$.

IEEE 754 Double Floating Point: $\epsilon_{\text{machine}} = 2^{-53}$ en $x \circledast y = \text{fl}(x * y)$.

Definitie: Een algoritme $\tilde{f}$ voor een probleem f van $\mathbb{C}^n$ naar $\mathbb{C}^m$ is **stabiël** voor elke $x \in \mathbb{C}^n$ indien

$$\frac{\|\tilde{f}(x) - f(\tilde{x})\|}{\|f(\tilde{x})\|} = O(\epsilon_{\text{machine}}),$$

voor een bepaalde $\tilde{x}$ waarvoor geldt dat

$$\frac{\|\tilde{x} - x\|}{\|x\|} = O(\epsilon_{\text{machine}}).$$

Stabiël: "Ongeveer juiste uitkomst voor ongeveer juiste input"

Er bestaat een constante $C_1 > 0$ en $\epsilon_1 > 0$ zodat voor alle $\epsilon_{\text{machine}} \leq \epsilon_1$ geldt

$$\|\tilde{f}(x) - f(\tilde{x})\| \leq C_1 \epsilon_{\text{machine}} \|f(\tilde{x})\|.$$

Analoog moet er een $C_2 > 0$ en $\epsilon_2 > 0$ bestaan zodat

$$\|\tilde{x} - x\| \leq C_2 \epsilon_{\text{machine}} \|x\|,$$

voor alle $\epsilon_{\text{machine}} \leq \epsilon_2$. De constanten C_1, C_2, ϵ_1 en ϵ_2 moeten tevens geldig zijn voor alle $x \in \mathbb{C}^n$.

Oneindige reeks machines met $\epsilon_{\text{machine}} \rightarrow 0$, dan $g(x) = O(\epsilon_{\text{machine}})$ als $g(x)$ minstens even snel naar nul als $\epsilon_{\text{machine}}$

Is big-O wel gepast?

- C_1 (en C_2) mag groot zijn. Als $C_1 = 2^{100}$ en $\epsilon_{\text{machine}} = 2^{-52}$ dan is $C_1 \epsilon_{\text{machine}}$ erg groot! Geen garantie op nauwkeurig resultaat.
- Definitie is zeker zinvol als C_1 en C_2 klein.
- C_1 en C_2 zijn norm en dimensie afhankelijk. Moeten gelden voor alle x , soms uitzonderlijk grote C_1 en C_2 nodig voor uiterst zeldzame x (zie Gauss eliminatie met gedeeltelijke pivotering)
- Door big-O is definitie norm onafhankelijk

Een algoritme $\tilde{f}$ voor een probleem f van $\mathbb{C}^n$ naar $\mathbb{C}^m$ is **achterwaarts stabiel** voor elke $x \in \mathbb{C}^n$ indien $\tilde{f}(x) = f(\tilde{x})$ voor een bepaalde $\tilde{x}$ waarvoor geldt dat

$$\frac{\|\tilde{x} - x\|}{\|x\|} = O(\epsilon_{\text{machine}}).$$

Maw er bestaat C en ϵ , zodat $\|x - \tilde{x}\| / \|x\| \leq C \epsilon_{\text{machine}}$ voor $\epsilon_{\text{machine}} \leq \epsilon$

Achterwaartse Stabiel: "Exacte uitkomst voor ongeveer juiste input"

Stelling: Laat $\tilde{f}$ een achterwaarts stabiel algoritme zijn voor een probleem f van $\mathbb{C}^n$ naar $\mathbb{C}^m$ dan

$$\frac{\|\tilde{f}(x) - f(x)\|}{\|f(x)\|} = O(\kappa(x) \epsilon_{\text{machine}}).$$

Bewijs: Per definitie van de achterwaartse stabiteit bestaat er voor elke $x \in \mathbb{C}^n$ een $\tilde{x}$ en een ϵ zodat $\tilde{f}(x) = f(\tilde{x})$ met

$$\frac{\|\tilde{x} - x\|}{\|x\|} = O(\epsilon_{\text{machine}}).$$

Uit de definitie absolute conditiegetal $\hat{\kappa}(x)$ (met $\tilde{x} = x + \delta x$)

$$\|f(\tilde{x}) - f(x)\| \leq \hat{\kappa}(x) \|\tilde{x} - x\| + o(\|\tilde{x} - x\|).$$

Daar $\kappa(x) = \hat{\kappa}(x) \|x\| / \|f(x)\|$ en $\tilde{f}(x) = f(\tilde{x})$, zien we dat

$$\|\tilde{f}(x) - f(x)\| \leq \kappa(x) \|f(x)\| \frac{\|\tilde{x} - x\|}{\|x\|} + o(\|\tilde{x} - x\|).$$

Er bestaat dus een $C > 0$ en een $\epsilon > 0$ zodat voor $\epsilon_{\text{machine}} \leq \epsilon$ en x vast

$$\frac{\|\tilde{f}(x) - f(x)\|}{\|f(x)\|} \leq \kappa(x) C \epsilon_{\text{machine}} + o(\epsilon_{\text{machine}} \frac{\|x\|}{\|f(x)\|}) = O(\kappa(x) \epsilon_{\text{machine}}).$$

Merk op, daar de constante in de big-O notatie onafhankelijk moet zijn van x mogen we niet stellen dat $\|\tilde{f}(x) - f(x)\| / \|f(x)\| = O(\epsilon_{\text{machine}})$.

(1) Floating point operaties: De vier algoritmen $\tilde{f}(x, y) = \text{fl}(x) \circledast \text{fl}(y)$ met $\circledast = \oplus, \ominus, \otimes, \odiv$ voor de problemen $f(x, y) = x * y$ zijn achterwaarts stabiel:

(a) Voor de optelling geldt

$$\text{fl}(x) \oplus \text{fl}(y) = (x(1 + \epsilon_1) + y(1 + \epsilon_2))(1 + \epsilon_3), \quad |\epsilon_i| \leq \epsilon_{\text{machine}}.$$

Dus $\tilde{f}(x, y) = f(\tilde{x}, \tilde{y})$ met $\tilde{x} = x(1 + \epsilon_1)(1 + \epsilon_3)$ en $\tilde{y} = y(1 + \epsilon_2)(1 + \epsilon_3)$, zodat

$$|\tilde{x} - x|/|x| = |\epsilon_1 + \epsilon_3 + \epsilon_1\epsilon_3| = O(\epsilon_{\text{machine}}).$$

$$|\tilde{y} - y|/|y| = |\epsilon_2 + \epsilon_3 + \epsilon_2\epsilon_3| = O(\epsilon_{\text{machine}}).$$

(b) Hetzelfde geldt voor $\ominus, \otimes$ en $\odiv$:

$$\text{fl}(x) \odiv \text{fl}(y) = \frac{x(1+\epsilon_1)}{y(1+\epsilon_2)}(1 + \epsilon_3),$$

met $\tilde{x} = x(1 + \epsilon_1)(1 + \epsilon_3)$ en $\tilde{y} = y(1 + \epsilon_2)$ en

$$\text{fl}(x) \otimes \text{fl}(y) = x(1 + \epsilon_1)y(1 + \epsilon_2)(1 + \epsilon_3).$$

met $\tilde{x} = x(1 + \epsilon_1)$ en $\tilde{y} = y(1 + \epsilon_2)(1 + \epsilon_3)$.

(2) Plus één: Stel $f(x) = x + 1$ en $\tilde{f}(x) = \text{fl}(x) \oplus 1$, dan

$$\text{fl}(x) \oplus 1 = x(1 + \epsilon_1)(1 + \epsilon_2) + (1 + \epsilon_2),$$

dus $\tilde{f}(x) = f(\tilde{x})$ met $\tilde{x} = x(1 + \epsilon_1)(1 + \epsilon_2) + \epsilon_2$. De relatieve fout

$$|\tilde{x} - x|/|x| = |\epsilon_1 + \epsilon_2 + \epsilon_1\epsilon_2 + \epsilon_2/x| \neq O(\epsilon_{\text{machine}})$$

door de term $\epsilon_2/|x|$. Bijgevolg is $\tilde{f}(x)$ niet achterwaarts stabiel voor alle x . Wanneer we x niet in de buurt van 0 nemen, bv $|x| \geq 1/2$, dan is $\tilde{f}(x)$ achterwaarts stabiel, want

$$|\tilde{x} - x|/|x| \leq |\epsilon_1 + \epsilon_2 + \epsilon_1\epsilon_2 + 2\epsilon_2| = O(\epsilon_{\text{machine}}).$$

Voor $|x| \leq 1/2$ kunnen we wel stabiliteit aantonen: neem

$\tilde{x} = x(1 + \epsilon_1)(1 + \epsilon_2)$, dan $|\tilde{x} - x|/|x| = |\epsilon_1 + \epsilon_2 + \epsilon_1\epsilon_2| = O(\epsilon_{\text{machine}})$ en

$$|\tilde{f}(x) - f(\tilde{x})|/|f(\tilde{x})| = |\epsilon_2|/|1 + \tilde{x}| \leq 2|\epsilon_2| = O(\epsilon_{\text{machine}}).$$

Hetzelfde geldt voor $f(x) = x + a$ met $a \neq 0$.

(3) Inwendig en uitwendig product: Voor $x, y \in \mathbb{R}^n$ is het inwendig product $\tilde{f}(x, y) = \bigoplus_{i=1}^n (\text{fl}(x_i) \otimes \text{fl}(y_i))$ achterwaarts stabiel (zie oefeningen).

Het uitwendig product $a_{ij} = x_i y_j$ niet:

$$\tilde{f}(x, y) = \begin{bmatrix} \bar{x}_1 \bar{y}_1 (1 + \epsilon_5) & \bar{x}_1 \bar{y}_2 (1 + \epsilon_6) \\ \bar{x}_2 \bar{y}_1 (1 + \epsilon_7) & \bar{x}_2 \bar{y}_2 (1 + \epsilon_8) \end{bmatrix},$$

met

$$\bar{x}_1 = x_1(1 + \epsilon_1), \bar{x}_2 = x_2(1 + \epsilon_2), \bar{y}_1 = y_1(1 + \epsilon_3), \bar{y}_2 = y_2(1 + \epsilon_4).$$

Omdat de fouttermen niet uniform zijn, is $\tilde{f}(x, y)$ meestal geen rang-één matrix: het algoritme is dus niet achterwaarts stabiel (maar wel stabiel).

Algemeen: als $\tilde{f} : \mathbb{R}^n \rightarrow \mathbb{R}^m$ met $m > n$, dan is $\tilde{f}$ vaak niet achterwaarts stabiel.

(4) Sinus en cosinus: (a) Voor $f(x) = \cos x$ geldt via de Taylorreeks

$$\cos x = 1 - x^2/2! + x^4/4! - \dots = 1 + g(x), \quad g(x) = o(x).$$

Een algoritme $\tilde{f}(x) = 1 \oplus \tilde{g}(x)$ vertoont dus hetzelfde probleem als bij **Plus één** en is dus niet achterwaarts stabiel. Algemeen: als $f(0) \neq 0$, dan is achterwaartse stabiliteit meestal niet haalbaar in 0.

(b) Voor $f(x) = \sin x$ (met $\sin 0 = 0$) lijkt de situatie gunstiger. Zelfs indien we erin slagen dat

$$\tilde{f}(x) = \text{fl}(f(x)) = f(x)(1 + \epsilon)$$

met $|\epsilon| \leq \epsilon_{\text{machine}}$, volgt uit

$$\tilde{f}(x) = f(\tilde{x}) \quad \xRightarrow{\text{Taylor reeks}} \quad |x - \tilde{x}| \approx \left| \frac{f(x) - \tilde{f}(x)}{f'(x)} \right| = O\left(\epsilon_{\text{machine}} \frac{|f(x)|}{|f'(x)|}\right).$$

Voor $f(x) = \sin x$ hebben we $|x - \tilde{x}| \approx O(\epsilon_{\text{machine}} \tan x)$. Nemen we nu $x = \frac{\pi}{2} + k\pi$, dan $|x - \tilde{x}|/|x|$ oneindig in deze punten en het algoritme is niet achterwaarts stabiel nabij deze x .

Algemeen: indien $f'(x) = 0$ kan achterwaartse stabiliteit verloren gaan, maar niet altijd. Voor $f(x) = x^2$ is $f'(0) = 0$, maar hier $|x - \tilde{x}| = O(\epsilon_{\text{machine}} |x|/2)$, waardoor we wel achterwaartse stabiliteit hebben.

Lineair stelsel:

$$\begin{bmatrix} r_{11} & r_{12} & \dots & r_{1m} \\ & r_{22} & & \vdots \\ & & \ddots & \vdots \\ 0 & & & r_{mm} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix},$$

met $b \in \mathbb{C}^m$ en $R \in \mathbb{C}^{m,m}$.

Achterwaartse substitutie: Voor $j = m, \dots, 1$:

$$x_j = \left(b_j - \sum_{k=j+1}^m x_k r_{jk} \right) / r_{jj}$$

Tonen dat de numerieke oplossing $\tilde{x}$ voldoet aan $(R + \delta R)\tilde{x} = b$ met δR een bovendriehoeksmatrix met $\|\delta R\| = O(\epsilon_{\text{machine}}) \|R\|$. In het bijzonder geldt voor elke i, j dat

$$|\delta r_{ij}| \leq (m\epsilon_{\text{machine}} + O(\epsilon_{\text{machine}}^2)) |r_{ij}|.$$

Merk op, deze laatste uitdrukking geeft aan dat $\|\delta R\| = O(\epsilon_{\text{machine}}) \|R\|$ voor de F_1 -norm. We nemen aan dat r_{ij} en b_j floats zijn.

m = 1: $\tilde{x}_1 = \text{fl}(b_1) \odiv \text{fl}(r_{11}) = b_1 \odiv r_{11}$, dus

$$\tilde{x}_1 = \frac{b_1}{r_{11}}(1 + \epsilon_1),$$

met $|\epsilon_1| \leq \epsilon_{\text{machine}} \cdot r_{11}$ perturberen: factor in noemer ipv teller. Trucje:

$$1 + \epsilon_1 = \frac{1}{1 + \epsilon'_1} \Leftrightarrow \epsilon'_1 = -\frac{\epsilon_1}{1 + \epsilon_1} = -\epsilon_1 \sum_{i=0}^{\infty} (-\epsilon_1)^i = -\epsilon_1 + O(\epsilon_{\text{machine}}^2).$$

Bijgevolg is

$$\tilde{x}_1 = \frac{b_1}{r_{11}(1 + \epsilon'_1)},$$

met $|\epsilon'_1| \leq \epsilon_{\text{machine}} + O(\epsilon_{\text{machine}}^2)$. Met andere woorden $(r_{11} + \delta r_{11})\tilde{x}_1 = b_1$ en $\delta r_{11} = r_{11}\epsilon'_1$, waardoor

$$|\delta r_{11}| \leq (\epsilon_{\text{machine}} + O(\epsilon_{\text{machine}}^2)) |r_{11}|.$$

m = 2: De eerste stap is analoog als het geval $m = 1$, kortom

$$\tilde{x}_2 = \frac{b_2}{r_{22}(1 + \epsilon_1)},$$

met $|\epsilon_1| \leq \epsilon_{\text{machine}} + O(\epsilon_{\text{machine}}^2)$.

Verder

$$\tilde{x}_1 = (b_1 \ominus (\tilde{x}_2 \otimes r_{12})) \oslash r_{11}$$

dus

$$\tilde{x}_1 = \frac{(b_1 - \tilde{x}_2 r_{12} (1 + \epsilon_2)) (1 + \epsilon_3)}{r_{11} (1 + \epsilon_4)},$$

met $|\epsilon_2|, |\epsilon_3|, |\epsilon_4| \leq \epsilon_{\text{machine}}$.

Twee maal trucje:

$$\tilde{x}_1 = \frac{b_1 - \tilde{x}_2 r_{12} (1 + \epsilon_2)}{r_{11} (1 + \epsilon'_3) (1 + \epsilon'_4)},$$

met $|\epsilon'_3|, |\epsilon'_4| \leq \epsilon_{\text{machine}} + O(\epsilon_{\text{machine}}^2)$. Vereenvoudigen tot

$$\tilde{x}_1 = \frac{b_1 - \tilde{x}_2 r_{12} (1 + \epsilon_2)}{r_{11} (1 + 2\epsilon_5)},$$

met $|\epsilon_5| \leq \epsilon_{\text{machine}} + O(\epsilon_{\text{machine}}^2)$. Kortom, wanneer we r_{11} , r_{12} en r_{22} vervangen door $r_{11}(1 + 2\epsilon_5)$, $r_{12}(1 + \epsilon_2)$ en $r_{22}(1 + \epsilon_1)$ dan is $\tilde{x}$ een exacte oplossing, d.i., $(R + \delta R)\tilde{x} = b$ met

$$\begin{bmatrix} |\delta r_{11}|/|r_{11}| & |\delta r_{12}|/|r_{12}| \\ 0 & |\delta r_{22}|/|r_{22}| \end{bmatrix} \leq \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix} \epsilon_{\text{machine}} + O(\epsilon_{\text{machine}}^2).$$

m = 3: De eerste twee stappen zijn analoog aan het geval $m = 2$:

$$\begin{aligned}\tilde{x}_3 &= \frac{b_3}{r_{33}(1 + \epsilon_1)}, \\ \tilde{x}_2 &= \frac{b_2 - \tilde{x}_3 r_{23}(1 + \epsilon_2)}{r_{22}(1 + 2\epsilon_3)},\end{aligned}$$

met

$$\begin{bmatrix} 2|\epsilon_3| & 1|\epsilon_2| \\ 0 & 1|\epsilon_1| \end{bmatrix} \leq \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix} \epsilon_{\text{machine}} + O(\epsilon_{\text{machine}}^2).$$

Verder

$$\tilde{x}_1 = [(b_1 \ominus (\tilde{x}_2 \otimes r_{12})) \ominus (\tilde{x}_3 \otimes r_{13})] \oslash r_{11}$$

dus

$$\tilde{x}_1 = \frac{[(b_1 - \tilde{x}_2 r_{12}(1 + \epsilon_4))(1 + \epsilon_6) - \tilde{x}_3 r_{13}(1 + \epsilon_5)](1 + \epsilon_7)}{r_{11}(1 + \epsilon_8)},$$

met $|\epsilon_i| \leq \epsilon_{\text{machine}}$ voor $i = 4, \dots, 8$.

Twee maal trucje:

$$\tilde{x}_1 = \frac{(b_1 - \tilde{x}_2 r_{12}(1 + \epsilon_4))(1 + \epsilon_6) - \tilde{x}_3 r_{13}(1 + \epsilon_5)}{r_{11}(1 + \epsilon'_7)(1 + \epsilon'_8)},$$

met $|\epsilon'_7|, |\epsilon'_8| \leq \epsilon_{\text{machine}} + O(\epsilon_{\text{machine}}^2)$.

Probleem: de term $b_1(1 + \epsilon_6)$. Oplossing: Trucje op $(1 + \epsilon_6)$

$$\tilde{x}_1 = \frac{(b_1 - \tilde{x}_2 r_{12}(1 + \epsilon_4)) - \tilde{x}_3 r_{13}(1 + \epsilon_5)(1 + \epsilon'_6)}{r_{11}(1 + \epsilon'_6)(1 + \epsilon'_7)(1 + \epsilon'_8)}.$$

Kortom, $\tilde{x}$ is de exacte oplossing van $(R + \delta R)\tilde{x} = b$ met

$$\begin{bmatrix} |\delta r_{11}|/|r_{11}| & |\delta r_{12}|/|r_{12}| & |\delta r_{13}|/|r_{13}| \\ & |\delta r_{22}|/|r_{22}| & |\delta r_{23}|/|r_{23}| \\ & & |\delta r_{33}|/|r_{33}| \end{bmatrix} \leq \begin{bmatrix} 3 & 1 & 2 \\ & 2 & 1 \\ & & 1 \end{bmatrix} \epsilon_{\text{machine}} + O(\epsilon_{\text{machine}}^2).$$

m > 3: In het algemene geval verloopt alles gelijkaardig als voor $m = 3$, waardoor men kan tonen dat $\tilde{x}$ de oplossing is van $(R + \delta R)\tilde{x} = b$ waarbij $|\delta r_{ij}| / |r_{ij}|$ begrensd wordt door het (i, j) -de element van onderstaande matrix (voor $m = 5$):

$$\begin{bmatrix} 5 & 1 & 2 & 3 & 4 \\ & 4 & 1 & 2 & 3 \\ & & 3 & 1 & 2 \\ & & & 2 & 1 \\ & & & & 1 \end{bmatrix} \epsilon_{\text{machine}} + O(\epsilon_{\text{machine}}^2).$$

Dit patroon komt als volgt tot stand. De vermenigvuldigingen $\tilde{x}_k r_{jk}$ veroorzaken $\epsilon_{\text{machine}}$ perturbaties volgens het patroon

$$\otimes : \begin{bmatrix} 0 & 1 & 1 & 1 & 1 \\ & 0 & 1 & 1 & 1 \\ & & 0 & 1 & 1 \\ & & & 0 & 1 \\ & & & & 0 \end{bmatrix}.$$

De delingen door r_{kk} resulteren in $\epsilon_{\text{machine}} + O(\epsilon_{\text{machine}}^2)$ perturbaties op de diagonaal

$$\odot : \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ & 1 & 0 & 0 & 0 \\ & & 1 & 0 & 0 \\ & & & 1 & 0 \\ & & & & 1 \end{bmatrix}.$$

Terwijl de verschillen (doordat we deze van links naar rechts uitvoerde) resulteren in

$$\ominus : \begin{bmatrix} 4 & 0 & 1 & 2 & 3 \\ & 3 & 0 & 1 & 2 \\ & & 2 & 0 & 1 \\ & & & 1 & 0 \\ & & & & 0 \end{bmatrix}.$$

Andere volgorde bewerkingen: Stel $\tilde{s} = \bigoplus_{k=j+1}^m (\tilde{x}_k \otimes r_{jk})$, dan $\tilde{x}_j = (b_j \ominus \tilde{s}) \oslash r_{jj}$.

m=3:

$$\tilde{x}_1 = [b_1 \ominus \{(\tilde{x}_2 \otimes r_{12}) \oplus (\tilde{x}_3 \otimes r_{13})\}] \oslash r_{11}$$

dus

$$\tilde{x}_1 = \frac{[b_1 - \{\tilde{x}_2 r_{12} (1 + \epsilon_4) + \tilde{x}_3 r_{13} (1 + \epsilon_5)\} (1 + \epsilon_6)] (1 + \epsilon_7)}{r_{11}} (1 + \epsilon_8),$$

met $|\epsilon_i| \leq \epsilon_{\text{machine}}$ voor $i = 4, \dots, 8$. Twee maal trucje:

$$\tilde{x}_1 = \frac{[b_1 - \{\tilde{x}_2 r_{12} (1 + \epsilon_4) + \tilde{x}_3 r_{13} (1 + \epsilon_5)\} (1 + \epsilon_6)]}{r_{11} (1 + \epsilon'_7) (1 + \epsilon'_8)},$$

Meteen exacte oplossing wanneer we r_{11} , r_{12} en r_{13} vervangen door $r_{11} (1 + \epsilon'_7) (1 + \epsilon'_8)$, $r_{12} (1 + \epsilon_4) (1 + \epsilon_6)$ en $r_{13} (1 + \epsilon_5) (1 + \epsilon_6)$.

Dan:

$$\otimes : \begin{bmatrix} 0 & 1 & 1 & 1 & 1 \\ & 0 & 1 & 1 & 1 \\ & & 0 & 1 & 1 \\ & & & 0 & 1 \\ & & & & 0 \end{bmatrix} . \oslash : \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ & 1 & 0 & 0 & 0 \\ & & 1 & 0 & 0 \\ & & & 1 & 0 \\ & & & & 1 \end{bmatrix} .$$

en

$$\oplus : \begin{bmatrix} 0 & 3 & 3 & 2 & 1 \\ & 0 & 2 & 2 & 1 \\ & & 0 & 1 & 1 \\ & & & 0 & 0 \\ & & & & 0 \end{bmatrix} . \ominus : \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ & 1 & 0 & 0 & 0 \\ & & 1 & 0 & 0 \\ & & & 1 & 0 \\ & & & & 0 \end{bmatrix} .$$

Laat $Q \in \mathbb{C}^{m,m}$ een unitaire matrix zijn en $A \in \mathbb{C}^{m,n}$, dan bestaat er een $\delta A \in \mathbb{C}^{m,n}$ zodat $\widetilde{QA} = Q(A + \delta A)$ met $\|\delta A\| = \|A\| O(\epsilon_{\text{machine}})$.

Bewijs: Stel $\widetilde{QA} = Q(A + \delta A)$. We tonen dat $\|\delta A\|_2 = \|A\|_2 O(\epsilon_{\text{machine}})$.
Aangezien $\delta A = Q^* \widetilde{QA} - A = Q^*(\widetilde{QA} - QA)$, hebben we

$$\|\delta A\|_2 = \|\widetilde{QA} - QA\|_2.$$

We kunnen eenvoudig tonen dat (zie oefening scalair product)

$$\oplus_{k=1}^m (\text{fl}(q_{ik}) \otimes \text{fl}(a_{kj})) = \sum_k q_{ik} a_{kj} (1 + mO(\epsilon_{\text{machine}})).$$

Kortom, de absolute waarde van het (i,j) -de element van $\widetilde{QA} - QA$ is begrensd door

$$\left| \sum_k q_{ik} a_{kj} \right| mO(\epsilon_{\text{machine}}) \leq \sum_k |q_{ik}| |a_{kj}| mO(\epsilon_{\text{machine}}) \leq \sum_k |a_{kj}| mO(\epsilon_{\text{machine}}),$$

$mO(\epsilon_{\text{machine}})(\sum_k |a_{kj}|)$ daar $|q_{ik}| \leq 1$ (want Q is unitair). Verder

$$\begin{aligned} mO(\epsilon_{\text{machine}}) \left(\sum_k |a_{kj}| \right) &\leq mO(\epsilon_{\text{machine}}) \left(\sum_{k,j} |a_{kj}| \right) \\ &= mO(\epsilon_{\text{machine}}) \|A\|_{F_1} \\ &= mO(\epsilon_{\text{machine}}) \|A\|_2, \end{aligned}$$

daar alle matrixnormen equivalent zijn. Bijgevolg is

$$\|\delta A\|_2 = \|\widetilde{QA} - QA\|_2 \leq K \|\widetilde{QA} - QA\|_{F_1} \leq m^3 O(\epsilon_{\text{machine}}) \|A\|_2,$$

voor een bepaalde constante K , die mogelijk ook afhankelijk is van m , waardoor het bewijs compleet is.

Laat $Q_1, \dots, Q_k \in \mathbb{C}^{m,m}$ unitaire matrices zijn en $A \in \mathbb{C}^{m,n}$, dan bestaat er een $\delta A \in \mathbb{C}^{m,n}$ zodat $\widetilde{Q_k \dots Q_1 A} = Q_k \dots Q_1 (A + \delta A)$ met $\|\delta A\| = \|A\| O(\epsilon_{\text{machine}})$.

Bewijs: Per inductie op k . Voor $k = 1$: voorgaande eigenschap.

Stel $B = Q_k \dots Q_1 A$ en $\tilde{B} = Q_k \dots Q_1 (A + \delta A_k)$

$$\|\delta A_k\|_2 = O(\epsilon_{\text{machine}}) \|A\|_2,$$

per inductie.

We moeten tonen dat $\widetilde{Q_{k+1} \tilde{B}} = Q_{k+1} Q_k \dots Q_1 (A + \delta A)$ voor een δA met $\|\delta A\|_2 = O(\epsilon_{\text{machine}}) \|A\|_2$.

Uit de voorgaande eigenschap weten we dat $\widetilde{Q_{k+1} \tilde{B}} = Q_{k+1} (\tilde{B} + \delta \tilde{B})$ met

$$\begin{aligned} \|\delta \tilde{B}\|_2 &= O(\epsilon_{\text{machine}}) \|\tilde{B}\|_2 = O(\epsilon_{\text{machine}}) \|A + \delta A_k\|_2 \\ &\leq O(\epsilon_{\text{machine}}) (\|A\|_2 + \|\delta A_k\|_2) = O(\epsilon_{\text{machine}}) \|A\|_2. \end{aligned}$$

Verder is

$$\begin{aligned} \widetilde{Q_{k+1} \tilde{B}} &= Q_{k+1} (\tilde{B} + \delta \tilde{B}) \\ &= Q_{k+1} (Q_k \dots Q_1 (A + \delta A_k) + \delta \tilde{B}) \\ &= Q_{k+1} Q_k \dots Q_1 (A + \delta A_k + Q_1^* \dots Q_k^* \delta \tilde{B}). \end{aligned}$$

Door $\delta A = \delta A_k + Q_1^* \dots Q_k^* \delta \tilde{B}$ bekomen we het gevraagde daar

$$\|\delta A\|_2 \leq \|\delta A_k\|_2 + \|\delta \tilde{B}\|_2 = O(\epsilon_{\text{machine}}) \|A\|_2.$$

Numerieke Lineaire Algebra

LU factorisatie

Gebaseerd op cursusnotities van Benny VH

Gegeven $A \in \mathbb{C}^{m,m}$. Zoeken L, U zodat

$$A = LU,$$

met $L \in \mathbb{C}^{m,m}$ een benedendriehoeksmatrix en $U \in \mathbb{C}^{m,m}$ een bovendriehoeksmatrix:

$$A = \begin{bmatrix} \times & \times & \times & \times \\ \times & \times & \times & \times \\ \times & \times & \times & \times \\ \times & \times & \times & \times \end{bmatrix} = \underbrace{\begin{bmatrix} \times & 0 & 0 & 0 \\ \times & \times & 0 & 0 \\ \times & \times & \times & 0 \\ \times & \times & \times & \times \end{bmatrix}}_L \underbrace{\begin{bmatrix} \times & \times & \times & \times \\ 0 & \times & \times & \times \\ 0 & 0 & \times & \times \\ 0 & 0 & 0 & \times \end{bmatrix}}_U$$

Methode (Gauss eliminatie zonder pivoting): Bepalen $L_1 \in \mathbb{C}^{m,m}$ zodat :

$$L_1 A = \begin{bmatrix} \times & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \end{bmatrix}.$$

Daarna bepalen we $L_2 \in \mathbb{C}^{m,m}$ zodat

$$L_2 L_1 A = \begin{bmatrix} \times & \times & \times & \times & \times \\ 0 & \times & \times & \times & \times \\ 0 & 0 & \times & \times & \times \\ 0 & 0 & \times & \times & \times \\ 0 & 0 & \times & \times & \times \end{bmatrix}.$$

Herhalen we tot we de matrices $L_1, \dots, L_{m-1}$ hebben bepaald zodat

$$U = L_{m-1} \dots L_2 L_1 A,$$

een bovendriehoeksmatrix is. Hieruit volgt

$$A = \underbrace{L_1^{-1} L_2^{-1} \dots L_{m-1}^{-1}}_L U.$$

Stap 1: Laat $x_1 = (x_{11}, \dots, x_{m1})^T$ eerste kolom zijn van A met $x_{11} \neq 0$, dan

$$\underbrace{\begin{bmatrix} 1 & & & & \\ -x_{21}/x_{11} & 1 & & & \\ -x_{31}/x_{11} & & 1 & & \\ \vdots & & & \ddots & \\ -x_{m1}/x_{11} & & & & 1 \end{bmatrix}}_{L_1} A = \begin{bmatrix} \times & \times & \times & \dots & \times \\ 0 & \times & \times & \dots & \times \\ 0 & \times & \times & \dots & \times \\ \vdots & \vdots & \vdots & \ddots & \times \\ 0 & \times & \times & \times & \times \end{bmatrix} = A_2.$$

Namelijk door $-x_{i1}/x_{11}$ keer de eerste rij van A op te tellen bij de i -de rij van A krijgen we een nul in de eerste positie.

Stap 2: Laat $x_2 = (x_{12}, \dots, x_{m2})^T$ de 2-de kolom van $A_2 = L_1 A$ zijn, dan

$$L_2 A_2 = \begin{bmatrix} 1 & & & & \\ & 1 & & & \\ -x_{32}/x_{22} & 1 & & & \\ \vdots & & \ddots & & \\ -x_{m2}/x_{22} & & & 1 & \end{bmatrix} A_2 = \begin{bmatrix} \times & \times & \times & \dots & \times \\ 0 & \times & \times & \dots & \times \\ 0 & 0 & \times & \dots & \times \\ \vdots & \vdots & \vdots & \ddots & \times \\ 0 & 0 & \times & \times & \times \end{bmatrix} = A_3.$$

Door $-x_{i2}/x_{22}$ keer de tweede rij van A_2 op te tellen bij de i -de rij van A_2 krijgen we eveneens een nul in de tweede positie.

Stap k: Laat $x_k = (x_{k1}, \dots, x_{mk})^T$ de k -de kolom van $A_k = L_{k-1} \dots L_1 A$ en stel $\ell_{ik} = x_{ik}/x_{kk}$ dan

$$L_k = \begin{bmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -\ell_{k+1,k} & 1 & \\ & & \vdots & & \ddots \\ & & -\ell_{mk} & & & 1 \end{bmatrix}.$$

Zodat $A_{k+1} = L_k A_k = L_k \dots L_1 A$ nullen bevat onder de hoofddiagonaal in de eerste k kolommen. Bijgevolg is

$$A_m = L_{m-1} \dots L_1 A = U$$

is een bovendriehoeksmatrix

Compactie notatie L_k : Laat $\ell_k = (0, \dots, 0, \ell_{k+1,k}, \dots, \ell_{mk})^T$ dan

$$L_k = I - \ell_k \mathbf{e}_k^*.$$

Stelling: $L_k^{-1} = I + \ell_k \mathbf{e}_k^*.$

Bewijs: Door op te merken dat $\mathbf{e}_k^* \ell_k = 0$ zien we dat

$$(I - \ell_k \mathbf{e}_k^*)(I + \ell_k \mathbf{e}_k^*) = I - \ell_k \mathbf{e}_k^* + \ell_k \mathbf{e}_k^* - \ell_k \underbrace{\mathbf{e}_k^* \ell_k}_0 \mathbf{e}_k^* = I$$

Stelling: $L_1^{-1} \dots L_k^{-1} = I + \sum_{i=1}^k \ell_i \mathbf{e}_i^*.$

Bewijs: Per inductie op k (voor $k = 1$ is vorige eigenschap). Voor $k + 1$:

$$\begin{aligned} \left(\prod_{i=1}^k L_i^{-1} \right) L_{k+1}^{-1} &= (I + \sum_{i=1}^k \ell_i \mathbf{e}_i^*)(I + \ell_{k+1} \mathbf{e}_{k+1}^*) \\ &= I + \sum_{i=1}^k \ell_i \mathbf{e}_i^* + \ell_{k+1} \mathbf{e}_{k+1}^* + \sum_{i=1}^k \ell_i \underbrace{\mathbf{e}_i^* \ell_{k+1}}_0 \mathbf{e}_{k+1}^* \\ &= I + \sum_{i=1}^{k+1} \ell_i \mathbf{e}_i^*, \end{aligned}$$

Besluit:

$$L = L_1^{-1} \dots L_{m-1}^{-1} = I + \sum_{i=1}^{m-1} \ell_i \mathbf{e}_i^* = \begin{bmatrix} 1 & & & & \\ \ell_{21} & 1 & & & \\ \vdots & \ddots & \ddots & & \\ \ell_{i,1} & \dots & \ell_{i,i-1} & 1 & \\ \vdots & \ddots & \vdots & \ddots & \ddots \\ \ell_{m1} & \dots & \ell_{mk} & \dots & \ell_{m,m-1} & 1 \end{bmatrix},$$

Voorbeeld:

$$A = \begin{bmatrix} 4 & 1 & 1 & 1 \\ 1 & 4 & 1 & 1 \\ 1 & 1 & 4 & 1 \\ 1 & 1 & 1 & 4 \end{bmatrix}$$

Stap 1: $x_1 = (4, 1, 1, 1)^T$ en

$$L_1 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ -\frac{1}{4} & 1 & 0 & 0 \\ -\frac{1}{4} & 0 & 1 & 0 \\ -\frac{1}{4} & 0 & 0 & 1 \end{bmatrix}, \quad A_2 = L_1 A = \begin{bmatrix} 4 & 1 & 1 & 1 \\ 0 & \frac{15}{4} & \frac{3}{4} & \frac{3}{4} \\ 0 & \frac{3}{4} & \frac{15}{4} & \frac{3}{4} \\ 0 & \frac{3}{4} & \frac{3}{4} & \frac{15}{4} \end{bmatrix}.$$

Stap 2: $x_2 = (1, 15/4, 3/4, 3/4)^T$ en

$$L_2 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & -\frac{1}{5} & 1 & 0 \\ 0 & -\frac{1}{5} & 0 & 1 \end{bmatrix}, \quad A_3 = L_2 A_2 = \begin{bmatrix} 4 & 1 & 1 & 1 \\ 0 & \frac{15}{4} & \frac{3}{4} & \frac{3}{4} \\ 0 & 0 & \frac{18}{5} & \frac{3}{5} \\ 0 & 0 & \frac{3}{5} & \frac{18}{5} \end{bmatrix}.$$

Stap 3: $x_3 = (1, 3/4, 18/5, 3/5)^T$ en

$$L_3 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & -\frac{1}{6} & 1 \end{bmatrix}, \quad U = L_3 A_3 = \begin{bmatrix} 4 & 1 & 1 & 1 \\ 0 & \frac{15}{4} & \frac{3}{4} & \frac{3}{4} \\ 0 & 0 & \frac{18}{5} & \frac{3}{5} \\ 0 & 0 & 0 & \frac{7}{2} \end{bmatrix}.$$

Besluit: $A = LU$ met

$$L = L_1^{-1} L_2^{-1} L_3^{-1} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ \frac{1}{4} & 1 & 0 & 0 \\ \frac{1}{4} & \frac{1}{5} & 1 & 0 \\ \frac{1}{4} & \frac{1}{5} & \frac{1}{6} & 1 \end{bmatrix}, \quad U = \begin{bmatrix} 4 & 1 & 1 & 1 \\ 0 & \frac{15}{4} & \frac{3}{4} & \frac{3}{4} \\ 0 & 0 & \frac{18}{5} & \frac{3}{5} \\ 0 & 0 & 0 & \frac{7}{2} \end{bmatrix}.$$

Gauss eliminatie zonder pivoting $\sim 2m^3/3$ flops

$$U = A, L = I$$

for $k = 1$ **to** $m - 1$

$$L_{k+1:m,k} = U_{k+1:m,k} / U_{k,k}$$

$$U_{k+1:m,k:m} = U_{k+1:m,k:m} - L_{k+1:m,k} U_{k,k:m}$$

Stelling: Een matrix $A \in \mathbb{C}^{m,m}$ heeft een LU factorisatie indien $\det(A_{1:k,1:k}) \neq 0$ voor alle $k = 1, \dots, m-1$. Indien A inverteerbaar is, dan bestaat er een unieke LU factorisatie met $L_{ii} = 1$ voor $i \in \{1, \dots, m\}$.

Bewijs: (Existentie) Het volstaat te tonen dat we nooit delen door nul. Dit volgt uit het gegeven omdat

$$\begin{aligned} x_{11}x_{22} \dots x_{kk} &= \det((A_k)_{1:k,1:k}) = \det\left(\prod_{i=1}^k (L_i)_{1:k,1:k} A_{1:k,1:k}\right) \\ &= \prod_{i=1}^k \underbrace{\det((L_i)_{1:k,1:k})}_{=1} \det(A_{1:k,1:k}) \neq 0, \end{aligned}$$

moet gelden na k stappen.

(Uniciteit) Stel A inverteerbaar en $A = L_1 U_1 = L_2 U_2$, dan

$$L_2^{-1} L_1 = U_2 U_1^{-1},$$

waarbij $L_2^{-1} L_1$ een benedendriehoeksmatrix is met alle diagonaalelementen gelijk aan één en $U_2 U_1^{-1}$ is een bovendriehoeksmatrix. Bijgevolg is $L_2^{-1} L_1 = U_2 U_1^{-1} = I$, want aangeeft dat $L_1 = L_2$ en $U_1 = U_2$.

Opmerking: Indien $A = LU$, dan is $L' = LD$ en $U' = D^{-1}U$ eveneens een LU -factorisatie, met D een willekeurige diagonaalmatrix.

Probleem: Los $Ax = b$ op met $A \in \mathbb{C}^{m,m}$ inverteerbaar via LU factorisatie:

$$Ax = b \Leftrightarrow LUx = b,$$

of nog

$$Ly = b, \quad \text{en} \quad Ux = y.$$

Los $Ly = b$ op via voorwaartse substitutie, los $Ux = y$ op via achterwaartse substitutie.

Lineaire stelsels via LU factorisatie

$\sim 2m^3/3$ flops (via Gauss eliminatie)

- 1 Bepaal de LU factorisatie van A .
- 2 Los het stelsel $Ly = b$ op (via voorwaartse substitutie).
- 3 Los het stelsel $Ux = y$ op (via achterwaartse substitutie).

Stelling: Laat $A = LU$ een LU factorisatie zijn van $A \in \mathbb{C}^{m,m}$ en laat $\tilde{L} \in \mathbb{C}^{m,m}$ en $\tilde{U} \in \mathbb{C}^{m,m}$ de output zijn van Gauss eliminatie zonder pivoting met A als input, dan

$$A + \delta A = \tilde{L}\tilde{U},$$

met $\|\delta A\| = O(\epsilon_{\text{machine}}) \|L\| \|U\|$.

Deze eigenschap zou achterwaartse stabiliteit geven indien $\|L\| \|U\| = O(\|A\|)$.

Voorbeeld: Neem

$$A = \begin{bmatrix} 10^{-n} & 1 \\ 1 & 1 \end{bmatrix},$$

met $n \geq 1$ een geheel getal. Dan is $\|A\|_{\infty} = 2$ terwijl

$$A = \begin{bmatrix} 10^{-n} & 1 \\ 1 & 1 \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 0 \\ 10^n & 1 \end{bmatrix}}_L \underbrace{\begin{bmatrix} 10^{-n} & 1 \\ 0 & 1 - 10^n \end{bmatrix}}_U,$$

wat aangeeft dat $\|L\|_{\infty} = 10^n + 1$ en $\|U\|_{\infty} = 10^n - 1$.

$\Rightarrow$ Gauss eliminatie zonder pivoting is niet achterwaarts stabiel.

Definitie: Een matrix $P \in \mathbb{R}^{m,m}$ is een **permutatiematrix** wanneer deze bekomen kan worden door de rijen van de eenheidsmatrix I te permuteren. Wanneer P bekomen werd door slechts twee rijen om te wisselen noemen we P een **verwisseling**.

Voorbeelden:

$$P_a = \begin{bmatrix} 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 \end{bmatrix} \quad \text{en} \quad P_b = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 & 0 \end{bmatrix}.$$

De matrix P_a : permutatie (4, 1, 2, 5, 3) en P_b : permutatie (1, 5, 3, 4, 2).

Voor- en navermenigvuldigen met P geeft

- PA met P permutatie matrix verwisselt rijen van A
- AP met P permutatie matrix verwisselt kolommen van A

Stelling: Een permutatiematrix P is unitair.

Bewijs: De set met de m kolommen van P is dezelfde als de set met de m kolommen van de eenheidsmatrix I . Deze set is duidelijk een orthonormale set. Bijgevolg is P unitair.

Het unitair zijn van P geeft aan dat $|\det(P)| = 1$.

Doel: Deling door nul vermijden indien mogelijk

Stap 1a: Laat $A_1 = A$ en stel x_1 gelijk aan kolom 1 van A_1 . Kies j zodat

$$|x_{j1}| = \max_{i \geq 1} |x_{i1}|,$$

en laat P_1 de verwisseling zijn die element 1 en j omwisselt

Stap 1b: Laat y_1 de eerste kolom zijn van $P_1 A$, stel $\ell_{i1} = y_{i1}/y_{11}$ en

$$L_1 = \begin{bmatrix} 1 & & & & \\ -\ell_{21} & 1 & & & \\ -\ell_{31} & & 1 & & \\ \vdots & & & \ddots & \\ -\ell_{m1} & & & & 1 \end{bmatrix}, \text{ zodat } L_1 P_1 A_1 = \underbrace{\begin{bmatrix} \times & \times & \times & \dots & \times \\ 0 & \times & \times & \dots & \times \\ 0 & \times & \times & \dots & \times \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & \times & \times & \dots & \times \end{bmatrix}}_{A_2}$$

Stap 2a: Stel x_2 gelijk aan kolom 2 van A_2 . Kies j zodat

$$|x_{j2}| = \max_{i \geq 2} |x_{i2}|,$$

en laat P_2 de verwisseling zijn zodat P_2 element 2 en j omwisselt

Stap 2b: Laat y_2 de tweede kolom zijn van $P_2 A_2$ en stel $\ell_{i2} = y_{i2}/y_{22}$ en

$$L_2 = \begin{bmatrix} 1 & & & & \\ & 1 & & & \\ -\ell_{32} & & 1 & & \\ \vdots & & & \ddots & \\ -\ell_{m2} & & & & 1 \end{bmatrix}, \text{ zodat } L_2 P_2 A_2 = \underbrace{\begin{bmatrix} \times & \times & \times & \dots & \times \\ 0 & \times & \times & \dots & \times \\ 0 & 0 & \times & \dots & \times \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \times & \dots & \times \end{bmatrix}}_{A_3}$$

Na Stap (m-1)b: We verkrijgen bovendriehoeksmatrix U :

$$\underbrace{L_{m-1} P_{m-1} \dots L_2 P_2 L_1 P_1}_{\text{geen benedendriehoeksmatrix}} A = U,$$

Stelling: Stel $L'_k = P_{m-1} \dots P_{k+1} L_k P_{k+1}^{-1} \dots P_{m-1}^{-1}$ dan

$$L_{m-1} P_{m-1} \dots L_{k+1} P_{k+1} L_k P_k = L'_{m-1} \dots L'_{k+1} L'_k P_{m-1} \dots P_{k+1} P_k,$$

voor $k = 1, \dots, m-1$.

Bewijs: Voor $k = m-1$: $L'_{m-1} = L_{m-1}$, waardoor de uitspraak klopt. Stel waar voor $k+1$ dan, per inductie

$$\begin{aligned} L_{m-1} P_{m-1} \dots L_{k+1} P_{k+1} L_k P_k &= L'_{m-1} \dots L'_{k+1} P_{m-1} \dots P_{k+1} L_k P_k \\ &= L'_{m-1} \dots L'_{k+1} \underbrace{P_{m-1} \dots P_{k+1} L_k P_{k+1}^{-1} \dots P_{m-1}^{-1}}_{L'_k} P_{m-1} \dots P_{k+1} P_k \end{aligned}$$

Wanneer we dit gebruiken voor $k = 1$, dan kunnen we

$$L_{m-1} P_{m-1} \dots L_2 P_2 L_1 P_1 A = U,$$

herschrijven als

$$L'_{m-1} \dots L'_2 L'_1 P_{m-1} \dots P_2 P_1 A = U,$$

of nog

$$\underbrace{P_{m-1} \dots P_2 P_1}_P A = \underbrace{(L'_1)^{-1} \dots (L'_{m-1})^{-1}}_L U,$$

waarbij L een benedendriehoeksmatrix is.

Merk op dat $L'_k = P_{m-1} \dots P_{k+1} L_k P_{k+1}^{-1} \dots P_{m-1}^{-1}$ identiek is aan L_k behalve dat de elementen $\ell_{k+1,k}, \dots, \ell_{m,k}$ herschikt zijn door de permutatie die overeenstemt met $P_{m-1} \dots P_{k+1}$.

Bijvoorbeeld: Stel $m = 3$ en P_2 verwisselt element 2 en 3 dan

$$\underbrace{P_2 L_1 P_2^{-1}}_{L'_1} = P_2 \begin{bmatrix} 1 & 0 & 0 \\ -\ell_{2,1} & 1 & 0 \\ -\ell_{3,1} & 0 & 1 \end{bmatrix} P_2^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ -\ell_{3,1} & 0 & 1 \\ -\ell_{2,1} & 1 & 0 \end{bmatrix} P_2^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ -\ell_{3,1} & 1 & 0 \\ -\ell_{2,1} & 0 & 1 \end{bmatrix}$$

Voorbeeld:

$$A = \begin{bmatrix} 1 & 1 & 1 & 4 \\ 1 & 1 & 4 & 1 \\ 1 & 4 & 1 & 1 \\ 4 & 1 & 1 & 1 \end{bmatrix}.$$

Stap 1: $j = 4$, P_1 verwisselt element 1 en 4:

$$P_1 = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix}, \quad P_1 A = \begin{bmatrix} 4 & 1 & 1 & 1 \\ 1 & 1 & 4 & 1 \\ 1 & 4 & 1 & 1 \\ 1 & 1 & 1 & 4 \end{bmatrix}.$$

Maak nullen in kolom 1 onder hoofddiagonaal:

$$L_1 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ -\frac{1}{4} & 1 & 0 & 0 \\ -\frac{1}{4} & 0 & 1 & 0 \\ -\frac{1}{4} & 0 & 0 & 1 \end{bmatrix}, \quad U_1 = L_1 P_1 A = \begin{bmatrix} 4 & 1 & 1 & 1 \\ 0 & \frac{3}{4} & \frac{15}{4} & \frac{3}{4} \\ 0 & \frac{15}{4} & \frac{3}{4} & \frac{3}{4} \\ 0 & \frac{3}{4} & \frac{3}{4} & \frac{15}{4} \end{bmatrix}.$$

Stap 2: $j = 3$, P_2 verwisselt element 2 en 3:

$$P_2 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad P_2 U_1 = \begin{bmatrix} 4 & 1 & 1 & 1 \\ 0 & \frac{15}{4} & \frac{3}{4} & \frac{3}{4} \\ 0 & \frac{3}{4} & \frac{15}{4} & \frac{3}{4} \\ 0 & \frac{3}{4} & \frac{3}{4} & \frac{15}{4} \end{bmatrix}.$$

Maak nullen in kolom 2 onder hoofddiagonaal:

$$L_2 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & -\frac{1}{5} & 1 & 0 \\ 0 & -\frac{1}{5} & 0 & 1 \end{bmatrix}, \quad U_2 = L_2 P_2 U_1 = \begin{bmatrix} 4 & 1 & 1 & 1 \\ 0 & \frac{15}{4} & \frac{3}{4} & \frac{3}{4} \\ 0 & 0 & \frac{18}{5} & \frac{3}{5} \\ 0 & 0 & \frac{3}{5} & \frac{18}{5} \end{bmatrix}.$$

Stap 3: $j = 3$:

$$P_3 = I, \quad P_3 U_2 = U_2 = \begin{bmatrix} 4 & 1 & 1 & 1 \\ 0 & \frac{15}{4} & \frac{3}{4} & \frac{3}{4} \\ 0 & 0 & \frac{18}{5} & \frac{3}{5} \\ 0 & 0 & \frac{3}{5} & \frac{18}{5} \end{bmatrix}.$$

Maak nullen in kolom 3 onder hoofddiagonaal:

$$L_3 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & -\frac{1}{6} & 1 \end{bmatrix}, \quad U = L_3 U_2 = \begin{bmatrix} 4 & 1 & 1 & 1 \\ 0 & \frac{15}{4} & \frac{3}{4} & \frac{3}{4} \\ 0 & 0 & \frac{18}{5} & \frac{3}{5} \\ 0 & 0 & 0 & \frac{7}{2} \end{bmatrix}.$$

Eindresultaat: We hebben $L'_k = L_k$ en

$$P = P_3 P_2 P_1 = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix}, \quad L = (L'_1)^{-1} (L'_2)^{-1} (L'_3)^{-1} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ \frac{1}{4} & 1 & 0 & 0 \\ \frac{1}{4} & \frac{1}{5} & 1 & 0 \\ \frac{1}{4} & \frac{1}{5} & \frac{1}{6} & 1 \end{bmatrix},$$

met $PA = LU$.

Stelling: Laat $A \in \mathbb{C}^{m,m}$ inverteerbaar zijn, dan bestaat er een permatatiematrix P zodat $PA = LU$.

Bewijs: Stel bij stap k is $x_{jk} = 0$, voor alle $j \geq k$, met x_{jk} het (j, k) -de element van $X = L_{k-1}P_{k-1} \dots L_1P_1A$, dan

$$X = \left[\begin{array}{ccc|c|c} \times & \dots & \times & & \\ & \ddots & \vdots & & \\ & & \times & & \\ \hline 0 & \dots & 0 & 0 & \\ \vdots & & \vdots & \vdots & \\ 0 & \dots & 0 & 0 & \end{array} \right] \begin{array}{l} \left. \begin{array}{c} \\ \\ \\ \end{array} \right\} k-1 \text{ rijen} \\ \left. \begin{array}{c} \\ \\ \\ \end{array} \right\} m-k+1 \text{ rijen} \end{array}$$

k kolommen

wat aangeeft dat $\det(X) = 0$ (want één van de laatste $m - k + 1$ rijen is lineaire combinatie van overige). Echter

$$\begin{aligned} |\det(X)| &= |\det(L_{k-1}P_{k-1} \dots L_1P_1A)| \\ &= |\det(A)| \prod_{i=1}^{k-1} |\det(L_i)| |\det(P_i)| = |\det(A)|, \end{aligned}$$

aangezien $|\det(P_i)| = 1$ en $\det(L_i) = 1$. Wat in tegenspraak is met $\det(A) = 0$.

Stelling: Laat $PA = LU$ een LU factorisatie zijn van $A \in \mathbb{C}^{m,m}$ en laat $\tilde{P}, \tilde{L}$ en $\tilde{U} \in \mathbb{C}^{m,m}$ de output zijn van Gauss eliminatie met gedeeltelijke pivoting met A als input, dan

$$\tilde{P}A + \delta A = \tilde{L}\tilde{U},$$

met $\|\delta A\| = O(\epsilon_{\text{machine}}) \|L\| \|U\|$.

Opmerkingen:

- 1 Indien $|\ell_{ij}| < 1$ voor alle $i > j$, wat aangeeft dat er nooit een keuze was voor de pivot, dan zal $P = \tilde{P}$ voor $\epsilon_{\text{machine}}$ voldoende klein.
- 2 Aangezien $|\ell_{ij}| \leq 1$ hebben we $\|L\|_{F_\infty} \leq 1$. Kortom $\|L\| = O(1)$ voor alle normen dankzij normequivalentie.
- 3 Definieer de groeifactor ρ als

$$\rho = \frac{\max_{i,j} |u_{ij}|}{\max_{i,j} |a_{ij}|},$$

dan $\|U\|_{F_\infty} = \rho \|A\|_{F_\infty}$, of nog, $\|U\| = O(\rho \|A\|)$.

Wanneer we item 2 en 3 combineren zien we: $\|L\| \|U\| = O(\rho \|A\|)$. Indien ρ een bovengrens heeft die geldig is voor alle matrices A , dan geeft bovenstaande eigenschap achterwaartse stabiliteit.

Stelling: Laat $A \in \mathbb{C}^{m,m}$, dan $\rho \leq 2^{m-1}$.

Bewijs: zie oefeningen.

Opmerkingen:

- 1 Verborgen constante in big-O notatie is van de vorm 2^m , wat niet geruststellend is voor $m = 100$ en $\epsilon_{\text{machine}} = 2^{-53}$, want dan is $2^{m-1} \epsilon_{\text{machine}} = 2^{46}$.
- 2 Er bestaan matrices met groeifactor gelijk aan 2^{m-1} (zie verder)

Q: Waarom toch Gauss eliminatie ipv QR-factorisatie voor oplossen lineaire stelsels?

A: Twee maal sneller en grote groeifactors zijn uiterst zeldzaam

Voorbeeld:

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 \\ -1 & 1 & 0 & 0 & 1 \\ -1 & -1 & 1 & 0 & 1 \\ -1 & -1 & -1 & 1 & 1 \\ -1 & -1 & -1 & -1 & 1 \end{bmatrix}$$

Stap 1 en 2:

$$L_1 A = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 2 \\ 0 & -1 & 1 & 0 & 2 \\ 0 & -1 & -1 & 1 & 2 \\ 0 & -1 & -1 & -1 & 2 \end{bmatrix}, \quad L_2 L_1 A = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 2 \\ 0 & 0 & 1 & 0 & 4 \\ 0 & 0 & -1 & 1 & 4 \\ 0 & 0 & -1 & -1 & 4 \end{bmatrix}$$

Stap 3 en 4:

$$L_3 L_2 L_1 A = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 2 \\ 0 & 0 & 1 & 0 & 4 \\ 0 & 0 & 0 & 1 & 8 \\ 0 & 0 & 0 & -1 & 8 \end{bmatrix}, \quad U = L_4 L_3 L_2 L_1 A = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 2 \\ 0 & 0 & 1 & 0 & 4 \\ 0 & 0 & 0 & 1 & 8 \\ 0 & 0 & 0 & 0 & 16 \end{bmatrix}.$$

Kortom $\rho = 16 = 2^{m-1}$. Dit idee werkt duidelijk voor algemene m .

Gedeeltelijke pivoting

Stap k: Stel x_k gelijk aan kolom k van A_k . Kies j zodat

$$|x_{jk}| = \max_{i \geq k} |x_{ik}|,$$

en laat P_k de verwisseling zijn die element k en j omwisselt.

$$A_3 = \begin{bmatrix} \times & \times & \times & \dots & \times \\ 0 & \times & \times & \dots & \times \\ 0 & 0 & x_{33} & \dots & \times \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & x_{m3} & \dots & \times \end{bmatrix}$$

Maak vervolgens nullen aan in kolom k onder hoofddiagonaal zodat

$$A_{k+1} = L_k P_k A_k.$$

Complete pivoting

Stap k: Stel $x_k, \dots, x_m$ gelijk aan kolommen k tem m van A_k . Kies j zodat

$$|x_{ji}| = \max_{u \geq k} \max_{v \geq k} |x_{uv}|,$$

en laat P_k de verwisseling zijn die element k en j omwisselt en Q_k de verwisseling zijn die element k en i omwisselt.

$$A_3 = \begin{bmatrix} \times & \times & \times & \dots & \times \\ 0 & \times & \times & \dots & \times \\ 0 & 0 & x_{33} & \dots & x_{3m} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & x_{m3} & \dots & x_{mm} \end{bmatrix}$$

Maak vervolgens nullen aan in kolom k onder hoofddiagonaal zodat

$$A_{k+1} = L_k P_k A_k Q_k.$$

Dit resulteert in

$$L_{m-1} P_{m-1} \dots L_1 P_1 A Q_1 \dots Q_{m-1} = U,$$

of nog $PAQ = LU$.

Voorbeeld:

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 \\ -1 & 1 & 0 & 0 & 1 \\ -1 & -1 & 1 & 0 & 1 \\ -1 & -1 & -1 & 1 & 1 \\ -1 & -1 & -1 & -1 & 1 \end{bmatrix}, \quad A_2 = L_1 A = \begin{bmatrix} 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 2 \\ 0 & -1 & 1 & 0 & 2 \\ 0 & -1 & -1 & 1 & 2 \\ 0 & -1 & -1 & -1 & 2 \end{bmatrix},$$

Stap 2:

$$A_2 Q_2 = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 & 1 \\ 0 & 2 & 1 & 0 & -1 \\ 0 & 2 & -1 & 1 & -1 \\ 0 & 2 & -1 & -1 & -1 \end{bmatrix}, \quad A_3 = L_2 A_2 Q_2 = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 & -2 \\ 0 & 0 & -1 & 1 & -2 \\ 0 & 0 & -1 & -1 & -2 \end{bmatrix},$$

Stap 3:

$$A_3 Q_3 = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 \\ 0 & 2 & 1 & 0 & 0 \\ 0 & 0 & -2 & 0 & 1 \\ 0 & 0 & -2 & 1 & -1 \\ 0 & 0 & -2 & -1 & -1 \end{bmatrix}, \quad A_4 = L_3 A_3 Q_3 = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 \\ 0 & 2 & 1 & 0 & 0 \\ 0 & 0 & -2 & 0 & 1 \\ 0 & 0 & 0 & 1 & -2 \\ 0 & 0 & 0 & -1 & -2 \end{bmatrix}.$$

Stap 4:

$$A_4 Q_4 = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 \\ 0 & 2 & 1 & 0 & 0 \\ 0 & 0 & -2 & 1 & 0 \\ 0 & 0 & 0 & -2 & 1 \\ 0 & 0 & 0 & -2 & -1 \end{bmatrix}, \quad U = L_4 A_4 Q_4 = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 \\ 0 & 2 & 1 & 0 & 0 \\ 0 & 0 & -2 & 1 & 0 \\ 0 & 0 & 0 & -2 & 1 \\ 0 & 0 & 0 & 0 & -2 \end{bmatrix}.$$

⇒ Groefactor $\rho = 2$.

- Kan bewijzen dat $\rho \leq m^{\frac{1}{2} \log_2 m} = 2^{\frac{1}{2}(\log_2 m)^2}$, wat beter is dan 2^{m-1}
- Groefactor doorgaans niet veel beter voor typische matrices
- Complete pivoting is duurder: $O(m^3)$ voor kiezen van pivot elementen