

Numerieke Lineaire Algebra - Oplossingssleutel

Hoofdstuk 4: Conditionering en stabiliteit

We noteren in het vervolg altijd ϵ_m om de machineprecisie $\epsilon_{\text{machine}}$ aan te duiden.

Oefening 1.

- a. We hebben $f(x) = 2x$ en $\tilde{f}(x) = \text{fl}(x) \oplus \text{fl}(x)$. Dankzij (4.4) en (4.5) weten we dat

$$\begin{aligned}\tilde{f}(x) &= x(1 + \epsilon_1) \oplus x(1 + \epsilon_1) \\ &= (x(1 + \epsilon_1) + x(1 + \epsilon_1))(1 + \epsilon_2) \\ &= 2x(1 + \epsilon_1)(1 + \epsilon_2)\end{aligned}$$

voor $|\epsilon_1|, |\epsilon_2| < \epsilon_m$. Stel nu $\tilde{x} = x(1 + \epsilon_1)(1 + \epsilon_2)$, dan is $f(\tilde{x}) = \tilde{f}(x)$. We zien eveneens dat

$$\frac{|x - \tilde{x}|}{|x|} = |\epsilon_1 + \epsilon_2 + \epsilon_1\epsilon_2| \leq |\epsilon_1| + |\epsilon_2| + |\epsilon_1||\epsilon_2| \leq 2\epsilon_m + \epsilon_m^2 = \mathcal{O}(\epsilon_m).$$

Dit algoritme is dus achterwaarts stabiel (en bijgevolg ook stabiel aangezien achterwaartse stabiliteit sterker is).

- b. We hebben $f(x) = x^2$ en $\tilde{f}(x) = \text{fl}(x) \otimes \text{fl}(x)$. Dankzij (4.4) en (4.5) weten we dat

$$\begin{aligned}\tilde{f}(x) &= x(1 + \epsilon_1) \otimes x(1 + \epsilon_1) \\ &= (x(1 + \epsilon_1)x(1 + \epsilon_1))(1 + \epsilon_2) \\ &= x^2(1 + \epsilon_1)^2(1 + \epsilon_2)\end{aligned}$$

voor $|\epsilon_1|, |\epsilon_2| < \epsilon_m$. Stel nu $\tilde{x} = x(1 + \epsilon_1)\sqrt{1 + \epsilon_2}$, dan is $f(\tilde{x}) = \tilde{f}(x)$. We tonen nu eerst aan dat er een ϵ_3 bestaat waarvoor geldt dat $1 + \epsilon_3 = \sqrt{1 + \epsilon_2}$ en $|\epsilon_3| < \epsilon_m$.

$$\begin{aligned}1 + \epsilon_3 &= \sqrt{1 + \epsilon_2} \\ \Rightarrow 1 + 2\epsilon_3 + \epsilon_3^2 &= 1 + \epsilon_2 \\ \Rightarrow \epsilon_3(2 + \epsilon_3) &= \epsilon_2 \\ \Rightarrow |\epsilon_3||2 + \epsilon_3| &= |\epsilon_2|\end{aligned}$$

Aangezien $2 + \epsilon_3 \geq 1$, vinden we dat

$$|\epsilon_3| \leq |\epsilon_3||2 + \epsilon_3| = |\epsilon_2| \leq \epsilon_m.$$

Dit betekent dat $\tilde{x} = x(1 + \epsilon_1)(1 + \epsilon_3)$ en dus is het algoritme achterwaarts stabiel (een product van factoren $1 + \epsilon_i$ is altijd $1 + \mathcal{O}(\epsilon_m)$ als $|\epsilon_i| < \epsilon_m$ zoals in deel a).

c. We hebben $f(x) = 1$ en $\tilde{f}(x) = \text{fl}(x) \oplus \text{fl}(x)$. Dankzij (4.4) en (4.5) weten we dat

$$\begin{aligned}\tilde{f}(x) &= x(1 + \epsilon_1) \oplus x(1 + \epsilon_1) \\ &= \frac{x(1 + \epsilon_1)}{x(1 + \epsilon_1)} (1 + \epsilon_2) \\ &= 1 + \epsilon_2\end{aligned}$$

voor $|\epsilon_1|, |\epsilon_2| < \epsilon_m$. Dit algoritme is dus niet achterwaarts stabiel aangezien er geen enkele $\tilde{x}$ bestaat waarvoor geldt dat $1 = f(\tilde{x}) = \tilde{f}(x) = 1 + \epsilon_2$. Het algoritme is wel stabiel voor $\tilde{x} = x$ aangezien

$$\frac{|\tilde{f}(x) - f(\tilde{x})|}{|f(\tilde{x})|} = \frac{|1 + \epsilon_2 - 1|}{1} = |\epsilon_2| < \epsilon_m = \mathcal{O}(\epsilon_m)$$

en

$$\frac{|\tilde{x} - x|}{|x|} = 0 = \mathcal{O}(\epsilon_m).$$

d. We hebben $f(x) = 0$ en $\tilde{f}(x) = \text{fl}(x) \ominus \text{fl}(x)$. Dankzij (4.4) en (4.5) weten we dat

$$\begin{aligned}\tilde{f}(x) &= x(1 + \epsilon_1) \ominus x(1 + \epsilon_1) \\ &= (x(1 + \epsilon_1) - x(1 + \epsilon_1))(1 + \epsilon_2) \\ &= 0\end{aligned}$$

voor $|\epsilon_1|, |\epsilon_2| < \epsilon_m$. Voor de keuze $\tilde{x} = x$ geldt dus $f(\tilde{x}) = \tilde{f}(x)$. Dit algoritme is bijgevolg achterwaarts stabiel.

Oefening 2.

We tonen dit eerst aan voor dimensie 3 en bekijken daarna het algemene geval.

$n = 3$

We hebben $x = [x_1, x_2, x_3]^T$, $y = [y_1, y_2, y_3]^T$, $f(x, y) = x_1y_1 + x_2y_2 + x_3y_3$ en $\tilde{f}(x, y) = (\text{fl}(x_1) \otimes \text{fl}(y_1)) \oplus (\text{fl}(x_2) \otimes \text{fl}(y_2)) \oplus (\text{fl}(x_3) \otimes \text{fl}(y_3))$. Na het toepassen van (4.4) en (4.5) vinden we (we werken de som van links naar rechts uit)

$$\begin{aligned}\tilde{f}(x, y) &= \left(\left((x_1(1 + \epsilon_1)y_1(1 + \delta_1)(1 + \gamma_1) + x_2(1 + \epsilon_2)y_2(1 + \delta_2)(1 + \gamma_2))(1 + \beta_1) \right) \right. \\ &\quad \left. + x_3(1 + \epsilon_3)y_3(1 + \delta_3)(1 + \gamma_3) \right) (1 + \beta_2),\end{aligned}$$

waarvoor geldt dat $|\epsilon_i|, |\delta_i|, |\gamma_i|, |\beta_i| < \epsilon_m$. De ϵ_i zijn veroorzaakt door $\text{fl}(x_i)$, de δ_i door $\text{fl}(y_i)$, de δ_i door het product $\otimes$ en tenslotte de β_i door de optellingen $\oplus$. Stel nu $\tilde{y}_i = y_i$ en

$$\begin{aligned}\tilde{x}_1 &= x_1(1 + \epsilon_1)(1 + \delta_1)(1 + \gamma_1)(1 + \beta_1)(1 + \beta_2) = x_1 p_1, \\ \tilde{x}_2 &= x_2(1 + \epsilon_2)(1 + \delta_2)(1 + \gamma_2)(1 + \beta_1)(1 + \beta_2) = x_2 p_2, \\ \tilde{x}_3 &= x_3(1 + \epsilon_3)(1 + \delta_3)(1 + \gamma_3)(1 + \beta_2) = x_3 p_3,\end{aligned}$$

dan geldt $f(\tilde{x}, \tilde{y}) = \tilde{f}(x, y)$. Bovendien vinden we dat (merk op dat alle vectornormen equivalent zijn, dus dat we zelf een norm mogen kiezen)

$$\frac{\|\tilde{y} - y\|}{\|y\|} = 0 = \mathcal{O}(\epsilon_m)$$

en

$$\frac{\|\tilde{x} - x\|_\infty}{\|x\|_\infty} = \frac{\max(|x_1| |p_1 - 1|, |x_2| |p_2 - 1|, |x_3| |p_3 - 1|)}{\max(|x_1|, |x_2|, |x_3|)} \leq \max(|p_1 - 1|, |p_2 - 1|, |p_3 - 1|) = \mathcal{O}(\epsilon_m).$$

De laatste gelijkheid is geldig aangezien elke p_i een product is van termen van de vorm $(1 + \alpha_i)$ met $|\alpha_i| < \epsilon_m$, waardoor $|p_i - 1| = \mathcal{O}(\epsilon_m)$. Het inwendig product is dus achterwaarts stabiel voor dimensie 3.

$n > 3$

We herhalen dit nu voor algemene n . In dit geval hebben we

$$f(x, y) = \sum_{i=1}^n x_i y_i \quad \text{en} \quad \tilde{f}(x, y) = \bigoplus_{i=1}^n (\text{fl}(x_i) \otimes \text{fl}(y_i)).$$

Na het toepassen van (4.4) en (4.5) bekomen we

$$\begin{aligned}\tilde{f}(x, y) &= \bigoplus_{i=1}^n (x_i(1 + \epsilon_i)y_i(1 + \delta_i)(1 + \gamma_i)) \\ &= \bigoplus_{i=1}^n x_i y_i q_i \quad (\text{voor } q_i = (1 + \epsilon_i)(1 + \delta_i)(1 + \gamma_i)) \\ &= \left(\left(\dots \left(((x_1 y_1 q_1) + (x_2 y_2 q_2))(1 + \beta_1) + (x_3 y_3 q_3) \right) (1 + \beta_2) \dots \right) (1 + \beta_{n-2}) + (x_n y_n q_n) \right) (1 + \beta_{n-1}) \\ &= \sum_{i=1}^n x_i y_i q_i \prod_{j=i-1}^{n-1} (1 + \beta_j) \quad (\text{veronderstel } \beta_0 = 1) \\ &= \sum_{i=1}^n x_i y_i p_i \quad \left(\text{voor } p_i = q_i \prod_{j=i-1}^{n-1} (1 + \beta_j) \right)\end{aligned}$$

Stel $\tilde{y}_i = y_i$ en $\tilde{x}_i = x_i p_i$, dan geldt $f(\tilde{x}, \tilde{y}) = \tilde{f}(x, y)$. We vinden bovendien dat

$$\frac{\|\tilde{y} - y\|}{\|y\|} = 0 = \mathcal{O}(\epsilon_m)$$

en

$$\frac{\|\tilde{x} - x\|_\infty}{\|x\|_\infty} = \frac{\max(|x_i| |p_i - 1|)}{\max(|x_i|)} \leq \max(|p_i - 1|) = \mathcal{O}(\epsilon_m).$$

Het inwendig product van twee vectoren is dus ook achterwaarts stabiel voor willekeurige dimensie.

Als enkel x een input parameter is, dan is het bovenstaande nog steeds geldig na schrappen van de $(1 + \delta_i)$ termen aangezien $\tilde{y}_i = y$.

Oefening 3.

Oefening 2 vertelt ons dat het product van een rijvector en kolomvector (waarbij de rijvector de input is en de kolomvector vast) achterwaarts stabiel is. Dit betekent dat er voor elke rijvector x een andere rijvector δx bestaat zodat

$$(x + \delta x)y = \tilde{x}y \quad \text{en} \quad \|\delta x\|_1 = \mathcal{O}(\epsilon_m) \|x\|_1.$$

Stel nu

$$A = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \end{pmatrix},$$

waarvoor a_i de i -de rij van A voorstelt. Dan wordt de floating point representatie van het matrix-vector product Ab gegeven door

$$\tilde{A}b = \begin{pmatrix} \widetilde{a_1 b} \\ \widetilde{a_2 b} \\ \vdots \\ \widetilde{a_m b} \end{pmatrix}.$$

Aangezien elk van deze elementen de floating point representatie is van een inwendig product, bestaan er rijvectoren δa_i waarvoor

$$(a_i + \delta a_i)b = \widetilde{a_i b} \quad \text{en} \quad \|\delta a_i\|_1 = \mathcal{O}(\epsilon_m) \|a_i\|_1.$$

Als we nu de volgende matrix definiëren

$$\delta A = \begin{pmatrix} \delta a_1 \\ \delta a_2 \\ \vdots \\ \delta a_m \end{pmatrix},$$

dan zien we direct dat $(A + \delta A)b = \widetilde{A}b$.

Het feit dat $\|\delta a_i\|_1 = \mathcal{O}(\epsilon_m) \|a_i\|_1$ betekent dat er constanten ϵ en K_i bestaan zodat voor alle $\epsilon_m < \epsilon$ geldt dat $\|\delta a_i\|_1 < K_i \epsilon_m \|a_i\|_1$. Voor de norm van δA betekent dit dat weer dat

$$\|\delta A\|_\infty = \max_{i=1}^m \|\delta a_i\|_1 < \max_{i=1}^m (K_i \epsilon_m \|a_i\|_1) \leq \left(\max_{i=1}^m K_i \right) \left(\max_{i=1}^m \|a_i\|_1 \right) \epsilon_m = K \epsilon_m \|A\|_\infty.$$

Bijgevolg is de matrix-vector vermenigvuldiging dus ook achterwaarts stabiel.

Oefening 4.

Indien we de verschillen van rechts naar links uitwerken, rekenen we de x_j uit aan de hand van

$$x_j = \frac{b_j - x_m r_{j,m} - \cdots - x_{j+1} r_{j,j+1}}{r_{j,j}}$$

in plaats van

$$x_j = \frac{b_j - x_{j+1} r_{j,j+1} - \cdots - x_m r_{j,m}}{r_{j,j}}.$$

Voor $m = 1, 2$ worden er nog geen verschillen uitgewerkt (behalve die voor de b_j) en dus zijn deze gevallen volledig gelijk aan het bewijs in de cursus. Vanaf $m = 3$ wisselen de termen voor deze verschillen.

$m = 3$

De eerste twee stappen zijn analoog aan het geval $m = 2$:

$$\tilde{x}_3 = \frac{b_3}{r_{33}(1 + \epsilon_1)}, \quad \text{en} \quad \tilde{x}_2 = \frac{b_2 - \tilde{x}_3 r_{23}(1 + \epsilon_2)}{r_{22}(1 + 2\epsilon_3)},$$

met

$$\begin{pmatrix} 2|\epsilon_3| & 1|\epsilon_2| \\ 0 & 1|\epsilon_1| \end{pmatrix} \leq \begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix} \epsilon_m + \mathcal{O}(\epsilon_m^2).$$

Voor $\tilde{x}_1 = [(b_1 \ominus (\tilde{x}_3 \otimes r_{13})) \ominus (\tilde{x}_2 \otimes r_{12})] \oplus r_{11}$ bekomen we via (4.5) dat

$$\tilde{x}_1 = \frac{[(b_1 - \tilde{x}_3 r_{13}(1 + \epsilon_4))(1 + \epsilon_6) - \tilde{x}_2 r_{12}(1 + \epsilon_5)](1 + \epsilon_7)}{r_{11}}(1 + \epsilon_8)$$

met $|\epsilon_i| \leq \epsilon_m$ voor $i = 4, \dots, 8$. Door ϵ'_7 en ϵ'_8 in te voeren, verkrijgen we dat

$$\tilde{x}_1 = \frac{(b_1 - \tilde{x}_3 r_{13}(1 + \epsilon_4))(1 + \epsilon_6) - \tilde{x}_1 r_{12}(1 + \epsilon_5)}{r_{11}(1 + \epsilon'_7)(1 + \epsilon'_8)}$$

met $|\epsilon'_7|, |\epsilon'_8| \leq \epsilon_m + \mathcal{O}(\epsilon_m^2)$. Het enige probleem in deze uitdrukking is de term $b_1(1 + \epsilon_6)$ vandaar dat we ook nog eens ϵ'_6 invoeren om te komen tot

$$\tilde{x}_1 = \frac{(b_1 - \tilde{x}_3 r_{13}(1 + \epsilon_4)) - \tilde{x}_1 r_{12}(1 + \epsilon_5)(1 + \epsilon'_6)}{r_{11}(1 + \epsilon'_6)(1 + \epsilon'_7)(1 + \epsilon'_8)}.$$

Kortom, $\tilde{x}$ is de exacte oplossing van $(R + \delta R)\tilde{x} = b$ met

$$\begin{pmatrix} |\delta r_{11}|/|r_{11}| & |\delta r_{12}|/|r_{12}| & |\delta r_{13}|/|r_{13}| \\ & |\delta r_{22}|/|r_{22}| & |\delta r_{23}|/|r_{23}| \\ & & |\delta r_{33}|/|r_{33}| \end{pmatrix} \leq \begin{pmatrix} 3 & 2 & 1 \\ & 2 & 1 \\ & & 1 \end{pmatrix} \epsilon_m + \mathcal{O}(\epsilon_m^2).$$

$m > 3$

In het algemene geval verloopt alles gelijkaardig als voor $m = 3$, waardoor men kan tonen dat $\tilde{x}$ de oplossing is van $(R + \delta R)\tilde{x} = b$ waarbij $|\delta r_{ij}|/|r_{ij}|$ begrensd wordt door het (i, j) -de element van onderstaande matrix (voor $m = 5$):

$$\begin{pmatrix} 5 & 4 & 3 & 2 & 1 \\ & 4 & 3 & 2 & 1 \\ & & 3 & 2 & 1 \\ & & & 2 & 1 \\ & & & & 1 \end{pmatrix} \epsilon_m + \mathcal{O}(\epsilon_m^2).$$

Dit patroon komt als volgt tot stand. De vermenigvuldigingen $\tilde{x}_k r_{jk}$ veroorzaken ϵ_m perturbaties volgens het patroon

$$\otimes : \begin{pmatrix} 0 & 1 & 1 & 1 & 1 \\ & 0 & 1 & 1 & 1 \\ & & 0 & 1 & 1 \\ & & & 0 & 1 \\ & & & & 0 \end{pmatrix}.$$

De delingen door r_{kk} resulteren in $\epsilon_m + \mathcal{O}(\epsilon_m^2)$ perturbaties op de diagonaal

$$\oplus : \begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ & 1 & 0 & 0 & 0 \\ & & 1 & 0 & 0 \\ & & & 1 & 0 \\ & & & & 1 \end{pmatrix}.$$

Terwijl de verschillen (doordat we deze van rechts naar links uitvoerde) ervoor zorgen dat we initieel $(1 + \epsilon_i)$ factoren hebben op dezelfde posities als waar de producten voor een perturbatie zorgden, maar deze worden omgezet in $1/(1 + \epsilon'_i)$ factoren die elk een $\epsilon_m + \mathcal{O}(\epsilon_m^2)$ perturbatie veroorzaken in de noemer (d.i., op de diagonaal), als ook op elke linkse term. Het patroon ziet er dus uit als

$$\ominus : \begin{pmatrix} 4 & 3 & 2 & 1 & 0 \\ & 3 & 2 & 1 & 0 \\ & & 2 & 1 & 0 \\ & & & 1 & 0 \\ & & & & 0 \end{pmatrix}.$$

Oefening 5.

Eigenschap. Laat $B \in \mathbb{C}^{m,m}$ een inverteerbare matrix zijn en $A \in \mathbb{C}^{m,n}$, dan bestaat er een $\delta A \in \mathbb{C}^{m,n}$ zodat $\widetilde{BA} = B(A + \delta A)$ met $\|\delta A\| = \|A\| \mathcal{O}(\kappa(B)\epsilon_m)$ en $\kappa(B) = \|B^{-1}\| \|B\|$.

Bewijs. We zoeken een δA zodat $\widetilde{BA} = B(A + \delta A)$ met $\|\delta A\| = \|A\| \mathcal{O}(\kappa(B)\epsilon_m)$. Neem $\delta A = B^{-1}(\widetilde{BA} - BA)$ dan is

$$\|\delta A\|_2 = \|B^{-1}(\widetilde{BA} - BA)\|_2 = \|B^{-1}\|_2 \|\widetilde{BA} - BA\|_2.$$

We moeten dus tonen dat de *voorwaartse fout* voldoende klein is. Via (4.4) en (4.5) kunnen we eenvoudig tonen dat

$$\bigoplus_{k=1}^m (\text{fl}(b_{ik}) \otimes \text{fl}(a_{kj})) = \sum_{k=1}^m b_{ik}a_{kj}(1 + m\mathcal{O}(\epsilon_m)).$$

Kortom, de fout op $\sum_k b_{ik}a_{kj}$, wat het (i, j) -de element van $\widetilde{BA} - BA$ weergeeft, is begrensd door

$$\begin{aligned} \left| (\widetilde{BA} - BA)_{ij} \right| &= \left| \sum_{k=1}^m b_{ik}a_{kj}(1 + m\mathcal{O}(\epsilon_m)) - \sum_{k=1}^m b_{ik}a_{kj} \right| \\ &= \left| \sum_{k=1}^m b_{ik}a_{kj}m\mathcal{O}(\epsilon_m) \right| \\ &= m\mathcal{O}(\epsilon_m) \left| \sum_{k=1}^m b_{ik}a_{kj} \right| \\ &\leq m\mathcal{O}(\epsilon_m) \sum_{k=1}^m |b_{ik}| \sum_{k=1}^m |a_{kj}| \\ &\leq m\mathcal{O}(\epsilon_m) \sum_{k=1}^m \sum_{i=1}^m |b_{ik}| \sum_{k=1}^m \sum_{j=1}^n |a_{kj}| \\ &= m\mathcal{O}(\epsilon_m) \|B\|_{F_1} \|A\|_{F_1} \\ &\leq m\mathcal{O}(\epsilon_m) \|B\|_2 \|A\|_2 \end{aligned}$$

daar alle matrixnormen equivalent zijn (zie sectie 1.3.). Bijgevolg is

$$\begin{aligned} \|\delta A\|_2 &= \|B^{-1}\|_2 \|\widetilde{BA} - BA\|_2 \\ &\leq K \|B^{-1}\|_2 \|\widetilde{BA} - BA\|_{F_1} \\ &= K \|B^{-1}\|_2 \sum_{i=1}^m \sum_{j=1}^n \left| (\widetilde{BA} - BA)_{ij} \right| \\ &\leq m^2 n \mathcal{O}(\epsilon_m) \|B^{-1}\|_2 \|B\|_2 \|A\|_2 \\ &= \|A\| \mathcal{O}(\kappa(B)\epsilon_m) \end{aligned}$$

wat het gestelde bewijst. ■